

LICITACIÓN PÚBLICA

Licitación N.º TFEP-01/2026

Proyecto de Plataforma Digital de Misión Crítica

Caso 02 — Logística

Sobre N.º 2 — Oferta Técnica

Propuesta Técnica

Subdocumento 4 — Arquitectura de la solución

Apartados 4.2 y 4.3 — Arquitectura física, de despliegue y data center · Formularios T-7 y T-21

MANDANTE

Distribuidora Puelche S.A.

PROPONENTE

LafroX SpA

RUT 77.418.902-K

Av. Brasil 2241, Valparaíso

REPRESENTANTE LEGAL

Alex Aravena

Jefe de Proyecto y Apoderado

contacto@lafrox.cl

+56 32 250 4100

VERSIÓN	FECHA DE EMISIÓN	ESTADO	TOTAL DE FOLIOS
2.0	05 de octubre de 2026	Versión final para entrega	115

FIRMA DEL REPRESENTANTE LEGAL

Alex Aravena

Jefe de Proyecto y Apoderado · LafroX SpA

Índice general

Índice general	2
Lista de figuras	6
Lista de tablas	7
Arquitectura física y de despliegue de la solución	10
4.2 Arquitectura física	11
4.2.1 Emplazamiento de cada componente	12
4.2.1.1 Instalaciones y dominios	12
4.2.1.2 Correspondencia con la arquitectura lógica	14
4.2.1.3 Síntesis del emplazamiento por dominio y criterio	15
4.2.1.4 Componentes de nube pura	16
4.2.1.5 Componentes on-premise	18
4.2.1.6 Componentes híbridos	19
4.2.1.7 Autonomía de cada ámbito sin enlace	20
4.2.2 Servicios contratados en la plataforma de nube	21
4.2.2.1 Servicios por función	22
4.2.2.2 Región secundaria y residencia de los datos	23
4.2.2.3 Servicios que no se contratan	24
4.2.2.4 Modelo de contratación	24
4.2.3 Arquitectura de despliegue	25
4.2.3.1 Ambientes y ciclo de entrega	25
4.2.3.1.1 Artefacto y perfiles de ejecución	28
4.2.3.1.2 Liberación y reversión	29

4.2.3.1.3	Transición al backend Laravel	30
4.2.3.1.4	Calendario y cadencia	31
4.2.3.2	Red de despliegue	32
4.2.3.3	Alta disponibilidad	33
4.2.3.4	Recuperación ante desastres	35
4.2.3.4.1	Conmutación y retorno	36
4.2.3.4.2	Sitios secundarios y amenazas comunes	38
4.2.3.4.3	Operación durante una contingencia regional	38
4.2.3.5	Respaldos	39
4.2.3.6	Verificación de la continuidad	40
4.2.4	Conexiones, puntos de falla y contingencia	41
4.2.4.1	Conexiones entre sitios, terreno y nube	41
4.2.4.2	Puntos de falla en los sitios y en los enlaces	44
4.2.4.3	Puntos de falla en la nube, el terreno y las integraciones	45
4.2.5	Dimensionamiento y plan de capacidad	47
4.2.5.1	Criterios y método	47
4.2.5.2	Volumetría de referencia	48
4.2.5.3	Transacciones por segundo	50
4.2.5.4	Usuarios, concurrencia y dispositivos	51
4.2.5.5	Almacenamiento y datos a migrar	52
4.2.5.6	Integraciones y volumen de mensajes	52
4.2.5.7	Ancho de banda, dispositivos de reparto y sincronización	54
4.2.5.8	Mesa de ayuda y equipo de operación	55
4.2.5.9	Síntesis de las dieciséis dimensiones	55
4.2.5.10	Dimensionamiento on-premise	57
4.2.5.11	Perfiles PHP, conexiones y colas	59
4.2.5.12	Dimensionamiento en nube	61
4.2.5.13	Plan de capacidad y crecimiento de 3 veces	62
4.2.5.14	Umbrales de desempeño	63

4.2.5.15	Primer cuello de botella	64
4.2.5.16	Degradación controlada	65
4.2.5.17	Pruebas de carga y estrés	65
4.2.5.18	Actualización del plan de capacidad	66
4.2.6	Especificaciones Implementos a proveer (Hardware y Software)	66
4.2.6.1	Síntesis del equipamiento por familia	67
4.2.6.2	Criterios de selección	68
4.2.6.3	Software y licenciamiento	68
4.3	Data center primario y secundario	70
4.3.1	Data Center Primario	70
4.3.1.1	Proveedor	70
4.3.1.2	Región y zonas de disponibilidad	71
4.3.1.3	Servicios contratados en la región primaria	71
4.3.1.4	Sitio on-premise: CD Talca (sala técnica secundaria)	72
4.3.2	Data Center Secundario	77
4.3.2.1	Modalidad del sitio secundario	78
4.3.2.2	Región o sitio de recuperación	78
4.3.2.3	Replicación	80
4.3.2.4	RPO y RTO	81
4.3.2.5	Procedimiento de conmutación	82
4.3.2.6	Procedimiento de retorno	83
4.3.2.7	Pruebas del plan de recuperación y respaldos	83
4.4	Registro de decisiones de arquitectura	85
4.4.1	ADR-01 · Estilo arquitectónico	85
4.4.2	ADR-02 · Conectividad WAN	86
4.4.3	ADR-03 · Modelo de despliegue híbrido	86

4.4.4 ADR-04 · Persistencia políglota	87
4.4.5 ADR-05 · Mensajería asíncrona	87
4.4.6 ADR-06 · Identidad híbrida (Modelo B)	88
4.4.7 ADR-07 · Movilidad de terreno	89
4.4.8 ADR-08 · Destino del WMS legado 2013	89
4.4.9 ADR-09 · Estrategia DR	90
4.4.10 ADR-10 · Almacenamiento on-premise y RAID	90
4.4.11 ADR-11 · Integración B2B/EDI canal moderno	91
4.4.12 ADR-12 · Absorción del peak de septiembre	91
4.4.13 ADR-13 · Puerta de enlace de servicios	92
4.4.14 ADR-14 · Plataforma de observabilidad	93
4.4.15 ADR-15 · Gestión de secretos	93
Formulario T-11: Especificaciones técnicas ofertadas	94

Lista de figuras

Figura 1	Ubicación de los componentes por dominio y por sitio	13
Figura 2	Conexiones entre los sitios, el terreno y la nube	42

Lista de tablas

Tabla 1	Correspondencia entre la arquitectura lógica y la física	15
Tabla 2	Distribución de los componentes por dominio y criterio de emplazamiento	16
Tabla 3	Autonomía por ámbito ante la pérdida del enlace	21
Tabla 4	Servicios contratados en la plataforma de nube, por función	23
Tabla 5	Ambientes de despliegue	26
Tabla 6	Perfiles de ejecución del artefacto Laravel	28
Tabla 7	Ventanas de despliegue	31
Tabla 8	Direccionamiento y segmentación	32
Tabla 9	Clasificación de servicios por nivel de servicio	34
Tabla 10	Replicación y RPO por dominio de datos	36
Tabla 11	Secuencia de conmutación de región	37
Tabla 12	Respaldo y restauración por dominio de datos	40
Tabla 13	Conexiones de la solución y su camino alternativo	43
Tabla 14	Puntos de falla en los sitios y en los enlaces	45
Tabla 15	Puntos de falla en la nube, el terreno y las integraciones	47
Tabla 16	Valores base de dimensionamiento	49
Tabla 17	Proyección de la volumetría a tres años	49
Tabla 18	Transacciones por segundo de diseño	50
Tabla 19	Usuarios y terminales concurrentes	51

Tabla 20 Volumen de mensajes por integración	53
Tabla 21 Ancho de banda por sitio	54
Tabla 22 Las dieciséis dimensiones del numeral 14.2 del caso	56
Tabla 23 Utilización del clúster de Talca con un nodo caído	57
Tabla 24 Máquinas virtuales del clúster de Talca	57
Tabla 25 Máquinas virtuales del servidor de Concepción	58
Tabla 26 Almacenamiento y rendimiento de la base transaccional	59
Tabla 27 Capacidad de los servicios en nube	62
Tabla 28 Plan de capacidad para el crecimiento de 3 veces	63
Tabla 29 Umbrales de desempeño en percentil 95	64
Tabla 30 Pruebas de carga y estrés	66
Tabla 31 Síntesis del equipamiento a proveer por familia	67
Tabla 4.3-1 Carga eléctrica de TI proyectada del recinto (RT-06.11)	74
Tabla 4.3-2 Carga térmica sensible proyectada del recinto (RT-06.11)	75
Tabla 4.3-3 Sitios de recuperación: distancia y análisis de amenazas comunes (RT-07.02)	79
Tabla 4.3-4 Replicación y RPO por dominio de datos (RT-07.03, RT-07.04)	80
Tabla 4.3-5 Objetivos de continuidad (RT-07.04)	81
Tabla 4.3-6 Secuencia de conmutación de región (RT-07.05)	82
Tabla 32 Formulario T-11: infraestructura de cómputo y almacenamiento	96
Tabla 33 Formulario T-11: red y seguridad	100

Tabla 34	Formulario T-11: dispositivos de terreno y de operación	104
Tabla 35	Formulario T-11: infraestructura de la sala técnica de Talca	107
Tabla 36	Formulario T-11: gabinetes de borde	108
Tabla 37	Formulario T-11: plataforma de nube y servicios gestionados	112
Tabla 38	Formulario T-11: software de base y licenciamiento	115

Arquitectura física y de despliegue de la solución

| Apartados 4.2 y 4.3 del Subdocumento 4. La arquitectura lógica es el apartado 4.1 del mismo subdocumento; ambas comparten el registro de decisiones y la volumetría, y se leen juntas.

4.2 Arquitectura física

La arquitectura física declara dónde vive cada componente de la solución, qué servicios se contratan en la nube, cómo se conectan los sitios entre sí y con la nube, qué ocurre cuando falla cada conexión y cuánta capacidad se provee.

Esa arquitectura materializa el despliegue híbrido obligatorio del Artículo 16° de las Bases Administrativas. La carga principal corre en nube pública AWS, con la región primaria en sa-east-1 (São Paulo, Brasil) y la recuperación ante desastres en us-east-1 (Norte de Virginia, EE. UU.), y los componentes on-premise garantizan la continuidad de la operación de bodega, plataformas y terreno durante los cortes del enlace. La solución cubre las seis instalaciones en cuatro regiones que declara el caso, cinco de ellas con cómputo; la séptima que proyecta el caso a tres años se agrega por parametrización, sin cambios de desarrollo ni crecimiento de servidores en el CD Talca. Dos principios gobiernan el diseño:

- **Carga principal en nube:** el núcleo transaccional de preventa, reparto y canal moderno, la analítica, la integración y el almacenamiento consolidado se ejecutan en AWS sa-east-1, con escalado elástico para el peak de septiembre.
- **Autonomía total de la operación de bodega:** la preparación, el despacho, la recepción y el conteo corren siempre contra los servidores del centro de distribución, no contra la nube, de modo que la conexión a Internet no interviene en la operación de bodega.

La correspondencia con la arquitectura lógica (apartado 4.1) se declara módulo por módulo en la Tabla 1, que asocia cada módulo y cada capa transversal al componente físico que lo ejecuta. Los componentes físicos usan un catálogo único: A-01 a A-05 para el núcleo de bodega, B-01 a B-03 para la cadena de frío, C-01 a C-05 para los dispositivos de operación, D-01 a D-06 para la red, E-01 para los cross-docking, F-01 a F-03 para observabilidad y seguridad de los nodos, y N-01 a N-13 para la nube. Los módulos y las capas conservan en esta parte los mismos nombres que en la arquitectura lógica.

Este apartado se ordena en seis partes. La sección 4.2.1 justifica el emplazamiento de cada componente conforme a los criterios del Artículo 16.2. La sección 4.2.2 enumera los servicios contratados en la plataforma de nube. La sección 4.2.3 describe cómo la solución se pone en marcha y se mantiene en operación: ambientes y ciclo de entrega, red de despliegue, alta disponibilidad, recuperación ante desastres, respaldos y su veri-

ficación. La sección 4.2.4 describe las conexiones, sus puntos de falla y la contingencia de cada uno. La sección 4.2.5 deriva el dimensionamiento y el plan de capacidad desde la volumetría del caso. La sección 4.2.6 resume el equipamiento a proveer, cuyo detalle se entrega en el Formulario T-11. Las especificaciones del data center primario y del secundario se desarrollan en el apartado 4.3, a continuación de este.

4.2.1 Emplazamiento de cada componente

El emplazamiento de cada componente se decide con los seis criterios del Artículo 16.2 de las Bases Administrativas: latencia tolerada, criticidad operacional, volumen de datos, restricciones regulatorias, disponibilidad de conectividad y costo total de propiedad. En este caso la conectividad y la latencia pesan más que en una operación de oficina, porque el caso describe una red que se corta: la fibra de Talca tiene en promedio cuatro cortes al año de hasta seis horas, Concepción no tiene respaldo, los cross-docking solo tienen red móvil y en Los Ángeles la señal es intermitente justo en su ventana de madrugada, las cámaras no tienen cobertura en su interior y hay rutas sin señal durante dos horas o durante el turno completo (Caso, Cap. 6).

De esos hechos se desprende la regla que ordena todo el emplazamiento: lo que debe funcionar sin enlace vive en el sitio, y lo que escala, se comparte o está expuesto a Internet vive en la nube. Los 36 componentes del catálogo se reparten en 13 de nube pura, 11 on-premise y 12 híbridos, que tienen una parte en cada dominio (ADR-03). Los identificadores son los mismos de la arquitectura lógica.

4.2.1.1 Instalaciones y dominios

La solución cubre las seis instalaciones que declara la volumetría del caso (Caso, Tabla 14.1), más la calle y los 14.200 puntos de entrega. El cómputo on-premise se despliega en los cinco recintos que la operación nombra y a los que se asigna tipología (RT-06.01): el CD Talca es la sala técnica secundaria que fija el caso, con un clúster de tres nodos con Proxmox VE y almacenamiento Ceph que aloja las máquinas virtuales VM-01 a VM-06; el CD Concepción opera en un gabinete de borde, con un servidor de borde con Proxmox VE que replica la misma pila en las máquinas VM-C01 a VM-C04; y las plataformas de cross-docking de Curicó, Chillán y Los Ángeles operan cada una en un gabinete de borde, con un mini-PC industrial que ejecuta el WMS en contenedores. La sexta de las instalaciones que declaran la volumetría (Tabla 14.1) y RT-21.16 es la casa matriz de Talca, contigua al centro de distribución principal (Caso, Cap. 2.3): aloja oficinas, no

requiere cómputo propio y usa la nube, por lo que el dimensionamiento se calcula sobre los cinco recintos que alojan cómputo. La séptima instalación que proyecta el caso a tres años se incorpora parametrizando la infraestructura como código, sobre el bloque de direccionamiento ya reservado (Tabla 8), sin obras en la sala de Talca (RT-02.12).

En la nube, la región primaria es sa-east-1 y cada servicio se despliega en al menos dos zonas de disponibilidad. La región us-east-1 solo aloja la recuperación ante desastres. La Figura 1 ubica cada componente en su sitio.

Nube AWS	On-premise	Terreno
sa-east-1, dos zonas o más N-01 a N-03 Portales N-04 Plataforma de aplicación N-05 Base de datos en nube N-06 Telemetría cruda N-07 Caché N-08 Ingesta de IoT N-09 Mensajería N-10 Plataforma analítica N-12 Seguridad y gobierno N-13 Gestión de dispositivos Parte en nube de los híbridos	CD Talca, sala técnica secundaria Máquinas VM-01 a VM-06 con A-01 a A-05 y F-01 Red: D-01 en par, D-02 a D-05 Frío: B-01 y B-02 Bodega: C-03 a C-05 Gestión: F-02 y F-03	Calle C-01 App de preventa 62 terminales EC55 C-02 App de reparto 200 terminales TC58e
us-east-1, recuperación N-11 Respaldo inmutable y réplica	CD Concepción, gabinete de borde Máquinas VM-C01 a VM-C04 con A-01 a A-03, A-05 y F-01 Red: D-01 a D-04 Frío: B-01 y B-02 Bodega: C-03 a C-05 Gestión: F-03	Camiones de frío B-03 Termógrafos, 28
	Cross-docking, tres sitios Mini-PC E-01 con A-01 a A-03 y caché de A-05 Red: D-01 compacto, D-02, D-04 y D-06 Gestión: F-01 y F-03	Locales de clientes 14.200 puntos de entrega
	Casa matriz, Talca Sin cómputo; usa la nube	

Figura 1 Ubicación de los componentes por dominio y por sitio

La figura muestra que ninguna instalación depende de otra para operar. Talca y Concepción tienen cada uno su WMS, su base, su broker y su caché de identidad; los cross-docking reúnen esas mismas funciones en un solo equipo; y el terreno lleva su propio almacén local en el dispositivo. La nube concentra lo que es común a todos los sitios: los portales, el transaccional compartido, la analítica y los servicios de seguridad. Los doce componentes híbridos aparecen en los dos dominios porque cada uno tiene

una parte que debe seguir operando en el sitio y otra que consolida en la nube.

4.2.1.2 Correspondencia con la arquitectura lógica

La Tabla 1 asocia cada módulo y cada capa transversal de la arquitectura lógica (apartado 4.1) con el componente físico que lo ejecuta y con el lugar donde corre. Es la traza que permite seguir una responsabilidad lógica hasta su emplazamiento.

Módulo o capa (4.1)	Componente físico (4.2)	Dónde se ejecuta
M1 Recepción	A-01 y A-02, con C-03 y C-05	Sitio
M2 Inventario	A-01 y A-02 en el sitio; N-04 y N-05 para el consolidado	Sitio y nube
M3 Preventa	C-01 en el terminal; N-04, N-05 y N-07	Terreno y nube
M4 Rutas	N-04 y N-05; motor de optimización en su propio contenedor	Nube
M5 Preparación	A-01 y A-02, con C-03 y C-04	Sitio
M6 Reparto	C-02 en el terminal; N-04 y N-05, con la evidencia en S3	Terreno y nube
M7 Rendición	C-02; N-04; A-04 hacia el ERP	Terreno, nube y VM-04
M8 Devoluciones	C-02; N-04; A-01 en la recepción del retorno	Terreno, nube y sitio
M9 Calidad	B-01, B-02 con el bloqueo en el borde y B-03; N-06 y N-08	Sitio, camiones y nube
M10 Analítica	N-10	Nube
M11 Canal moderno	N-04 con el perfil EDI y el transporte AS2; A-04	Nube y VM-04
M12 Flota	N-04 y N-06, con la API del proveedor de telemetría	Nube
Capa 1, portales	N-01 a N-03	Nube
Capas 2 y 3, entrada y puerta de enlace	CloudFront, WAF y API Gateway (N-01 a N-03 y N-12); puerta de API local en A-01	Nube y sitio

Tabla 1 — continuación

Módulo o capa (4.1)	Componente físico (4.2)	Dónde se ejecuta
Capa 5, integración y eventos	A-03; N-09; A-04	Sitio y nube
Capa 6, datos	A-02; N-05, N-06, N-07, N-10 y N-11	Sitio y nube
Capa 7, seguridad e identidad	A-05 con el verificador local; F-03; N-12	Nube y sitio
Capa 8, observabilidad	F-01 y CloudWatch (N-12)	Sitio y nube

Tabla 1 Correspondencia entre la arquitectura lógica y la física

La tabla muestra la regla del emplazamiento aplicada a la lógica. M1, M2 y M5, junto con el bloqueo de M9, tienen su parte operativa en el sitio, porque son las funciones que el caso exige sostener sin enlace; los demás módulos corren en la nube dentro del monolito (N-04), y el terreno conserva su captura en el terminal. El monolito es un solo artefacto PHP 8.5 con Laravel 13, construido una vez por versión con sus dependencias fijadas en `composer.lock`, que se ejecuta en perfiles separados según el lugar y la función: en la nube, los perfiles de API, de consumo de reconciliación, de trabajos y de planificación; en los sitios, el perfil `wms_only`, limitado a M1, M2, M5 y al bloqueo de M9, y el shipper que vacía el broker local hacia la nube. Los perfiles comparten la misma revisión de código y de esquema, pero tienen permisos, concurrencia y escalado propios, como se detalla en la arquitectura de despliegue. Las dos excepciones con runtime propio son el motor de optimización de rutas de M4 y el transporte AS2 de M11, que se aíslan tras un contrato versionado porque su equivalencia en PHP no está demostrada (ADR-01).

4.2.1.3 Síntesis del emplazamiento por dominio y criterio

La Tabla 2 resume cómo se distribuyen los 36 componentes entre los tres dominios y los seis criterios del Artículo 16.2 que deciden cada emplazamiento. La justificación de cada componente, con su producto, su ubicación, su cantidad y su fundamento, se detalla en el Formulario T-11, que acompaña a este subdocumento como archivo propio, y se recorre dominio por dominio en los apartados siguientes.

Criterio (Art. 16.2)	Nube pura	On -premise	Híbridos	Total
Latencia tolerada	1	4	1	6
Criticidad operacional	2	2	3	7
Volumen de datos	3*	—	—	3
Conectividad	—	4	7	11
Regulación	5	—	1	6
Costo total de propiedad	3*	1	—	4
Total de componentes	13	11	12	36

Tabla 2 Distribución de los componentes por dominio y criterio de emplazamiento

El emplazamiento no obedece a una preferencia sino a cuatro hechos del caso. La conectividad decide once componentes y domina el on -premise y los híbridos, porque el caso describe enlaces que se cortan y terreno sin señal. La regulación decide seis y domina la nube pura, porque el Artículo 21 impide exponer los sitios a Internet y separa los públicos externos en la DMZ. El costo y el volumen concentran en la nube lo que escala y se paga por uso, y la latencia y la criticidad dejan en el sitio lo que debe responder sin enlace. La columna Total suma 37 en las filas de criterios porque la plataforma analítica (N-10) se contabiliza en los dos criterios que deciden su emplazamiento, volumen de datos y costo total de propiedad; la fila final suma los 36 componentes efectivos.

4.2.1.4 Componentes de nube pura

Los trece componentes de nube pura viven solo en la nube. La justificación de cada uno y el criterio del Artículo 16.2 que la determina son los siguientes:

- **N-01 Portal de Clientes** (regulación): atiende el catálogo, la autoatención y el pago de los clientes desde Internet, por lo que se publica solo en la DMZ de la nube y ningún tráfico externo llega a los sitios del CLIENTE.
- **N-02 Portal de Transportistas** (regulación): los conductores externos entran con una clave de un solo uso y sin cuenta corporativa (RF-06.08), y ese acceso se resuelve en la DMZ de la nube.
- **N-03 Portal de Proveedores** (regulación): los 180 proveedores consultan órdenes

de compra, recepciones y devoluciones desde Internet, aislados de la red de bodega.

- **N-04 Plataforma de aplicación** (costo): el monolito Laravel corre en ECS Fargate en perfiles separados —API con PHP-FPM detrás del balanceador, consumidor de reconciliación, trabajos y planificador— que escalan cada uno por su propia señal en el peak de septiembre, sin servidores permanentes que mantener. En la misma plataforma corre, en un contenedor propio, el motor de optimización de rutas de M4, y el transporte AS2 del hub EDI de M11 se contrata como servicio administrado (AWS Transfer Family), ambos tras un contrato versionado (ADR-01, ADR-11).
- **N-05 Base de datos en nube** (criticidad): Aurora PostgreSQL guarda el transaccional de los módulos en nube y la réplica del WMS, conmuta entre zonas en menos de 30 s y se replica a us-east-1.
- **N-06 Telemetría cruda** (volumen): DynamoDB recibe las lecturas de temperatura sin gestión de capacidad y las expira a los 30 días, cuando ya están consolidadas en la capa analítica.
- **N-07 Caché** (latencia): ElastiCache mantiene en memoria el stock, el crédito y las sesiones para que la consulta de preventa responda en menos de 2 s.
- **N-08 Ingesta de IoT** (volumen): IoT Core y Lambda reciben los 16.100 mensajes diarios de cadena de frío por MQTTs, validan cada lectura y gestionan los gateways del borde.
- **N-09 Mensajería** (criticidad): una cola SQS FIFO recibe la reconciliación de los sitios como sobres JSON versionados, en orden por grupo y sin duplicados; otras colas SQS, separadas de esa, transportan los trabajos internos de Laravel; y SNS difunde las alertas de excursión térmica.
- **N-10 Plataforma analítica** (volumen y costo): S3, Glue, Redshift Serverless y Quick-Sight conservan 5 años de datos separados del transaccional y publican los tableros del CLIENTE.
- **N-11 Respaldo inmutable y réplica** (regulación): S3 Object Lock, AWS Backup y la réplica en us-east-1 guardan la copia que ni un administrador puede borrar y sostienen el RTO de 4 h y el RPO de 15 min.
- **N-12 Seguridad y gobierno** (regulación): KMS, Secrets Manager, WAF, Shield, Security Lake y CloudWatch cumplen los controles del Artículo 21 como servicios que un equipo de TI de cuatro personas puede operar.
- **N-13 Gestión de dispositivos** (costo): Android Enterprise y Zebra DNA gestionan como servicio el parque de terminales de preventa, reparto y cámara, con borrado remoto selectivo y sin infraestructura en los sitios (RT-03.18).

Ningún componente de nube pura participa en las transacciones que el caso exige

resolver sin enlace: la confirmación de preparación, el despacho y el registro de entrega se ejecutan en el sitio o en el dispositivo. Lo que sube a la nube lo hace por tres razones. Los portales y la gestión de identidades externas lo hacen por regulación, porque el Artículo 21 impide exponer los sitios a Internet. La plataforma de aplicación, la analítica y la telemetría lo hacen por volumen y costo, porque su carga varía con la estación y se paga por uso. Y la seguridad y el respaldo lo hacen porque un equipo de TI de cuatro personas no puede operar esos controles en sus propios servidores.

4.2.1.5 Componentes on-premise

Los once componentes on-premise viven solo en las instalaciones del CLIENTE. La justificación de cada uno y su criterio:

- **B-01 Sensores de temperatura** (latencia): los 28 puntos de medición de las cámaras se leen por Modbus en el mismo sitio, porque dentro de la cámara no hay señal y la lectura no puede esperar al enlace.
- **B-02 Gateway IoT** (latencia): los gateways de Talca y Concepción detectan la excursión térmica y bloquean el despacho en menos de 5 s, con un buffer de 24 h si cae el enlace, igual a la autonomía del centro de distribución.
- **C-03 Terminales de bodega** (conectividad): los 174 terminales MC9400 trabajan en la cámara a -22°C , sin señal móvil, contra el WMS del sitio por la red inalámbrica de la bodega.
- **C-04 Impresoras de andén** (latencia): las seis impresoras ZT411 imprimen la etiqueta SSCC en el andén al armar la unidad logística, sin salir de la red local.
- **C-05 Balanzas de recepción** (latencia): las tres balanzas envían el peso de recepción al WMS del sitio en línea, sin digitación y sin depender del enlace.
- **D-02 Switching** (criticidad): los switches de cada sitio segmentan la red local por VLAN (RT-03.23) y la mantienen operativa aunque caiga la WAN.
- **D-03 Enlace de fibra** (conectividad): es el camino principal de la VPN en Talca y Concepción, con 20 y 10 Mbps en régimen.
- **D-04 Enlace LTE** (conectividad): respalda la fibra en los CD y, con dos proveedores, respalda a Starlink en los cross-docking, con conmutación en menos de 30 s.
- **D-06 Enlace satelital** (conectividad): Starlink es el camino principal de los cross-docking, que no tienen fibra y cuya red móvil falla en la madrugada de Los Ángeles.
- **E-01 WMS de cross-docking** (criticidad): el mini-PC de cada plataforma opera 100 % en local la ventana de 3 h de recepción, desconsolidación y re-despacho, con su propio broker y su propia base.

- **F-02 Gestión de parches** (costo): Ansible aplica los parches y las líneas base CIS a los nodos de los cinco sitios por la red de gestión, sin licencia de plataforma.

En el on-premise dominan la latencia y la conectividad. Los sensores, las impresoras, las balanzas y los terminales de cámara son periféricos que trabajan donde está la mercadería, y ninguno puede depender de un enlace que el caso describe como intermitente. Los tres enlaces y el switching tampoco podrían emplazarse en otro lugar: son la infraestructura que conecta el sitio con la nube y sostiene su red interna cuando esa conexión falla.

4.2.1.6 Componentes híbridos

Los doce componentes híbridos tienen una parte en cada dominio. Para cada uno, la justificación explica qué parte vive en el sitio, qué parte vive en la nube y por qué se reparten así:

- **A-01 Motor WMS** (latencia): el perfil `wms_only` del artefacto Laravel, con su servidor web y PHP-FPM, corre en VM-01, VM-C01 y E-01 porque la confirmación de preparación debe responder en 1 s sin depender del enlace, y su réplica en Aurora sostiene la continuidad. El mismo motor expone la puerta de API local de la bodega, que durante un corte valida el esquema, la tasa, el UUID y la auditoría de las solicitudes de los terminales sin pasar por API Gateway.
- **A-02 Base transaccional del WMS** (criticidad): PostgreSQL 16 en VM-02 y VM-C02 es el registro de la bodega durante un corte, y DMS replica sus cambios a Aurora para continuidad y lectura, con un RPO de 15 min mientras hay enlace.
- **A-03 Broker de colas** (conectividad): RabbitMQ en VM-03, VM-C04 y E-01 guarda hasta 24 h de eventos sin enlace, con mensajes persistentes y confirmación de publicación; el shipper, un proceso PHP con el adaptador AMQP `php-amqp-lib`, los publica como sobres JSON en SQS FIFO y solo los retira del broker cuando SQS confirma la recepción.
- **A-04 Capa anticorrupción del ERP** (criticidad): corre en VM-04 junto al ERP de 2017, que no se modifica, y el trabajador Laravel `erp-sync` de la nube la consulta por la VPN como única puerta al legado, con una clave idempotente por operación para que un reintento no emita un segundo documento tributario.
- **A-05 Identidad** (conectividad): el IdP maestro Keycloak corre en Fargate y sus cachés de solo lectura en VM-05, VM-C03 y E-01 validan las sesiones de bodega y de cross-docking sin enlace; en el mismo nodo, un verificador local habilita cada relevo de turno durante un corte con el manifiesto de turno firmado y un segundo factor

local, el PIN personal.

- **B-03 Termógrafos de camión** (conectividad): los 28 termógrafos —18 en los camiones propios y 10 en los de los transportistas— registran la temperatura durante toda la ruta sin señal y sincronizan por Bluetooth con el terminal del conductor, que alerta la excursión térmica en el momento y la reenvía a la nube cuando recupera cobertura; al volver el camión, el mismo terminal descarga el registro completo y lo envía a la nube para que IoT Core lo valide.
- **C-01 App de preventa** (conectividad): toma pedidos contra el almacén local del terminal cuando no hay señal y sincroniza con API Gateway al reconectar, sin duplicar pedidos.
- **C-02 App de reparto** (conectividad): registra entregas, evidencia y cobros durante 14 h sin señal y los sincroniza con la nube al recuperar cobertura.
- **D-01 Firewall y Customer Gateway** (criticidad): el par de Talca, el firewall de Concepción y el firewall compacto de cada cross-docking terminan los túneles IPsec hacia el Transit Gateway de AWS y conmutan de enlace en menos de 30 s.
- **D-05 Respaldo local** (conectividad): el NAS WORM de Talca restaura el WMS en 4 h sin depender del enlace, y su complemento inmutable vive en S3 Object Lock.
- **F-01 Telemetría de observabilidad** (conectividad): los colectores ADOT de VM-06, VM-C04 y E-01 guardan hasta 24 h de métricas y trazas en disco y las envían a CloudWatch al reconectar.
- **F-03 Detección en endpoints** (regulación): los agentes EDR de cada nodo y estación reportan a una consola central, lo que cumple RT-11.16 en nube y on-premise con una sola respuesta.

Los componentes híbridos siguen todos el mismo patrón: la parte que atiende la operación queda en el sitio y la parte que consolida queda en la nube, unidas por un mecanismo que tolera el corte. En el núcleo de bodega ese mecanismo es la réplica por DMS y las colas; en el terreno, el almacén local del dispositivo; y en la observabilidad, el buffer en disco de los colectores. Por eso la conectividad es el criterio dominante en siete de los doce: cada uno existe en dos lugares precisamente porque el enlace entre ellos no es confiable.

4.2.1.7 Autonomía de cada ámbito sin enlace

El emplazamiento anterior se verifica en lo que cada ámbito puede hacer cuando pierde el enlace. La Tabla 3 declara esa autonomía y el tiempo en que cada ámbito vuelve a quedar sincronizado.

Ámbito	Autonomía sin enlace	Norma de operación
Centros de distribución de Talca y Concepción	24 h o más	RT-03.10 y RT-03.12, reconciliación determinista
Terreno	14 h, un turno completo	RT-03.10
Cross-docking	24 h o más; la ventana de 3 h opera 100 % local	RT-03.10 y RT-03.11
Sincronización al reconectar	CD en 2 h; flota en 10 min	RT-03.13 y RNF-07.01

Tabla 3 Autonomía por ámbito ante la pérdida del enlace

Durante la autonomía, cada ámbito mantiene su operación completa contra sus datos locales. El centro de distribución sigue con recepción, preparación, despacho, conteo cíclico y trazabilidad contra la base local (RT-03.12). El terreno sigue con toma de pedido, entrega, evidencia, devoluciones y cobros contra el almacén local del dispositivo (RT-03.10). El cross-docking mantiene recepción, desconsolidación, validación de frío y re-despacho (RT-03.11). Al reconectar, el vuelco ocurre en orden estricto, sin duplicados y con reconciliación determinista (RT-03.13, RNF-07.01).

La autonomía de cada ámbito cubre el corte más largo que describe el caso para ese lugar. Las seis horas del peor corte de fibra de Talca quedan dentro de las 24 horas del centro de distribución, y la ruta rural que recupera cobertura solo al regresar queda dentro del turno de 14 horas del terreno. Los tiempos de sincronización se sostienen con los enlaces dimensionados en la sección 4.2.5, y lo que ocurre ante cada falla se desarrolla en la sección 4.2.4.

4.2.2 Servicios contratados en la plataforma de nube

La plataforma de nube es Amazon Web Services. Todos los servicios se contratan en cuentas del CLIENTE, organizadas bajo AWS Control Tower con una cuenta por ambiente, de modo que la propiedad de los datos y de la infraestructura es del CLIENTE desde el primer día. La selección sigue tres reglas: preferir el servicio administrado cuando existe, porque el área de TI del CLIENTE es de cuatro personas (Caso, Cap. 2.4); preferir servicios compatibles con estándares abiertos, para que salir de la plataforma no exija

reescribir la solución; y contratar en la región secundaria solo lo que la recuperación ante desastres necesita.

4.2.2.1 Servicios por función

La Tabla 4 agrupa los servicios contratados por la función que cumplen en la arquitectura y los asocia a los componentes del catálogo que los usan. El listado servicio por servicio, con su justificación y su cantidad, se entrega en el Formulario T-11.

Función	Servicios contratados	Componentes	Región
Entrada pública y borde	Route 53, CloudFront, AWS WAF, Shield Advanced, API Gateway	N-01, N-02, N-03, N-12	Global y sa-east-1
Cómputo de aplicación	ECS Fargate, Application Load Balancer, Lambda	N-04, N-08, A-05	sa-east-1 y us-east-1
Datos operacionales	Aurora PostgreSQL, Database Migration Service, DynamoDB, ElastiCache	N-05, A-02, N-06, N-07	sa-east-1 y us-east-1
Mensajería	SQS FIFO para la reconciliación, SQS para los trabajos de Laravel, SNS	N-09, A-03	sa-east-1
Integración B2B	AWS Transfer Family con AS2	N-04 (M11)	sa-east-1
Internet de las cosas	IoT Core, IoT Greengrass	N-08, B-02, B-03	sa-east-1 y borde
Analítica	S3, Glue, Redshift Serverless, QuickSight	N-10	sa-east-1
Respaldo y recuperación	AWS Backup, S3 Object Lock, replicación de S3 entre regiones	N-11, D-05	sa-east-1 y us-east-1
Red y conectividad	VPC, Transit Gateway, Site-to-Site VPN, NAT Gateway, VPC Endpoints	D-01	sa-east-1 y us-east-1
Identidad, claves y secretos	KMS, Secrets Manager, Parameter Store, IAM Identity Center	A-05, N-12	sa-east-1 y us-east-1
Detección y cumplimiento	Security Lake, GuardDuty, Security Hub, Inspector, Macie, CloudTrail, Config	N-12, F-03	sa-east-1; CloudTrail, GuardDuty y Config también en us-east-1

Tabla 4 — continuación

Función	Servicios contratados	Componentes	Región
Operación y gobierno	CloudWatch, Systems Manager, Control Tower, Organizations, Cost Explorer, Budgets	F-01, F-02, N-12	sa-east-1
Construcción y registro de imágenes	CodeBuild, Elastic Container Registry	N-04, A-01	sa-east-1
Servicios de terceros en nube	Android Enterprise y Zebra DNA; consola del EDR	N-13, F-03	Servicio gestionado

Tabla 4 Servicios contratados en la plataforma de nube, por función

La tabla deja ver que la solución no opera servidores en la nube: todo el cómputo corre en contenedores administrados o en funciones, y todos los datos viven en motores administrados. Las piezas de software que el adjudicatario mantiene sobre esa plataforma son la aplicación Laravel, con sus perfiles de API, consumo, trabajos y planificación; los portales web, contruidos en Angular y publicados como contenido estático en S3 y CloudFront; el motor de optimización de rutas de M4, en su propio contenedor; y el IdP Keycloak. Todas se promueven por el mismo pipeline. Las colas se separan por formato: la cola FIFO de reconciliación solo transporta los sobres JSON versionados que publican los sitios, y los trabajos internos de Laravel usan colas SQS distintas, de modo que un mensaje externo nunca llega al deserializador de trabajos del framework. ElastiCache conserva únicamente su papel de caché y no se usa como cola. Los servicios de detección, cumplimiento y gobierno se concentran en la región primaria porque vigilan la operación productiva, mientras que los datos operacionales y el respaldo tienen presencia en las dos regiones porque son lo que la recuperación ante desastres debe restituir.

4.2.2.2 Región secundaria y residencia de los datos

La región us-east-1 no es una segunda producción. Solo contiene la réplica de Aurora mediante Aurora Global Database, la réplica de las tablas de temperatura de DynamoDB mediante Global Tables, la copia de los buckets de S3 salvo el de geolocalización, las copias de AWS Backup y una réplica reducida de ECS que escala a carga completa en menos de 30 minutos durante una conmutación (ADR-09). Dos capacidades quedan

fuera de esa región por diseño: la analítica, porque la región secundaria no se explota analíticamente, y los datos de geolocalización de personas, que no se replican fuera de sa-east-1 conforme a los resguardos de la arquitectura de seguridad (apartado 4.1). Así, la transferencia internacional de datos que exige la continuidad queda acotada a lo estrictamente necesario para reanudar la operación.

4.2.2.3 Servicios que no se contratan

Los registros de decisión descartan de forma expresa varios servicios y productos, y ninguno de ellos aparece en la arquitectura. No se instala Redis ni Laravel Horizon en los sitios, porque la continuidad local descansa en PostgreSQL y RabbitMQ, y un tercer motor por sitio agregaría operación sin beneficio (ADR-05). No se contrata un clúster de Kubernetes (EKS), porque el volumen de alrededor de 105 transacciones por segundo no justifica su plano de control (ADR-01). No se contrata Kafka administrado (MSK), porque RabbitMQ en cada sitio y SQS FIFO en la nube resuelven el orden y la durabilidad con menos operación (ADR-05). No se contratan servicios de trazas y métricas separados de CloudWatch, porque las Bases piden una sola plataforma de observabilidad para nube y on-premise (ADR-14, RT-03.16). Y no se autoaloja un gestor de secretos, porque Secrets Manager rota las credenciales sin el desollado manual que exigiría uno propio (ADR-15).

4.2.2.4 Modelo de contratación

Los servicios se contratan por uso, con la capacidad base comprometida mediante Savings Plans y el peak de septiembre cubierto con capacidad efímera que se libera al terminar (ADR-12). Los ambientes de Desarrollo, QA y Preproducción se reducen o apagan fuera del horario de uso. La reversibilidad está asegurada por la elección de servicios: Aurora es compatible con PostgreSQL, los datos analíticos se guardan en formato Parquet, y Keycloak, Laravel, PostgreSQL y RabbitMQ son de código abierto, de modo que la solución puede trasladarse a otra plataforma sin reescribir la aplicación. Los montos de estos servicios se declaran en la Oferta Económica y no en este documento (Art. 50.2).

4.2.3 Arquitectura de despliegue

La arquitectura física describe qué componentes existen, dónde viven y cómo se conectan. Esta sección describe cómo esa solución se pone en marcha y se mantiene en operación durante los 56 meses del contrato: por qué ambientes pasa un cambio antes de llegar a las bodegas y a la calle, sobre qué red se despliega, cómo sigue operando cuando algo falla y cómo se recupera cuando se pierde un sitio completo o se daña un dato. Los puntos de falla de cada conexión y de cada equipo, con su resolución inmediata, se declaran en la sección de conexiones y contingencia (Tablas 14 y 15); aquí se describen los mecanismos que sostienen esa continuidad y cómo se verifican.

Esos mecanismos son tres y no se sustituyen entre sí. La alta disponibilidad responde a la falla de un componente sin que la operación lo note. La recuperación ante desastres responde a la pérdida de un sitio o de una región completa. El respaldo responde al daño del dato, sea un borrado accidental, una corrupción o un cifrado malicioso, frente a los cuales las réplicas no protegen, porque replican el daño con la misma fidelidad que una escritura legítima.

4.2.3.1 Ambientes y ciclo de entrega

Un cambio recorre tres ambientes antes de llegar a Producción: Desarrollo, QA y Pre-producción. Se construye y se prueba de forma unitaria en Desarrollo, se valida en QA con pruebas funcionales, de integración y de regresión automatizadas, y se ensaya en Preproducción, donde ocurren las pruebas de aceptación, de carga y de resiliencia y el ensayo del paso a producción. Solo entonces se promueve a Producción, sin recompilar, de modo que el artefacto que llega a producción es el mismo que se probó. La marcha blanca de cada etapa ocurre ya en Producción, porque es operación supervisada con datos y usuarios reales en paralelo con la operación vigente. Un quinto ambiente, de Recuperación ante Desastres, sostiene la continuidad (RT-04.01): reside en la región us-east-1 para el dominio de nube, mientras que la recuperación del dominio on-premise la asume el CD Concepción, que forma parte de Producción, como se describe en la recuperación ante desastres de esta sección. La Tabla 5 muestra cada ambiente con su bloque de direccionamiento, su región y su función.

Ambiente	VPC	Región	Función
Desarrollo	10.104.0.0/16	sa-east-1	Construcción y pruebas unitarias
QA	10.103.0.0/16	sa-east-1	Pruebas funcionales, de integración y de regresión; análisis dinámico
Preproducción	10.102.0.0/16	sa-east-1	Aceptación, carga, resiliencia y ensayo del paso a producción
Producción	10.101.0.0/16	sa-east-1	Operación en varias zonas, con los sitios on-premise; marcha blanca
Recuperación ante Desastres	10.201.0.0/16	us-east-1	Réplica en caliente del dominio de nube

Tabla 5 Ambientes de despliegue

Cada ambiente reside en una cuenta AWS propia, bajo una organización de AWS Control Tower cuyas políticas de control de servicio impiden que un error o un acceso indebido en un ambiente alcance a otro; la organización incorpora además sus cuentas de gestión, de archivo de registros y de auditoría. Los bloques de direccionamiento no se solapan entre sí ni con los de los sitios on-premise, y solo el ambiente de recuperación reside fuera de la región primaria. Los cinco ambientes están habilitados como condición del hito H3.

Desarrollo y QA son aislados y se reconstruyen desde código. Desarrollo trabaja con datos sintéticos o anonimizados, y QA con un juego de datos de prueba controlado y versionado que se restituye a un estado conocido antes de cada ciclo de pruebas. Ningún ambiente no productivo recibe datos productivos sin anonimización o seudonimización verificable (RT-11.25). Desarrollo, QA y Preproducción se reducen o apagan fuera del horario de uso, con el ahorro reflejado en la estructura de costos (RT-15.02, RT-04.13).

Las bodegas no tienen ambientes propios de prueba, y no los necesitan. El on-premise es producción: la imagen wms_only que corre en los centros de distribución es la misma que recorrió Desarrollo, QA y Preproducción en la nube, y la infraestructura de cada sitio se declara como código versionado. Lo que se ensayó en la nube es, por lo tanto, lo que se instala en Talca y en Concepción, dentro de la ventana de 24 horas del cutover. QA y Preproducción ensayan esa imagen con el verificador local de identidad y la puerta de

API local del WMS, con adaptadores simulados del ERP, y reproducen el corte de enlace y el relevo de turno antes de cada paso a producción.

Preproducción es equivalente a Producción en versiones, configuración, dimensionamiento y topología de nube (RT-04.02). Las diferencias que subsisten se declaran y se justifican, y son tres. Primero, se reduce o apaga fuera del horario de uso, por costo. Segundo, trabaja con datos sintéticos generados desde la volumetría del caso, cuya anonimización se verifica con Amazon Macie, porque no se admiten datos productivos reales fuera de Producción sin anonimización verificable (RT-11.25). Tercero, el sitio on-premise se emula dentro de su propia VPC, con la misma imagen `wms_only`, el mismo broker y el mismo verificador local, pero sin túnel hacia las bodegas, para que un ensayo no pueda alcanzar la operación real. La emulación reproduce la topología del sitio y no su hardware; por eso la primera instalación de cada versión en los centros de distribución avanza sitio por sitio, como se describe en la liberación. Durante las pruebas de carga y estrés de la Tabla 30 opera con el dimensionamiento completo de Producción.

El paso de un ambiente a otro lo controla el pipeline de integración continua: GitLab CI lo orquesta y AWS CodeBuild construye cada imagen de forma hermética, con procedencia SLSA nivel 3. Cada cambio instala las dependencias exactamente como las fija `composer.lock` y pasa por `composer audit`, las pruebas PHPUnit, el análisis estático con PHPStan y Larastan, el formato con Laravel Pint, las pruebas de contrato contra OpenAPI 3.1 y AsyncAPI 2.6, el escaneo de secretos y de imágenes de contenedor y la medición de cobertura; el pipeline bloquea el despliegue ante un hallazgo crítico o alto, ante un contrato público roto sin versión nueva o ante una cobertura de la lógica de negocio inferior al 70 % (RT-04.05, RT-04.11). La imagen aprobada se firma, se publica en Elastic Container Registry y se promueve por su digest, de modo que ningún ambiente recompila. La configuración se externaliza por ambiente y los secretos se gestionan en AWS Secrets Manager con rotación automática (ADR-15); la imagen no contiene secretos ni el archivo de entorno. Las migraciones de base de datos son migraciones Laravel basales y aditivas, que siguen la estrategia de expandir y contraer: se ejecutan como un paso único del despliegue antes de cambiar el tráfico, cada versión solo agrega estructuras, de modo que la versión anterior y la nueva de la aplicación funcionan sobre el mismo esquema durante el despliegue, y las estructuras obsoletas se eliminan en una versión posterior (RT-04.10). El gobierno del repositorio, con ramas protegidas y revisión obligatoria por pares, y la trazabilidad desde el requerimiento hasta el despliegue se desarrollan en el plan de calidad (Subdocumento 9). A Producción no se llega de otra forma: el acceso administrativo excepcional es temporal, mediante AWS Systems Manager Session Manager, con MFA, aprobación previa y sesión grabada.

Los portales de clientes, transportistas y proveedores siguen el mismo ciclo: su aplicación web, construida en Angular con TypeScript y Tailwind CSS, se publica por ambiente en

S3 y CloudFront, con la imagen de aplicación del mismo ambiente como backend, y entra a producción con el hito de enero de 2029.

4.2.3.1.1 Artefacto y perfiles de ejecución

La aplicación se construye una sola vez por versión como una imagen PHP 8.5 con Laravel 13 que contiene el código, el vendor resuelto desde `composer.lock`, PHP-FPM, el intérprete de línea de comandos y las extensiones que la solución usa: `pdo_pgsql`, `mbstring`, `intl`, `openssl`, `opcache`, `curl` para el SDK de AWS, `sockets` para el adaptador AMQP `php-amqp-lib`, la extensión de OpenTelemetry y `pcntl`, que solo usan los procesos de línea de comandos para terminar de forma ordenada al recibir la señal de detención. Un servidor web liviano acompaña a PHP-FPM en los perfiles HTTP. La misma imagen corre en todos los ambientes y en todos los sitios; lo que cambia es el perfil con que arranca, como muestra la Tabla 6.

Perfil	Proceso y función	Dónde corre	Escala por
API	Servidor web y PHP-FPM; APIs de M1-M12 para portales, preventa y reparto	N-04, ECS Fargate en 2 zonas	Procesos PHP-FPM ocupados
wms_only	Servidor web y PHP-FPM; M1, M2, M5 y bloqueo de M9, con la puerta de API local	VM-01, VM-C01 y E-01	Fijo, dimensionado al sitio
Shipper	PHP CLI; lee RabbitMQ con <code>php-amqp-lib</code> y publica sobres JSON en SQS FIFO	VM-03, VM-C04 y E-01	Uno por sitio
Consumidor de reconciliación	PHP CLI con el SDK de AWS; aplica los sobres al estado central	N-04, ECS Fargate	Edad del mensaje más antiguo
Trabajos	PHP CLI con el trabajador de colas de Laravel; notificaciones, <code>exp-sync</code> y EDI en colas separadas	N-04, ECS Fargate	Profundidad de cada cola
Planificador	PHP CLI; tareas periódicas del ambiente	N-04, una sola tarea por ambiente	No escala

Tabla 6 Perfiles de ejecución del artefacto Laravel

Los perfiles comparten la revisión de código y la versión de esquema, pero cada uno tiene su propio rol de IAM o credencial local, con solo los permisos que su función necesita: el perfil de API no puede leer la cola de reconciliación, el consumidor no puede escribir en las colas de trabajos y el shipper solo puede enviar a su cola FIFO. El planificador corre como una sola tarea por ambiente, con despliegue que detiene la tarea anterior antes de iniciar la nueva, y cada tarea periódica toma además un bloqueo en la base de datos para impedir ejecuciones superpuestas; los sitios no ejecutan planificador, porque sus procesos permanentes son el servidor del WMS y el shipper. En los centros de distribución, el perfil `wms_only` y el shipper corren como contenedores sobre las máquinas virtuales de Proxmox, y en cada cross-docking se orquestan con Docker Compose en E-01, junto a PostgreSQL, RabbitMQ y la caché de identidad. Fuera de la imagen Laravel quedan solo dos piezas, ambas tras un contrato versionado: el motor de optimización de rutas de M4, que se construye por el mismo pipeline como imagen propia y corre como tarea de Fargate bajo demanda durante cada corrida de ruteo, y el transporte AS2 del hub EDI, que presta AWS Transfer Family (ADR-01, ADR-11).

Cada perfil declara cómo arranca, cómo informa su salud y cómo se detiene. Al arrancar, el contenedor verifica la versión de esquema esperada y no acepta tráfico ni mensajes si no coincide. Los perfiles HTTP exponen una ruta de salud de proceso, que usa el balanceador, y una de disponibilidad que comprueba la base y la cola; los procesos de línea de comandos informan su salud por un latido que el orquestador vigila. Al detenerse, el balanceador deja de enviar solicitudes nuevas y espera 30 segundos a que terminen las vigentes; los trabajadores reciben la señal de detención, terminan el mensaje en curso sin tomar otro y salen antes de 120 segundos, plazo mayor que el tiempo máximo de un trabajo, y el mensaje no confirmado vuelve a la cola al vencer su visibilidad. Así ningún reinicio, escalado o despliegue deja un trabajo a medias.

4.2.3.1.2 Liberación y reversión

Cada versión se libera con estrategia azul-verde: la versión nueva se despliega junto a la vigente y recibe tráfico de forma gradual, en etapas de canario, después de haberse demostrado el mismo procedimiento en Preproducción (RT-04.07). La puesta en producción avanza por proceso, por sitio o por zona comercial, nunca como un evento único que afecte a la vez a la bodega, la preventa, el reparto y la facturación (Caso, Cap. 13.3). En la sustitución del WMS de 2013 por olas, cada capacidad se activa además por sitio mediante indicadores de funcionalidad (*feature flags*), de modo que revertir una ola es apagar su indicador, sin volver a desplegar.

Mientras dura el canario, la versión anterior permanece desplegada, por lo que revertir es devolverle el tráfico, sin recompilar ni volver a desplegar. La reversión es automática

y se dispara cuando el percentil 95 de una transacción supera su umbral comprometido (Tabla 29) o cuando la versión nueva registra más errores que la estable en la misma ventana de observación. No se pierde ninguna transacción confirmada: las operaciones en curso quedan en los buffers locales, 24 horas por sitio en el broker y la caché de turno en los dispositivos, y se reprocesan de forma idempotente contra la versión restituida. El esquema tampoco se revierte, porque la migración de la versión solo agregó estructuras. Lo que se pierde es la versión, no la operación. El tiempo efectivo de reversión se mide en cada ensayo en Preproducción, con un máximo contractual de 4 horas (Art. 78.3).

Si la falla de un despliegue se manifestara durante la ventana de despacho, la bodega y el reparto continuarían con su operación local (Tabla 3) mientras se revierte, sin detener la salida de los camiones (Caso, Cap. 17.6).

Cada promoción ensaya además la compatibilidad de los mensajes pendientes. Un sitio puede volver de un corte de 24 horas con sobres publicados por la versión anterior, de modo que el consumidor de reconciliación acepta la versión vigente y la inmediatamente anterior del sobre JSON, y rechaza hacia la cola de mensajes fallidos cualquier versión que no reconozca, sin aplicarla. Preproducción reproduce ese caso —sitio emulado desconectado, promoción de la versión nueva y reconexión— antes de cada paso a producción.

4.2.3.1.3 Transición al backend Laravel

La arquitectura lógica fija la implantación progresiva del backend (apartado 4.1), y su secuencia física es la siguiente. Primero se registran los contratos OpenAPI y AsyncAPI, el sobre JSON y el esquema PostgreSQL de partida, que es la línea base de las migraciones Laravel. Luego se construye el backend y se prueban las colas y la capa anticorrupción con fallas inducidas: corte de enlace, ERP caído, mensajes duplicados y fuera de orden. Después se habilita un sitio piloto, dimensionado por su capacidad real, con el WMS de 2013 disponible para la reversión, y el tráfico se migra por olas con un único escritor autorizado para cada operación: nunca escriben a la vez el sistema anterior y el nuevo sobre el stock, los cobros o los documentos tributarios. Antes de cada corte se drenan los mensajes que el sistema nuevo no puede leer; si algún ambiente conservara mensajes serializados por un framework anterior, se drenan o se transforman al sobre JSON antes del corte, porque Laravel no puede consumirlos. Cada ola cierra verificando saldos de stock, cobros y folios contra el origen, y se revierte por sitio si falla un umbral acordado con el CLIENTE. La reversión devuelve el tráfico al escritor anterior solo después de detener el nuevo, conciliar los pendientes y comprobar que el esquema sigue legible por la versión previa.

4.2.3.1.4 Calendario y cadencia

El calendario de Puelche limita cuándo se puede intervenir la plataforma. El caso prohíbe intervenir los sistemas entre el 1 y el 25 de septiembre, en diciembre y durante el cierre contable de cada mes, prohíbe el paso a producción en todo septiembre y en diciembre, y exige indisponibilidad cero en la ventana de despacho (Caso, Cap. 10, restricción 8, y Cap. 13.3). La Tabla 7 cruza cada período con lo que admite.

Período	Despliegue	Indisponibilidad programada
Todo septiembre; sin intervención alguna del 1 al 25	No	No
Todo diciembre	No	No
Tres primeros días hábiles del mes	No	No
05:30–07:00, lunes a sábado	No	No
22:00–06:00, preparación de pedidos	Sí, sin interrupción	No
08:00–18:00, recepción de proveedores	Sí, sin interrupción	No
Resto del calendario	Sí, sin interrupción	Excepcional, con aviso de 10 días hábiles

Tabla 7 Ventanas de despliegue

El despliegue sin interrupción es, por lo tanto, la regla y no una capacidad opcional: solo fuera de las ventanas protegidas se admite una indisponibilidad programada, y únicamente por excepción. En la ventana nocturna, además, toda intervención en bodega considera el turno de preparación. Descontados los congelamientos, quedan unos diez meses desplegables al año, de los que se excluyen los tres primeros días hábiles de cada mes. Sobre ese margen se fija una cadencia quincenal de despliegue y un tiempo de hasta cinco días hábiles desde que se confirma un cambio de código hasta que llega a producción, compatible con el plazo de siete días para remediar una vulnerabilidad crítica que declara la arquitectura de seguridad (apartado 4.1). La tasa de cambios fallidos no supera el 5 % de los despliegues del mes y el tiempo de restauración no supera 4 horas, conforme al Artículo 78.3 (RT-04.12). Las correcciones de incidentes críticos

usan el mismo pipeline, con prioridad y fuera de la cadencia quincenal, dentro del plazo de resolución de 4 horas.

4.2.3.2 Red de despliegue

La sección de conexiones describe los caminos entre los sitios, el terreno y la nube, y su conmutación (Figura 2 y Tabla 13). El despliegue agrega tres definiciones sobre esa red: dónde llegan los túneles, cómo se reparte el direccionamiento y cómo se dirige el tráfico entre regiones.

Los túneles VPN de los cinco sitios terminan en un Transit Gateway en sa-east-1, que enruta entre ellos y los une solo a la VPC de Producción. Es la única VPC con enlace hacia los sitios, coherente con que el on-premise es producción: Desarrollo, QA y Preproducción no tienen conectividad con las bodegas, de modo que un error en un ambiente de prueba no puede alcanzarlas. El direccionamiento se asigna sin solapamiento, según la Tabla 8.

Dominio	Bloque	Segmentación
Talca	10.1.0.0/16	VLAN de gestión, servidores, operación, estaciones e IoT
Concepción	10.2.0.0/16	Mismas VLAN que Talca
Cross-docking	10.3.0.0/16 a 10.5.0.0/16	VLAN de gestión y de operación tras el firewall del sitio, por la VPN
Sitio adicional previsto	10.6.0.0/16	Reservado
VPC Producción, zona pública	10.101.1.0/24 y 10.101.2.0/24	Balanceador, origen de CloudFront, NAT y portales
VPC Producción, zona privada	Resto de 10.101.0.0/16	Aplicación, datos y adjunto del Transit Gateway

Tabla 8 Direccionamiento y segmentación

Cada sitio con cómputo dispone de un bloque propio, y el centro de distribución que Puelche evalúa abrir hacia 2030 ya tiene el suyo reservado, de modo que su incorporación es una parametrización de la infraestructura como código y no un rediseño (RT-02.12). En la nube, solo la zona pública expone servicios: la aplicación y los datos residen en

subredes privadas y consumen los servicios de AWS por VPC Endpoints, sin tráfico por Internet, por lo que ningún componente de datos es alcanzable desde fuera (RT-03.04).

El tráfico de los usuarios externos entra por CloudFront y por la capa de protección descrita en la arquitectura de seguridad (apartado 4.1). Entre regiones, Route 53 opera con enrutamiento de conmutación por falla y verificaciones de salud activas: sa-east-1 recibe todo el tráfico en operación normal y la conmutación hacia us-east-1 es automática ante falla, coherente con la modalidad activo-pasiva del ADR-09. Para esa conmutación, la conexión Site-to-Site VPN de los sitios hacia la VPC de recuperación en us-east-1 está declarada como código y se activa en el paso de reconexión del broker (Tabla 11).

La red también debe devolver a la normalidad a un sitio que operó desconectado. El compromiso es resincronizar la flota en hasta 10 minutos y un centro de distribución en hasta 2 horas después de un corte de 24 horas (Tabla 3). Tomando como cota el volumen transaccional anual de toda la solución, unos 375 GB (Tabla 22), atribuido a un solo centro de distribución y duplicado por el peak de septiembre, un corte de 24 horas acumula unos 2,1 GB. La evidencia de entrega no se suma, porque el terreno la envía por la red celular sin pasar por el centro de distribución. Con los anchos de banda de la Tabla 21, ese volumen se drena en unos 14 minutos por la fibra de Talca y en 27 por la de Concepción; aun por los enlaces LTE de respaldo tarda 55 minutos en Talca y 1 hora y 31 minutos en Concepción, dentro del compromiso de 2 horas en todos los casos. Al reconectar, la calidad de servicio prioriza el broker y el registro de escritura anticipada sobre la telemetría.

4.2.3.3 Alta disponibilidad

No todos los servicios necesitan el mismo nivel de continuidad. El Artículo 78 fija cuatro niveles de servicio, y la solución asigna cada servicio a uno según el efecto de su indisponibilidad sobre la operación (RT-10.02), como muestra la Tabla 9.

Nivel	Disponibilidad	Resolución	Servicios
Crítico	99,9 %	4 h	Preparación y despacho en la ventana de 05:30 a 07:00, con el bloqueo por excursión térmica y la identidad de bodega que lo habilitan

Tabla 9 — continuación

Nivel	Disponibilidad	Resolución	Servicios
Alto	99,5 %	8 h	Toma de pedido de preventa y consulta de stock y crédito, entrega y evidencia de entrega, planificación de rutas, documentos tributarios, integración con el ERP, cobranza y rendición, y registro de temperatura
Medio	99,0 %	24 h	Canal moderno (EDI), notificaciones, analítica y tableros, portales, consultas de geolocalización y registros de auditoría y seguridad
Bajo	98,0 %	48 h	Reportería e informes a pedido

Tabla 9 Clasificación de servicios por nivel de servicio

Solo es crítico lo que detiene un proceso de negocio sin alternativa operativa (Art. 78.1): la ventana de despacho de 05:30 a 07:00 no admite ejecución manual (Caso, Cap. 10, restricción 1), y el bloqueo por excursión térmica y la identidad de bodega son condiciones para que la carga salga. Los servicios altos son funciones críticas con una alternativa costosa: la toma de pedido, la entrega y la consulta de stock y crédito siguen siendo transacciones operacionales críticas en desempeño (RT-09.01, Tabla 29), pero el dispositivo las captura sin conexión durante un turno completo y las sincroniza al reconectar; la ruta puede planificarse a mano en 3,5 horas y las transacciones hacia el ERP se retienen en cola hasta 24 horas. Los medios tienen una alternativa disponible, y los bajos no impiden operar. La consecuencia para la arquitectura es directa: el compromiso penalizable del 99,9 % recae sobre la preparación y el despacho, que se ejecutan contra la base local del centro de distribución sin atravesar la WAN, y sobre la identidad, cuya autoridad reside en la nube y se sostiene con el despliegue en varias zonas de disponibilidad (apartado 4.3.1.2).

Esa es la razón por la que el 99,9 % de extremo a extremo no depende de multiplicar las disponibilidades de la infraestructura. El numeral 7.2 de las Transversales fija un mínimo de 99,95 % mensual para la energía, la climatización, la red, el cómputo, la base de datos y los portales, pero esos valores son pisos por subsistema y su producto en serie quedaría por debajo del 99,9 %. El compromiso se sostiene en la redundancia interna de cada subsistema y en la ruta que sigue cada transacción. La confirmación de preparación, la más estricta, se ejecuta contra la base local del centro de distribución y no atraviesa la WAN ni la nube; descansa sobre energía y climatización en N+1, un par

de firewall en alta disponibilidad, dos switches en stack, un clúster de tres nodos N+1 y almacenamiento Ceph sobre RAID 10, con un solo elemento en serie, la instancia de escritura VM-02, que se reinicia en otro nodo del clúster (Tabla 14). La identidad, por su parte, se sostiene en la nube con Keycloak en dos zonas y, en cada sitio, con la caché de solo lectura y el verificador local de relevo de turno.

En la nube, todos los servicios con requisito de alta disponibilidad operan en al menos dos zonas (RT-03.02). Aurora escribe en sa-east-1a y mantiene lectores en sa-east-1b y sa-east-1c, a los que conmuta en menos de 30 segundos; ElastiCache mantiene primario y réplica entre sa-east-1a y sa-east-1b y conmuta en menos de 60 segundos; las tareas de ECS Fargate se distribuyen en dos zonas y se reprograman solas ante la pérdida de una; y DynamoDB, el balanceador y los NAT Gateway son multizona por diseño. Ninguna conmutación supera un minuto. Ante el peak de septiembre, el escalamiento automático y la degradación controlada del apartado de dimensionamiento sostienen los umbrales de desempeño sin intervención.

4.2.3.4 Recuperación ante desastres

La recuperación ante desastres es activo-pasiva en caliente (ADR-09): la región us-east-1 mantiene una réplica reducida pero funcional de la plataforma, escalable a carga completa en menos de 30 minutos, que se promueve solo cuando se pierde la región primaria. Los objetivos son un RTO de hasta 4 horas y un RPO de hasta 15 minutos para los servicios críticos (RT-07.04). Cada dominio de datos alcanza ese RPO con su propio mecanismo de replicación, como muestra la Tabla 10.

Dominio	Mecanismo	RPO
Transaccional en nube	Aurora Global Database hacia us-east-1	< 1 s
Telemetría de temperatura	DynamoDB Global Tables	Continuo
Evidencia, documentos y respaldos	Replicación de S3 entre regiones con control de tiempo	< 15 min
WMS on-premise	AWS DMS sobre el registro de escritura anticipada, por la VPN	≤ 15 min con enlace
Mensajes críticos	Patrón outbox en base y cola	≤ 15 min
Mensajes no críticos	Cola con reposición diferida	≤ 24 h

Tabla 10 — continuación

Dominio	Mecanismo	RPO
---------	-----------	-----

Tabla 10 Replicación y RPO por dominio de datos

Todos los dominios críticos se replican de forma continua. El único cuyo RPO depende de una condición externa es el WMS on-premise, porque su réplica viaja por la WAN. Si un sitio pierde sus dos caminos, la base local sigue siendo autoritativa y el slot de replicación lógica que lee AWS DMS retiene en VM-02 el registro de escritura anticipada hasta reconectar, de modo que los cambios se entregan sin pérdida. Mientras dure el corte, en cambio, la réplica en nube queda desactualizada, hasta un máximo de 24 horas: el RPO remoto de 15 minutos rige solo con enlace y no se promete durante un corte que lo impide. El registro retenido se acota con un tope de 50 GB por slot, frente a los unos 2,1 GB diarios de cambios que estima el dimensionamiento, lo que cubre un día sin enlace con amplio margen sin arriesgar el disco de VM-02. El retraso de replicación y el tamaño del registro retenido se miden de forma continua y generan alarma a los 5 y a los 15 minutos de retraso (RT-07.03).

La réplica por DMS y la reconciliación por eventos cumplen funciones distintas y no se mezclan. DMS copia las tablas del WMS a un esquema de réplica por sitio en Aurora, de solo lectura, que sirve a la continuidad y a las consultas. El consumidor de reconciliación, en cambio, aplica los sobres JSON a las tablas de dominio del estado central —stock consolidado, trazabilidad de lotes, pedidos, entregas y cobros—, y en la misma transacción registra la clave de origen del evento, formada por el sitio y el identificador único que el evento trae desde su captura. Una restricción de unicidad sobre esa clave impide aplicar dos veces el mismo evento, aunque SQS lo entregue de nuevo o llegue después de la ventana de deduplicación de la cola. Ninguna tabla de dominio se alimenta de la réplica DMS, y ningún evento escribe en el esquema de réplica.

4.2.3.4.1 Conmutación y retorno

La conmutación de región separa lo reversible de lo irreversible. El enrutamiento se conmuta de forma automática, porque si la región primaria se recupera el tráfico vuelve solo. La promoción de la base de datos, en cambio, rompe la replicación y obliga a reconciliar al volver, por lo que exige la autorización del CLIENTE. La Tabla 11 muestra la secuencia completa.

Paso	Acción	Ejecución	Tiempo
1	Detección por verificación de salud de la región primaria	Route 53	< 5 min
2	Conmutación del enrutamiento hacia us-east-1	Automática	—
3	Confirmación y autorización de la promoción	CLIENTE, con aviso por SNS	—
4	Promoción de Aurora en us-east-1	Systems Manager Automation	15–20 min
5	Escalado de ECS a carga completa	Systems Manager Automation	< 30 min
6	Actualización de DNS	Systems Manager Automation	45–60 min
7	Reconexión del broker y sincronización del borde	Systems Manager Automation	—
8	Validación funcional de extremo a extremo	Operación	—

Tabla 11 Secuencia de conmutación de región

Los pasos con tiempo declarado suman, en el peor caso y ejecutados en serie, cerca de 2 horas más el tiempo de la decisión, dentro del RTO de 4 horas. Solo el tercer paso requiere intervención humana, y es ahí donde reside la protección contra una conmutación innecesaria. Como los pasos cuarto a séptimo están automatizados, el equipo de tecnologías de información de Puelche, de cuatro personas, puede ejecutar el procedimiento tras la transferencia de conocimiento (RT-07.05), con el acompañamiento del servicio de operación del adjudicatario.

El retorno a la región primaria sigue seis pasos: resincronización con verificación de alcance, reconciliación de las transacciones de la contingencia contra la bitácora, transferencia de los eventos pendientes, conmutación coordinada del DNS, validación funcional e informe con el tiempo real empleado (RT-07.06).

4.2.3.4.2 Sitios secundarios y amenazas comunes

La solución tiene dos sitios secundarios, uno por dominio: el CD Concepción para el on-premise y la región us-east-1 para la nube. Talca y Concepción, separados por unos 200 km en línea recta y 250 km por carretera, comparten dos amenazas: un terremoto o maremoto de zona costera y un corte de la malla eléctrica nacional. La distancia disponible dentro del área de operación de Puelche, que abarca 340 km entre sus extremos (RT-21.16), no neutraliza esa exposición. La mitiga, primero, la independencia operacional de ambos sitios, que operan 24 horas sin depender el uno del otro, Talca con generación propia y Concepción con alimentación protegida en su gabinete de borde; y, segundo, la nube, que está a unos 2.750 km de Talca en línea recta y no comparte esas amenazas. Ante un evento que afecte a los dos centros, el dato transaccional permanece en la región primaria con su RPO de 15 minutos: la bodega se detiene por la indisponibilidad física de los recintos, no por pérdida de información. La región de recuperación, a unos 7.700 km de la primaria, completa la independencia del dominio en nube (RT-07.02).

Cuando la contingencia afecta solo a la bodega de Talca, el DRP local promueve el WMS de Concepción (VM-C01) en cinco pasos, con un RTO adicional de 1 a 2 horas. La identidad no necesita conmutación en ningún escenario: su autoridad reside en la nube y las cachés locales son de solo lectura, de modo que no existe un maestro local que promover (ADR-06).

4.2.3.4.3 Operación durante una contingencia regional

Mientras la región primaria no está disponible, la bodega y el terreno siguen operando contra sus bases locales y sus dispositivos, y los servicios en nube vuelven con la promoción de la réplica. Dos capacidades quedan fuera hasta el retorno, por diseño: la analítica, porque la región secundaria no se explota analíticamente, y las consultas sobre datos de geolocalización de personas, que no se replican fuera de sa-east-1 conforme a los resguardos de residencia y transferencia internacional declarados en la arquitectura de seguridad (apartado 4.1). Ninguna de las dos es un servicio crítico, y ambas se restituyen al volver a la región primaria.

La réplica que sostiene todo lo anterior se compone de la base Aurora promovible en us-east-1, alimentada por Aurora Global Database desde la región primaria, que a su vez recibe el WMS de los sitios por AWS DMS; de las copias inmutables en ambas regiones; de la bóveda física externa; de la copia local D-05 en Talca; y del procedimiento de conmutación y retorno. Se reparte en dos dominios y cuatro ubicaciones, de modo que la pérdida de una sola no deja al dato sin copia.

4.2.3.5 RespalDOS

El respaldo protege contra lo que las réplicas replican: un dato borrado por error, corrompido o cifrado de forma maliciosa. La solución aplica un esquema 3-2-1-1-0 único para la nube y el on-premise. Mantiene tres copias —los datos activos, las instantáneas de Aurora junto con la copia local D-05, y el respaldo exportado a S3— en dos medios, base de datos y almacenamiento de objetos. Una copia está fuera del sitio, replicada a us-east-1, y otra es inmutable, en S3 Object Lock en modo Compliance con AWS Backup Vault Lock. El cero corresponde a los errores de restauración, que se verifican cada mes.

La copia inmutable es el control frente a un ataque con credenciales administrativas comprometidas: en modo Compliance, ni un administrador ni la cuenta raíz pueden borrarla ni modificarla durante su retención, y el bloqueo de la bóveda, con 3 días de enfriamiento y un año de retención mínima, impide eliminar los respaldos una vez activado (RT-07.11). La copia local D-05 cumple otra función: es la copia de recuperación rápida, cifrada con una clave independiente de la de producción, que permite restaurar el WMS en hasta 4 horas sin depender del enlace (RT-07.10), y por eso no se cuenta como la copia inmutable. Un medio físico cifrado se rota además cada semana a una bóveda externa, y se conserva en el recinto de custodia declarado en el Formulario T-11 (D10) hasta su traslado.

La Tabla 12 muestra, para cada dominio de datos, con qué frecuencia se respalda, cuánto tiempo se retiene y en cuánto tiempo se restaura por completo.

Dominio	Frecuencia	Retención	Restauración
Transaccional de bodega	Continua y copia local D-05	35 días	≤ 4 h
Transaccional en nube	Diaria y recuperación continua	35 días	≤ 4 h
Identidad	Diaria y recuperación continua	35 días	≤ 4 h
Trazabilidad sanitaria	Continua	Vida útil + 6 meses, mínimo 5 años	< 2 h
Registros de temperatura	Diaria y continua	5 años	≤ 8 h

Tabla 12 — continuación

Dominio	Frecuencia	Retención	Restauración
Evidencia de entrega	Continua con versionado	6 años	≤ 8 h
Respaldo de documentos tributarios	Continua con versionado	6 años	≤ 8 h
Geolocalización de personas	Continua	12 meses	≤ 24 h
Registros de seguridad y auditoría	Continua	7 años	≤ 24 h

Tabla 12 Respaldo y restauración por dominio de datos

Cada tiempo de restauración corresponde al plazo de resolución que el Artículo 78.2 asigna a la criticidad del servicio que usa el dato, con una excepción más exigente: la trazabilidad sanitaria se restaura en menos de 2 horas, porque ese es el plazo en que Puelche debe responder un retiro sanitario (Caso, Cap. 18). Las retenciones cumplen o superan las del caso. La restauración, además, puede ser parcial: la recuperación de Aurora a un instante específico, sobre una instancia temporal, permite restituir un registro, una tabla, un módulo o el sistema completo sin intervenir el ambiente productivo (RT-07.14).

AWS Backup materializa esas frecuencias sobre los recursos de la plataforma: respalda Aurora a diario con recuperación continua a un instante específico y DynamoDB a diario, ambos con 35 días de retención; los documentos legales en S3 de forma continua, con versionado y Object Lock durante 6 años y réplica entre regiones; y los registros de seguridad y auditoría durante 7 años bajo Object Lock.

4.2.3.6 Verificación de la continuidad

Los mecanismos anteriores se verifican con pruebas periódicas; no se dan por supuestos. Antes de cada paso a producción, y al menos una vez por semestre durante la Operación, se inyectan de forma controlada las fallas que enumera RT-10.07 —caída de una instancia, de una zona o de una dependencia externa, latencia elevada y saturación de disco— y se comprueba que cada una produzca la resolución declarada en las Tablas 14 y 15. La recuperación ante desastres se ensaya dos veces al año con conmutación real, y el RTO y el RPO efectivamente alcanzados deben cumplir el compromiso en el 100 % de los ensayos (RT-07.07, Art. 78.3). Los respaldos se restauran cada mes sobre una

muestra representativa, con medición del tiempo real de restauración (RT-07.12). Todas estas pruebas se programan fuera de la ventana de despacho y de los períodos de congelamiento, y cada una produce un informe con las desviaciones encontradas y su plan de corrección.

La aplicación se instrumenta con OpenTelemetry para PHP y Laravel, y el `transaction_id` viaja en las cabeceras HTTP, en las propiedades de los mensajes de RabbitMQ, en los atributos de los mensajes de SQS y en las llamadas a la capa anticorrupción, de modo que una misma traza une la entrega, su evidencia, la guía de despacho y el acuse del ERP. Además de las métricas de infraestructura, cada perfil publica las suyas: procesos PHP-FPM ocupados y solicitudes en espera, reinicios de contenedor, profundidad y edad del mensaje más antiguo por cola y por grupo, mensajes en las colas de fallidos, latencia de la capa anticorrupción y del ERP, y latencia de escritura de VM-02. Estas señales disparan el escalado y las alarmas declaradas en el dimensionamiento.

La disponibilidad efectiva de cada servicio, las métricas del proceso de despliegue y el resultado de estas pruebas se miden sobre la plataforma de observabilidad y se entregan en el informe mensual de nivel de servicio (Art. 79). Es ahí donde el CLIENTE puede comprobar que lo que declara esta sección se cumple.

4.2.4 Conexiones, puntos de falla y contingencia

Esta sección describe cómo se conectan los sitios, el terreno y la nube, identifica cada punto donde esa conexión o su infraestructura puede fallar, y declara cómo se resuelve cada falla o, cuando no se resuelve de forma automática, cuál es la contingencia. Su punto de partida es el caso: la conectividad actual de Puelche se corta con frecuencia y en algunos lugares no existe (Caso, Cap. 6), por lo que la solución no puede suponer un enlace disponible y debe decir, para cada conexión, qué pasa cuando no lo está.

4.2.4.1 Conexiones entre sitios, terreno y nube

Los dos dominios fijos, la nube y el on-premise, se conectan por túneles VPN IPsec que terminan en el firewall de cada sitio (D-01) y en el Transit Gateway de AWS en sa-east-1, con enrutamiento dinámico BGP; el mismo Transit Gateway enruta entre los sitios, de modo que Concepción y los cross-docking alcanzan Talca sin exponerla a Internet. Cada sitio tiene dos caminos físicamente independientes: fibra y LTE en los centros de distribución, y Starlink y LTE de dos proveedores en los cross-docking, que no tienen fibra (ADR-02). El terreno no pasa por los sitios: los terminales de preventa

y de reparto hablan directamente con API Gateway por la red celular del operador. La Figura 2 muestra esas conexiones.




Figura 2 Conexiones entre los sitios, el terreno y la nube

La figura distingue dos tipos de conexión. Las líneas continuas son conexiones hacia la nube, y todas se inician desde el sitio o desde el dispositivo, sin puertos abiertos hacia el on-premise. Las únicas excepciones son la réplica de AWS DMS, que lee el registro de escritura de PostgreSQL en VM-02, y el trabajador Laravel exp-sync, que consulta la capa anticorrupción en VM-04; ambas entran por el túnel IPsec autenticado y quedan auditadas. Las líneas discontinuas son sincronizaciones entre sitios o descargas locales, que no dependen de la nube: Concepción sincroniza con Talca por la VPN, los cross-docking envían a Talca el detalle de su WMS entre brokers por la VPN, y los termógrafos sincronizan por Bluetooth con el terminal del conductor durante la ruta —que alerta la excursión térmica en el momento y la reenvía a la nube cuando recupera cobertura— y, cuando el camión vuelve, le descargan el registro completo, que el terminal envía a la nube. Los eventos críticos de los cross-docking van directo a SQS FIFO, de modo que la operación de esas plataformas no depende de Talca.

La Tabla 13 resume cada conexión con su medio, su camino alternativo y el tiempo de conmutación entre ambos.

Conexión	Medio y protocolo	Camino alternativo	Conmutación
CD Talca con la nube	Fibra D-03, túneles IPsec con BGP	LTE D-04	Menos de 30 s
CD Concepción con la nube	Fibra D-03, túneles IPsec con BGP	LTE D-04	Menos de 30 s
Cross-docking con la nube	Starlink D-06, túneles IPsec con BGP	LTE D-04 de dos proveedores	Menos de 30 s
Concepción con Talca	TCP 8080 y 5432 con TLS sobre la VPN	Operación autónoma	No aplica
Cross-docking con Talca	AMQPS 5671 entre brokers, por la VPN	Envío diferido	No aplica
Terreno con la nube	Red celular del operador, HTTPS	Almacén local del dispositivo	No aplica
Termógrafos con el terminal del conductor	BLE con el terminal del conductor, en ruta y al regresar	Registro interno del termógrafo	No aplica
Usuarios externos con los portales	Internet, HTTPS por CloudFront	Ninguno: el autoservicio requiere conexión	No aplica
Región primaria con la secundaria	Replicación nativa de Aurora, DynamoDB y S3	Respaldo inmutable	Promoción autorizada

Tabla 13 Conexiones de la solución y su camino alternativo

Solo tres conexiones tienen un segundo camino de red, y son las que unen un sitio con la nube. Las demás no lo necesitan porque su alternativa no es otro enlace sino la operación sin conexión: Concepción opera sin Talca, el terreno opera sin señal y el termógrafo guarda su propio registro. Por eso la redundancia de enlaces reduce la frecuencia de las desconexiones, pero no es condición para operar. El portal de clientes es la única conexión sin alternativa, y eso es deliberado: el autoservicio no se ofrece sin conexión (RT-03.13).

4.2.4.2 Puntos de falla en los sitios y en los enlaces

Cada conexión se apoya en equipos del sitio que también pueden fallar. La Tabla 14 recorre esos puntos de falla, desde el enlace hasta la energía del recinto, e indica para cada uno el mecanismo que la resuelve y la contingencia si ese mecanismo no basta.

Punto de falla	Resolución	Contingencia
Fibra de un centro de distribución	BGP conmuta los túneles al LTE en menos de 30 s.	Si cae también el LTE, operación local 24 h.
Starlink de un cross-docking	El LTE de dos proveedores toma el tráfico en menos de 30 s.	La ventana de 3 h opera 100 % local y sincroniza al reconectar.
Enlace de Los Ángeles en la madrugada	Starlink queda como camino único, porque la red móvil falla a esa hora.	La ventana de madrugada opera íntegramente local.
Firewall de Talca	La unidad pasiva asume las direcciones y los túneles en menos de 30 s.	Operación local 24 h sin enlace.
Firewall de Concepción	Equipo único; se repone.	Concepción opera 24 h sin enlace mientras se reemplaza.
Nodo del clúster de Talca	Las VM se reinician en los nodos restantes, con sus datos replicados por Ceph.	Ante un segundo nodo, el DRP local promueve el WMS de Concepción en 1 a 2 h.
Instancia de escritura VM-02	Se reinicia en otro nodo del clúster.	D-05 restaura la base en hasta 4 h sin enlace.
Disco de un nodo de Talca	El RAID 10 reconstruye sobre el repuesto en caliente.	Ceph conserva una segunda copia en otro nodo.
Miembro del stack de switches de Talca	El otro miembro mantiene el tráfico.	Reposición sin corte.
Servidor de borde de Concepción	El RAID 10 tolera la falla de un disco; el equipo tiene fuente única y, ante su falla, se repone.	La pila se restaura desde la réplica en Aurora.
Mini-PC de un cross-docking	Equipo único; se repone.	El nuevo equipo se resincroniza desde Talca y SQS FIFO.

Tabla 14 — continuación

Punto de falla	Resolución	Contingencia
Firewall de un cross-docking	Equipo único; se repone.	La ventana de 3 h opera 100 % local y sincroniza al reconectar.
Periféricos de andén	Sin redundancia por equipo.	La etiqueta se emite en otra de las impresoras del centro de distribución.
Energía de la sala de Talca	UPS N+1 de 30 min y generador que toma carga en 8 a 15 s.	Estanque de 24 h y contrato de reabastecimiento.
Climatización de la sala de Talca	Segunda unidad de precisión en N+1.	Alerta del monitoreo de los sensores ambientales.

Tabla 14 Puntos de falla en los sitios y en los enlaces

La tabla muestra que los puntos únicos de falla que quedan están donde la redundancia no compensa su costo: el firewall y el servidor de Concepción, el firewall y el mini-PC de cada cross-docking y los periféricos de andén. En los cuatro primeros casos la contingencia es la misma autonomía que ya existe para los cortes de enlace. El firewall y el servidor de Concepción y el firewall, el mini-PC y el switch de cada cross-docking operan, además, con fuente única; la excepción a RT-08.04 se declara con el mismo fundamento (RT-02.11). En la ruta de la ventana de despacho de Talca quedan dos elementos sin duplicar: la instancia de escritura VM-02, que se reinicia en otro nodo del clúster, y cada impresora de andén, cuya etiqueta puede emitir otra de las impresoras del centro de distribución; el resto de esa ruta tiene redundancia en cada capa. Los mecanismos de alta disponibilidad que sostienen estas resoluciones se desarrollan en la sección de arquitectura de despliegue.

4.2.4.3 Puntos de falla en la nube, el terreno y las integraciones

La Tabla 15 completa el recorrido con los puntos de falla que están fuera de los sitios: la nube, el terreno y los sistemas de terceros.

Punto de falla	Resolución	Contingencia
Zona de disponibilidad de sa-east-1	Aurora conmuta en menos de 30 s, ElastiCache en menos de 60 s y Fargate reprograma las tareas.	La operación continúa en las zonas restantes.
Región sa-east-1 completa	Route 53 redirige el tráfico y, con autorización del CLIENTE, se promueve la réplica en us-east-1.	RTO de 4 h y RPO de 15 min; la bodega y el terreno operan en local, y los terminales de bodega trabajan contra la puerta de API local del WMS.
Túnel VPN durante la replicación	DMS encola los cambios en el origen.	Reanuda sin pérdida al reconectar; la réplica queda desactualizada durante el corte.
IdP maestro o enlace de identidad	La caché de solo lectura, de 24 h, conserva los datos de identidad recibidos, y el verificador local habilita los relevos de turno con el manifiesto firmado y el PIN personal.	La credencial de turno dura hasta 8 h en bodega y 14 h en terreno; no hay revocación remota mientras dure el corte; cuenta de emergencia sellada (ADR-06, ADR-15).
Señal móvil en ruta	La aplicación opera contra el almacén local del dispositivo.	Sincroniza al reconectar dentro de los 10 min de la Tabla 3.
ERP legado	El trabajador <code>erp-sync</code> retiene las operaciones en su cola SQS hasta 24 h y reintenta con la misma clave idempotente, de modo que un reintento no emite otro documento.	El camión no se libera sin guía confirmada o contingencia tributaria aprobada por el CLIENTE.
Perfil de API saturado	El balanceador reparte entre tareas y el escalado agrega tareas cuando los procesos PHP-FPM ocupados superan el 70 %.	Limitación de tasa en API Gateway con mensaje explícito al usuario (RT-09.08).
Mensaje de reconciliación inválido o que falla	El consumidor rechaza el sobre de versión desconocida sin aplicarlo; tras cinco intentos pasa a la cola de mensajes fallidos.	Alarma inmediata y reproceso manual trazable; el grupo afectado no bloquea a los demás.
Excursión térmica sin enlace	El gateway bloquea el despacho en menos de 5 s en el borde.	Buffer de 24 h y alerta al reconectar.

Tabla 15 — continuación

Punto de falla	Resolución	Contingencia
SII, cadenas o notificaciones	Reintento con espera creciente y cola de mensajes fallidos.	Reproceso desde la cola al recuperarse el tercero.
Carga del peak de septiembre	Escalado automático e independiente de los perfiles de API y de trabajadores en Fargate, y de Aurora (ADR-12).	Limitación de tasa en API Gateway.

Tabla 15 Puntos de falla en la nube, el terreno y las integraciones

Ninguna de estas fallas detiene la bodega ni el terreno. La peor de ellas, la pérdida de toda la región primaria, deja sin servicio a los portales y a la analítica hasta la promoción de la réplica, pero la preparación, el despacho y la entrega siguen operando contra sus bases locales y sus dispositivos, porque ninguna de esas transacciones depende de la nube para confirmarse.

4.2.5 Dimensionamiento y plan de capacidad

Esta sección deriva la capacidad de la solución desde la volumetría del caso, declara las dieciséis dimensiones que el numeral 14.2 pide estimar, dimensiona el cómputo, el almacenamiento y los enlaces en ambos dominios, y fija el plan para crecer tres veces sin rediseño. El caso advierte que un dimensionamiento basado en el promedio diario estará equivocado, porque la carga no es plana (Caso, Cap. 14.2). Por eso cada valor se calcula sobre la ventana en que ocurre, y cuando se adopta un supuesto se declara junto a su fundamento.

4.2.5.1 Criterios y método

El perfil de un día hábil concentra la carga en cuatro ventanas que no coinciden entre sí (Caso, Cap. B.1):

- **Preparación de pedidos:** de 22:00 a 06:00 en Talca, con 120 terminales de cámara

en simultáneo.

- **Despacho:** de 05:30 a 07:00, con la salida de 96 camiones, 42 propios y 54 de transportistas.
- **Preventa:** de 09:00 a 18:00, con 62 preventistas y unas 2.600 visitas diarias.
- **Sincronización de la flota:** de 17:00 a 20:00, al regreso de los dispositivos de terreno.

Sobre ese perfil, el dimensionamiento sigue cinco reglas. La carga de diseño es el peak de septiembre multiplicado por 1,5, es decir $2.600 \times 1,5 = 3.900$ entregas diarias toleradas sin degradación (RNF-19.04). La solución debe soportar tres veces la volumetría inicial sin rediseño (RT-09.03). Toda medición de desempeño se expresa en percentil 95. El cómputo en nube escala de forma automática y se paga por uso (ADR-12), mientras que el on-premise se dimensiona al margen útil, sin sobrecompra. Y los totales de esta sección son los mismos que usan los registros de decisión ADR-01, ADR-04, ADR-10 y ADR-12.

4.2.5.2 Volumetría de referencia

La Tabla 16 reúne los valores que entrega el CLIENTE y que sirven de base a todos los cálculos de esta sección.

Magnitud	Valor base
Clientes activos y puntos de entrega	14.200
Pedidos	31.000 al mes
Líneas de pedido y de preparación	260.000 al mes
Unidades despachadas	2,4 millones al mes
SKU activos	8.400
Posiciones de almacén en Talca	11.400, con 87 % de ocupación
Entregas en día hábil normal	1.400
Entregas en día hábil de peak de septiembre	2.600
Kilómetros recorridos	420.000 al mes
Documentos tributarios	34.000 al mes

Tabla 16 — continuación

Magnitud	Valor base
Camiones con equipo de frío	28: 18 propios y 10 de transportistas
Puntos de medición de temperatura	28, en 7 módulos de 4 canales
Instalaciones	6, de las cuales 5 alojan cómputo

Tabla 16 Valores base de dimensionamiento

De estos valores, el que gobierna el dimensionamiento no es el número de clientes sino la relación entre el día normal y el peak: 2.600 entregas frente a 1.400 son 1,86 veces más carga durante las tres primeras semanas de septiembre. El dimensionamiento del on-premise se calcula sobre los cinco recintos que alojan cómputo (RT-06.01): los centros de distribución de Talca y Concepción y las tres plataformas de cross-docking de Curicó, Chillán y Los Ángeles. La sexta instalación es la casa matriz de Talca, contigua al centro de distribución principal (Caso, Cap. 2.3), que aloja oficinas y no requiere cómputo propio.

La Tabla 17 muestra la proyección del caso a tres años.

Magnitud	Año 0	Año 3	Variación
Clientes	14.200	15.500	+9 %
Pedidos al mes	31.000	36.000	+16 %
Líneas al mes	260.000	305.000	+17 %
Entregas en día normal	1.400	1.650	+18 %
Entregas en día de peak	2.600	3.100	+19 %
Kilómetros al mes	420.000	480.000	+14 %
Documentos tributarios al mes	34.000	40.000	+18 %
Instalaciones	6	7	+1

Tabla 17 Proyección de la volumetría a tres años

El crecimiento real que proyecta el caso es de 16 % a 19 % en tres años, muy por debajo del factor 3 que exige RT-09.03. El dimensionamiento que sigue cubre ese factor 3, de modo que la solución tiene margen ante un crecimiento mayor al proyectado.

4.2.5.3 Transacciones por segundo

La preparación nocturna mueve 260.000 líneas al mes; en 25 días hábiles son 10.400 líneas por noche, que en las 8 horas del turno (28.800 s) dan una demanda media de 0,36 líneas por segundo. El diseño no se hace sobre esa media sino sobre la concurrencia máxima: 120 terminales confirmando una línea cada 6 segundos son 20 transacciones por segundo, 55 veces la demanda media, lo que absorbe el inicio del turno, cuando todos los preparadores confirman a la vez, y el conteo cíclico que comparte la ventana. Con el mismo criterio, 62 preventistas registrando una línea cada 8 segundos son 8 transacciones por segundo. La Tabla 18 suma esos flujos.

Flujo	Cálculo	TPS
Confirmación de preparación	120 terminales × 1 confirmación cada 6 s	20
Registro de preventa	62 preventistas × 1 línea cada 8 s	8
Movimientos, sincronización y telemetría	Supuesto que cubre el vuelco de los brokers y los 76.600 mensajes diarios de telemetría	7
Régimen normal	20 + 8 + 7	35
Diseño en peak de septiembre	35 × 3	105

Tabla 18 Transacciones por segundo de diseño

El factor 3 del peak no es arbitrario: combina el aumento estacional de 1,86 veces con el margen de 1,5 de la carga de diseño, lo que da 2,8, redondeado a 3. Los 105 transacciones por segundo resultantes son el valor único de diseño de esta sección, el mismo que citan el ADR-01 y el ADR-12, y sostienen el dimensionamiento de la base transaccional y el escalado del cómputo en nube.

La ventana de despacho, en cambio, no es la de mayor carga. En ella ocurren 1.400 confirmaciones de carga, 1.400 verificaciones de que la guía ya fue emitida por el ERP durante la preparación, 96 vinculaciones de conductor con camión y 96 cierres de ruta, en total 2.992 transacciones; aun concentradas en la primera media hora (1.800 s), son

1,7 transacciones por segundo. La ventana es crítica porque no admite indisponibilidad, no por su volumen: el cómputo se dimensiona por la preparación nocturna y el peak de septiembre, y la resiliencia por la ventana de despacho.

4.2.5.4 Usuarios, concurrencia y dispositivos

Las personas usuarias internas son unas 620: 62 preventistas, 42 conductores propios, cerca de 160 conductores de terceros, 310 personas de centro de distribución, unas 40 de administración y gerencia, y 4 de TI. Las externas son unas 14.400 al cierre de la Etapa 2: 14.200 clientes con autoatención, 180 proveedores y 10 empresas transportistas. La Tabla 19 detalla la concurrencia por rol.

Rol	Concurrencia	Dispositivo
Preventistas	62	Zebra EC55, parque de 62 más 20 % de reserva
Conductores	≈ 200	Zebra TC58e, parque único para propios y externos
Preparadores del turno nocturno	120	Zebra MC9400 Cold Storage, 144 en Talca y 30 en Concepción
Personal de centro de distribución	110	Estaciones y terminales fijos
Supervisión y mesa de ayuda	≈ 20	Estaciones de trabajo
Dispositivos de terreno registrados	≈ 270, hasta 300	EC55 y TC58e

Tabla 19 Usuarios y terminales concurrentes

La suma de los perfiles da unas 510 personas concurrentes: 62 + 200 + 120 + 110 + 20. Es una cota superior, porque la preventa y la preparación nocturna no coinciden en el tiempo. Los dispositivos de terreno en operación simultánea son los 62 de preventa y los cerca de 200 de reparto, unos 270; con la proyección a tres años, 70 preventistas y 230 conductores, llegan a 300.

4.2.5.5 Almacenamiento y datos a migrar

El almacenamiento se calcula por tipo de dato, porque cada uno tiene su propio ritmo y su propia retención.

- **Transaccional:** se estima en 375 GB por año entre el maestro de bodega y el transaccional en nube. A cinco años suma cerca de 1,9 TB, del mismo orden que los 1.890 GB asignados al clúster de Talca.
- **Evidencia de entrega:** 1.400 entregas diarias en 300 días hábiles son 420.000 entregas al año. Con una firma de 30 KB y una o dos fotografías de 200 KB, cada entrega ocupa unos 230 KB, lo que da $420.000 \times 230 \text{ KB} \approx 97 \text{ GB}$, unos 100 GB al año. Con la retención de 6 años suman unos 600 GB, en almacenamiento por niveles.
- **Series de temperatura y de posicionamiento:** 56 fuentes de temperatura, 28 puntos de cámara y 28 termógrafos, con una muestra cada 5 minutos, generan 5,89 millones de registros al año; 42 camiones con una posición cada 30 segundos durante 12 horas y 300 días generan 18,1 millones. Con unos 145 bytes por registro, los 24 millones suman 3,5 GB en crudo al año, que en formato columnar comprimido quedan en unos 0,9 GB. El crudo vive 30 días; la serie consolidada se conserva 5 años para temperatura y 12 meses para geolocalización de personas.
- **Datos históricos a migrar:** unos 30 GB estructurados. Solo las ventas y pedidos de tres años son 9,4 millones de líneas de 1 KB, 9,4 GB, y los movimientos de inventario de dos años son 3,4 millones de registros de 0,5 KB, 1,7 GB; el resto corresponde a los maestros, a cinco años de trazabilidad sanitaria y a las cuentas por cobrar vivas. El histórico documental permanece en el ERP, que sigue siendo la fuente tributaria.

El dato que más crece no es el transaccional sino la evidencia de entrega, y por eso se guarda en almacenamiento de objetos por niveles y no en la base de datos. Las series de tiempo, que dominan el número de registros, tampoco pasan por la base transaccional: se ingieren en DynamoDB y se consolidan en la capa analítica.

4.2.5.6 Integraciones y volumen de mensajes

La solución tiene 15 integraciones. La Tabla 20 deriva el volumen de las diez que mueven mensajes, sobre 25 días hábiles al mes y con el peak de septiembre al doble en los flujos que siguen a los pedidos y a las entregas; la telemetría depende del número de fuentes y de las horas de ruta, no del volumen de entregas.

Integración	Mensajes al día	Peak	Derivación
ERP por la capa anticorrupción	4.700	9.400	1.240 pedidos, 46 recepciones, 1.400 preparaciones, 1.400 entregas y 600 recaudaciones
Documentos tributarios y acuse	2.700	5.400	34.000 documentos al mes y su acuse, en 25 días
Trazabilidad GS1 EPCIS	52.000	104.000	260.000 líneas al mes × 5 eventos, en 25 días
Telemetría de cadena de frío	16.100	16.100	56 fuentes × 288 muestras diarias
Telemetría de flota	60.500	72.000	42 camiones × 120 posiciones por hora × 12 h
Sincronización de terreno	13.000	26.000	1.240 pedidos, 1.400 entregas y 10.400 confirmaciones
Intercambio con el canal moderno	550	1.100	136 pedidos diarios × 4 mensajes
Notificaciones	2.800	5.600	Hora estimada de llegada y acuse por entrega
Autorización de pago	500	1.000	Fracción del canal tradicional que migra a pago electrónico
Mapas y geocodificación	200	400	Una corrida de ruteo por zona y recálculos por incidencia

Tabla 20 Volumen de mensajes por integración

El total en régimen es de unos 153.000 mensajes al día. Dos series de tiempo, la trazabilidad y la telemetría, aportan unos 129.000 de ellos, y ninguna atraviesa la base transaccional. Las cinco integraciones restantes del catálogo son de configuración y administración, con volumen despreciable frente a estas cifras.

4.2.5.7 Ancho de banda, dispositivos de reparto y sincronización

El enlace de cada centro de distribución transporta la replicación de la base, el vuelco de los brokers, la telemetría y el respaldo hacia la nube. No transporta la sincronización del terreno, que viaja por la red celular directo a la nube. La Tabla 21 declara el ancho de banda por sitio.

Sitio	Régimen	Peak	Respaldo
CD Talca	20 Mbps por fibra	50 Mbps	LTE de 5 a 10 Mbps
CD Concepción	10 Mbps por fibra	20 Mbps	LTE de 3 a 5 Mbps
Cross-docking, cada uno	Hasta 2 Mbps por Starlink, plan de 500 GB al mes	Hasta 5 Mbps	LTE de 2 a 5 Mbps, dos proveedores

Tabla 21 Ancho de banda por sitio

El peak lo fija el respaldo. El respaldo semanal a la nube pesa hoy unos 40 GB y llega a 120 GB con el crecimiento de 3 veces; transmitido en la ventana nocturna de 8 horas exige $120\text{ GB} \times 8 / 28.800\text{ s} \approx 33\text{ Mbps}$, que caben en los 50 Mbps de Talca junto con el tráfico de régimen. La replicación y los brokers, en cambio, son pequeños: aun atribuyendo a un solo sitio el volumen transaccional anual completo, duplicado por el peak, suman unos 2,1 GB al día, 0,2 Mbps en promedio. Por eso el régimen de 20 Mbps deja holgura para las consolas web del personal del sitio, y el LTE de respaldo alcanza para la replicación y los brokers, aunque no para el respaldo semanal, que se difiere hasta que vuelve la fibra. En los cross-docking la demanda queda acotada por su respaldo: como el LTE de 2 a 5 Mbps debe sostener la ventana de 3 horas cuando cae Starlink (Tabla 14), el tráfico de régimen se fija en hasta 2 Mbps y el de peak en hasta 5 Mbps; los 500 GB del plan son el volumen mensual contratado, no el ancho de banda.

Un dispositivo de reparto genera entre 8 y 12 MB en un turno sin señal. En el peak, 2.600 entregas repartidas en 96 camiones son unas 27 por ruta, que se redondean a 30; con 230 KB de evidencia cada una suman 6,9 MB, a los que se agregan la ruta del día, el maestro acotado de productos y precios y la cola de escrituras pendientes. Al recuperar cobertura, 10 MB se sincronizan en $10 \times 8 / 0,2 = 400\text{ s}$, menos de 7 minutos, aun con apenas 0,2 Mbps efectivos de red celular, lo que sostiene el objetivo de 10 minutos por dispositivo de la Tabla 3. La flota completa, unos 200 dispositivos de 10 MB, suma 2 GB

en la ventana de 17:00 a 20:00, apenas 1,5 Mbps agregados en la entrada de la nube.

4.2.5.8 Mesa de ayuda y equipo de operación

Con 620 personas usuarias internas y un contacto mensual por persona en operación estabilizada, la mesa recibe unos 620 contactos al mes; durante las oleadas de puesta en producción el factor sube a 2,5, unos 1.550 contactos, y en el peak de septiembre aumenta 40 %. Los clientes del canal tradicional no entran por esta mesa: se atienden por autoatención. Los 620 contactos en 25 días hábiles son unos 25 al día; si el 20 % se concentra en la hora punta, son unos 5 contactos por hora, que con 8 minutos de atención suman $5 \times 8 / 60 = 0,67$ Erlang. Con el modelo Erlang C, dos agentes cumplen el objetivo de atender el 80 % de los contactos en 20 segundos. A esa base se suman la cobertura de la ventana de despacho y del turno nocturno de bodega, el segundo nivel y la supervisión, lo que da una mesa de 7 personas: 3 agentes diurnos, 1 nocturno, 1 supervisor y 2 especialistas de segundo nivel. Los parámetros se recalibran con los datos de la operación real. El NOC, al que se integran el monitoreo de la sala de Talca y el de los gabinetes de borde, y la confiabilidad se prestan como servicio gestionado.

4.2.5.9 Síntesis de las dieciséis dimensiones

La Tabla 22 reúne el valor declarado para cada dimensión del numeral 14.2 del caso, con la subsección donde se deriva.

Dimensión	Valor declarado	Derivación
TPS en régimen normal	35	Transacciones por segundo
TPS en la ventana de despacho	1,7	Transacciones por segundo
TPS en el peak de septiembre	105	Transacciones por segundo
Personas usuarias registradas	620 internas y 14.400 externas	Usuarios y concurrencia
Personas usuarias concurrentes en peak	510 como cota superior	Usuarios y concurrencia

Tabla 22 — continuación

Dimensión	Valor declarado	Derivación
Dispositivos de terreno simultáneos	270, hasta 300	Usuarios y concurrencia
Almacenamiento transaccional anual	375 GB	Almacenamiento
Evidencia de entrega anual	100 GB	Almacenamiento
Series de temperatura y posición anuales	3,5 GB en crudo y 0,9 GB consolidados	Almacenamiento
Datos históricos a migrar	30 GB	Almacenamiento
Integraciones y mensajes	15 integraciones y 153.000 mensajes al día	Integraciones
Ancho de banda por sitio	Talca 20 a 50 Mbps, Concepción 10 a 20 Mbps y cada cross-docking hasta 2 a 5 Mbps	Ancho de banda
Datos de un dispositivo de reparto por turno	8 a 12 MB	Ancho de banda
Sincronización de la flota	10 min por dispositivo	Ancho de banda
Contactos mensuales a la mesa	620 en régimen y 1.550 en marcha blanca	Mesa de ayuda
Dotación de la mesa	7 personas	Mesa de ayuda

Tabla 22 Las dieciséis dimensiones del numeral 14.2 del caso

Ninguna dimensión queda sin valor ni sin derivación. Las que exigieron un supuesto propio, como el ritmo máximo de confirmación, el tamaño de la evidencia o el volumen transaccional anual, lo declaran en su subsección, de modo que el CLIENTE puede recalcular el resultado si el supuesto cambia.

4.2.5.10 Dimensionamiento on -premise

El clúster de Talca tiene tres nodos iguales, de modo que la pérdida de cualquiera deja dos supervivientes capaces de sostener todas las máquinas virtuales (N+1). La Tabla 23 compara lo asignado con lo que queda disponible tras perder un nodo.

Recurso	Asignado	Físico en el clúster	Utilización N+1
vCPU	30	192 hilos, 3 nodos de 64	30 de 128, 23 %
Memoria	68 GB	384 GB, 3 nodos de 128	68 de 256, 27 %
Almacenamiento Ceph	1.890 GB	5,76 TB útiles	1.890 de 3.840 GB, 49 %

Tabla 23 Utilización del clúster de Talca con un nodo caído

Con un nodo caído, el clúster todavía usa menos de un cuarto de su cómputo, poco más de un cuarto de su memoria y la mitad de su almacenamiento. Cada nodo es un servidor de rack de 2U con dos procesadores de 16 núcleos, 64 hilos en total (Formulario T- 11, C1). La capacidad de almacenamiento resulta de tres nodos con cuatro discos NVMe de 1,92 TB en RAID 10, 3,84 TB por nodo, y de la réplica 2 de Ceph: $3 \times 3,84 / 2 = 5,76$ TB, que con un nodo caído baja a $2 \times 3,84 / 2 = 3,84$ TB. La Tabla 24 muestra cómo se reparten los recursos asignados entre las seis máquinas virtuales.

VM	Rol	vCPU	Memoria	Disco
VM-01	Motor WMS	8	16 GB	100 GB
VM-02	Base transaccional del WMS	8	32 GB	1.500 GB
VM-03	Broker de colas y shipper	4	8 GB	200 GB
VM-04	Capa anticorrupción del ERP	4	4 GB	20 GB
VM-05	Caché de identidad y verificador local	4	4 GB	20 GB
VM-06	Colector de observabilidad y agente SSM	2	4 GB	50 GB

Tabla 24 Máquinas virtuales del clúster de Talca

VM-02 concentra casi la mitad de la memoria y el 80 % del disco, porque es el único punto de escritura del maestro de bodega; es también el primer cuello de botella, como se explica más adelante. El servidor de borde de Concepción, un Dell PowerEdge R250 con Xeon E-2300 o un HPE ProLiant DL20 Gen11 con Xeon E-2400, con 32 GB de memoria, RAID 10 sobre sus cuatro bahías, sin repuesto en caliente, y fuente única, se dimensiona a su propia bodega, de la mitad de tamaño que Talca y sin congelado, sin sobrecompra. Ante una contingencia que afecte solo a Talca, el DRP local promueve el motor de almacenes de Concepción, que ya opera todos los días, con un RTO adicional de 1 a 2 horas.

Concepción se dimensiona por su carga real y no como copia de Talca. Sus 30 terminales de cámara, confirmando una línea cada 6 segundos, generan 5 transacciones por segundo, un cuarto de las 20 de Talca (Tabla 18); por eso el cómputo y la memoria de cada máquina virtual se fijan en un cuarto de los de su par en Talca, con un mínimo de 2 vCPU y 2 GB por máquina, y el disco en la mitad, porque su bodega tiene la mitad de la superficie. La Tabla 25 muestra el resultado; los supuestos se declaran para que el CLIENTE pueda recalcularlo. En cada cross-docking, el mini-PC industrial ejecuta el WMS, su base y su broker en contenedores, detrás del firewall compacto que termina Starlink, el LTE de respaldo y la VPN.

VM	Rol	vCPU	Memoria	Disco
VM-C01	Motor WMS	2	4 GB	50 GB
VM-C02	Base transaccional del WMS	2	8 GB	750 GB
VM-C03	Caché de identidad y verificador local	2	2 GB	10 GB
VM-C04	Broker de colas, shipper y colector de observabilidad	2	3 GB	125 GB
Total		8	17 GB	935 GB

Tabla 25 Máquinas virtuales del servidor de Concepción

El servidor de Concepción, con un procesador de 8 núcleos y 16 hilos (Xeon E-2378 en el R250 o E-2478 en el DL20 Gen11), queda con 8 de 16 hilos (50 %) y 17 de 32 GB (53 %), lo que deja memoria para el hipervisor. Su RAID 10 de cuatro discos SSD de 1,92 TB entrega 3,84 TB útiles, ocupados al 24 %. Con el crecimiento de 3 veces, la memoria se amplía hasta 128 GB, el máximo del mismo equipo (51 GB, 40 %) y el disco llega al 73 %; el cómputo pasa a 24 vCPU sobre 16 hilos, una sobresuscripción de

1,5 que se acepta porque la carga resultante, 15 transacciones por segundo, sigue por debajo de las 20 que hoy atiende Talca con 16 vCPU entre el motor WMS y la base.

La Tabla 26 verifica el almacenamiento y el rendimiento de la base transaccional.

Aspecto	Cálculo	Resultado
Ocupación inicial del pool	1.890 GB de 5.760 GB	33 %
Ocupación con crecimiento de 3 veces	$1.890 \text{ GB} \times 3 = 5.670 \text{ GB}$	Requiere ampliar los discos
Pool con 8 NVMe por nodo	$3 \times 7,68 \text{ TB} / 2 = 11,52 \text{ TB}$	49 %; 74 % con un nodo caído
Respaldo local D-05	NAS en RAID 6 con 4 discos de 4 TB	8 TB útiles
Operaciones de disco de VM-02	$105 \text{ TPS} \times 8 \text{ operaciones por transacción}$	840 IOPS frente a más de 100.000

Tabla 26 Almacenamiento y rendimiento de la base transaccional

El almacenamiento no es el límite del clúster en régimen, pero sí con el crecimiento de 3 veces: 5.670 GB llenarían el 98 % del pool de tres nodos, por encima del umbral en que Ceph deja de aceptar escrituras con seguridad. La ampliación se hace dentro de los mismos nodos: pasar de cuatro a ocho discos NVMe de 1,92 TB por nodo eleva el pool a 11,52 TB y deja la ocupación en 49 %, y en 74 % con un nodo caído. En rendimiento de disco la holgura es de dos órdenes de magnitud.

4.2.5.11 Perfiles PHP, conexiones y colas

El dimensionamiento de la aplicación parte de dónde ocurre cada transacción. De los 35 TPS del régimen normal (Tabla 18), las 20 confirmaciones de preparación se atienden en el perfil `wms_only` del sitio y no llegan a la nube; a la nube llegan la preventa y la sincronización, $8 + 7 = 15 \text{ TPS}$, que con el factor 3 del peak son 45 TPS. El cálculo usa dos supuestos que deben confirmarse en la prueba de carga: una solicitud consume en promedio 50 ms de CPU y permanece 150 ms en su proceso PHP-FPM, incluida la espera de la base. Con ellos, una tarea de 1 vCPU y 2 GB atiende $1 / 0,05 = 20$ solicitudes por segundo, y 14 al 70 % de utilización que se fija como objetivo.

- **Perfil de API:** el peak exige $45 / 14 = 3,2$ tareas, es decir 4, y el régimen normal $15 / 14 = 1,1$, que sube a 2 porque el mínimo es una tarea por zona de disponibilidad. El techo se fija en 8 tareas, 112 solicitudes por segundo, que cubren la prueba de carga de 1,5 veces el peak (68 solicitudes por segundo en la nube) y dejan margen. En cada tarea hay en promedio $14 \times 0,15 = 2,1$ solicitudes simultáneas, por lo que 16 procesos PHP-FPM bastan con holgura para las ráfagas; con unos 64 MB por proceso ocupan 1 GB, y el resto de la memoria queda para OPcache y el servidor web.
- **Perfil wms_only:** en Talca, el peak de 60 TPS consume $60 \times 0,05 = 3$ vCPU de las 8 de VM-01, un 38 %, con $60 \times 0,15 = 9$ solicitudes simultáneas; se fijan 32 procesos PHP-FPM, que ocupan 2 GB de sus 16 GB. En Concepción, 15 TPS consumen 0,75 de sus 2 vCPU, también un 38 %, con 12 procesos.
- **Conexiones a PostgreSQL:** cada proceso abre a lo más una conexión. En la nube, el techo suma $8 \times 16 = 128$ conexiones de la API, 16 del consumidor de reconciliación, 16 de los trabajos y una del planificador, además del grupo propio de Keycloak; el total queda muy por debajo del límite por defecto de Aurora en db.r6g.large, que ronda las 1.800 conexiones. En VM-02, los 32 procesos del WMS, el shipper y el slot de DMS suman menos de 50 frente a las 100 que admite PostgreSQL por defecto; si la prueba de carga lo exigiera, el gestor de conexiones previsto en la mitigación del primer cuello de botella se adelanta.
- **Broker local:** un corte de 24 horas en el peak acumula, como cota, 30.000 sobres por centro de distribución —las 19.400 confirmaciones de una noche de septiembre ($10.400 \times 1,86$) más recepciones, movimientos y bloqueos—, unos 60 MB a 2 KB por sobre, frente a los 200 GB de disco de VM-03. Las colas son durables, los mensajes persistentes y la publicación se confirma antes de retirar el mensaje del terminal.
- **Cola FIFO de reconciliación:** al reconectar, el shipper publica en lotes de 10; con 100 ms por llamada son 100 sobres por segundo, y los 30.000 salen en unos 5 minutos. El orden se garantiza dentro de cada grupo, formado por el sitio y el agregado de negocio (ubicación, pedido o lote), de modo que grupos distintos se aplican en paralelo. Con 50 ms por sobre y 8 procesos de consumo, el drenaje toma unos 3 minutos; aun si todo cayera en un solo grupo, a 20 sobres por segundo tomaría 25 minutos. Ambos casos quedan dentro de las 2 horas comprometidas para resincronizar un centro de distribución. La cola usa como identificador de deduplicación el del evento, una visibilidad de 60 segundos, mayor que el tiempo máximo de aplicación de un sobre, cinco intentos antes de pasar a la cola de mensajes fallidos y una retención de 4 días, que excede el corte más largo previsto.
- **Trabajador exp-sync:** en el peak se emiten 2.600 guías entre el cierre de la carga y la salida, unas 7,5 horas o 27.000 segundos, es decir 0,1 guías por segundo. Si el ERP

tarda hasta 5 segundos por guía, basta medio proceso ocupado; se fijan 2 procesos y no más, porque el ERP de 2017 no escala y más concurrencia solo lo saturaría.

Estos valores son estimaciones con supuestos declarados, no mediciones. Su aceptación depende de la prueba de carga de la Tabla 30, que debe medir el consumo real por solicitud de cada perfil, el tiempo de aplicación de un sobre, el drenaje de un corte de 24 horas y el rendimiento efectivo del ERP; si alguno difiere, se recalculan las tareas y los procesos con el mismo método antes del paso a producción.

4.2.5.12 Dimensionamiento en nube

La Tabla 27 declara la capacidad base y la de peak de cada servicio de cómputo y datos en nube, con el criterio que dispara el escalado.

Servicio	Base	Peak	Escala por
Perfil de API (PHP-FPM)	2 tareas	4 tareas; techo de 8	Procesos PHP-FPM ocupados sobre 70 %
Consumidor de reconciliación	2 tareas de 4 procesos	4 tareas	Edad del mensaje más antiguo sobre 5 min
Trabajos de Laravel	2 tareas	4 tareas; erp-sync fijo en 2 procesos	Profundidad de cada cola
Planificador	1 tarea	1 tarea	No escala
Motor de optimización de rutas	Bajo demanda	1 tarea por corrida	Corridas de ruteo
Lambda de validación y firma	100 concurrentes	500 reservadas	Eventos de IoT Core y S3
Aurora PostgreSQL	db.r6g.large, escritor y 2 lectores en 3 zonas	db.r6g.xlarge, escritor y 2 lectores	CPU sobre 60 %

Tabla 27 — continuación

Servicio	Base	Peak	Escala por
ElastiCache	cache.r6g.large	cache.r6g.xlarge	Memoria sobre 75 %
DynamoDB	Bajo demanda	Bajo demanda	Sin gestión de capacidad
IoT Core	2 gateways y 28 termógrafos	Igual a la base	Sin gestión de capacidad
Keycloak	2 tareas en 2 zonas	4 tareas en 2 zonas	CPU sobre 60 %

Tabla 27 Capacidad de los servicios en nube

El paso de base a peak duplica la API, el consumidor, los trabajos y la base, conforme al cálculo de la subsección anterior, y cada perfil escala por su propia señal, de modo que un pico de preventa no multiplica los consumidores ni una cola atrasada multiplica la API. El escalado combina un componente predictivo, que en agosto precalienta las tareas y reserva la concurrencia de Lambda, con uno reactivo que responde en menos de 2 minutos y aprovisiona en menos de 3. DynamoDB y Lambda escalan sin configuración, y la capacidad se paga por uso.

4.2.5.13 Plan de capacidad y crecimiento de 3 veces

El crecimiento se absorbe con el mismo diseño, sin cambiar la topología, las VLAN, la réplica ni la nube. La Tabla 28 muestra la acción para cada recurso on-premise.

Recurso	Diseño	Con 3 veces	Acción
vCPU del clúster	30 de 128, 23 %	90 asignadas	Caben en los 128 hilos con N+1, 70 %, sin sobresuscripción

Tabla 28 — continuación

Recurso	Diseño	Con 3 veces	Acción
Memoria	68 de 256 GB, 27 %	205 GB	Ampliación de 128 a 256 GB por nodo: 205 de 512 GB con N+1, 40 %
Pool Ceph	1.890 de 5.760 GB	5.670 GB	Ocho NVMe por nodo llevan el pool a 11,52 TB, 49 %
Enlaces de Talca y Concepción	20 y 10 Mbps	50 y 20 Mbps	Contrato escalonado de los enlaces
TPS de VM-02	105	315	Escala de 8 a 12 vCPU y de 32 a 64 GB, con particionado mensual

Tabla 28 Plan de capacidad para el crecimiento de 3 veces

El crecimiento de 3 veces no exige servidores adicionales: se absorbe agregando discos y memoria dentro de los tres nodos, que quedan con el cómputo en el umbral de alerta del 70 % y con la memoria y el almacenamiento bajo la mitad. Como esa ampliación cabe en el margen de crecimiento del 20 % que reservan los racks y la carga eléctrica de la sala, no requiere obras. En nube, el mismo factor se absorbe con el escalado automático de la Tabla 27, sin cambios de arquitectura.

4.2.5.14 Umbrales de desempeño

La Tabla 29 fija el umbral de respuesta, en percentil 95, de cada operación que el caso y las Bases declaran crítica.

Operación	Umbral
Confirmación de una línea de preparación de pedidos	1 s
Registro de una entrega en el local del cliente	2 s
Registro de una línea en la toma de pedido de preventa	1,5 s
Consulta de stock y crédito en preventa	2 s

Tabla 29 — continuación

Operación	Umbral
Transacción operacional crítica de terreno, de extremo a extremo	3 s
Carga inicial de una página del portal	2 s
Navegación entre vistas ya cargadas	1 s
Interfaz de programación de consulta simple	500 ms
Interfaz de programación de escritura transaccional	800 ms
Búsqueda con criterios compuestos	3 s
Informe estándar en línea	30 s

Tabla 29 Umbrales de desempeño en percentil 95

Las cuatro primeras operaciones son las que fija el caso, y tres de ellas se resuelven sin atravesar la WAN: la confirmación de preparación contra la base local del sitio y los dos registros de terreno contra el almacén local del dispositivo. La consulta de stock y crédito es la única que depende de la nube, y por eso se atiende desde la caché. Los umbrales se miden con CloudWatch y se verifican en Preproducción con las pruebas de carga.

4.2.5.15 Primer cuello de botella

En la ventana de despacho, el primer cuello de botella es la emisión de guías del ERP a través de la capa anticorrupción. Cada camión necesita su guía de despacho electrónica antes de salir, el ERP de 2017 no tiene interfaces documentadas ni escala, y agregar tareas de la aplicación no acelera al emisor legado; en esa ventana salen 96 camiones que no admiten ejecución manual (Caso, Cap. 10, restricción 1). Se detecta cuando crecen las guías pendientes antes de la salida, el percentil 95 de su emisión y la antigüedad de los mensajes en la cola hacia el ERP. Se mitiga solicitando la guía al cerrar la carga, durante la preparación nocturna y no en la ventana; priorizando las guías sobre los demás mensajes hacia el ERP; y reteniendo el camión afectado, sin marcarlo como liberado, mientras falte el documento o una contingencia tributaria autorizada por el CLIENTE. La prueba de carga mide si el ERP es efectivamente el primer límite.

Entre los recursos propios de la solución, el primero que se satura al crecer la carga

es VM-02, la base transaccional del maestro de bodega, porque toda la preparación nocturna y todo el despacho pasan por su único punto de escritura. Se detecta cuando el percentil 95 de escritura supera 800 ms, cuando el tiempo de confirmación se triplica, cuando la espera de disco supera 15 % o cuando la cola de conexiones supera entre 5 y 10. La mitigación es progresiva: primero, escalar VM-02 de 8 a 12 vCPU y de 32 a 64 GB dentro del margen N+1; luego, particionar las tablas por mes y agregar un gestor de conexiones; después, una réplica de solo lectura para las consultas; y por último, la partición de la base o un nodo adicional al agotar el margen. En nube, el equivalente es Aurora, que escala con lectores, y SQS FIFO absorbe el pico de sincronización de las 17:00 a las 20:00 (ADR-05).

4.2.5.16 Degradación controlada

Cuando la carga o la red exceden lo previsto, la solución degrada en orden y sin perder transacciones. En el enlace, la calidad de servicio prioriza el broker y el registro de escritura anticipada, las colas no críticas se difieren fuera de la ventana de despacho y la conmutación entre caminos ocurre en menos de 30 segundos. Sin enlace, los brokers y los colectores guardan hasta 24 horas y reconcilian en orden al reconectar. En la nube, API Gateway limita la tasa de solicitudes, los trabajadores de Laravel y el consumidor de reconciliación aplican tiempos de espera y reintentos con espera creciente, y los mensajes que fallan pasan a una cola de mensajes fallidos para su reproceso. Cuando una solicitud se encola o se limita, la persona usuaria recibe un mensaje explícito con el estado de su operación, nunca un error genérico (RT-09.08).

4.2.5.17 Pruebas de carga y estrés

Los valores de esta sección se verifican con pruebas en Preproducción, que opera con el dimensionamiento completo de Producción durante esas pruebas. La Tabla 30 declara las tres pruebas.

Prueba	Carga	Resultado esperado
Carga	1,5 veces la carga de diseño: 5.850 entregas diarias, unas 160 TPS sostenidas	Umbrales de la Tabla 29 cumplidos con perfiles horarios reales

Tabla 30 — continuación

Prueba	Carga	Resultado esperado
Estrés	Incremento hasta el punto de quiebre, al menos 3 veces	Curva de tiempo de respuesta frente a la carga
Informe de carga	Curvas, saturación y uso de CPU, memoria, disco, enlace y colas	Insumo de los hitos de producción de los meses 16 y 21

Tabla 30 Pruebas de carga y estrés

La prueba de carga multiplica por 1,5 una carga de diseño que ya incluía ese margen, de modo que $105 \times 1,5 \approx 160$ transacciones por segundo verifican la solución por encima de cualquier volumen que el caso proyecta. Las pruebas usan k6 y Gatling con controladores propios contra las API de integración y del broker, se ejecutan al cierre del desarrollo de la Etapa 1 (mes 12) y de la Etapa 2 (mes 18), antes de cada marcha blanca, y se repiten cada trimestre. Su calendario formal está en el Formulario T-13.

4.2.5.18 Actualización del plan de capacidad

Durante la operación, la capacidad se revisa cada trimestre comparando el consumo real con el proyectado en cómputo, memoria, almacenamiento, enlace, colas y transacciones por segundo. Una alerta anticipada se dispara cuando un recurso alcanza el 70 % o cuando la tendencia indica que se agotará en dos semanas, y cada alerta produce una propuesta de ajuste de dimensionamiento y de costo. La ampliación sigue el orden de la Tabla 28: vCPU, memoria y discos dentro del equipamiento físico, contrato escalonado de enlaces y, al agotar el margen, un nodo adicional. En nube, los umbrales del escalado automático y la concurrencia reservada se revisan al menos 30 días antes de cada peak de septiembre.

4.2.6 Especificaciones Implementos a proveer (Hardware y Software)

Esta sección resume y analiza el equipamiento y el software que la solución requiere en las instalaciones del CLIENTE, en el terreno y en la plataforma de nube. El detalle de

cada elemento, con su producto ofertado, su ubicación, su cantidad y su justificación, se entrega en el Formulario T-11, que acompaña a este subdocumento como archivo propio. El equipamiento físico lo adquiere el CLIENTE, y el adjudicatario lo especifica, instala, integra y mantiene durante el contrato (Art. 14.2).

4.2.6.1 Síntesis del equipamiento por familia

La Tabla 31 agrupa el equipamiento en ocho familias, con sus cantidades y los sitios donde se instala.

Familia	Equipamiento y cantidad	Sitios
Cómputo	3 servidores del clúster, 1 servidor de borde y 3 mini-PC industriales	Talca, Concepción y cross-docking
Almacenamiento de respaldo	1 NAS WORM cifrado, D-05	Talca
Red y seguridad	6 firewalls, 6 switches de sitio, 1 switch de gestión y 9 puntos de acceso Wi-Fi 6E	Los cinco sitios con cómputo
Enlaces	2 enlaces de fibra, 2 enlaces LTE en los CD, 3 módems LTE de doble SIM con dos proveedores en los cross-docking y 3 kits Starlink	CD y cross-docking
Terreno	62 terminales EC55 más 20 % de reserva, cerca de 200 terminales TC58e, 200 impresoras de cabina y 200 terminales de pago	Calle y camiones
Bodega	174 terminales de cámara, 6 impresoras de andén, 3 balanzas y 6 escáneres GS1	CD y cross-docking
Cadena de frío	7 módulos de sensores con 28 puntos, 2 gateways IoT y 28 termógrafos	CD, cámaras y camiones
Puestos, sala técnica y gabinetes de borde	8 estaciones de trabajo; la infraestructura de la sala de Talca: UPS, generador, 2 unidades de clima de precisión, 2 gabinetes y cámaras según plano; y los gabinetes de borde de Concepción y de los tres cross-docking	Talca, Concepción y cross-docking

Tabla 31 Síntesis del equipamiento a proveer por familia

Más de nueve de cada diez unidades están en el terreno y en la bodega, no en la sala técnica: son unos 860 dispositivos de trabajo frente a unos 60 equipos de cómputo, red, sala técnica y gabinetes de borde. Esa proporción refleja el caso, donde la operación ocurre en la calle, en la cámara y en el andén, y explica por qué la gestión de dispositivos (N-13) es un componente con emplazamiento propio y no un accesorio.

4.2.6.2 Criterios de selección

Cada familia se especifica contra una condición del caso que el equipamiento de oficina no resiste. Los 174 terminales de cámara están certificados para trabajar a -30°C con guantes gruesos y batería de recambio en caliente, porque la preparación de congelados ocurre a -22°C (Caso, Cap. 4.5); su número cubre los 120 preparadores simultáneos de Talca con 20 % de reserva por la rotación de 38 %, más 30 en Concepción. Los terminales de terreno operan un turno completo sin señal, a una mano y bajo sol directo (RT-13.08). Los mini-PC de los cross-docking son de rango industrial, porque las naves no tienen climatización y el supuesto de diseño es de hasta 50°C bajo la techumbre en verano. Los 28 termógrafos cubren los 18 camiones propios y los 10 refrigerados de los transportistas que declara la Tabla 16 del caso, porque el instrumento viaja con la carga y su registro ampara la cadena de frío aun cuando el vehículo no sea del CLIENTE; están calibrados contra un patrón NIST en dos puntos, porque su registro es la prueba de la cadena de frío ante un cliente o ante la autoridad sanitaria.

En la sala técnica el criterio es la redundancia sin sobrecompra. Los tres servidores del clúster son idénticos, de modo que la pérdida de cualquiera deja capacidad para todas las máquinas virtuales, y el crecimiento de 3 veces se absorbe agregando discos y memoria en los mismos nodos, dentro del margen de crecimiento de los racks. El servidor de Concepción se dimensiona a su propia bodega, sin sobrecompra. Los firewalls de Talca van en par, y los de Concepción y de cada cross-docking son únicos, porque en esos sitios la contingencia ante la falla es la misma autonomía que cubre los cortes de enlace.

4.2.6.3 Software y licenciamiento

El software de base es de código abierto en todos los componentes que el adjudicatario opera: PostgreSQL con PostGIS, RabbitMQ, Keycloak, Proxmox VE, Ceph y Docker, además de la aplicación, escrita en PHP 8.5 con Laravel 13 y sus dependencias fijadas por Composer, y del motor de optimización de rutas; los portales, en Angular y TypeScript; y, en el terreno, en Kotlin. Las dependencias de PHP se revisan en cada construcción

con `composer audit` y su licencia se verifica contra una lista de licencias admitidas antes de incorporarlas. Los únicos elementos con suscripción son los servicios de la plataforma de nube, descritos en la sección 4.2.2, la gestión de dispositivos, los agentes de detección en endpoints y el orquestador de integración continua GitLab CI. Esta composición mantiene la reversibilidad de la solución y evita que el CLIENTE quede atado a un licenciamiento propietario. El Formulario T- 11 detalla, además del equipamiento, cada servicio de nube y cada componente de software con su cantidad y su justificación.

4.3 Data center primario y secundario

4.3.1 Data Center Primario

El Data Center Primario concentra la operación productiva de la solución en dos dominios que se exigen mutuamente por el carácter híbrido obligatorio del despliegue (Bases Administrativas, Art. 16.1), para la región primaria de la nube en sa-east-1 ubicada en São Paulo en Brasil y para la sala técnica secundaria on-premise del centro de distribución de Talca, tipología que el propio caso fija (RT-06.01 del caso, numeral 6.1 de las Transversales). Ambos dominios se especifican en esta sección como que un centro de datos no es solo donde están los servidores, sino donde se garantizan sin interrupción las condiciones que sostienen la operación, la energía acondicionada, el clima controlado, la conectividad, la seguridad física y el monitoreo permanente con procedimiento escrito.

La sección declara que para cada dominio el proveedor, la región y las zonas de disponibilidad, los servicios contratados y el sitio on-premise deben contar con los objetivos de continuidad verificables que los gobiernan como la disponibilidad de infraestructura de 99,95 % mensual por componente (numeral 7.2 de las Transversales) y para los servicios críticos un $RTO \leq 4 \text{ h}$ y $RPO \leq 15 \text{ min}$ (RT-07.04), sobre los que se sostiene el compromiso contractual penalizable de $\geq 99,9 \%$ mensual de la transacción de negocio de extremo a extremo (Bases Administrativas, Art. 78.2; RT-10.01). El desglose servicio por servicio y componente por componente se entrega en el Formulario T-11.

4.3.1.1 Proveedor

Para la nube en Amazon Web Services todos los servicios se contratan en cuentas del CLIENTE, que son organizadas bajo AWS Control Tower con una cuenta por ambiente de modo que la propiedad de los datos y de la infraestructura es del CLIENTE desde el primer día. La selección de servicios sigue tres reglas que son preferir el servicio administrado cuando existe porque el área de TI del CLIENTE es de cuatro personas (Caso 02, Cap. 10, Restricción N.º 9), preferir servicios compatibles con estándares abiertos para que salir de la plataforma no exija reescribir la solución y contratar en la región secundaria solo lo que la recuperación ante desastres necesita. AWS satisface el requisito de presencia de región o zona en Chile o en Sudamérica (RT-03.01; Bases Administrativas, Art. 16.2) con la región primaria sa-east-1. El cumplimiento de los estándares y marcos de referencia

del Artículo 4.3 de las Bases Administrativas entre ellos ISO/IEC 27017 (nube) e ISO/IEC 27018 (datos personales en nube) se logra acreditar mediante la matriz de controles de seguridad (RT-11.05) y no se repite en esta sección.

Para el On-premise en la infraestructura de las instalaciones del CLIENTE en el CD de Talca el caso exige cómputo, almacenamiento y procesamiento on-premise en las instalaciones del CLIENTE para sostener recepción, preparación y despacho durante un corte de enlace (Caso 02, RT-06.01 y RT-03.10), por lo que obliga a la modalidad híbrida (Bases Administrativas, Art. 16.1). Por ese alcance se necesita un cómputo local para la continuidad de un sitio operacional sin albergar el núcleo, por lo que el sitio adopta la tipología de **sala técnica secundaria o de sitio** del numeral 6.1 de las Transversales, con disponibilidad de infraestructura de 99,95 % (numeral 7.2) y el dimensionamiento proporcional al equipamiento real.

4.3.1.2 Región y zonas de disponibilidad

La región primaria de la nube es en sa-east-1 ubicada en São Paulo en Brasil, por lo que todo componente con requisito de alta disponibilidad se despliega en al menos dos zonas de disponibilidad y no se acepta un diseño en una sola zona (RT-03.02). La distribución por zona de la solución es la siguiente, la base de datos Aurora PostgreSQL se escribe en sa-east-1a y se lee en sa-east-1b y sa-east-1c con conmutación automática, para DynamoDB se opera Multi-AZ de forma nativa y transparente, para ECS Fargate, ElastiCache Redis, el balanceador de aplicación y el NAT Gateway operan entre sa-east-1a y sa-east-1b con conmutación automática. El único componente con escritor único es la base de datos que conmuta de forma automática entre las zonas. Este diseño sostiene el compromiso de extremo a extremo de $\geq 99,9$ % mensual de la transacción crítica (Bases Administrativas, Art. 78.2; RT-10.01) y la conmutación se verifica en las pruebas de resiliencia por inyección de fallas de la arquitectura de despliegue (RT-10.07).

4.3.1.3 Servicios contratados en la región primaria

Los servicios contratados en la plataforma de nube se agrupan por la función que cumplen en la arquitectura como el listado servicio por servicio con su justificación y su cantidad, además se entrega en el Formulario T-11. En la región primaria se concentran la operación productiva, la analítica y los servicios de detección, cumplimiento y gobierno:

- Borde público: Route 53, CloudFront, AWS WAF, Shield Advanced y API Gateway.
- Cómputo de aplicación: ECS Fargate, Application Load Balancer y Lambda.

- Datos operacionales: Aurora PostgreSQL, Database Migration Service, DynamoDB y ElastiCache.
- Mensajería: SQS FIFO para la reconciliación, SQS para los trabajos de la aplicación y SNS.
- Integración B2B: AWS Transfer Family con AS2.
- Internet de las cosas: IoT Core e IoT Greengrass.
- Analítica: S3, Glue, Redshift Serverless y QuickSight.
- Respaldo y recuperación: AWS Backup, S3 Object Lock y replicación de S3 entre regiones.
- Red y conectividad: VPC, Transit Gateway, Site-to-Site VPN, NAT Gateway y VPC Endpoints.
- Identidad, claves y secretos: KMS, Secrets Manager, Parameter Store e IAM Identity Center.
- Detección y cumplimiento: Security Lake, GuardDuty, Security Hub, Inspector, Macie, CloudTrail y Config.
- Operación y gobierno: CloudWatch, Systems Manager, Control Tower, Organizations, Cost Explorer y Budgets.
- Construcción y registro de imágenes: CodeBuild y Elastic Container Registry.
- Servicios de terceros en nube: Android Enterprise, Zebra DNA, consola del EDR y GitLab CI.

La solución no opera servidores en la nube ya que el cómputo corre en contenedores administrados y todos los datos viven en motores administrados. Las piezas de software que el adjudicatario mantiene sobre la plataforma son la aplicación Laravel con sus perfiles de ejecución, el motor de optimización de rutas y el IdP Keycloak. El Registro de Decisiones de la Arquitectura descarta de forma expresa los servicios que nunca aparecen en la arquitectura (como ejemplo no se contrata EKS ni MSK, no se contratan servicios de observabilidad fuera de CloudWatch) y fija la gestión de secretos con AWS Secrets Manager y SSM Parameter Store.

4.3.1.4 Sitio on-premise: CD Talca (sala técnica secundaria)

Para la tipología y alcance, en el caso se fija para el CD de Talca una sala técnica secundaria que es "dimensionada para sostener recepción, preparación y despacho durante un corte", y advierte que la sala actual de 25 m² no cumple el Capítulo 6 del documento transversal (Caso 02, RT-06.01). Conforme a la tipología del numeral 6.1 de las

Transversales, a este sitio no se aplica íntegramente la serie RT-06.01 a RT-06.24 (que corresponde a la sala técnica principal), sino el subconjunto dimensionado al sitio como la energía, climatización, control de acceso, detección de incendio y monitoreo. El numeral 6.1 de las Transversales exige declarar la tipología y justificar el dimensionamiento y advierte que “sobredimensionar el recinto es tan penalizado como subdimensionarlo: ambos revelan que el cálculo de capacidad no se hizo”. La superficie proyectada de la sala queda determinada por el equipamiento real que debe alojar y por los cálculos eléctrico y térmico (RT-06.11) que son desarrollados a continuación y se fija en el plano de distribución interna (RT-06.03, Figura 4.3-1).

Para el equipamiento que la sala debe alojar el sitio aloja el núcleo del componente on-premise en el motor WMS y el borde operacional del CD (Registro de Decisiones, Decisión 17) sobre un clúster virtualizado de tres nodos con redundancia N+1 que tolera la pérdida de cualquier nodo manteniendo quórum, también una NAS local con el respaldo de recuperación rápida y los dos firewalls de la frontera del sitio. El listado completo de componentes de sala (UPS, generador, climatización, seguridad física, extinción, cableado y gabinetes) y del equipamiento de cómputo y red que alojan los gabinetes se entrega en el Formulario T-11, la ocupación por rack y el margen de crecimiento se declaran según RT-06.05 (Figura 4.3-2).

Para la disponibilidad y la redundancia la disponibilidad de infraestructura comprometida es del 99,95 % mensual por componente en energía del recinto, climatización, red y comunicaciones, servidores y cómputo, y motor de base de datos (numeral 7.2 de las Transversales). Además se sostiene con redundancia N+1 en energía y climatización (RT-06.12 deseable para alimentación; RT-06.13 obligatorio para clima), con facturación de generación autónoma y con monitoreo continuo con alertamiento. No se invoca una clasificación de instalación de terceros (ejemplo un nivel TIER certificado), por lo que los niveles de disponibilidad de infraestructura del numeral 7.2 son un medio, no un fin y el compromiso que se mide y se penaliza es el de la transacción de negocio de extremo a extremo (Artículo 78° de las Bases Administrativas; RT-10.01).

Para la energía la cadena eléctrica se ordena empalme hacia el tablero general hacia la transferencia automática hacia el UPS luego el PDU del rack luego la fuente del equipo y por último al servidor que consta de UPS de doble conversión on-line en configuración N+1 con autonomía mínima de 30 minutos a plena carga (RT-06.07), la generación autónoma para un rango mínimo de 24 horas continuas con estanque de combustible dimensionado y contrato de reabastecimiento declarado (RT-06.08), la instalación eléctrica independiente de la del resto del edificio y conforme a la normativa eléctrica chilena vigente, incluida la NCh Elec. 2777 (RT-06.09) y la revisión y medición semestral con informe entregable al CLIENTE (RT-06.10).

Para el cálculo de carga eléctrica (RT-06.11) la carga se proyecta sobre los equipos que el Formulario T-11 declara para el recinto, usando su potencia de placa (suma de las fuentes del equipo, que es el valor con que se dimensiona el UPS), proyectada por equipo en la Tabla 4.3-1:

Equipo (Formulario T-11)	Cantidad	Potencia de placa por unidad	Subtotal
Nodo de cómputo del clúster (servidor rack 2U, doble procesador)	3	1.600 W (2 fuentes de 800 W)	4.800 W
NAS local	1	400 W	400 W
Firewall del perímetro del sitio	2	150 W	300 W
Conmutador de núcleo (switch core)	2	150 W	300 W
Switch de gestión	1	50 W	50 W
Carga TI base			5.850 W
Margen de crecimiento a tres años (20 %, RT-06.05)			+ 1.170 W
Carga TI de diseño			7.020 W ≈ 7,0 kW

Tabla 4.3-1 Carga eléctrica de TI proyectada del recinto (RT-06.11)

El factor de potencia declarado es de 0,95, por lo que la potencia aparente de diseño es $7,0 \text{ kW} \div 0,95 \approx 7,4 \text{ kVA}$. El UPS se dimensiona al 80 % de utilización: $7,4 \text{ kVA} \div 0,8 \approx 9,2 \text{ kVA}$, por lo que se selecciona un UPS modular de 10 kVA, doble conversión on-line, en configuración N+1 y con bypass de mantenimiento (RT-06.12, deseable, y RT-06.07). La PUE estimada de diseño es 1,5 que es derivada del desglose proyectado de consumo del recinto con la carga TI 7,0 kW, climatización de precisión $\approx 2,3 \text{ kW}$, iluminación y apoyo $\approx 0,6 \text{ kW}$ y pérdidas de conversión del UPS $\approx 0,55 \text{ kW}$ con un total de $\approx 10,4 \text{ kW}$ y luego $10,4 \div 7,0 \approx 1,5$. Los puntos de medición se declaran (numerador: tablero general del recinto y denominador: salida de las PDU de los racks) con medición semestral e informe entregable (RT-06.10), además el PUE del recinto on-premise se declara conforme a RT-15.04 junto con la intensidad de carbono de la región de nube. La carga total que debe sostener el generador es la carga del sitio $\approx 10,4 \text{ kW}$, por lo que se selecciona un grupo electrógeno de 15 kVA con estanque dimensionado a 24 horas

continuas y contrato de reabastecimiento declarado (RT-06.08).

Figura 4.3-1 — Distribución interna del recinto técnico del CD Talca por zonas y líneas de acceso (RT-06.03).

[Insertar aquí la Figura 4.3-1]

El plano ordena el recinto en profundidad progresiva y los generadores quedan en el exterior junto a la acometida luego las zonas de baterías/UPS y de climatización y al final la sala de servidores y comunicaciones. Los puestos de trabajo y el área de respaldo quedan en la línea técnica, separados de la sala de equipos (RT-06.30), de modo que las labores habituales de operación no exigen ingresar a la línea restringida. La separación física de generadores y baterías respecto del área de servidores evita que una falla de energía o de clima contamine el cómputo y deja al proveedor de fibra y al de climatización sin cruzar la última línea del recinto.

Para la climatización de precisión en la operación continua es redundante en configuración N+1, con control de temperatura y de humedad relativa dentro de los rangos que recomienda el fabricante del equipamiento (RT-06.13).

Para el cálculo de carga térmica (RT-06.11 y RT-06.13) físicamente cada kW eléctrico consumido por el equipamiento se disipa como aproximadamente 1 kW de calor sensible (≈ 3.412 BTU/h), por lo que la carga térmica se dimensiona sobre la carga TI de diseño más las pérdidas de conversión del UPS, como resume la Tabla 4.3-2:

Origen del calor	Potencia equivalente
Carga TI de diseño	7.000 W
Pérdidas de conversión del UPS (eficiencia $\approx 0,92$)	≈ 610 W
Carga térmica sensible de diseño	$\approx 7,6$ kW

Tabla 4.3-2 Carga térmica sensible proyectada del recinto (RT-06.11)

Sobre esa carga se instalan dos unidades de climatización de precisión en configuración N+1 (RT-06.13), cada una con capacidad de enfriamiento de 10 kW (≈ 34.000 BTU/h) que cuenta con la pérdida de la unidad mayor, ya que la restante cubre la carga de diseño ($7,6 \text{ kW} < 10 \text{ kW}$) con holgura y la temperatura y la humedad relativa se controlan dentro de los rangos del fabricante del equipamiento (RT-06.13). No se declaran equipos ni potencias sin el cálculo que los respalde (Aclaración 2.3). La consola KVM y el equipo

de acceso del operador (ONT de fibra y router LTE) suman en conjunto menos de 0,1 kW y quedan cubiertos por el margen de diseño del 20 % de la Tabla 4.3-1, sin alterar el dimensionamiento del UPS (10 kVA) ni del generador (15 kVA).

Figura 4.3-2 — Diagrama de racks: distribución y ocupación proyectada (RT-06.05).

[Insertar aquí la Figura 4.3-2]

Los racks de servidores son independientes de los racks de equipos de comunicación (RT-06.05). La ocupación proyectada reserva margen de crecimiento a tres años, coherente con el 20 % de reserva de la carga eléctrica (Tabla 4.3-1), de modo que la ocupación declarada y su margen quedan fijados en la figura y en el Formulario T-11.

Para la protección contra incendios se realiza una detección temprana por aspiración de aire con tecnología láser, tipo AnaLASER (RT-06.16) y extinción automática con agente limpio tipo FM-200 con aprobación UL e instalación conforme a norma NFPA, con botón de aborto (RT-06.17) y un sistema secundario de extintores portátiles habilitados con mantención y certificación vigentes (RT-06.18). El sistema de detección y extinción se integra al monitoreo en línea y notifica al NOC y a la contraparte del CLIENTE (RT-06.19). No se cita una edición específica de la norma NFPA ya que el requisito se cumple conforme a RT-06.17 y la norma externa no se invoca como fuente.

Para el control de acceso y seguridad física el ingreso se controla con seguridad física y control de acceso biométrico basado principalmente en biometría facial con AFIS como respaldo (RT-06.20) y todo ingreso y egreso queda registrado en una bitácora auditable con identificación, fecha, hora y motivo (RT-06.21), entre el acceso principal y el término del pasillo de la zona de control se dispone un espacio para la atención de personas en proceso de enrolamiento (RT-06.22) y además se habilita una estación de enrolamiento fuera de las instalaciones del recinto técnico, al término del pasillo se instala un acceso que impide el paso de más de una persona a la vez con nueva verificación de identidad previa al ingreso (RT-06.23) y el recinto cuenta con videovigilancia y monitoreo IP con imágenes en línea disponibles al menos los últimos 30 días y respaldo recuperable (RT-06.24). Las instalaciones sanitarias, las zonas de seguridad ante emergencia y las áreas exteriores existentes en el edificio del CLIENTE se utilizan y no se implementan nuevamente dentro del recinto (RT-06.31). La bitácora auditable se conserva por un período de retención no inferior a cinco años coherente con el piso que las Bases fijan para la retención de la auditoría del proyecto (RT-16.10).

Para el monitoreo del sitio se monitorean en línea la temperatura, la humedad y la presencia de agua con alertamiento integrado a la plataforma de observabilidad (RT-06.14) y el estado de los puntos controlados del recinto converge en la plataforma de monitoreo con destinatario, canal, tiempo de respuesta y procedimiento escrito (RT-06.19). La

observabilidad reutiliza el mecanismo del sitio on-premise hacia la nube que define la arquitectura de despliegue (apartado 4.2.3). La convergencia en un solo tablero es la plataforma de observabilidad del sitio por lo que no se declara una plataforma DCIM/BMS de terceros porque las Bases no la exigen y RT-06.14 y RT-06.19 se satisfacen con el monitoreo en línea y su alertamiento integrado.

Para el cómputo almacenado onsite el cómputo corre sobre un clúster virtualizado de tres nodos con redundancia N+1 y almacenamiento distribuido que tolera la pérdida de al menos un nodo con quórum real, el almacenamiento local combina un nivel para la base transaccional y otro para el respaldo local (NAS D-05, RAID 6) con nivel RAID declarado y justificado frente a las alternativas (RT-03.14; Registro de Decisiones, Decisión 28). La instancia de escritura es el punto único declarado y se mitiga con reinicio en otro nodo del clúster.

4.3.2 Data Center Secundario

El Data Center Secundario es el componente de la solución que sostiene la continuidad cuando la operación primaria no está disponible y garantiza la recuperación de la plataforma y de los datos con objetivos de tiempo y de pérdida declarados y lo hace bajo la modalidad activo-pasiva, que primero se declara y justifica (RT-07.01) y luego se materializa en sitios de recuperación, replicación, objetivos RPO/RTO y procedimientos de conmutación y retorno.

En coherencia con el carácter híbrido obligatorio de la solución (Bases Administrativas, Arts. 16.1 y 16.2; Registro de Decisiones, Decisión 17), la solución tiene dos sitios de recuperación, uno por dominio que es la región AWS us-east-1 para el dominio en nube y el gabinete de borde del centro de distribución de Concepción para el dominio de on-premise. En ambos se sostienen los objetivos de continuidad que la sección declara de forma incondicional, para los servicios críticos como el $RTO \leq 4$ horas y $RPO \leq 15$ minutos (RT-07.04; RNF-20.06; Decisión 27), probados al menos dos veces al año con conmutación real (RT-07.07) y con respaldo 3-2-1-1-0 (RNF-20.07; Decisión 27); sobre esos objetivos se sostiene el compromiso contractual penalizable de $\geq 99,9\%$ mensual de la transacción de negocio de extremo a extremo (Bases Administrativas, Art. 78.2; RT-10.01). El desglose componente por componente de la réplica y de la política de respaldo se entrega en el Formulario T-11.

4.3.2.1 Modalidad del sitio secundario

La modalidad declarada es activo-pasiva en caliente (Registro de Decisiones, Decisión 27): la región de recuperación mantiene una réplica reducida pero funcional de la plataforma que es escalable a carga completa durante la conmutación y que se promueve sólo ante la indisponibilidad de la región primaria. La elección se justifica frente a las alternativas, como exige el RT-07.01:

- Frente al activo-activo: duplica la infraestructura y exige reconciliación de doble escritura entre sitios sin beneficio medible para el volumen transaccional del caso, el costo y la complejidad operacional que introduce no se justifican (RT-07.01; Decisión 27).
- Frente a la recuperación en frío desde respaldos: su tiempo de recuperación del orden de 24 a 72 horas incumple el objetivo de continuidad de los servicios críticos (RNF-20.06; RT-07.04).

El costo de la modalidad se acota porque la región secundaria no es una segunda producción ya que contiene solo lo que la recuperación que exige la réplica pasiva promovible del núcleo transaccional, la réplica reducida de aplicación que escala durante la conmutación y las copias de respaldo, criterio que se expresa en el propio caso al exigir declarar la región primaria y la secundaria (RT-03.01).

4.3.2.2 Región o sitio de recuperación

La solución tiene dos sitios de recuperación, uno por dominio en coherencia con el carácter híbrido obligatorio (Bases Administrativas, Arts. 16.1 y 16.2): la región AWS us-east-1 para el dominio en nube y el gabinete de borde del CD Concepción para el dominio on-premise. La Tabla 4.3-3 compara ambos sitios en distancia y amenazas comunes:

Sitio de recuperación	Dominio que restituye	Distancia declarada	Análisis de amenazas comunes
Región AWS us-east-1	Nube	≈ 7.700 km de la región primaria sa-east-1	Continente distinto y sin dependencia de la sismicidad ni de la malla eléctrica chilena y no comparte eventos de fuerza mayor con el sitio principal (RT-07.02)
CD Concepción (gabinete de borde)	On-premise	≈ 200 km del CD Talca en línea recta, 250 km por carretera	Comparte con Talca la sismicidad de zona costera y el corte de la malla eléctrica nacional, también la exposición se mitiga con la independencia operacional de ambos sitios (operación autónoma 24 horas y alimentación protegida) y porque el dominio en nube no comparte esas amenazas (RT-07.02)

Tabla 4.3-3 Sitios de recuperación: distancia y análisis de amenazas comunes (RT-07.02)

Para el Sitio de recuperación en nube la elección de la región us-east-1 y la habilitación de la recuperación ante desastres quedan declaradas de forma incondicional, ya que la transferencia internacional de datos personales que la continuidad exige se trata con los resguardos de la arquitectura de seguridad, acuerdo de tratamiento con el proveedor de nube, cifrado en reposo y en tránsito extremo a extremo, minimización (la región secundaria no se explota analíticamente ni se usa para consultas de negocio, solo para continuidad) y exclusión de los datos de geolocalización de personas de la replicación transfronteriza, que permanecen solo en sa-east-1 y se registra en el inventario de tratamientos. En consecuencia los objetivos de RTO y RPO no quedan supeditados a una aprobación futura (RT-07.04) ya que la alternativa de continuidad “solo intrarregional” de la propuesta observada se descarta porque degradaba el objetivo de continuidad.

La región secundaria contiene la réplica de Aurora mediante Aurora Global Database, la réplica de DynamoDB mediante Global Tables, la copia de los buckets de S3, las copias de AWS Backup y una réplica reducida de la plataforma de aplicación que escala a carga completa durante una conmutación. Dos capacidades quedan fuera de esa región por diseño como la analítica porque la región secundaria no se explota analíticamente y las consultas sobre datos de geolocalización de personas que no se replican fuera de sa-east-1 conforme a los resguardos de residencia declarados.

Para el Sitio de recuperación on-premise en el gabinete de borde del CD Concepción no es un sitio en espera ya que opera de forma autónoma todos los días con una tipología de borde operacional del numeral 6.1 de las Transversales, conforme a RT-06.01 del caso y ante una contingencia que afecte solo a la bodega de Talca, asume la carga de esa bodega mediante la promoción controlada del motor de almacenes. El gabinete de borde de Concepción se especifica en energía, climatización y control de acceso, dimensionado a la tipología de borde operacional (numeral 6.1) que corresponde a la alimentación protegida con UPS y respaldo para la autonomía declarada, climatización de precisión acorde al equipamiento del borde, control de acceso y monitoreo remoto integrado al NOC del sitio. Además el listado componente por componente (cómputo, almacenamiento, enlace redundante y respaldo de alimentación) se entrega en el Formulario T-11. Los gabinetes de borde de los tres cross-docking no forman parte del sitio de recuperación y se especifican en el emplazamiento del sitio (Formulario T-11), sin repetir aquí la tipología.

4.3.2.3 Replicación

La replicación de datos es continua hacia el sitio de recuperación en nube con medición y alertamiento del retraso de replicación (RT-07.03). Cada dominio de datos alcanza el objetivo de punto de recuperación con su propio mecanismo, como resume la Tabla 4.3-4:

Dominio de datos	Mecanismo de replicación	RPO / retraso declarado
Transaccional en nube (Aurora PostgreSQL)	Aurora Global Database hacia us-east-1	< 1 s
Telemetría (DynamoDB)	Global Tables	Continuo
Evidencia, documentos y respaldos (S3, AWS Backup)	Replicación de S3 entre regiones con control de tiempo	< 15 min
WMS on-premise (PostgreSQL de Talca)	AWS DMS por la VPN sobre el registro de escritura anticipada	≤ 15 min con enlace
Mensajes críticos	Patrón outbox en base y cola	≤ 15 min

Tabla 4.3-4 Replicación y RPO por dominio de datos (RT-07.03, RT-07.04)

Todos los dominios críticos se replican de forma continua. El único dominio cuyo retraso de replicación depende de una condición externa es la réplica del WMS on-premise ya que viaja por la WAN, en caso de que un sitio pierde simultáneamente sus dos caminos de enlace, el AWS DMS encola los cambios en origen y los entrega sin pérdida al reconectar, luego la base local permanece autoritativa durante el corte por lo que no hay pérdida de información y el retraso se mide de forma continua con alertas a los 5 y a los 15 minutos (RT-07.03). Durante ese corte la copia remota del WMS queda desactualizada hasta un máximo de 24 horas, por lo que el RPO remoto de 15 minutos de esa réplica rige solo con enlace; el registro que el corte obliga a retener está dimensionado en la arquitectura de despliegue.

4.3.2.4 RPO y RTO

Los objetivos de continuidad de los servicios críticos son $RTO \leq 4$ horas y $RPO \leq 15$ minutos (RT-07.04; RNF-20.06; Registro de Decisiones, Decisión 27). La Tabla 4.3-5 resume los objetivos que gobiernan este sitio secundario y el compromiso sobre el que se miden.

Activo	Objetivo	Valor declarado	Fuente
Servicios críticos	Tiempo de recuperación (RTO)	≤ 4 h	RT-07.04; RNF-20.06; Decisión 27
Servicios críticos	Punto de recuperación (RPO)	≤ 15 min	RT-07.04; RNF-20.06; Decisión 27
Transacción de negocio crítica de extremo a extremo	Disponibilidad mensual	$\geq 99,9$ %	Bases Administrativas, Art. 78.2; RT-10.01
Infraestructura por componente	Disponibilidad mensual	99,95 %	Numeral 7.2 de las Transversales

Tabla 4.3-5 Objetivos de continuidad (RT-07.04)

Estos objetivos se declaran **sin condiciones** ya que no dependen de aprobaciones ni de otros eventos futuros del CLIENTE (RT-07.04). La única precisión corresponde a la réplica remota del WMS durante un corte de enlace: mientras el sitio está aislado su base

local es la fuente autoritativa y no pierde información, pero la copia en la nube no puede actualizarse hasta que el enlace vuelve, como se indicó en la replicación. El RPO de la sección anterior se verifica en las pruebas de recuperación (RT-07.07) que miden el RTO y el RPO efectivamente alcanzados.

4.3.2.5 Procedimiento de conmutación

El procedimiento de conmutación está documentado, automatizado en la mayor medida posible y ejecutable por el personal del CLIENTE tras la transferencia de conocimiento (RT-07.05). La conmutación de región separa lo reversible de lo irreversible por lo que el enrutamiento se conmuta de forma automática porque si la región primaria se recupera el tráfico vuelve solo mientras que la promoción de la base de datos rompe la replicación y obliga a reconciliar al volver por lo que exige confirmación y autorización del CLIENTE. La Tabla 4.3-6 muestra la secuencia completa.

Paso	Acción	Ejecución	Tiempo
1	Detección por verificación de salud de la región primaria	Route 53	< 5 min
2	Conmutación del enrutamiento hacia us-east-1	Automática	—
3	Confirmación y autorización de la promoción	CLIENTE, con aviso por SNS	—
4	Promoción de Aurora en us-east-1	Systems Manager Automation	15–20 min
5	Escalado de la plataforma de aplicación a carga completa	Systems Manager Automation	< 30 min
6	Actualización de DNS	Systems Manager Automation	45–60 min
7	Reconexión del broker y sincronización del borde	Systems Manager Automation	—
8	Validación funcional de extremo a extremo	Operación	—

Tabla 4.3-6 Secuencia de conmutación de región (RT-07.05)

Los pasos con tiempo declarado suman y en el peor caso y ejecutados en serie cerca

de 2 horas más el tiempo de la decisión dentro del RTO de 4 horas (RT-07.04). Solo el tercer paso requiere intervención humana y es ahí donde reside la protección contra una conmutación innecesaria (RT-07.08, deseable). Como los pasos cuarto a séptimo están automatizados el equipo de tecnologías de información del CLIENTE de cuatro personas puede ejecutar el procedimiento tras la transferencia de conocimiento (RT-07.05; Caso 02, Cap. 10, Restricción N.º 9), con el acompañamiento del servicio de operación del proyecto.

Cuando la contingencia afecta solo a la bodega de Talca el plan de recuperación local promueve el motor de almacenes del CD Concepción ya que opera de forma autónoma todos los días mediante cinco pasos con un RTO adicional de 1 a 2 horas dentro de la ventana de 4 horas (RT-07.04). La identidad no requiere conmutación en ningún escenario por lo que su autoridad reside en la nube y las cachés locales son de solo lectura de modo que no existe un maestro local que promover.

4.3.2.6 Procedimiento de retorno

Existe un procedimiento de retorno al sitio principal que es igualmente documentado y probado con reconciliación de los datos generados durante la contingencia (RT-07.06). El retorno a la región primaria sigue seis pasos, la resincronización con verificación de alcance, la reconciliación de las transacciones de la contingencia contra la bitácora, la transferencia de los eventos pendientes, la conmutación coordinada del DNS, la validación funcional y el informe con el tiempo real empleado (RT-07.06). El procedimiento de retorno se prueba en cada ensayo de recuperación semestral (RT-07.07) de modo que no queda declarado pero no ejercitado.

4.3.2.7 Pruebas del plan de recuperación y respaldos

Para las pruebas del plan de recuperación ante desastres se prueba al menos dos veces al año mediante conmutación real con informe de resultados, medición del RTO y del RPO efectivamente alcanzados y plan de corrección de las brechas detectadas, el RTO y el RPO comprometidos deben cumplirse en el 100 % de los ensayos (RT-07.07; RNF-20.06; Decisión 27). Además se ejecutan las pruebas de resiliencia por inyección controlada de fallas por la caída de una instancia de una zona o de una dependencia externa, también la latencia elevada y saturación de disco antes de cada paso a producción y al menos una vez por semestre durante la operación (RT-10.07; RNF-20.04) y la prueba de restauración de respaldos se ejecuta y se documenta al menos mensualmente sobre una muestra representativa con medición del tiempo efectivo de restauración (RT-07.12).

Para el respaldo 3-2-1-1-0 la política de respaldo sigue el esquema 3-2-1-1-0 único para la nube y el on-premise (RT-07.09; RNF-20.07; Decisión 27): tres copias de los datos activos, las instantáneas de la base junto con la copia local del sitio y el respaldo exportado a almacenamiento de objetos de modo que en dos medios la base de datos y almacenamiento de objetos se genera una copia fuera del sitio que es replicada a us-east-1 y una copia inmutable en Amazon S3 Object Lock en modo Compliance con AWS Backup Vault Lock que se suman a la bóveda física externa y a la copia de recuperación rápida del sitio y cero errores de restauración que son verificados en la prueba mensual (RT-07.09, RT-07.12). Las copias inmutables están protegidas contra borrado y contra modificación durante su período de retención incluso frente a credenciales administrativas comprometidas (RT-07.11), además los respaldos están cifrados en reposo y en tránsito con clave gestionada de forma independiente de la infraestructura respaldada (RT-07.10). La frecuencia de respaldo, el período de retención y el tiempo estimado de restauración completa por dominio de datos se declaran en el Formulario T-11 (RT-07.13) y la restauración granular en un registro, una tabla, un módulo o el sistema completo logra quedar como capacidad deseable (RT-07.14).

Las pruebas se programan fuera de la ventana de despacho y de los períodos de congelamiento y cada una produce un informe con las desviaciones encontradas y su plan de corrección, la disponibilidad efectiva y el resultado de estas pruebas se entregan en el informe mensual de nivel de servicio (Artículo 79 de las Bases Administrativas).

4.4 Registro de decisiones de arquitectura

Registro consolidado de las quince decisiones de arquitectura que condicionan esta propuesta. Es entregable contractual conforme a RT-02.04 y se mantiene actualizado durante toda la ejecución. Para cada decisión se indica la alternativa escogida, las alternativas descartadas con el motivo de rechazo, y el criterio de selección; las decisiones reformuladas para el backend Laravel agregan sus consecuencias y la evidencia que deberá confirmarlas. ADR-01, ADR-05, ADR-11, ADR-12 y ADR-14 quedan en estado *propuesta* hasta su aprobación por el equipo; en ADR-04, ADR-06, ADR-08 y ADR-13 se ajustó la implementación sin cambiar la decisión. Este es el registro único del Subdocumento 4: la arquitectura lógica (4.1) cita estas mismas decisiones por su número.

4.4.1 ADR-01 · Estilo arquitectónico

Decisión adoptada. Monolito modular en Laravel 13 sobre PHP 8.5, con los módulos M1-M12 separados por espacios de nombres PSR-4 y dependencias fijadas por `composer.lock`. Un solo artefacto, construido una vez por versión, se ejecuta en perfiles separados: API y `wms_only` con PHP-FPM, y shipper, consumidor de reconciliación, trabajos y planificador como procesos PHP de línea de comandos. El motor de optimización de rutas de M4 y el transporte AS2 de M11 quedan fuera del artefacto, tras un contrato versionado. Estado: propuesta.

Alternativas descartadas. *Monolito modular en Django y Python 3.12*: técnicamente viable con los mismos contratos, pero la arquitectura lógica adopta Laravel y mantener ambos runtimes obligaría a operar dos cadenas de construcción, de dependencias y de parches. *Microservicios en EKS*: el volumen de unos 105 TPS está dos órdenes bajo el umbral que los justifica, cuatro personas no operan un plano de control y el costo total de propiedad en 56 meses sube sin beneficio. *Monolito clásico del WMS de 2013*: sin fronteras de módulo y con el proveedor desaparecido; incumple RT-02.02. *Traducir a PHP el ruteo y el AS2 sin prueba*: la equivalencia de un solver o de un conector no se deduce del cambio de lenguaje, por eso ambos se aíslan.

Criterio de selección. Coherencia con la arquitectura lógica (4.1); pertinencia al volumen

real (numeral 2.3 de las Bases Técnicas Transversales); operabilidad por cuatro personas; despliegue y escalado independiente por perfil sin particionar el dominio. Normativa: RT-02.01/02.02/02.03, RT-09.05, Art. 16, RNF-19.01-04.

Consecuencias. La imagen incluye PHP-FPM, el intérprete de línea de comandos y las extensiones declaradas en la arquitectura de despliegue; el pipeline agrega `composer audit`, `PHPUnit`, `PHPStan/Larastan` y `Pint`; el dimensionamiento de los perfiles se recalcula para PHP en lugar de trasladar los valores anteriores. El motor de ruteo agrega una imagen propia al pipeline y una tarea de Fargate bajo demanda.

Evidencia exigida. Pruebas de paridad de contratos, datos y colas; prueba de carga por perfil; y, para el motor de ruteo, la generación de rutas de toda la operación en menos de 20 minutos (Caso, Cap. 18), que es condición de aceptación del motor que se seleccione.

4.4.2 ADR-02 · Conectividad WAN

Decisión adoptada. Doble camino por sitio: fibra + LTE en los centros de distribución, Starlink + LTE en los cross-docking. Conmutación automática < 30 s.

Alternativas descartadas. *Fibra en cross-docks:* naves industriales sin cobertura de fibra; costo de obra desproporcionado. *VSAT GEO:* latencia 500–700 ms RTT; penaliza RNF-05.01 y costo superior. *Tri-camino (fibra + Starlink + LTE):* tercer camino no aporta disponibilidad significativa dado que cada sitio opera autónomamente ante pérdida total de enlace (24 h CD, 14 h terreno).

Criterio de selección. Dos caminos de física distinta satisfacen RT-03.17 sin punto único de fallo; la autonomía local cubre la pérdida total de enlace, por lo que un tercer camino es innecesario; cero mantención de radio para el equipo de 4 personas del CLIENTE. Normativa: RT-03.10/03.17, RT-10.05, RNF-13.01/13.07/13.08. Relacionada: Decisión N° 26 del registro de decisiones.

4.4.3 ADR-03 · Modelo de despliegue híbrido

Decisión adoptada. Borde operacional on-premise (WMS maestro Talca, edge Concepción, WMS en cross-docks) + carga principal en AWS. 11 componentes on-prem, 12 híbridos, 13 nube pura.

Alternativas descartadas. *Solo nube:* inadmisible (Art. 16); sin enlace la bodega muere en minutos; picking en cámara –22 °C inviable con RTT 40–80 ms. *Solo on-premise:*

inadmisibile (Art. 16).

Criterio de selección. Único modelo que satisface Art. 16 en sus 4 numerales; latencia $\leq$ 1 s en cámara resuelta localmente; autonomía 24 h CD / 14 h terreno; TCO contenido con servicios administrados AWS. Normativa: Art. 16.1–16.4, RT-03.01/03.02/03.10/03.19, RNF-02.01/05.01/05.02. Relacionada: Decisión N° 17 del registro de decisiones.

4.4.4 ADR-04 · Persistencia políglota

Decisión adoptada. PostgreSQL+PostGIS (transaccional WMS, CP), Aurora (OLTP cloud + DRP), DynamoDB (IoT raw, AP, TTL 30 d), S3+Redshift Serverless (OLAP + series de temperatura), S3 Object Lock/Glacier (retención legal por dominio de datos, de 5 a 7 años según la tabla de respaldos). La aplicación accede a PostgreSQL con PDO y el Query Builder de Laravel; las consultas geográficas de M4 usan SQL PostGIS parametrizado sobre índices espaciales GiST, y el esquema evoluciona con migraciones Laravel aditivas. La réplica DMS del WMS alimenta solo un esquema de réplica de lectura; el estado central se actualiza por los eventos de reconciliación, con una clave de origen única por evento.

Alternativas descartadas. *Motor único relacional:* no escala ingesta IoT sin degradar picking (RNF-11.02). *InfluxDB:* segundo motor exótico a operar; serie de tiempo cabe en capa OLAP. *DynamoDB para todo:* no ofrece ACID cross-tabla para reconciliación determinista.

Criterio de selección. Posición CAP declarada por dominio (RT-05.02); 3 motores administrados operables por el equipo de TI del CLIENTE; retención sanitaria D.S. 977/96 con inmutabilidad; RPO $\leq$ 15 min por réplica Aurora. Normativa: RT-05.01/05.02/05.11–15, RNF-09.01/09.02/11.02. Relacionada: Decisión N° 18 del registro de decisiones.

4.4.5 ADR-05 · Mensajería asíncrona

Decisión adoptada. RabbitMQ local por sitio, con colas durables, mensajes persistentes y confirmación de publicación, como buffer de 24 h. Un shipper PHP con el adaptador AMQP php-amqp publica cada evento como sobre JSON canónico y versionado en una cola SQS FIFO de reconciliación, por HTTPS hacia un VPC Endpoint, y solo retira el mensaje local cuando SQS confirma la recepción. Un consumidor PHP dedicado lee esa cola con el SDK de AWS, valida el esquema del sobre, lo aplica y confirma solo después de persistir el resultado. Los trabajos internos de Laravel usan colas SQS distintas, de modo que ningún sobre externo llega al deserializador de trabajos del framework. IoT

Core MQTT mantiene la ingesta del borde. Estado: propuesta.

Alternativas descartadas. *REST síncrono*: no sobrevive un corte a mitad de ventana y rompe la reconciliación. *Kafka/MSK*: operar clústeres en cinco sitios es desproporcionado para el equipo disponible y 105 TPS. *Una sola cola SQS para eventos y trabajos*: acopla el formato externo al serializador del framework e impide versionar el sobre. *Redis y Horizon en los sitios*: agregan un tercer motor local sin mejorar la durabilidad que ya dan PostgreSQL y RabbitMQ. *Workers Celery*: correspondían al backend Django y se retiran con él.

Criterio de selección. Resiliencia offline (buffer local y reproducción idempotente); reconciliación determinista (RT-03.12); independencia del formato respecto del lenguaje; Zero Trust (todo saliente); costo total proporcional al volumen. Normativa: RT-02.06/02.07, RT-03.10/03.12, RNF-07.01/13.01, Art. 21.

Consecuencias. La cola FIFO agrupa el orden por sitio y agregado de negocio, deduplica por el identificador del evento, usa una visibilidad de 60 s, cinco intentos antes de la cola de mensajes fallidos y una retención de 4 días; la base central guarda la clave de origen de cada evento aplicado para impedir su doble aplicación. El consumidor acepta la versión vigente del sobre y la anterior. Las alarmas vigilan la edad del mensaje más antiguo, la profundidad por grupo y los mensajes fallidos.

Evidencia exigida. Prueba de corte de 24 h por sitio con drenaje completo sin pérdida ni duplicados, dentro de las 2 h comprometidas; prueba de mensajes duplicados, fuera de orden y de versión desconocida.

4.4.6 ADR-06 · Identidad híbrida (Modelo B)

Decisión adoptada. Keycloak IdP maestro en AWS (ECS Fargate, 2 tareas Multi-AZ, backend Aurora) + caché local solo lectura (TTL 24 h, igual a la autonomía del CD) en Talca, Concepción y los cross-docking, con un verificador local en el mismo nodo que, en cada relevo de turno sin enlace, valida el manifiesto de turno firmado por Keycloak y un segundo factor local: el PIN personal sobre el terminal enrolado por MDM. La caché de 24 h y la credencial de turno cumplen propósitos distintos: la caché conserva los datos de identidad y de turno recibidos y no emite sesiones, mientras que la credencial de turno —hasta 8 h en bodega y 14 h en reparto— limita cuánto dura el acceso de una persona; así, un corte de 24 h cubre dos relevos en bodega, cada uno habilitado por el verificador. Durante el corte no se promete revocación remota inmediata. El backend Laravel valida los JWT OIDC de Keycloak —firma con las claves publicadas, emisor, audiencia, vencimiento y alcance— y aplica políticas por recurso, turno, ruta, sitio y

empresa; no se incorpora Sanctum ni Passport como segundo emisor de identidades. OTP para conductores externos.

Alternativas descartadas. *IdP solo nube*: paraliza bodega ante corte. *AD maestro local*: duplica administración, crea maestro a promover en DR. *Keycloak maestro local*: nube no puede autenticar si el enlace cae.

Criterio de selección. Autonomía offline sin maestro local a promover; autoridad única en nube; OTP sin correo para externos (RT-12.12); MFA Art. 22; operado por el equipo reducido del CLIENTE sin directorio propietario. Normativa: RT-12.10/12.11/12.12, RT-03.10, RNF-13.01, Art. 22, RF-15.01-05, RF-06.08. Relacionada: Decisión N° 34 del registro de decisiones.

4.4.7 ADR-07 · Movilidad de terreno

Decisión adoptada. App nativa Android Kotlin para preventa, reparto y picking. SQLite/Room, SDK Zebra DataWedge (GS1 + QR), impresión BT (ZQ620), POS PAX. Dispositivos Rugged: EC55, TC58e, MC9400 Cold Storage.

Alternativas descartadas. *PWA*: no controla SDK Zebra de forma fiable ni persiste turno completo sin capa nativa. *Híbrida Flutter*: runtime intermedio degrada interacción con periféricos industriales.

Criterio de selección. Control nativo de periféricos (DataWedge intents); offline total 14 h con sincro < 10 min; UI para guantes –22 °C, una mano, lluvia; curva de aprendizaje ≤ 2 h; un artefacto para 3 perfiles. Normativa: RT-13.08, RT-12.11, RT-03.19, RNF-05.02/05.03/06.01, RF-06.11-13. Relacionada: Decisión N° 19 del registro de decisiones.

4.4.8 ADR-08 · Destino del WMS legado 2013

Decisión adoptada. Reemplazo total en Etapa 1 por módulo WMS del monolito (ADR-01): Talca maestro, Concepción edge, cross-docks sobre E-01. Migración por dominio, oleadas por sitio, reversión azul-verde. Durante la coexistencia cada operación tiene un único escritor autorizado, de modo que el WMS de 2013 y el nuevo nunca escriben a la vez stock, cobros o documentos tributarios; la reversión devuelve el tráfico al escritor anterior solo tras detener el nuevo y conciliar los pendientes.

Alternativas descartadas. *Mantener e integrar*: proveedor desaparecido, sin soporte;

no soporta multi-sitio, picking FEFO (primero en expirar, primero en salir), SSCC GS1 ni conteo cíclico ciego. *Extender a otros sitios*: arrastra riesgo de soporte inexistente en ventana crítica.

Criterio de selección. Requisitos RF-02.x que el WMS 2013 no contempla; riesgo operacional inaceptable; TCO amortizado con reducción conteo 2,3 %→~0,3 % y merma 1,7 %→<1 %; reversión azul-verde garantizada. Normativa: RT-05.11-15, RT-03.10, RNF-02.01/05.01, Caso 16.1 N° 14. Relacionada: Decisión 16.1 N° 14 (delegada por el CLIENTE).

4.4.9 ADR-09 · Estrategia DR

Decisión adoptada. Activo-pasivo warm standby multi-región: DMS CDC desde los sitios hacia Aurora y Aurora Global Database hacia us-east-1; DRP local Talca→Concepción (RTO +1-2 h); pruebas 2×/año; respaldo 3-2-1-1-0 con S3 Object Lock.

Alternativas descartadas. *Activo-activo*: duplica infraestructura y exige reconciliación de doble escritura sin beneficio medible. *Backup + restore frío*: RTO 24-72 h, incumple RNF-20.06. *Solo intrarregional*: degrada el objetivo de continuidad, porque ante la caída de la región el RTO sería de 24 a 72 h; se descarta y la recuperación en us-east-1 queda declarada de forma incondicional.

Criterio de selección. $RTO \leq 4 \text{ h}$ / $RPO \leq 15 \text{ min}$; proporcionalidad al volumen; DR de identidad resuelto en nube (ADR-06); pruebas semestrales reales. Normativa: RT-07.01/07.07, RNF-20.06/20.07, Art. 20. Relacionada: Decisión N° 27 del registro de decisiones.

4.4.10 ADR-10 · Almacenamiento on-premise y RAID

Decisión adoptada. RAID 10 NVMe en los nodos del clúster de Talca y RAID 10 sobre las cuatro bahías del servidor de Concepción; RAID 6 en el NAS de respaldo local D-05; la evidencia de entrega vive en S3; hipervisor Ceph N+1.

Alternativas descartadas. *RAID 5*: probabilidad de URE durante rebuild en discos 8-16 TB; solo tolera 1 fallo. *RAID 1 puro para todo*: sobre-coste 50 % aplicado a datos no críticos sin beneficio proporcional.

Criterio de selección. IOPS deterministas en ventana de despacho (>100 K vs. ~840 necesarios); tolerancia a fallo de disco (RNF-13.04) con justificación (RNF-13.05);

TCO contenido con RAID 10 solo en lo transaccional. Normativa: RT-03.14, RNF-13.03/13.04/13.05. Relacionada: Decisión N° 28 del registro de decisiones.

4.4.11 ADR-11 · Integración B2B/EDI canal moderno

Decisión adoptada. Hub EDI centralizado GS1 (EANCOM/GS1 XML + EPCIS) en nube, con conector configurable por cadena, equivalencias GTIN (RF-12.03), bandeja de excepciones (RF-12.06) y ACL hacia ERP/GDE. La transformación y las reglas corren en el perfil EDI de Laravel; el transporte AS2 lo presta AWS Transfer Family, que firma, cifra, gestiona los certificados y emite y recibe los acuses MDN, y entrega los mensajes al perfil EDI por un contrato versionado. Canal moderno operativo ≤ enero 2029. Estado: propuesta.

Alternativas descartadas. *Punto-a-punto por cadena:* multiplica adaptadores; mantenimiento desproporcionado ante cambios de cadena. *EDI delegado al ERP:* expone frontera frágil; viola Zero Trust (escritura directa desde cadena). *Conector AS2 en una biblioteca PHP:* no hay una implementación validada contra las cadenas; se mantiene como alternativa solo si supera las mismas pruebas de interoperabilidad.

Criterio de selección. Estandarización GS1 (Cap. 16.2); esfuerzo marginal por cadena nueva; aislamiento ERP por ACL (Zero Trust); transporte AS2 administrado para un equipo de cuatro personas; plazo enero 2029. Normativa: RT-05.23, RT-16.16/16.17, RNF-12.01, RF-12.03/12.06. Relacionada: RF-12, RF-01.10.

Evidencia exigida. Prueba de interoperabilidad AS2 con cada cadena —firma, cifrado, certificados y MDN— antes de habilitarla, como condición de aceptación del canal moderno.

4.4.12 ADR-12 · Absorción del peak de septiembre

Decisión adoptada. Cómputo elástico con escalado independiente por perfil: API con PHP-FPM de 2 a 4 tareas en el peak y techo de 8, por procesos ocupados sobre 70 %; consumidor de reconciliación de 2 a 4 tareas, por la edad del mensaje más antiguo; trabajos de 2 a 4 tareas, por la profundidad de cada cola, con `erp-sync` fijo en 2 procesos para no saturar el ERP; planificador en una sola tarea. Lambda 100→500, Aurora large→xlarge (escritor y 2 lectores en 3 zonas), DynamoDB bajo demanda. Escala predictiva y reactiva. Base con Savings Plans, peak con cómputo efímero. Estado: propuesta.

Alternativas descartadas. *Capacidad fija al peak:* paga 12 meses la capacidad de 3 semanas. *Solo escala reactiva:* el peak de septiembre es predecible y la reactiva sola introduce retardo en la ventana crítica. *Trasladar las cifras del backend anterior (6 tareas de aplicación y 4 de workers Celery):* eran supuestos de otro runtime y no valen para PHP-FPM.

Criterio de selección. Perfil no plano al peak $\times 1,5$ (RNF-19.04); cuello de botella identificado (RT-09.05); FinOps (RT-03.06): base reservada y peak efímero; congelamiento del 1 al 25 de septiembre y de diciembre (RT-10.05). Normativa: RT-09.05, RT-03.06/03.08/03.09, RNF-19.01-04, RT-10.05. Relacionada: Decisión N° 30 del registro de decisiones.

Consecuencias. El número de tareas se deriva de dos supuestos declarados en el dimensionamiento —50 ms de CPU y 150 ms de residencia por solicitud— y no de una medición; las conexiones a PostgreSQL quedan acotadas por el número de procesos de cada perfil.

Evidencia exigida. Prueba de carga en Preproducción que mida el consumo real por solicitud y por sobre, la saturación de PHP-FPM, las conexiones, la edad de las colas y el rendimiento del ERP; si difieren de los supuestos, se recalculan tareas y procesos antes del paso a producción.

4.4.13 ADR-13 · Puerta de enlace de servicios

Decisión adoptada. Amazon API Gateway como Capa 3 en la nube, complementada en cada sitio por la puerta de API local del WMS para operar sin enlace: autorizador OIDC (Keycloak), validación de esquema OpenAPI, cuotas y límites de tasa por actor/ruta, versionado /v{major}, propagación de transaction_id a Capa 8.

Alternativas descartadas. *Kong autoadministrado:* agrega componente crítico a parchar en ruta de la venta; riesgo en ventana 05:30-07:00 con el equipo disponible. *Desarrollo propio (middleware de la aplicación):* sin cuotas ni límites de tasa administrados en el borde; viola Art. 21.2. La validación del token en el backend Laravel complementa a la puerta de enlace y no la reemplaza (ADR-06).

Criterio de selección. Cumplimiento literal Art. 21.2 sin desarrollo propio; servicio administrado para 4 personas; coherencia entre vistas (Art. 16.4); reversibilidad por contratos OpenAPI/AsyncAPI estándar. Normativa: Art. 21.2, RT-02.01/02.02, RT-11.11, RT-05.16/05.18, Art. 16.3.

4.4.14 ADR-14 · Plataforma de observabilidad

Decisión adoptada. Plataforma única en nube: instrumentación con OpenTelemetry para PHP y Laravel y para las aplicaciones Kotlin, con el `transaction_id` propagado por HTTP, RabbitMQ, SQS y la capa anticorrupción; métricas propias por perfil (procesos PHP-FPM ocupados, reinicios, profundidad y edad de cola por grupo, mensajes fallidos, latencia del ERP y de escritura de VM-02); colectores ADOT on-premise con buffer 24 h, logs en CloudWatch Logs (12+24 m), métricas en CloudWatch Metrics (13 meses) y trazas en CloudWatch con retención declarada. Tableros nativos de CloudWatch para operación. Estado: propuesta.

Alternativas descartadas. *Prometheus+Grafana+Loki local + cloud*: dos plataformas (viola Art. 16.4 y RT-03.16); VM-06 sin capacidad. *AMP + X-Ray + Grafana*: cuatro servicios de observabilidad para un equipo de 4 personas; complejidad operativa desproporcionada sin ganancia funcional sobre CloudWatch nativo.

Criterio de selección. Art. 16.4 y RT-03.16 piden una plataforma; buffer ADOT resuelve «sin puntos ciegos» durante corte; ninguna decisión 05:30–07:00 depende de tablero; CloudWatch es nativo de AWS y no requiere infraestructura adicional; el equipo del CLIENTE no opera servidores de observabilidad. Normativa: Art. 16.4, RT-03.16, RT-14.01–09, RT-09.01.

4.4.15 ADR-15 · Gestión de secretos

Decisión adoptada. AWS Secrets Manager (secretos con rotación: ERP, SII, Transbank, certificados AS2/EDI) + SSM Parameter Store (config no sensible). Consumo outbound por VPC Endpoint. Cifrado CMK KMS, separación de funciones. Cuenta de emergencia en sobre sellado offline.

Alternativas descartadas. *HashiCorp Vault autoadministrado*: modo sellado tras reinicio exige intervención humana de madrugada; agrega infraestructura. *Sin gestor centralizado*: prohibido por Art. 21.4.

Criterio de selección. Servicio administrado sin desellado manual; Zero Trust (consumo outbound); separación de funciones Art. 21.2 vía IAM/CloudTrail; contingencia offline independiente de la nube. Normativa: Art. 21.4/21.2, Art. 16.2/16.3, RT-04.09, RT-11.09.

Formulario T- 11: Especificaciones técnicas ofertadas

Este formulario detalla los componentes de infraestructura, plataforma, licenciamiento y hardware especificados para la solución, con su ubicación, su cantidad y su justificación, conforme al Formulario T-11 de las Bases Administrativas. Acompaña al Subdocumento 4 (Arquitectura lógica y física de la solución): su resumen y análisis están en el apartado 4.2.6 de ese subdocumento, y los servicios de nube se agrupan por función en su apartado 4.2.2. El equipamiento físico lo adquiere el CLIENTE, y el adjudicatario lo especifica, instala, integra y mantiene (Art. 14.2).

Infraestructura de cómputo y almacenamiento

La Tabla 32 detalla los servidores y el almacenamiento de respaldo de los cinco sitios con cómputo.

Componente	Producto ofertado	Ubicación	Cant.	Justificación
C1 — Servidor del clúster	Servidor de rack de 2U y doble procesador, Dell PowerEdge R7625 o HPE DL385 Gen11: 2 EPYC 9124 de 16 núcleos, 128 GB DDR5 ECC ampliables, RAID 1 para el sistema y RAID 10 con 4 NVMe de 1,92 TB y repuesto en caliente, con bahías para duplicar los discos, 2 puertos de 10 GbE y 2 fuentes de 800 W	CD Talca, gabinete R01	3	Tres nodos iguales dejan capacidad para todas las máquinas virtuales si falla uno (RT-03.14), con doble fuente en circuitos distintos (RT-08.04), y los discos NVMe en RAID 10 superan con holgura las operaciones de disco del peak de septiembre; el crecimiento de 3 veces se absorbe agregando discos y memoria en el mismo nodo.
C2 — NAS de respaldo local	NAS con bloqueo de escritura WORM y cifrado de disco	CD Talca, gabinete R01	1	Es la copia local de recuperación rápida del esquema 3-2-1-1-0: restaura el WMS en hasta 4 h sin depender del enlace (RNF-20.06), y complementa la copia inmutable en nube sin reemplazarla.

Tabla 32 — continuación

Componente	Producto ofertado	Ubicación	Cant.	Justificación
C3 — Servidor de Concepción	Dell PowerEdge R250 con Xeon E-2300 de 8 núcleos y 16 hilos (por ejemplo, E-2378) o HPE ProLiant DL20 Gen11 con Xeon E-2400 de 8 núcleos y 16 hilos (por ejemplo, E-2478); 32 GB ampliables a 128 GB; RAID 10 sobre las 4 bahías con discos SSD de 1,92 TB (sin repuesto en caliente)	CD Concepción, gabinete de borde	1	Sostiene el WMS de Concepción con 24 h de operación autónoma y la promoción controlada de su motor de almacenes ante una contingencia de Talca (RNF-02.01, RT-07.02), dimensionado a su propia bodega según la tabla de máquinas virtuales de Concepción del Subdocumento 4 (apartado 4.2.5). Fuente única declarada como punto único de falla aceptado (RT-02.11).
C4 — Nodo de cross-docking	Mini-PC industrial Advantech ARK-2250 o equivalente de rango industrial: Intel Core i5 o i7, 16 GB y NVMe de 512 GB	Curicó, Chillán y Los Ángeles	3	Opera en naves sin climatización, con un supuesto de diseño de hasta 50 °C en verano, y sin fibra (RT-03.17); se conecta a la nube y a Talca a través del firewall del sitio (C15b). Alimentación de entrada única: punto único de falla aceptado (RT-02.11), cubierto por la operación local de la ventana.

Tabla 32 Formulario T-11: infraestructura de cómputo y almacenamiento

Red y seguridad

La Tabla 33 detalla los equipos de red, los enlaces y la VPN.

Componente	Producto ofertado	Ubicación	Cant.	Justificación
C5 — Firewall y Customer Gateway	Clúster activo/pasivo de firewalls UTM de grado empresarial con sincronización de sesiones, D-01	CD Talca, gabinete R02	2	El sitio principal no admite un perímetro de equipo único (RT-08.03): la unidad pasiva asume direcciones y túneles en menos de 30 s, en circuitos eléctricos distintos (RT-08.04). Es el punto de terminación de la VPN Site-to-Site.
C6 — Switch core	Cisco Catalyst 9300-48P o equivalente en stack, con doble fuente, D-02	CD Talca, gabinete R02	2	Los dos equipos forman un único plano de distribución, de modo que la falla de uno no interrumpe el tráfico (RT-08.03), y cada uno tiene doble fuente (RT-08.04).
C7 — Switch de gestión	Switch de capa 2 para la VLAN de gestión	CD Talca, gabinete R02	1	Aísla los puertos de administración de los servidores en una VLAN dedicada con MFA, y permite recuperar los equipos aunque la red de producción esté caída.

Tabla 33 — continuación

Componente	Producto ofertado	Ubicación	Cant.	Justificación
C7b — Con- sola KVM	Consola KVM de 1U	CD Talca, rack R01 (U24)	1	Da acceso local a la consola de los tres no- dos y de la NAS del rack de servidores, sin co- nectar monitor y teclado a cada equipo.
C8 — Distri- bución hori- zontal	Paneles de fibra OM4 y cobre Cat6A certificado	CD Talca, racks R01 y R02	1	Cableado certifica- do enlace por enlace (RT-06.04), con dos ductos de ingreso in- dependientes a la sala (RT-06.32).
C9 — Red inalámbrica industrial	Puntos de acceso Wi-Fi 6E industriales en la VLAN de operaciones, con estudio de cobertu- ra en bodega y cámara	Bodegas de Talca y Concepción	9	Da cobertura a 120 terminales en Talca y 30 en Concepción, con segmentación por tipo de dispositivo y cobertura verificada dentro de las cámaras (RT-03.23).
C10 — Enlace principal	Fibra óptica simétrica: Talca de 20 a 50 Mbps y Concepción de 10 a 20 Mbps, D-03	CD Talca y CD Concep- ción	2	Dimensionado sobre la replicación de la base, el vuelco de los brokers y la telemetría, de unos 0,2 Mbps en promedio, y sobre el respaldo se- manal a la nube, de 40 a 120 GB en la ventana nocturna, unos 33 Mbps (RT-03.20); los valores cubren el crecimiento de 3 veces sin rediseño (RT-09.03).

Tabla 33 — continuación

Componente	Producto ofertado	Ubicación	Cant.	Justificación
C11 — Enlace de respaldo	LTE empresarial con SIM dedicada: Talca de 5 a 10 Mbps, Concepción de 3 a 5 Mbps y cross-docking de 2 a 5 Mbps con dos proveedores, D-04	CD Talca, CD Concepción y los tres cross-docking	5	Evita depender de un solo camino o proveedor (RT-03.17), con conmutación en menos de 30 s: en los centros de distribución respaldada a la fibra y en los cross-docking respaldada a Starlink.
C12 — VPN	AWS Site-to-Site VPN IPsec IKEv2 con BGP sobre Transit Gateway	Talca, Concepción y los tres cross-docking hacia sa-east-1, y hacia us-east-1 en la conmutación de región	2 túneles por sitio	Replica la base, sincroniza los brokers y transmite telemetría cifrado y con enrutamiento dinámico (RT-03.21), con una MTU de túnel de 1.436 bytes.
C13 — Firewall de borde	Firewall de borde de grado empresarial, D-01	CD Concepción, gabinete de borde	1	Es el Customer Gateway del túnel hacia AWS y conmuta entre fibra y LTE en menos de 30 s (RT-03.17). Equipo único por la topología de borde: punto único de falla declarado (RT-02.11), cuya contingencia es la operación autónoma de 24 h; su fuente única se declara con el mismo fundamento.

Tabla 33 — continuación

Componente	Producto ofertado	Ubicación	Cant.	Justificación
C14 — Switch de borde	Cisco Catalyst 9300 o equivalente, con doble fuente, D-02	CD Concepción, gabinete de borde	1	Sostiene la red de bodega del sitio secundario durante 24 h de autonomía, sin depender del sitio principal. Equipo único por la tipología de borde: punto único de falla declarado (RT-02.11).
C15 — Switch de cross-docking	Netgear GS308E o equivalente, de 8 puertos Gigabit gestionables, D-02	Curicó, Chillán y Los Ángeles	3	Equipo compacto para una nave sin sala técnica: conecta el mini-PC, el firewall, los escáneres y los terminales. Fuente externa única: punto único de falla aceptado (RT-02.11).
C15b — Firewall de cross-docking	Firewall compacto de grado empresarial con IPsec IKEv2, BGP y módem LTE Cat-12 de doble SIM, D-01	Curicó, Chillán y Los Ángeles	3	Es el Customer Gateway del sitio: termina Starlink como enlace principal y LTE de dos proveedores como respaldo, conmuta en menos de 30 s (RT-03.17) y evita exponer el sitio o Talca a Internet (Art. 21). Fuente única: punto único de falla aceptado (RT-02.11), cubierto por la operación 100 % local de la ventana.

Tabla 33 Formulario T-11: red y seguridad

Dispositivos de terreno y de operación

La Tabla 34 detalla los dispositivos que usan las personas en la calle, en la bodega y en la cadena de frío.

Componente	Producto ofertado	Ubicación	Cant.	Justificación
C16 — Terminal de pre-venta	Zebra EC55: Android, IP67, uso con guantes y lector 2D SE4100	Preventistas en cuatro regiones	62 más 20 %	Opera sin señal, dura la jornada con una carga, funciona con guantes y su pantalla se lee a pleno sol (RT-08.11).
C17 — Terminal de reparto	Zebra TC58e: 5G, lector SE55, batería de 7.000 mAh, GPS L1/L5, IP65/68 y -30 °C	42 conductores propios y cerca de 160 externos	200 más reserva	Un solo modelo para conductores propios y externos: mismo repuesto, misma capacitación y misma integración.
C18 — Impresora de cabina	Zebra ZQ620 Plus: 3 pulgadas, ZPL, IP54 y Link-OS	Una por conductor	200	Imprime la evidencia de entrega y los comprobantes en la cabina, con batería de reemplazo.
C19 — Terminal de pago	PAX A920 Pro: Android 14, PCI PTS 7.x y EMV L1/L2	Una por conductor	200	Cobra con tarjeta en el local del cliente con certificación PCI PTS y EMV, integrado por Bluetooth con la aplicación de reparto.
C20 — Terminal de cámara	Zebra MC9400 Cold Storage Freezer: -30 °C, lector SE58 de 100 pies, batería de 5.000 mAh y Wi-Fi 6E	Talca 144 y Concepción 30	174	Prepara pedidos en la cámara a -22 °C con guantes gruesos, lee a distancia y recambia la batería en caliente (RT-08.11, RT-08.12, RT-13.08).

Tabla 34 — continuación

Componente	Producto ofertado	Ubicación	Cant.	Justificación
C21 — Im- presora de andén	Zebra ZT411: 203 dpi, 14 ips, Ethernet y ZPL	Talca 4 y Concepción 2	6	Imprime la etiqueta SSCC GS1 - 128 al ar- mar la unidad logística (RF-01.07), legible a lo largo de toda la cadena (RT-05.23).
C22 — Balan- za de recep- ción	Dibal BEV con plata- forma ME e indicador DMI-610 inoxidable, RS-232 y Ethernet	Talca 2 y Concepción 1	3	Captura el peso de re- cepción en línea hacia el WMS (RF-01.01), sin digitación, con calibra- ción certificada.
C23 — Escáner de cross-docking	Zebra DS2208: 1D, 2D y GS1 DataBar, garantía de 60 meses	Curicó, Chi- llán y Los Ángeles	6	Lee los códigos GS1 en la desconsolidación y el re-despacho; dos por plataforma cubren dos muelles simultáneos.
C24 — Sensor de tempera- tura	Módulo Ebyte ME31-XDXX0400: 4 canales PT100, Mod- bus RTU/TCP, de -40 a +85 °C, con sondas de 3 hilos	Cámaras de Talca y Concepción	7 módulos, 28 puntos	Alimenta el registro continuo de la cadena de frío, con una exacti- tud de $\pm 1,1$ °C a -22 °C que distingue una ex- cursión real de la varia- ción del instrumento.

Tabla 34 — continuación

Componente	Producto ofertado	Ubicación	Cant.	Justificación
C25 — Termógrafo de camión	Onset InTemp CX450: Bluetooth, de -30 a +70 °C con $\pm 0,5$ °C y calibración NIST en dos puntos	Camiones con equipo de frío: 18 propios y 10 de transportistas	28	Registra la temperatura del transporte de forma independiente y sin conexión durante toda la ruta; alerta la excursión térmica en el terminal del conductor y, al volver, descarga el registro completo por Bluetooth a ese terminal, que lo envía a la nube. Los 10 camiones refrigerados de los transportistas se instrumentan con el mismo equipo, porque el termógrafo va con la carga y no depende del dueño del vehículo.
C26 — Estación de trabajo	PC i5 o i7, 16 GB, SSD NVMe de 512 GB cifrado y 2 monitores de 24 pulgadas	Talca 5 y Concepción 3	8	Puestos de despacho, administración, planificación, calidad y TI (RNF-23.04), con disco cifrado gestionado desde el EDR y doble monitor (RT-08.08).
C27 — Kit satelital	Starlink Enterprise fijo, antena en techumbre y router, plan de 500 GB al mes durante los 56 meses del contrato, D-06	Curicó, Chillán y Los Ángeles	3	Es el enlace principal de los cross-docking, que no tienen fibra, con LTE como respaldo automático (RT-03.17, RT-08.13); reposición de hardware estimada en 15 % durante el contrato.

Tabla 34 — continuación

Componente	Producto ofertado	Ubicación	Cant.	Justificación
C28 — Gate-way IoT	Gateway industrial con Linux, Moxa UC-8200 (Moxa Industrial Linux 3, Debian 11) o equivalente listado en el AWS Partner Device Catalog, con AWS IoT Greengrass V2, 2 puertos Gigabit Ethernet, 2 puertos serie RS-232/422/485, doble entrada de alimentación redundante de 12 a 48 VDC y operación de -40 a 85 °C, B-02	CD Talca y CD Concepción	2	Lee los módulos de temperatura por Modbus, detecta la excursión térmica y bloquea el despacho en el borde, con un buffer local de 24 h si cae el enlace, igual a la autonomía del centro de distribución.

Tabla 34 Formulario T-11: dispositivos de terreno y de operación

Infraestructura de la sala técnica de Talca

La Tabla 35 detalla la infraestructura de la sala técnica secundaria del CD Talca. Las especificaciones y los cálculos eléctrico y térmico del recinto se desarrollan en el apartado 4.3.1 del Subdocumento 4.

Componente	Producto ofertado	Ubicación	Cant.	Justificación
D1 — UPS	Modular de 10 kVA, doble conversión en línea, en N+1 y con bypass de mantenimiento	Zona de UPS y baterías (plano RT-06.03)	1	Dimensionado sobre la carga TI de diseño de 7,0 kW y $\approx 7,4$ kVA aparentes (factor de potencia 0,95), al 80 % de utilización, $\approx 9,2$ kVA (RT-06.11); autonomía de 30 min o más a plena carga (RT-06.07).
D2 — Generador	Grupo electrógeno de 15 kVA con estanque para 24 h continuas y contrato de reabastecimiento declarado	Exterior, junto a la acometida (zona de generadores del plano RT-06.03)	1	Sostiene la carga total del sitio, $\approx 10,4$ kW entre TI, climatización y apoyo, durante 24 h o más (RT-06.08).
D3 — Transferencia automática	Transferencia red-generador con tablero de protecciones	Acometida, accesible desde el exterior	1	Encadena empalme, tablero, transferencia, UPS, PDU y equipo sin interrupción (RT-06.07); se prueba cada mes con carga real y admite termografía (RT-06.10).
D4 — Climatización	2 unidades de precisión de 10 kW (≈ 34.000 BTU/h) en N+1	Zona de climatización, contigua a la sala de servidores y comunicaciones	2	Cubren la carga térmica sensible de diseño, $\approx 7,6$ kW, aun con la pérdida de una unidad, dentro de los rangos del fabricante (RT-06.13, RT-06.11).

Tabla 35 — continuación

Componente	Producto ofertado	Ubicación	Cant.	Justificación
D5 — Distri-bución eléc-trica	2 PDU verticales A/B por gabinete, con medi-dor	Racks R01 y R02	4	Dos caminos eléc-tricos por gabinete (RT-08.04); el medi-dor es el denominador de la PUE (RT-06.10, RT-15.04).
D6 — De-tección de incendio	Detección temprana por aspiración con tecnolo-gía láser, tipo AnaLASER o equivalente	Sala de ser-vidores y comunica-ciones	1	Detecta antes de que exista llama visible (RT-06.16) e integra el monitoreo en línea (RT-06.19).
D7 — Extin-ción	Agente limpio tipo FM-200 o equiva-lente, con aprobación UL, botón de aborto y extintores portátiles habilitados	Sala de ser-vidores y comunica-ciones	1	Extinción automática sobre equipos energí-zados (RT-06.17) y ex-tintores con mantención vigente (RT-06.18).
D8 — Control de acceso	Biometría facial con AFIS como respaldo, esclusa antipassback con nueva verificación, bitácora electrónica y estación de enrolamien-to interna y externa	Acceso del recinto téc-nico	1	RT-06.20 a RT-06.23; bitácora auditable con-servada 5 años o más (RT-06.21, RT-16.10).
D9 — Video-vigilancia	Cámaras IP con imá-genes en línea de 30 días o más y respaldo recuperable	Recinto y perímetro	Según plano RT-06.03	Cubre el acceso y el perímetro del recinto, integrada al monitoreo (RT-06.24).
D10 — Recin-to de custodia	Recinto con iluminación sin UV de hasta 300 lux, 40 a 60 % HR, venti-lación forzada y 18 a 27 °C	Área de res-paldo del re-cinto (plano RT-06.03)	1	Conserva los medios de respaldo sin degradarlos (RT-06.26, RT-06.27).

Tabla 35 — continuación

Componente	Producto ofertado	Ubicación	Cant.	Justificación
D11 — Gabi- netes	R01 servidores (3 no- dos 2U en U18-U23, NAS 2U en U1-U2, KVM 1U en U24, pa- neles OM4/Cat6A en U40-U42) y R02 co- municaciones (bandeja del operador con ONT de fibra y router LTE, 2U en U31-U32; 2 fire- walls 1U en U33-U34; switch de gestión 1U en U35; organizadores 1U en U36 y U39; 2 con- mutadores de núcleo 1U en U37-U38; ODF y paneles en U40-U42), 42U	Sala de ser- vidores y comunica- ciones	2	Racks de servidores independientes de los racks de comunicacio- nes (RT-06.05); ocupa- ción proyectada R01 y R02 de 12U/42U (29 %) cada uno, con 30U li- bres por rack para el margen de crecimiento a tres años, coherente con la reserva eléctri- ca del 20 % de la Tabla 4.3-1 (Figura 4.3-2)
D12 — Pi- so técnico y cableado	Cableado Cat6A y fi- bra OM4 certificados por enlace, sobre piso técnico	Sala	1	Cumple la norma por enlace (RT-06.04) con recorridos verificados para 10 GbE.

Tabla 35 Formulario T-11: infraestructura de la sala técnica de Talca

Gabinets de borde

La Tabla 36 detalla los gabinetes de borde del CD Concepción, sitio secundario del dominio on-premise, y de las tres plataformas de cross-docking, conforme a la tipología que fija el caso (RT-06.01) y al numeral 6.1 de las Transversales.

Componente	Producto ofertado	Ubicación	Cant.	Justificación
G1 — Gabinete de borde de Concepción	Gabinete industrializado con alimentación protegida (UPS y respaldo) para la autonomía declarada	CD Concepción	1	Sitio de recuperación del dominio on-premise, a $\approx$ 200 km de Talca en línea recta y 250 km por carretera (RT-07.02); opera de forma autónoma todos los días (RT-06.01 del caso; numeral 6.1).
G2 — Climatización del borde	Climatización de precisión acorde al equipamiento del borde	CD Concepción, gabinete de borde	1	Dimensionada al equipamiento real del borde, conforme a la tipología del numeral 6.1.
G3 — Control de acceso y monitoreo del borde	Acceso controlado y monitoreo remoto integrado al NOC	CD Concepción, gabinete de borde	1	Aplica la tipología de borde operacional del numeral 6.1 con supervisión remota del sitio.
G4 — Gabinete de borde de cross-docking	Gabinete de 12U con UPS interna de 30 min o más, cerradura biométrica con registro, sensores de temperatura, humedad y apertura enviados al NOC, y ventilación forzada	Curicó, Chillán y Los Ángeles	3	Cumple en cada plataforma los requisitos del gabinete de borde del numeral 6.1: protección eléctrica, control de acceso físico, monitoreo remoto y condiciones ambientales del equipo.

Tabla 36 Formulario T-11: gabinetes de borde

Plataforma de nube y servicios gestionados

La Tabla 37 detalla los servicios contratados en la plataforma de nube y en servicios gestionados de terceros, ordenados por componente del catálogo.

Componente	Servicio ofertado	Ubicación	Cant.	Justificación
N-01 a N-03 — Portales	S3, CloudFront, AWS WAF, API Gateway y la tarea portal en ECS Fargate	sa-east-1, DMZ pública	1 aplicación para 3 portales	Publica los portales de clientes, transportistas y proveedores sin exponer los sitios del CLIENTE (RT-03.04).
N-04 — Plataforma de aplicación	ECS Fargate, Application Load Balancer, Elastic Container Registry y CodeBuild	sa-east-1 en 2 zonas; réplica reducida en us-east-1	API: 2 a 4 tareas, techo 8; consumidor: 2 a 4; trabajos: 2 a 4; planificador: 1	Ejecuta los perfiles del monolito Laravel en tareas de 1 vCPU y 2 GB, cada uno con su escalado, su rol de IAM y sus métricas; el número de tareas es una estimación que confirma la prueba de carga (ADR-01, ADR-12).
N-04 — Motor de optimización de rutas	Contenedor propio en ECS Fargate, tras un contrato versionado con M4	sa-east-1	1 tarea por corrida, bajo demanda	Calcula la secuencia de rutas de M4 fuera del artefacto PHP; el motor se selecciona por la prueba de rutas en menos de 20 minutos, que es condición de aceptación (ADR-01).
N-04 — Transporte AS2	AWS Transfer Family con conectores y acuerdos AS2	sa-east-1	1 servidor AS2; 1 acuerdo por cadena	Firma, cifra, gestiona certificados y acuses MDN del canal moderno, y entrega los mensajes al perfil EDI; cada cadena se habilita tras su prueba de interoperabilidad (ADR-11).

Tabla 37 — continuación

Componente	Servicio ofertado	Ubicación	Cant.	Justificación
N-05 — Base de datos en nube	Aurora PostgreSQL con Aurora Global Database y AWS DMS	sa-east-1 y us-east-1	1 clúster	Transaccional de los módulos en nube y réplica de lectura del WMS, separada del estado central que actualizan los eventos; conmuta entre zonas en menos de 30 s, con RPO de 15 min, que para la réplica del WMS rige mientras hay enlace (ADR-04, ADR-09).
N-06 — Telemetría cruda	DynamoDB bajo demanda; Global Tables solo para temperatura, y la tabla de posiciones de flota solo en sa-east-1	sa-east-1 y us-east-1	1 tabla por serie	Recibe las lecturas de IoT sin gestión de capacidad y las expira a los 30 días (ADR-04).
N-07 — Caché	ElastiCache for Redis con primario y réplica	sa-east-1 en 2 zonas	1 clúster	Responde la consulta de stock y crédito de preventa en menos de 2 s.
N-08 — Ingesta de IoT	IoT Core, Lambda e IoT Greengrass	sa-east-1 y gateways de borde	2 gateways y 28 terminógrafos	Recibe, valida y alerta la telemetría de cadena de frío, y gestiona la flota de gateways.

Tabla 37 — continuación

Componente	Servicio ofertado	Ubicación	Cant.	Justificación
N-09 — Mensajería	SQS FIFO de reconciliación con su cola de mensajes fallidos; colas SQS de trabajos de Laravel; SNS	sa-east-1	1 cola FIFO con grupos por sitio y agregado; 3 colas de trabajos (notificaciones, exp-sync y EDI), cada una con su cola de fallidos	Reconcilia los sobres JSON de los sitios en orden por grupo y sin duplicados, separa los trabajos internos del formato externo y difunde las alertas de frío (ADR-05).
N-10 — Plataforma analítica	S3, Glue, Redshift Serverless y QuickSight	sa-east-1	1 lago de 5 años	Separa la analítica del transaccional y publica los tableros del CLIENTE.
N-11 — Respaldo y réplica	AWS Backup con Vault Lock, S3 Object Lock y replicación de S3 entre regiones	sa-east-1 y us-east-1	1 política	Mantiene la copia inmutable del esquema 3-2-1-1-0 y la réplica de recuperación (ADR-09). La frecuencia, la retención y el tiempo de restauración por dominio de datos (RT-07.13) son los de la tabla de respaldo y restauración por dominio de datos del Subdocumento 4 (apartado 4.2.3).

Tabla 37 — continuación

Componente	Servicio ofertado	Ubicación	Cant.	Justificación
N-12 — Seguridad y gobierno	KMS, Secrets Manager, Parameter Store, IAM Identity Center, Shield Advanced, GuardDuty, Security Hub, Inspector, Macie, Security Lake, CloudTrail, Config, CloudWatch, Systems Manager, Control Tower, Organizations, Cost Explorer y Budgets	sa-east-1; claves, secretos, CloudTrail, GuardDuty y Config también en us-east-1	8 cuentas: 5 ambientes, gestión, archivo de registros y auditoría	Cumple los controles del Artículo 21 y el gobierno de costos como servicios administrados (ADR-14, ADR-15).
D-01 — Red en nube y terminación de la VPN	VPC, Transit Gateway, Site-to-Site VPN, NAT Gateway, VPC Endpoints y Route 53	sa-east-1 y us-east-1	2 túneles por sitio	Conecta los sitios con la nube sin tráfico de datos por Internet (RT-03.03, RT-03.04).
N-13 — Gestión de dispositivos	Android Enterprise y Zebra DNA como servicio gestionado	Servicio en nube y agente en el dispositivo	Parque de EC55, TC58e y MC9400 de la Tabla 34	Enrola, configura, actualiza y borra de forma selectiva el parque de terreno y de bodega (RT-03.18).
F-03 — Detección en endpoints	Consola EDR gestionada y agentes	Servicio en nube y agente en cada nodo y estación	1 por endpoint	Detecta y responde en nube y on-premise desde una sola consola (RT-11.16).

Tabla 37 Formulario T-11: plataforma de nube y servicios gestionados

Software de base y licenciamiento

La Tabla 38 detalla el software que opera sobre el equipamiento y la plataforma anteriores.

Componente	Producto ofertado	Ubicación	Cant.	Justificación
Aplicación	Monolito modular en Laravel 13 sobre PHP 8.5, con PHP-FPM y PHP CLI, dependencias fijadas por composer.lock y las extensiones pdo_pgsql, mbstring, intl, openssl, opcache, curl, sockets, pcntl y OpenTelemetry; código abierto	Nube, VM-01, VM-C01, VM-03, VM-C04 y E-01	1 imagen firmada	Una sola base de código y de esquema para nube y sitios, ejecutada en perfiles de API, wms_only, shipper, consumidor, trabajos y planificador (ADR-01).
Aplicación de terreno	Aplicación nativa Android en Kotlin, con SQLite y Zebra DataWedge	EC55, TC58e y MC9400	1 artefacto para 3 perfiles	Controla los periféricos industriales y opera un turno completo sin señal (ADR-07).
Portales web	Angular con TypeScript y Tailwind CSS, código abierto	S3 y Cloud-Front, por ambiente	1 aplicación para 3 portales	Publica los portales de clientes, transportistas y proveedores con la identidad OIDC de Keycloak y reutiliza componentes y contratos TypeScript.
Base de datos	PostgreSQL 16 con PostGIS, código abierto	VM-02, VM-C02 y los tres E-01	5 instancias	Registro de la bodega durante los cortes, replicado a Aurora por DMS.
Broker	RabbitMQ, código abierto, con el adaptador AMQP php-amqp-lib	VM-03, VM-C04 y los tres E-01	5 instancias	Buffer de 24 h por sitio con mensajes persistentes y confirmación de publicación; el shipper vacía el buffer hacia SQS FIFO como sobres JSON (ADR-05).

Tabla 38 — continuación

Componente	Producto ofertado	Ubicación	Cant.	Justificación
Identidad	Keycloak, código abierto, con verificador local de relevo de turno	Fargate, VM-05, VM-C03 y los tres E-01	1 maestro, 5 cachés y 5 verificadores	Autoridad única en nube con cachés de solo lectura; el verificador local valida el manifiesto de turno firmado y el segundo factor local, el PIN personal, en los relevos sin enlace (ADR-06).
Virtualización	Proxmox VE con Ceph, código abierto	Clúster de Talca y servidor de Concepción	1 clúster de 3 nodos y 1 nodo	Tolera la pérdida de un nodo sin detener la bodega.
Contenedores en los sitios	Docker y Docker Compose, código abierto	Máquinas virtuales de Talca y Concepción y los tres cross-docking	5 sitios	Ejecutan la misma imagen de la aplicación que la nube; en los cross-docking orquestan además la base, el broker y la caché de identidad, con instalación y parcheo sin dependencia de la red.
Observabilidad de sitio	AWS Distro for OpenTelemetry y agente SSM	VM-06, VM-C04 y los tres E-01	5 colectores	Reciben las trazas y métricas de OpenTelemetry para PHP y las guardan hasta 24 h antes de enviarlas a CloudWatch al reconectar (ADR-14).
Configuración	Ansible y Terraform con CDK, código abierto	Repositorio del CLIENTE	1 repositorio	Infraestructura y configuración declaradas como código versionado.

Tabla 38 — continuación

Componente	Producto ofertado	Ubicación	Cant.	Justificación
Integración y entrega continuas	GitLab CI como orquestador y AWS CodeBuild para la construcción	Pipeline del repositorio del CLIENTE; construcción en sa-east-1	1 pipeline	Instala las dependencias desde composer.lock, ejecuta composer audit, PHPUnit, PHPS-tan/Larastan, Pint y las pruebas de contrato OpenAPI y AsyncAPI, escanea con bloqueo automático (RT-04.05) y construye y firma cada imagen de forma hermética, con procedencia SLSA nivel 3.

Tabla 38 Formulario T-11: software de base y licenciamiento