

LICITACIÓN PÚBLICA

Licitación N.º TFEP-01/2026

Proyecto de Plataforma Digital de Misión Crítica

Caso 02 — Logística

Sobre N.º 2 — Oferta Técnica

Propuesta Técnica

Subdocumento 4 — Arquitectura de la solución

Parte 4.2 — Arquitectura física y de despliegue · Formularios T-7 y T-21

MANDANTE

Distribuidora Puelche S.A.

PROPONENTE

LafroX SpA

RUT 77.418.902-K

Av. Brasil 2241, Valparaíso

REPRESENTANTE LEGAL

Alex Aravena

Jefe de Proyecto y Apoderado

contacto@lafrox.cl

+56 32 250 4100

VERSIÓN	FECHA DE EMISIÓN	ESTADO	TOTAL DE FOLIOS
2.0	05 de octubre de 2026	Versión final para entrega	114

FIRMA DEL REPRESENTANTE LEGAL

Alex Aravena

Jefe de Proyecto y Apoderado · LafroX SpA

Índice general

Índice general	2
Lista de figuras	6
Lista de tablas	7
Arquitectura física y de despliegue de la solución	9
1 Visión general de la arquitectura física	10
4.2 Arquitectura física	11
4.2.1 Emplazamiento de cada componente	11
4.2.1.1 Instalaciones y dominios	12
4.2.1.2 Componentes de nube pura	14
4.2.1.3 Componentes on-premise	16
4.2.1.4 Componentes híbridos	17
4.2.1.5 Autonomía de cada ámbito sin enlace	19
4.2.2 Servicios contratados en la plataforma de nube	20
4.2.2.1 Servicios por función	20
4.2.2.2 Región secundaria y residencia de los datos	22
4.2.2.3 Servicios que no se contratan	22
4.2.2.4 Modelo de contratación	22
4.2.3 Conexiones, puntos de falla y contingencia	23
4.2.3.1 Conexiones entre sitios, terreno y nube	23
4.2.3.2 Puntos de falla en los sitios y en los enlaces	25
4.2.3.3 Puntos de falla en la nube, el terreno y las integraciones	27

4.2.4 Dimensionamiento y plan de capacidad	29
4.2.4.1 Criterios y método	29
4.2.4.2 Volumetría de referencia	29
4.2.4.3 Transacciones por segundo	31
4.2.4.4 Usuarios, concurrencia y dispositivos	32
4.2.4.5 Almacenamiento y datos a migrar	33
4.2.4.6 Integraciones y volumen de mensajes	34
4.2.4.7 Ancho de banda, dispositivos de reparto y sincronización	35
4.2.4.8 Mesa de ayuda y equipo de operación	36
4.2.4.9 Síntesis de las dieciséis dimensiones	37
4.2.4.10 Dimensionamiento on-premise	38
4.2.4.11 Dimensionamiento en nube	40
4.2.4.12 Plan de capacidad y crecimiento de 3 veces	41
4.2.4.13 Umbrales de desempeño	42
4.2.4.14 Primer cuello de botella	43
4.2.4.15 Degradación controlada	44
4.2.4.16 Pruebas de carga y estrés	44
4.2.4.17 Actualización del plan de capacidad	45
4.2.5 Especificaciones Implementos a proveer (Hardware y Software)	45
4.2.5.1 Síntesis del equipamiento por familia	45
4.2.5.2 Criterios de selección	46
4.2.5.3 Software y licenciamiento	47
3 Tecnologías de software ofertadas	48
3.1 Integración con el ERP y documentos tributarios	49
4 Especificaciones del sitio principal on-premise (CD Talca)	50
5 Especificaciones del sitio secundario	54

6 Arquitectura de integración	56
6.1 Vista de integración	56
6.2 Mensajería (ADR-05)	57
6.3 Costuras híbridas: amarre con la arquitectura física	58
6.4 Carga y descarga masiva de datos	59
7 Arquitectura de seguridad	60
7.1 Principios rectores	60
7.2 Modelo Zero Trust aplicado	61
7.2.1 Zonas y flujos	61
7.3 Capa expuesta	61
7.4 Desarrollo seguro y cadena de suministro	62
7.4.1 Superficie de exposición completa	62
7.5 Identidad, acceso y sesiones	63
7.5.1 Modelo de identidad	63
7.5.2 Federación, SSO y factores	64
7.5.3 Política de sesión	64
7.5.4 Autenticación en terreno	64
7.6 Cifrado y gestión de claves	65
7.6.1 En tránsito	65
7.6.2 En reposo	65
7.6.3 Cifrado a nivel de campo	66
7.7 Clasificación de la información y controles por nivel	66
7.8 Detección, respuesta y evidencia	67
7.9 Datos personales, residencia y transferencia internacional	67
7.9.1 Derechos de los titulares, política de privacidad y EIPD	68
7.9.2 Base de licitud por tratamiento	68

8 Arquitectura de despliegue	70
8.1 Ambientes de despliegue	70
8.1.1 Diferencias entre Pre-Producción y Producción	72
8.1.2 Calendario de despliegue	73
8.1.3 Reversión de un paso a producción fallido	74
8.1.4 Métricas del proceso de despliegue	74
8.2 Redes (topología, segmentación y conectividad)	75
8.2.1 WAN — doble camino con conmutación automática	75
8.2.2 VPN Site-to-Site (costura C1)	76
8.2.3 Segmentación de red (sin solapamiento)	76
8.2.4 Zero Trust — flujos permitidos	77
8.2.5 Capa pública (DMZ) y DNS	78
8.2.6 Autonomía y resincronización tras un corte	78
8.3 Alta disponibilidad	79
8.3.1 Clasificación de servicios por criticidad	79
8.3.2 Capa cloud (sa-east-1) — Multi-AZ	80
8.3.3 Niveles de servicio de la infraestructura	81
8.3.4 Cómo se sostiene el 99,9 % de extremo a extremo	82
8.3.5 Capa on-premise	82
8.3.6 Escalamiento y degradación controlada	83
8.3.7 Pruebas de resiliencia con inyección de fallas	83
8.4 Recuperación ante desastres	84
8.4.1 Modalidad, objetivos y mecanismo por dominio de datos	84
8.4.2 Procedimiento de conmutación	85
8.4.3 Emplazamiento de los sitios secundarios y amenazas comunes	87
8.4.4 Componentes del sitio secundario y de la réplica	87
8.4.5 Capacidades durante una contingencia regional	88
8.4.6 Residencia y transferencia internacional de datos	89

8.4.7	DRP local (Talca → Concepción)	90
8.4.8	DRP de la identidad (ADR-06)	90
8.5	Respaldos — esquema 3-2-1-1-0	90
8.5.1	Frecuencia, retención y restauración por dominio de datos	91
8.5.2	Plan AWS Backup	92
8.5.3	Distinción entre réplica y respaldo	93
9	Registro de decisiones de arquitectura	94
9.1	ADR-01 · Estilo arquitectónico	94
9.2	ADR-02 · Conectividad WAN	94
9.3	ADR-03 · Modelo de despliegue híbrido	95
9.4	ADR-04 · Persistencia políglota	95
9.5	ADR-05 · Mensajería asíncrona	96
9.6	ADR-06 · Identidad híbrida (Modelo B)	96
9.7	ADR-07 · Movilidad de terreno	97
9.8	ADR-08 · Destino del WMS legado 2013	97
9.9	ADR-09 · Estrategia DR	97
9.10	ADR-10 · Almacenamiento on-premise y RAID	98
9.11	ADR-11 · Integración B2B/EDI canal moderno	98
9.12	ADR-12 · Absorción del peak de septiembre	99
9.13	ADR-13 · Puerta de enlace de servicios	99
9.14	ADR-14 · Plataforma de observabilidad	99
9.15	ADR-15 · Gestión de secretos	100
	Anexo — Formulario T-11: Especificaciones técnicas ofertadas	101

Lista de figuras

Figura 1	Ubicación de los componentes por dominio y por sitio	13
Figura 2	Conexiones entre los sitios, el terreno y la nube	24
Figura 3	Plano de distribución interna del recinto técnico, con la separación de las zonas de generador, baterías, climatización, servidores, comunicaciones y custodia de medios	51
Figura 4	Cadena eléctrica del recinto: acometida, transferencia automática, generación autónoma, alimentación ininterrumpida y distribución A/B por gabinete	51
Figura 5	Elevación de los cuatro gabinetes, con la ocupación proyectada de cada uno y el margen de crecimiento reservado en R04	53
Figura 6	Gabinete de borde industrializado del CD Concepción y de las tres plataformas de cross-docking: alimentación protegida, control de acceso y monitoreo remoto dimensionados al sitio (numeral 6.1, tipología de borde operacional)	55

Lista de tablas

Tabla 1	Emplazamiento de los componentes de nube pura	15
Tabla 2	Emplazamiento de los componentes on-premise	17
Tabla 3	Emplazamiento de los componentes híbridos	19
Tabla 4	Autonomía por ámbito ante la pérdida del enlace	20
Tabla 5	Servicios contratados en la plataforma de nube, por función	21
Tabla 6	Conexiones de la solución y su camino alternativo	25
Tabla 7	Puntos de falla en los sitios y en los enlaces	27
Tabla 8	Puntos de falla en la nube, el terreno y las integraciones	28
Tabla 9	Valores base de dimensionamiento	30
Tabla 10	Proyección de la volumetría a tres años	31
Tabla 11	Transacciones por segundo de diseño	32
Tabla 12	Usuarios y terminales concurrentes	33
Tabla 13	Volumen de mensajes por integración	35
Tabla 14	Ancho de banda por sitio	36
Tabla 15	Las dieciséis dimensiones del numeral 14.2 del caso	38
Tabla 16	Utilización del clúster de Talca con un nodo caído	39
Tabla 17	Máquinas virtuales del clúster de Talca	39
Tabla 18	Almacenamiento y rendimiento de la base transaccional	40
Tabla 19	Capacidad de los servicios en nube	41

Tabla 20	Plan de capacidad para el crecimiento de 3 veces	42
Tabla 21	Umbrales de desempeño en percentil 95	43
Tabla 22	Pruebas de carga y estrés	44
Tabla 23	Síntesis del equipamiento a proveer por familia	46
Tabla 24	Mensajería: planos y emplazamiento físico	57
Tabla 25	Costuras híbridas: amarre con la arquitectura física	58
Tabla 26	Superficie de exposición completa (RT-11.13)	63
Tabla 27	Cifrado en reposo por componente	65
Tabla 28	Clasificación de la información y controles por nivel (RT-11.03)	66
Tabla 29	Base de licitud por tratamiento (Ley 21.719, Art. 12 y 13)	69
Tabla 30	Ambientes de despliegue. Fuente: elaboración propia sobre RT-04.01	71
Tabla 31	Calendario de despliegue. Fuente: Caso 02, Cap. 10 (restricción 8) y Cap. 13.3; RT-10.05 y RT-10.06	73
Tabla 32	Métricas del proceso de despliegue. Fuente: RT-04.12; Art. 78.3 de las Bases Administrativas; elaboración propia	75
Tabla 33	Segmentación de red sin solapamiento. Fuente: elaboración propia; RT-02.12 y RT-03.04	76
Tabla 34	Flujos permitidos entre dominios. Fuente: elaboración propia sobre el emplazamiento y la arquitectura de seguridad de este documento	78
Tabla 35	Drenaje del acumulado de 24 h en el peak de septiembre. Fuente: elaboración propia con los volúmenes y enlaces de la sección de dimensionamiento	79
Tabla 36	Clasificación de servicios por criticidad. Fuente: Art. 78.1 y 78.2 de las Bases Administrativas; RT-10.02; Caso 02, RT-09.01	80

Tabla 37 Distribución Multi-AZ en sa-east-1. Fuente: elaboración propia	81
Tabla 38 Pruebas de resiliencia por inyección de fallas. Fuente: RT-10.07 y RT-10.08; elaboración propia	84
Tabla 39 Mecanismo de replicación y RPO por dominio de datos. Fuente: ADR-09; elaboración propia	85
Tabla 40 Secuencia de conmutación regional. Fuente: elaboración propia sobre ADR-09	86
Tabla 41 Distancia y amenazas comunes entre sitios. Fuente: análisis de emplazamiento del proponente; RT-21.16	87
Tabla 42 Componentes del sitio secundario y de la réplica. Fuente: elaboración propia	88
Tabla 43 Capacidades durante una contingencia regional. Fuente: elaboración propia sobre los resguardos de la arquitectura de seguridad	89
Tabla 44 Respaldo y restauración por dominio de datos. Fuente: RT-07.13; Art. 78.2 de las Bases Administrativas; Caso 02, Cap. 15 y Cap. 18	91
Tabla 45 Plan AWS Backup por recurso. Fuente: elaboración propia	92
Tabla 46 Formulario T-11: infraestructura de cómputo y almacenamiento	102
Tabla 47 Formulario T-11: red y seguridad	105
Tabla 48 Formulario T-11: dispositivos de terreno y de operación	108
Tabla 49 Formulario T-11: infraestructura de la sala técnica de Talca	110
Tabla 50 Formulario T-11: plataforma de nube y servicios gestionados	112
Tabla 51 Formulario T-11: software de base y licenciamiento	114

Arquitectura física y de despliegue de la solución

| Parte 4.2 del subdocumento 4. La arquitectura lógica es la parte 4.1 y se entrega por separado; ambas comparten el registro de decisiones y la volumetría, y se leen juntas.

Visión general de la arquitectura física

La arquitectura física materializa el despliegue híbrido obligatorio del Artículo 16° de las Bases Administrativas. La carga principal corre en nube pública AWS, con la región primaria en sa-east-1 (São Paulo, Brasil) y la recuperación ante desastres en us-east-1 (Norte de Virginia, EE. UU.). Los componentes on-premise garantizan la continuidad de la operación de bodega, plataformas y terreno durante cortes del enlace.

La red de instalaciones de la solución son 5 instalaciones en cuatro regiones. La proyección del caso a tres años incorpora una sexta instalación, sin requerir cambios en desarrollo o en crecimiento de servidores en CD Talca.

Los principios que gobiernan el diseño son los siguientes:

- **Carga principal en nube:** El núcleo transaccional de preventa, reparto y canal moderno, la analítica, la integración y el almacenamiento consolidado se ejecutan en AWS sa-east-1, con escalado elástico para el peak de septiembre.
- **Autonomía total de la operación de bodega:** El picking, despacho, recepción y conteo corren siempre contra los servidores del centro de distribución, no contra la nube. La conexión a internet no interviene en la operación de bodega.

Arquitectura física

La arquitectura física declara dónde vive cada componente de la solución, qué servicios se contratan en la nube, cómo se conectan los sitios entre sí y con la nube, qué ocurre cuando falla cada conexión y cuánta capacidad se provee. Responde al Artículo 16 de las Bases Administrativas: la carga principal corre en nube pública y los componentes on-premise sostienen lo que no puede depender de un enlace.

La correspondencia con la arquitectura lógica (Subdocumento 4.1) es total porque ambas usan el mismo catálogo de componentes, con los mismos identificadores: A-01 a A-05 para el núcleo de bodega, B-01 a B-03 para la cadena de frío, C-01 a C-05 para los dispositivos de operación, D-01 a D-06 para la red, E-01 para los cross-docking, F-01 a F-03 para observabilidad y seguridad de los nodos, y N-01 a N-13 para la nube. Un componente que aparece en una vista aparece con el mismo nombre en la otra.

Este capítulo se ordena en cinco partes. La sección 4.2.1 justifica el emplazamiento de cada componente conforme a los criterios del Artículo 16.2. La sección 4.2.2 enumera los servicios contratados en la plataforma de nube. La sección 4.2.3 describe las conexiones, sus puntos de falla y la contingencia de cada uno. La sección 4.2.4 deriva el dimensionamiento y el plan de capacidad desde la volumetría del caso. La sección 4.2.5 resume el equipamiento a proveer, cuyo detalle se entrega en el Formulario T-11, que acompaña a esta parte como anexo. Los ambientes, las redes, la alta disponibilidad, la recuperación ante desastres y los respaldos se desarrollan en el capítulo de arquitectura de despliegue, y las especificaciones de los sitios principal y secundario en los capítulos correspondientes.

4.2.1 Emplazamiento de cada componente

El emplazamiento de cada componente se decide con los seis criterios del Artículo 16.2 de las Bases Administrativas: latencia tolerada, criticidad operacional, volumen de datos, restricciones regulatorias, disponibilidad de conectividad y costo total de propiedad. En este caso la conectividad y la latencia pesan más que en una operación de oficina, porque el caso describe una red que se corta: la fibra de Talca tiene en promedio cuatro cortes al año de hasta seis horas, Concepción no tiene respaldo, los cross-docking

solo tienen red móvil y en Los Ángeles la señal es intermitente justo en su ventana de madrugada, las cámaras no tienen cobertura en su interior y hay rutas sin señal durante dos horas o durante el turno completo (Caso, Cap. 6).

De esos hechos se desprende la regla que ordena todo el emplazamiento: lo que debe funcionar sin enlace vive en el sitio, y lo que escala, se comparte o está expuesto a Internet vive en la nube. Los 36 componentes del catálogo se reparten en 13 de nube pura, 11 on-premise y 12 híbridos, que tienen una parte en cada dominio (ADR-03). Los identificadores son los mismos de la arquitectura lógica.

4.2.1.1 Instalaciones y dominios

La solución cubre las seis instalaciones que declara la volumetría del caso (Caso, Tabla 14.1), más la calle y los 14.200 puntos de entrega. Cinco de ellas alojan cómputo. El CD Talca es la sala técnica principal: un clúster de tres nodos con Proxmox VE y almacenamiento Ceph aloja las máquinas virtuales VM-01 a VM-06. El CD Concepción opera con un servidor de borde que replica la misma pila en formato reducido, en las máquinas VM-C01 a VM-C04. Las plataformas de cross-docking de Curicó, Chillán y Los Ángeles operan cada una con un mini-PC industrial que ejecuta el WMS en contenedores. La sexta instalación, la casa matriz de Talca, no aloja cómputo y usa la nube a través de los portales y del back-office. La séptima instalación que proyecta el caso a tres años se incorpora parametrizando la infraestructura como código y ocupando el gabinete de crecimiento R04 de la sala principal, sin obras adicionales (RT-02.12).

En la nube, la región primaria es sa-east-1 y cada servicio se despliega en al menos dos zonas de disponibilidad. La región us-east-1 solo aloja la recuperación ante desastres. La Figura 1 ubica cada componente en su sitio.

La figura muestra que ninguna instalación depende de otra para operar. Talca y Concepción tienen cada uno su WMS, su base, su broker y su caché de identidad; los cross-docking reúnen esas mismas funciones en un solo equipo; y el terreno lleva su propio almacén local en el dispositivo. La nube concentra lo que es común a todos los sitios: los portales, el transaccional compartido, la analítica y los servicios de seguridad. Los doce componentes híbridos aparecen en los dos dominios porque cada uno tiene una parte que debe seguir operando en el sitio y otra que consolida en la nube.




Figura 1 Ubicación de los componentes por dominio y por sitio

Fuente: elaboración propia a partir del catálogo de componentes de la arquitectura lógica y de la volumetría del caso (Caso, Tabla 14.1).

4.2.1.2 Componentes de nube pura

La Tabla 1 justifica los trece componentes que viven solo en la nube. La columna Criterio indica cuál de los seis criterios del Artículo 16.2 determina el emplazamiento, y la justificación explica qué hace el componente y por qué vive donde vive.

ID	Componente	Criterio	Justificación
N-01	Portal de Clientes	Regulación	Atiende el catálogo, la autoatención y el pago de los clientes desde Internet, por lo que se publica solo en la DMZ de la nube y ningún tráfico externo llega a los sitios del CLIENTE.
N-02	Portal de Transportistas	Regulación	Los conductores externos entran con una clave de un solo uso y sin cuenta corporativa (RF-06.08), y ese acceso se resuelve en la DMZ de la nube.
N-03	Portal de Proveedores	Regulación	Los 180 proveedores consultan órdenes de compra, recepciones y devoluciones desde Internet, aislados de la red de bodega.
N-04	Plataforma de aplicación	Costo	El monolito Django y sus workers Celery corren en ECS Fargate y escalan de 2 a 6 tareas en el peak de septiembre, sin servidores permanentes que mantener.
N-05	Base de datos en nube	Criticidad	Aurora PostgreSQL guarda el transaccional de los módulos en nube y la réplica del WMS, conmuta entre zonas en menos de 30 s y se replica a us-east-1.
N-06	Telemetría cruda	Volumen	DynamoDB recibe las lecturas de temperatura sin gestión de capacidad y las expira a los 30 días, cuando ya están consolidadas en la capa analítica.
N-07	Caché	Latencia	ElastiCache mantiene en memoria el stock, el crédito y las sesiones para que la consulta de preventa responda en menos de 2 s.
N-08	Ingesta de IoT	Volumen	IoT Core y Lambda reciben los 13.200 mensajes diarios de cadena de frío por MQTTS, validan cada lectura y gestionan los gateways del borde.

Tabla 1 — continuación

ID	Componente	Criterio	Justificación
N-09	Mensajería	Criticidad	SQS FIFO recibe la reconciliación de los sitios en orden y sin duplicados, y SNS difunde las alertas de excursión térmica.
N-10	Plataforma analítica	Volumen y costo	S3, Glue, Redshift Serverless y QuickSight conservan 5 años de datos separados del transaccional y publican los tableros del CLIENTE.
N-11	Respaldo inmutable y réplica	Regulación	S3 Object Lock, AWS Backup y la réplica en us-east-1 guardan la copia que ni un administrador puede borrar y sostienen el RTO de 4 h y el RPO de 15 min.
N-12	Seguridad y gobierno	Regulación	KMS, Secrets Manager, WAF, Shield, Security Lake y CloudWatch cumplen los controles del Artículo 21 como servicios que un equipo de TI de cuatro personas puede operar.
N-13	Gestión de dispositivos	Costo	Android Enterprise y Zebra DNA gestionan como servicio los 462 dispositivos del parque, con borrado remoto selectivo y sin infraestructura en los sitios (RT-03.18).

Tabla 1 Emplazamiento de los componentes de nube pura

Fuente: elaboración propia; criterios según el Art. 16.2 de las Bases Administrativas.

La tabla muestra que ningún componente de nube pura participa en las transacciones que el caso exige resolver sin enlace: la confirmación de preparación, el despacho y el registro de entrega se ejecutan en el sitio o en el dispositivo. Lo que sube a la nube lo hace por tres razones. Los portales y la gestión de identidades externas lo hacen por regulación, porque el Artículo 21 impide exponer los sitios a Internet. La plataforma de aplicación, la analítica y la telemetría lo hacen por volumen y costo, porque su carga varía con la estación y se paga por uso. Y la seguridad y el respaldo lo hacen porque un equipo de TI de cuatro personas no puede operar esos controles en sus propios servidores.

4.2.1.3 Componentes on-premise

La Tabla 2 justifica los once componentes que viven solo en las instalaciones del CLIENTE.

ID	Componente	Criterio	Justificación
B-01	Sensores de temperatura	Latencia	Los 28 puntos de medición de las cámaras se leen por Modbus en el mismo sitio, porque dentro de la cámara no hay señal y la lectura no puede esperar al enlace.
B-02	Gateway IoT	Latencia	Los gateways de Talca y Concepción detectan la excursión térmica y bloquean el despacho en menos de 5 s, con un buffer de 14 h si cae el enlace.
C-03	Terminales de bodega	Conectividad	Los 174 terminales MC9400 trabajan en la cámara a –22 °C, sin señal móvil, contra el WMS del sitio por la red inalámbrica de la bodega.
C-04	Impresoras de andén	Latencia	Las seis impresoras ZT411 imprimen la etiqueta SSCC en el andén al armar la unidad logística, sin salir de la red local.
C-05	Balanzas de recepción	Latencia	Las tres balanzas envían el peso de recepción al WMS del sitio en línea, sin digitación y sin depender del enlace.
D-02	Switching	Criticidad	Los switches de cada sitio segmentan la red local por VLAN (RT-03.23) y la mantienen operativa aunque caiga la WAN.
D-03	Enlace de fibra	Conectividad	Es el camino principal de la VPN en Talca y Concepción, con 20 y 10 Mbps en régimen.
D-04	Enlace LTE	Conectividad	Respalda la fibra en los CD y, con dos proveedores, respalda a Starlink en los cross-docking, con conmutación en menos de 30 s.
D-06	Enlace satelital	Conectividad	Starlink es el camino principal de los cross-docking, que no tienen fibra y cuya red móvil falla en la madrugada de Los Ángeles.

Tabla 2 — continuación

ID	Componente	Criterio	Justificación
E-01	WMS de cross-docking	Criticidad	El mini-PC de cada plataforma opera 100 % en local la ventana de 3 h de recepción, desconsolidación y re-despacho, con su propio broker y su propia base.
F-02	Gestión de parches	Costo	Ansible aplica los parches y las líneas base CIS a los nodos de los cinco sitios por la red de gestión, sin licencia de plataforma.

Tabla 2 Emplazamiento de los componentes on-premise

Fuente: elaboración propia; criterios según el Art. 16.2 de las Bases Administrativas.

En el on-premise dominan la latencia y la conectividad. Los sensores, las impresoras, las balanzas y los terminales de cámara son periféricos que trabajan donde está la mercadería, y ninguno puede depender de un enlace que el caso describe como intermitente. Los tres enlaces y el switching tampoco podrían emplazarse en otro lugar: son la infraestructura que conecta el sitio con la nube y sostiene su red interna cuando esa conexión falla.

4.2.1.4 Componentes híbridos

La Tabla 3 justifica los doce componentes que tienen una parte en cada dominio. Para cada uno, la justificación explica qué parte vive en el sitio, qué parte vive en la nube y por qué se reparten así.

ID	Componente	Criterio	Justificación
A-01	Motor WMS	Latencia	Corre en VM-01, VM-C01 y E-01 porque la confirmación de preparación debe responder en 1 s sin depender del enlace, y su réplica en Aurora sostiene la continuidad.

Tabla 3 — continuación

ID	Componente	Criterio	Justificación
A-02	Base transaccional del WMS	Criticidad	PostgreSQL 16 en VM-02 y VM-C02 es el registro de la bodega durante un corte, y DMS replica sus cambios a Aurora con un RPO de 15 min.
A-03	Broker de colas	Conectividad	RabbitMQ en VM-03, VM-C04 y E-01 guarda hasta 24 h de transacciones sin enlace y las entrega en orden a SQS FIFO, donde Celery las reconcilia.
A-04	Capa anticorrupción del ERP	Criticidad	Corre en VM-04 junto al ERP de 2017, que no se modifica, y el worker celery-erp-sync de la nube la consulta por la VPN como única puerta al legado.
A-05	Identidad	Conectividad	El IdP maestro Keycloak corre en Fargate y sus cachés de solo lectura en VM-05 y VM-C03 validan las sesiones de bodega sin enlace.
B-03	Termógrafos de camión	Conectividad	Los 18 termógrafos registran la temperatura durante toda la ruta sin señal y la descargan por Bluetooth al gateway al volver, para que IoT Core la valide.
C-01	App de preventa	Conectividad	Toma pedidos contra el almacén local del terminal cuando no hay señal y sincroniza con API Gateway al reconectar, sin duplicar pedidos.
C-02	App de reparto	Conectividad	Registra entregas, evidencia y cobros durante 14 h sin señal y los sincroniza con la nube al recuperar cobertura.
D-01	Firewall y Customer Gateway	Criticidad	El par de Talca y el firewall de Concepción terminan los túneles IPsec hacia el VPN Gateway de AWS y conmutan de enlace en menos de 30 s.
D-05	Respaldo local	Conectividad	El NAS WORM de Talca restaura el WMS en 4 h sin depender del enlace, y su complemento inmutable vive en S3 Object Lock.
F-01	Telemetría de observabilidad	Conectividad	Los colectores ADOT de VM-06, VM-C04 y E-01 guardan hasta 24 h de métricas y trazas en disco y las envían a CloudWatch al reconectar.

Tabla 3 — continuación

ID	Componente	Criterio	Justificación
F-03	Detección en endpoints	Regulación	Los agentes EDR de cada nodo y estación reportan a una consola central, lo que cumple RT-11.16 en nube y on-premise con una sola respuesta.

Tabla 3 Emplazamiento de los componentes híbridos

Fuente: elaboración propia; criterios según el Art. 16.2 de las Bases Administrativas.

Los componentes híbridos siguen todos el mismo patrón: la parte que atiende la operación queda en el sitio y la parte que consolida queda en la nube, unidas por un mecanismo que tolera el corte. En el núcleo de bodega ese mecanismo es la réplica por DMS y las colas; en el terreno, el almacén local del dispositivo; y en la observabilidad, el buffer en disco de los colectores. Por eso la conectividad es el criterio dominante en siete de los doce: cada uno existe en dos lugares precisamente porque el enlace entre ellos no es confiable.

4.2.1.5 Autonomía de cada ámbito sin enlace

El emplazamiento anterior se verifica en lo que cada ámbito puede hacer cuando pierde el enlace. La Tabla 4 declara esa autonomía y el tiempo en que cada ámbito vuelve a quedar sincronizado.

Ámbito	Autonomía	Operación que se mantiene
Centro de distribución	24 h o más	Recepción, preparación, despacho, conteo cíclico y trazabilidad contra la base local, con reconciliación determinista al reconectar (RT-03.12).
Terreno	14 h, un turno completo	Toma de pedido, entrega, evidencia, devoluciones y cobros contra el almacén local del dispositivo (RT-03.10).
Cross-docking	3 h, 100 % local	Recepción, desconsolidación, validación de frío y re-despacho (RT-03.11).

Tabla 4 — continuación

Ámbito	Autonomía	Operación que se mantiene
Sincronización al reconectar	Flota en 10 min; centro de distribución en 2 h	Vuelco en orden estricto, sin duplicados y con reconciliación determinista (RT-03.13, RNF-07.01).

Tabla 4 Autonomía por ámbito ante la pérdida del enlace

Fuente: elaboración propia a partir de los compromisos de operación desconectada del caso (Caso, Cap. 6).

La autonomía de cada ámbito cubre el corte más largo que describe el caso para ese lugar. Las seis horas del peor corte de fibra de Talca quedan dentro de las 24 horas del centro de distribución, y la ruta rural que recupera cobertura solo al regresar queda dentro del turno de 14 horas del terreno. Los tiempos de sincronización se sostienen con los enlaces dimensionados en la sección 4.2.4, y lo que ocurre ante cada falla se desarrolla en la sección 4.2.3.

4.2.2 Servicios contratados en la plataforma de nube

La plataforma de nube es Amazon Web Services. Todos los servicios se contratan en cuentas del CLIENTE, organizadas bajo AWS Control Tower con una cuenta por ambiente, de modo que la propiedad de los datos y de la infraestructura es del CLIENTE desde el primer día. La selección sigue tres reglas: preferir el servicio administrado cuando existe, porque el área de TI del CLIENTE es de cuatro personas (Caso, Cap. 2.4); preferir servicios compatibles con estándares abiertos, para que salir de la plataforma no exija reescribir la solución; y contratar en la región secundaria solo lo que la recuperación ante desastres necesita.

4.2.2.1 Servicios por función

La Tabla 5 agrupa los servicios contratados por la función que cumplen en la arquitectura y los asocia a los componentes del catálogo que los usan. El listado servicio por servicio, con su justificación y su cantidad, se entrega en el Formulario T-11.

Función	Servicios contratados	Componentes	Región
Entrada pública y borde	Route 53, CloudFront, AWS WAF, Shield Advanced, API Gateway	N-01, N-02, N-03, N-12	Global y sa-east-1
Cómputo de aplicación	ECS Fargate, Application Load Balancer, Lambda	N-04, N-08, A-05	sa-east-1 y us-east-1
Datos operacionales	Aurora PostgreSQL, Database Migration Service, DynamoDB, ElastiCache	N-05, A-02, N-06, N-07	sa-east-1 y us-east-1
Mensajería	SQS FIFO, SNS	N-09, A-03	sa-east-1
Internet de las cosas	IoT Core, IoT Greengrass	N-08, B-02, B-03	sa-east-1 y borde
Analítica	S3, Glue, Redshift Serverless, QuickSight	N-10	sa-east-1
Respaldo y recuperación	AWS Backup, S3 Object Lock, replicación de S3 entre regiones	N-11, D-05	sa-east-1 y us-east-1
Red y conectividad	VPC, Transit Gateway, Site-to-Site VPN, NAT Gateway, VPC Endpoints	D-01	sa-east-1 y us-east-1
Identidad, claves y secretos	KMS, Secrets Manager, Parameter Store, IAM Identity Center	A-05, N-12	sa-east-1 y us-east-1
Detección y cumplimiento	Security Lake, GuardDuty, Security Hub, Inspector, Macie, CloudTrail, Config	N-12, F-03	sa-east-1
Operación y gobierno	CloudWatch, Systems Manager, Control Tower, Organizations, Cost Explorer, Budgets	F-01, F-02, N-12	sa-east-1
Construcción y registro de imágenes	CodeBuild, Elastic Container Registry	N-04, A-01	sa-east-1
Servicios de terceros en nube	Android Enterprise y Zebra DNA; consola del EDR	N-13, F-03	Servicio gestionado

Tabla 5 Servicios contratados en la plataforma de nube, por función

Fuente: elaboración propia a partir del catálogo de componentes y de los registros de decisión ADR-01 a ADR-15.

La tabla deja ver que la solución no opera servidores en la nube: todo el cómputo corre en

contenedores administrados o en funciones, y todos los datos viven en motores administrados. Las únicas piezas de software que el adjudicatario mantiene sobre esa plataforma son la aplicación Django y el IdP Keycloak, ambos desplegados como contenedores que se promueven por el pipeline. Los servicios de detección, cumplimiento y gobierno se concentran en la región primaria porque vigilan la operación productiva, mientras que los datos operacionales y el respaldo tienen presencia en las dos regiones porque son lo que la recuperación ante desastres debe restituir.

4.2.2.2 Región secundaria y residencia de los datos

La región us-east-1 no es una segunda producción. Solo contiene la réplica de Aurora mediante Aurora Global Database, la réplica de DynamoDB mediante Global Tables, la copia de los buckets de S3, las copias de AWS Backup y una réplica reducida de ECS que escala a carga completa en menos de 30 minutos durante una conmutación (ADR-09). Dos capacidades quedan fuera de esa región por diseño: la analítica, porque la región secundaria no se explota analíticamente, y los datos de geolocalización de personas, que no se replican fuera de us-east-1 conforme a los resguardos de la arquitectura de seguridad. Así, la transferencia internacional de datos que exige la continuidad queda acotada a lo estrictamente necesario para reanudar la operación.

4.2.2.3 Servicios que no se contratan

Los registros de decisión descartan de forma expresa varios servicios de la misma plataforma, y ninguno de ellos aparece en la arquitectura. No se contrata un clúster de Kubernetes (EKS), porque el volumen de alrededor de 105 transacciones por segundo no justifica su plano de control (ADR-01). No se contrata Kafka administrado (MSK), porque RabbitMQ en cada sitio y SQS FIFO en la nube resuelven el orden y la durabilidad con menos operación (ADR-05). No se contratan servicios de trazas y métricas separados de CloudWatch, porque las Bases piden una sola plataforma de observabilidad para nube y on-premise (ADR-14, RT-03.16). Y no se autoaloja un gestor de secretos, porque Secrets Manager rota las credenciales sin el desellado manual que exigiría uno propio (ADR-15).

4.2.2.4 Modelo de contratación

Los servicios se contratan por uso, con la capacidad base comprometida mediante Savings Plans y el peak de septiembre cubierto con capacidad efímera que se libera al

terminar (ADR-12). Los ambientes de Desarrollo, Calidad y Pre-Producción se reducen o apagan fuera del horario de uso. La reversibilidad está asegurada por la elección de servicios: Aurora es compatible con PostgreSQL, los datos analíticos se guardan en formato Parquet, y Keycloak, Django y RabbitMQ son de código abierto, de modo que la solución puede trasladarse a otra plataforma sin reescribir la aplicación. Los montos de estos servicios se declaran en la Oferta Económica y no en este documento (Art. 50.2).

4.2.3 Conexiones, puntos de falla y contingencia

Esta sección describe cómo se conectan los sitios, el terreno y la nube, identifica cada punto donde esa conexión o su infraestructura puede fallar, y declara cómo se resuelve cada falla o, cuando no se resuelve de forma automática, cuál es la contingencia. Su punto de partida es el caso: la conectividad actual de Puelche se corta con frecuencia y en algunos lugares no existe (Caso, Cap. 6), por lo que la solución no puede suponer un enlace disponible y debe decir, para cada conexión, qué pasa cuando no lo está.

4.2.3.1 Conexiones entre sitios, terreno y nube

Los dos dominios fijos, la nube y el on-premise, se conectan por túneles VPN IPsec que terminan en el firewall de cada centro de distribución (D-01) y en el VPN Gateway de AWS, con enrutamiento dinámico BGP. Cada sitio tiene dos caminos físicamente independientes: fibra y LTE en los centros de distribución, y Starlink y LTE de dos proveedores en los cross-docking, que no tienen fibra (ADR-02). El terreno no pasa por los sitios: los terminales de preventa y de reparto hablan directamente con API Gateway por la red celular del operador. La Figura 2 muestra esas conexiones.

La figura distingue dos tipos de conexión. Las líneas continuas son conexiones hacia la nube, y todas se inician desde el sitio o desde el dispositivo, sin puertos abiertos hacia el on-premise. Las únicas excepciones son la réplica de AWS DMS, que lee el registro de escritura de PostgreSQL en VM-02, y el worker celery-erp-sync, que consulta la capa anticorrupción en VM-04; ambas entran por el túnel IPsec autenticado y quedan auditadas. Las líneas discontinuas son sincronizaciones entre sitios o descargas locales, que no dependen de la nube: Concepción sincroniza con Talca por la VPN, los cross-docking envían a Talca el detalle de su WMS entre brokers, y los termógrafos descargan su registro por Bluetooth al gateway del centro de distribución cuando el camión vuelve. Los eventos críticos de los cross-docking van directo a SQS FIFO, de modo que la operación de esas plataformas no depende de Talca.




Figura 2 Conexiones entre los sitios, el terreno y la nube

Fuente: elaboración propia.

La Tabla 6 resume cada conexión con su medio, su camino alternativo y el tiempo de conmutación entre ambos.

Conexión	Medio y protocolo	Camino alternativo	Conmutación
CD Talca con la nube	Fibra D-03, túneles IPsec con BGP	LTE D-04	Menos de 30 s
CD Concepción con la nube	Fibra D-03, túneles IPsec con BGP	LTE D-04	Menos de 30 s
Cross-docking con la nube	Starlink D-06, HTTPS y MQTTS salientes	LTE D-04 de dos proveedores	Menos de 30 s
Concepción con Talca	TCP 8080 y 5432 con TLS sobre la VPN	Operación autónoma	No aplica
Cross-docking con Talca	AMQPS 5671 entre brokers	Envío diferido	No aplica

Tabla 6 — continuación

Conexión	Medio y protocolo	Camino alternativo	Conmutación
Terreno con la nube	Red celular del operador, HTTPS	Almacén local del dispositivo	No aplica
Termógrafos con el sitio	Bluetooth al regresar al centro de distribución	Registro interno del termógrafo	No aplica
Usuarios externos con los portales	Internet, HTTPS por CloudFront	Ninguno: el autoservicio requiere conexión	No aplica
Región primaria con la secundaria	Replicación nativa de Aurora, DynamoDB y S3	Respaldo inmutable	Promoción autorizada

Tabla 6 Conexiones de la solución y su camino alternativo

Fuente: elaboración propia; conectividad actual según el caso (Caso, Cap. 6) y decisión ADR-02.

Solo tres conexiones tienen un segundo camino de red, y son las que unen un sitio con la nube. Las demás no lo necesitan porque su alternativa no es otro enlace sino la operación sin conexión: Concepción opera sin Talca, el terreno opera sin señal y el termógrafo guarda su propio registro. Por eso la redundancia de enlaces reduce la frecuencia de las desconexiones, pero no es condición para operar. El portal de clientes es la única conexión sin alternativa, y eso es deliberado: el autoservicio no se ofrece sin conexión (RT-03.13).

4.2.3.2 Puntos de falla en los sitios y en los enlaces

Cada conexión se apoya en equipos del sitio que también pueden fallar. La Tabla 7 recorre esos puntos de falla, desde el enlace hasta la energía del recinto, e indica para cada uno el mecanismo que la resuelve y la contingencia si ese mecanismo no basta.

Punto de falla	Resolución	Contingencia
Fibra de un centro de distribución	BGP conmuta los túneles al LTE en menos de 30 s.	Si cae también el LTE, el sitio opera 24 h con su base, su broker y su caché de identidad.
Starlink de un cross-docking	El LTE de dos proveedores toma el tráfico en menos de 30 s.	La ventana de 3 h opera 100 % en local y sincroniza al reconectar.
Enlace de Los Ángeles en la madrugada	Starlink queda como camino único, porque la red móvil es intermitente a esa hora.	La ventana de operación es íntegramente local, por lo que el corte no la detiene.
Firewall de Talca	La unidad pasiva del par asume las direcciones y los túneles en menos de 30 s.	El sitio opera 24 h sin enlace.
Firewall de Concepción	Es un equipo único y se repone.	Concepción opera 24 h sin enlace mientras se reemplaza.
Nodo del clúster de Talca	Las VM se reinician en los dos nodos restantes, con sus datos replicados por Ceph.	Si fallan dos nodos, el DRP local promueve el WMS de Concepción en 1 a 2 h.
Instancia de escritura VM-02	Se reinicia en otro nodo del clúster.	D-05 restaura la base en hasta 4 h sin depender del enlace.
Disco de un servidor	El RAID 10 reconstruye sobre el disco de repuesto en caliente.	Ceph conserva una segunda copia en otro nodo.
Miembro del stack de switches de Talca	El otro miembro mantiene el tráfico.	Se repone sin corte.
Servidor de borde de Concepción	RAID 10 con repuesto en caliente y doble fuente cubren las fallas más probables.	La pila se restaura en un equipo de reemplazo desde la réplica en Aurora.
Mini-PC de un cross-docking	Es un equipo único y se repone.	Los eventos críticos ya están en SQS FIFO y el detalle en Talca, desde donde se resincroniza el equipo nuevo.
Periféricos de andén	No tienen redundancia.	Respaldo manual de la operación del andén.

Tabla 7 — continuación

Punto de falla	Resolución	Contingencia
Energía de la sala de Talca	El UPS N+1 cubre 30 min y el generador toma la carga en 8 a 15 s.	El estanque cubre 24 h y hay contrato de reabastecimiento.
Climatización de la sala de Talca	La segunda unidad de precisión, en N+1, sostiene la temperatura.	Alerta de los sensores ambientales al monitoreo.

Tabla 7 Puntos de falla en los sitios y en los enlaces

Fuente: elaboración propia; puntos únicos de falla declarados conforme a RT-02.11.

La tabla muestra que los puntos únicos de falla que quedan están donde la redundancia no compensa su costo: el firewall y el servidor de Concepción, el mini-PC de cada cross-docking y los periféricos de andén. En los tres primeros casos la contingencia es la misma autonomía que ya existe para los cortes de enlace, y ningún punto único de falla está en la ruta de la ventana de despacho de Talca, que tiene redundancia en cada capa. Los mecanismos de alta disponibilidad que sostienen estas resoluciones se desarrollan en el capítulo de arquitectura de despliegue.

4.2.3.3 Puntos de falla en la nube, el terreno y las integraciones

La Tabla 8 completa el recorrido con los puntos de falla que están fuera de los sitios: la nube, el terreno y los sistemas de terceros.

Punto de falla	Resolución	Contingencia
Zona de disponibilidad de sa-east-1	Aurora conmuta en menos de 30 s, ElastiCache en menos de 60 s y Fargate reprograma las tareas.	La operación continúa en las zonas restantes.
Región sa-east-1 completa	Route 53 redirige el tráfico y, con autorización del CLIENTE, se promueve la réplica en us-east-1.	RTO de 4 h y RPO de 15 min; la bodega y el terreno siguen operando en local.

Tabla 8 — continuación

Punto de falla	Resolución	Contingencia
Túnel VPN durante la replicación	DMS encola los cambios en el origen.	Reanuda sin pérdida al reconectar; la réplica queda desactualizada mientras dure el corte.
IdP maestro o enlace de identidad	Las cachés de solo lectura validan las sesiones localmente.	Token de turno de 8 h en bodega y 14 h en terreno, y cuenta de emergencia en sobre sellado (ADR-15).
Señal móvil en ruta	La aplicación opera contra el almacén local del dispositivo.	Sincroniza al reconectar dentro de los 10 min de la Tabla 4.
ERP legado	La capa anticorrupción retiene las transacciones en cola hasta 24 h.	El ERP no se modifica; las transacciones se entregan al recuperarse.
Excursión térmica sin enlace	El gateway bloquea el despacho en menos de 5 s en el borde.	Buffer de 14 h y alerta al reconectar.
SII, cadenas o notificaciones	Reintento con espera creciente y cola de mensajes fallidos.	Reproceso desde la cola al recuperarse el tercero.
Carga del peak de septiembre	Escalado automático de Fargate, Celery y Aurora (ADR-12).	Limitación de tasa en API Gateway.

Tabla 8 Puntos de falla en la nube, el terreno y las integraciones

Fuente: elaboración propia a partir de los registros de decisión ADR-02, ADR-06, ADR-09, ADR-12 y ADR-15.

Ninguna de estas fallas detiene la bodega ni el terreno. La peor de ellas, la pérdida de toda la región primaria, deja sin servicio a los portales y a la analítica hasta la promoción de la réplica, pero la preparación, el despacho y la entrega siguen operando contra sus bases locales y sus dispositivos, porque ninguna de esas transacciones depende de la nube para confirmarse.

4.2.4 Dimensionamiento y plan de capacidad

Esta sección deriva la capacidad de la solución desde la volumetría del caso, declara las dieciséis dimensiones que el numeral 14.2 pide estimar, dimensiona el cómputo, el almacenamiento y los enlaces en ambos dominios, y fija el plan para crecer tres veces sin rediseño. El caso advierte que un dimensionamiento basado en el promedio diario estará equivocado, porque la carga no es plana (Caso, Cap. 14.2). Por eso cada valor se calcula sobre la ventana en que ocurre, y cuando se adopta un supuesto se declara junto a su fundamento.

4.2.4.1 Criterios y método

El perfil de un día hábil concentra la carga en cuatro ventanas que no coinciden entre sí (Caso, Cap. B.1):

- **Preparación de pedidos:** de 22:00 a 06:00 en Talca, con 120 terminales de cámara en simultáneo.
- **Despacho:** de 05:30 a 07:00, con la salida de 96 camiones, 42 propios y 54 de transportistas.
- **Preventa:** de 09:00 a 18:00, con 62 preventistas y unas 2.600 visitas diarias.
- **Sincronización de la flota:** de 17:00 a 20:00, al regreso de los dispositivos de terreno.

Sobre ese perfil, el dimensionamiento sigue cinco reglas. La carga de diseño es el peak de septiembre multiplicado por 1,5, es decir $2.600 \times 1,5 = 3.900$ entregas diarias toleradas sin degradación (RNF-19.04). La solución debe soportar tres veces la volumetría inicial sin rediseño (RT-09.03). Toda medición de desempeño se expresa en percentil 95. El cómputo en nube escala de forma automática y se paga por uso (ADR-12), mientras que el on-premise se dimensiona al margen útil, sin sobrecompra. Y los totales de esta sección son los mismos que usan los registros de decisión ADR-01, ADR-04, ADR-10 y ADR-12.

4.2.4.2 Volumetría de referencia

La Tabla 9 reúne los valores que entrega el CLIENTE y que sirven de base a todos los cálculos de esta sección.

Magnitud	Valor base
Clientes activos y puntos de entrega	14.200
Pedidos	31.000 al mes
Líneas de pedido y de preparación	260.000 al mes
Unidades despachadas	2,4 millones al mes
SKU activos	8.400
Posiciones de almacén en Talca	11.400, con 87 % de ocupación
Entregas en día hábil normal	1.400
Entregas en día hábil de peak de septiembre	2.600
Kilómetros recorridos	420.000 al mes
Documentos tributarios	34.000 al mes
Camiones propios con equipo de frío	18
Puntos de medición de temperatura	28, en 7 módulos de 4 canales
Instalaciones	6, de las cuales 5 alojan cómputo

Tabla 9 Valores base de dimensionamiento

Fuente: Caso, Cap. 2.2, Cap. 2.3 y Tabla 14.1; los puntos de medición son de elaboración propia.

De estos valores, el que gobierna el dimensionamiento no es el número de clientes sino la relación entre el día normal y el peak: 2.600 entregas frente a 1.400 son 1,86 veces más carga durante las tres primeras semanas de septiembre. La sexta instalación, la casa matriz de Talca, no aloja cómputo, por lo que el dimensionamiento del on-premise se calcula sobre cinco sitios.

La Tabla 10 muestra la proyección del caso a tres años.

Magnitud	Año 0	Año 3	Variación
Clientes	14.200	15.500	+9 %
Pedidos al mes	31.000	36.000	+16 %

Tabla 10 — continuación

Magnitud	Año 0	Año 3	Variación
Líneas al mes	260.000	305.000	+17 %
Entregas en día normal	1.400	1.650	+18 %
Entregas en día de peak	2.600	3.100	+19 %
Kilómetros al mes	420.000	480.000	+14 %
Documentos tributarios al mes	34.000	40.000	+18 %
Instalaciones	6	7	+1

Tabla 10 Proyección de la volumetría a tres años

Fuente: Caso, Tabla 14.1.

El crecimiento real que proyecta el caso es de 16 % a 19 % en tres años, muy por debajo del factor 3 que exige RT-09.03. El dimensionamiento que sigue cubre ese factor 3, de modo que la solución tiene margen ante un crecimiento mayor al proyectado.

4.2.4.3 Transacciones por segundo

La preparación nocturna mueve 260.000 líneas al mes; en 25 días hábiles son 10.400 líneas por noche, que en las 8 horas del turno (28.800 s) dan una demanda media de 0,36 líneas por segundo. El diseño no se hace sobre esa media sino sobre la concurrencia máxima: 120 terminales confirmando una línea cada 6 segundos son 20 transacciones por segundo, 55 veces la demanda media, lo que absorbe el inicio del turno, cuando todos los preparadores confirman a la vez, y el conteo cíclico que comparte la ventana. Con el mismo criterio, 62 preventistas registrando una línea cada 8 segundos son 8 transacciones por segundo. La Tabla 11 suma esos flujos.

Flujo	Cálculo	TPS
Confirmación de preparación	120 terminales × 1 confirmación cada 6 s	20
Registro de preventa	62 preventistas × 1 línea cada 8 s	8

Tabla 11 — continuación

Flujo	Cálculo	TPS
Movimientos, sincronización y telemetría	Supuesto que cubre el vuelco de los brokers y los 73.700 mensajes diarios de telemetría	7
Régimen normal	20 + 8 + 7	35
Diseño en peak de septiembre	35 × 3	105

Tabla 11 Transacciones por segundo de diseño

Fuente: elaboración propia a partir del perfil operacional del caso (Caso, Cap. B.1).

El factor 3 del peak no es arbitrario: combina el aumento estacional de 1,86 veces con el margen de 1,5 de la carga de diseño, lo que da 2,8, redondeado a 3. Los 105 transacciones por segundo resultantes son el valor único de diseño de esta sección, el mismo que citan el ADR-01 y el ADR-12, y sostienen el dimensionamiento de la base transaccional y el escalado del cómputo en nube.

La ventana de despacho, en cambio, no es la de mayor carga. En ella ocurren 1.400 confirmaciones de carga, 1.400 timbrados de guía, 96 vinculaciones de conductor con camión y 96 cierres de ruta, en total 2.992 transacciones; aun concentradas en la primera media hora (1.800 s), son 1,7 transacciones por segundo. La ventana es crítica porque no admite indisponibilidad, no por su volumen: el cómputo se dimensiona por la preparación nocturna y el peak de septiembre, y la resiliencia por la ventana de despacho.

4.2.4.4 Usuarios, concurrencia y dispositivos

Las personas usuarias internas son unas 620: 62 preventistas, 42 conductores propios, cerca de 160 conductores de terceros, 310 personas de centro de distribución, unas 40 de administración y gerencia, y 4 de TI. Las externas son unas 14.400 al cierre de la Etapa 2: 14.200 clientes con autoatención, 180 proveedores y 10 empresas transportistas. La Tabla 12 detalla la concurrencia por rol.

Rol	Concurrencia	Dispositivo
Preventistas	62	Zebra EC55, parque de 62 más 20 % de reserva
Conductores	≈ 200	Zebra TC58e, parque único para propios y externos
Preparadores del turno nocturno	120	Zebra MC9400 Cold Storage, 144 en Talca y 30 en Concepción
Personal de centro de distribución	110	Estaciones y terminales fijos
Supervisión y mesa de ayuda	≈ 20	Estaciones de trabajo
Dispositivos de terreno registrados	≈ 270, hasta 300	EC55 y TC58e

Tabla 12 Usuarios y terminales concurrentes

Fuente: elaboración propia a partir del Caso, Cap. 2.4 y Tabla 14.1.

La suma de los perfiles da unas 510 personas concurrentes: $62 + 200 + 120 + 110 + 20$. Es una cota superior, porque la preventa y la preparación nocturna no coinciden en el tiempo. Los dispositivos de terreno en operación simultánea son los 62 de preventa y los cerca de 200 de reparto, unos 270; con la proyección a tres años, 70 preventistas y 230 conductores, llegan a 300.

4.2.4.5 Almacenamiento y datos a migrar

El almacenamiento se calcula por tipo de dato, porque cada uno tiene su propio ritmo y su propia retención.

- **Transaccional:** se estima en 375 GB por año entre el maestro de bodega y el transaccional en nube. A cinco años suma cerca de 1,9 TB, del mismo orden que los 1.890 GB asignados al clúster de Talca.
- **Evidencia de entrega:** 1.400 entregas diarias en 300 días hábiles son 420.000 entregas al año. Con una firma de 30 KB y una o dos fotografías de 200 KB, cada

entrega ocupa unos 230 KB, lo que da $420.000 \times 230 \text{ KB} \approx 97 \text{ GB}$, unos 100 GB al año. Con la retención de 6 años suman unos 600 GB, en almacenamiento por niveles.

- **Series de temperatura y de posicionamiento:** 46 fuentes de temperatura, 28 puntos de cámara y 18 termógrafos, con una muestra cada 5 minutos, generan 4,84 millones de registros al año; 42 camiones con una posición cada 30 segundos durante 12 horas y 300 días generan 18,1 millones. Con unos 145 bytes por registro, los 22,9 millones suman 3,3 GB en crudo al año, que en formato columnar comprimido quedan en unos 0,8 GB. El crudo vive 30 días; la serie consolidada se conserva 5 años para temperatura y 12 meses para geolocalización de personas.
- **Datos históricos a migrar:** unos 30 GB estructurados. Solo las ventas y pedidos de tres años son 9,4 millones de líneas de 1 KB, 9,4 GB, y los movimientos de inventario de dos años son 3,4 millones de registros de 0,5 KB, 1,7 GB; el resto corresponde a los maestros, a cinco años de trazabilidad sanitaria y a las cuentas por cobrar vivas. El histórico documental permanece en el ERP, que sigue siendo la fuente tributaria.

El dato que más crece no es el transaccional sino la evidencia de entrega, y por eso se guarda en almacenamiento de objetos por niveles y no en la base de datos. Las series de tiempo, que dominan el número de registros, tampoco pasan por la base transaccional: se ingieren en DynamoDB y se consolidan en la capa analítica.

4.2.4.6 Integraciones y volumen de mensajes

La solución tiene 15 integraciones. La Tabla 13 deriva el volumen de las diez que mueven mensajes, sobre 25 días hábiles al mes y con el peak de septiembre al doble.

Integración	Mensajes al día	Peak	Derivación
ERP por la capa anticorrupción	4.700	9.400	1.240 pedidos, 46 recepciones, 1.400 preparaciones, 1.400 entregas y 600 recaudaciones
Documentos tributarios y acuse	2.700	5.400	34.000 documentos al mes y su acuse, en 25 días
Trazabilidad GS1 EPCIS	52.000	104.000	260.000 líneas al mes $\times$ 5 eventos, en 25 días

Tabla 13 — continuación

Integración	Mensajes al día	Peak	Derivación
Telemetría de cadena de frío	13.200	13.200	46 fuentes × 288 muestras diarias
Telemetría de flota	60.500	72.000	42 camiones × 120 posiciones por hora × 12 h
Sincronización de terreno	13.000	26.000	1.240 pedidos, 1.400 entregas y 10.400 confirmaciones
Intercambio con el canal moderno	550	1.100	136 pedidos diarios × 4 mensajes
Notificaciones	2.800	5.600	Hora estimada de llegada y acuse por entrega
Autorización de pago	500	1.000	Fracción del canal tradicional que migra a pago electrónico
Mapas y geocodificación	200	400	Una corrida de ruteo por zona y recálculos por incidencia

Tabla 13 Volumen de mensajes por integración

Fuente: elaboración propia a partir de la Tabla 14.1 del caso.

El total en régimen es de unos 150.000 mensajes al día. Dos series de tiempo, la trazabilidad y la telemetría, aportan unos 126.000 de ellos, y ninguna atraviesa la base transaccional. Las cinco integraciones restantes del catálogo son de configuración y administración, con volumen despreciable frente a estas cifras.

4.2.4.7 Ancho de banda, dispositivos de reparto y sincronización

El enlace de cada centro de distribución transporta la replicación de la base, el vuelco de los brokers, la telemetría y el respaldo hacia la nube. No transporta la sincronización del terreno, que viaja por la red celular directo a la nube. La Tabla 14 declara el ancho de banda por sitio.

Sitio	Régimen	Peak	Respaldo
CD Talca	20 Mbps por fibra	50 Mbps	LTE de 5 a 10 Mbps
CD Concepción	10 Mbps por fibra	20 Mbps	LTE de 3 a 5 Mbps
Cross-docking, cada uno	Starlink, plan de 500 GB	Ídem	LTE de 2 a 5 Mbps, dos proveedores

Tabla 14 Ancho de banda por sitio

Fuente: elaboración propia.

El peak lo fija el respaldo. El respaldo semanal a la nube pesa hoy unos 40 GB y llega a 120 GB con el crecimiento de 3 veces; transmitido en la ventana nocturna de 8 horas exige $120 \text{ GB} \times 8 / 28.800 \text{ s} \approx 33 \text{ Mbps}$, que caben en los 50 Mbps de Talca junto con el tráfico de régimen. La replicación y los brokers, en cambio, son pequeños: aun atribuyendo a un solo sitio el volumen transaccional anual completo, duplicado por el peak, suman unos 2,1 GB al día, 0,2 Mbps en promedio. Por eso el régimen de 20 Mbps deja holgura para las consolas web del personal del sitio, y el LTE de respaldo alcanza para la replicación y los brokers, aunque no para el respaldo semanal, que se difiere hasta que vuelve la fibra.

Un dispositivo de reparto genera entre 8 y 12 MB en un turno sin señal. En el peak, 2.600 entregas repartidas en 96 camiones son unas 27 por ruta, que se redondean a 30; con 230 KB de evidencia cada una suman 6,9 MB, a los que se agregan la ruta del día, el maestro acotado de productos y precios y la cola de escrituras pendientes. Al recuperar cobertura, 10 MB se sincronizan en $10 \times 8 / 0,2 = 400 \text{ s}$, menos de 7 minutos, aun con apenas 0,2 Mbps efectivos de red celular, lo que sostiene el objetivo de 10 minutos por dispositivo de la Tabla 4. La flota completa, unos 200 dispositivos de 10 MB, suma 2 GB en la ventana de 17:00 a 20:00, apenas 1,5 Mbps agregados en la entrada de la nube.

4.2.4.8 Mesa de ayuda y equipo de operación

Con 620 personas usuarias internas y un contacto mensual por persona en operación estabilizada, la mesa recibe unos 620 contactos al mes; durante las oleadas de puesta en producción el factor sube a 2,5, unos 1.550 contactos, y en el peak de septiembre aumenta 40 %. Los clientes del canal tradicional no entran por esta mesa: se atienden por autoatención. Los 620 contactos en 25 días hábiles son unos 25 al día; si el 20 %

se concentra en la hora punta, son unos 5 contactos por hora, que con 8 minutos de atención suman $5 \times 8 / 60 = 0,67$ Erlang. Con el modelo Erlang C, dos agentes cumplen el objetivo de atender el 80 % de los contactos en 20 segundos. A esa base se suman la cobertura de la ventana de despacho y del turno nocturno de bodega, el segundo nivel y la supervisión, lo que da una mesa de 7 personas: 3 agentes diurnos, 1 nocturno, 1 supervisor y 2 especialistas de segundo nivel. Los parámetros se recalibran con los datos de la operación real. El centro de operaciones de red y la confiabilidad se prestan como servicio gestionado.

4.2.4.9 Síntesis de las dieciséis dimensiones

La Tabla 15 reúne el valor declarado para cada dimensión del numeral 14.2 del caso, con la subsección donde se deriva.

Dimensión	Valor declarado	Derivación
TPS en régimen normal	35	Transacciones por segundo
TPS en la ventana de despacho	1,7	Transacciones por segundo
TPS en el peak de septiembre	105	Transacciones por segundo
Personas usuarias registradas	620 internas y 14.400 externas	Usuarios y concurrencia
Personas usuarias concurrentes en peak	510 como cota superior	Usuarios y concurrencia
Dispositivos de terreno simultáneos	270, hasta 300	Usuarios y concurrencia
Almacenamiento transaccional anual	375 GB	Almacenamiento
Evidencia de entrega anual	100 GB	Almacenamiento
Series de temperatura y posición anuales	3,3 GB en crudo y 0,8 GB consolidados	Almacenamiento
Datos históricos a migrar	30 GB	Almacenamiento

Tabla 15 — continuación

Dimensión	Valor declarado	Derivación
Integraciones y mensajes	15 integraciones y 150.000 mensajes al día	Integraciones
Ancho de banda por sitio	Talca 20 a 50 Mbps y Concepción 10 a 20 Mbps	Ancho de banda
Datos de un dispositivo de reparto por turno	8 a 12 MB	Ancho de banda
Sincronización de la flota	10 min por dispositivo	Ancho de banda
Contactos mensuales a la mesa	620 en régimen y 1.550 en marcha blanca	Mesa de ayuda
Dotación de la mesa	7 personas	Mesa de ayuda

Tabla 15 Las dieciséis dimensiones del numeral 14.2 del caso

Fuente: elaboración propia; dimensiones según el Caso, Cap. 14.2.

Ninguna dimensión queda sin valor ni sin derivación. Las que exigieron un supuesto propio, como el ritmo máximo de confirmación, el tamaño de la evidencia o el volumen transaccional anual, lo declaran en su subsección, de modo que el CLIENTE puede recalcular el resultado si el supuesto cambia.

4.2.4.10 Dimensionamiento on-premise

El clúster de Talca tiene tres nodos iguales, de modo que la pérdida de cualquiera deja dos supervivientes capaces de sostener todas las máquinas virtuales (N+1). La Tabla 16 compara lo asignado con lo que queda disponible tras perder un nodo.

Recurso	Asignado	Físico en el clúster	Utilización N+1
vCPU	30	96 hilos, 3 nodos de 32	30 de 64, 47 %
Memoria	68 GB	384 GB, 3 nodos de 128	68 de 256, 27 %
Almacenamiento Ceph	1.890 GB	5,76 TB útiles	33 %

Tabla 16 Utilización del clúster de Talca con un nodo caído

Fuente: elaboración propia.

Con un nodo caído, el clúster todavía usa menos de la mitad de su cómputo y poco más de un cuarto de su memoria. La capacidad de almacenamiento resulta de tres nodos con cuatro discos NVMe de 1,92 TB en RAID 10, 3,84 TB por nodo, y de la réplica 2 de Ceph: $3 \times 3,84 / 2 = 5,76$ TB. La Tabla 17 muestra cómo se reparten los recursos asignados entre las seis máquinas virtuales.

VM	Rol	vCPU	Memoria	Disco
VM-01	Motor WMS	8	16 GB	100 GB
VM-02	Base transaccional del WMS	8	32 GB	1.500 GB
VM-03	Broker de colas	4	8 GB	200 GB
VM-04	Capa anticorrupción del ERP	4	4 GB	20 GB
VM-05	Caché de identidad	4	4 GB	20 GB
VM-06	Colector de observabilidad y agente SSM	2	4 GB	50 GB

Tabla 17 Máquinas virtuales del clúster de Talca

Fuente: elaboración propia.

VM-02 concentra casi la mitad de la memoria y el 80 % del disco, porque es el único punto de escritura del maestro de bodega; es también el primer cuello de botella, como se explica más adelante. El servidor de borde de Concepción ofrece 12 vCPU y 24 GB de memoria sobre discos NVMe en RAID 10 con repuesto en caliente, suficientes

para el WMS de un sitio de la mitad de tamaño que Talca durante 24 horas sin enlace. En cada cross-docking, el mini-PC industrial ejecuta el WMS, su base y su broker en contenedores, y conecta el router de Starlink y el LTE de respaldo.

La Tabla 18 verifica el almacenamiento y el rendimiento de la base transaccional.

Aspecto	Cálculo	Resultado
Ocupación inicial del pool	1.890 GB de 5.760 GB	33 %
Ocupación con crecimiento de 3 veces	$1.890 \text{ GB} \times 3 = 5.670 \text{ GB}$	Requiere el cuarto nodo
Pool con el cuarto nodo	$4 \times 3,84 \text{ TB} / 2 = 7,68 \text{ TB}$	74 %
Respaldo local D-05	NAS en RAID 6 con 4 discos de 4 TB	8 TB útiles
Operaciones de disco de VM-02	$105 \text{ TPS} \times 8 \text{ operaciones por transacción}$	840 IOPS frente a más de 100.000

Tabla 18 Almacenamiento y rendimiento de la base transaccional

Fuente: elaboración propia.

El almacenamiento no es el límite del clúster en régimen, pero sí con el crecimiento de 3 veces: 5.670 GB llenarían el 98 % del pool de tres nodos, por encima del umbral en que Ceph deja de aceptar escrituras con seguridad. El cuarto nodo, que el plan de capacidad incorpora de todos modos por cómputo, eleva el pool a 7,68 TB y deja la ocupación en 74 %. En rendimiento de disco la holgura es de dos órdenes de magnitud.

4.2.4.11 Dimensionamiento en nube

La Tabla 19 declara la capacidad base y la de peak de cada servicio de cómputo y datos en nube, con el criterio que dispara el escalado.

Servicio	Base	Peak	Escala por
ECS Fargate, aplicación Django	2 tareas	6 tareas	CPU sobre 70 %

Tabla 19 — continuación

Servicio	Base	Peak	Escala por
ECS Fargate, workers Celery	2 tareas	4 tareas	Profundidad de cola
Lambda de validación y firma	100 concurrentes	500 reservadas	Eventos de IoT Core y S3
Aurora PostgreSQL	db.r6g.large en 2 zonas	db.r6g.xlarge y 2 lectores	CPU sobre 60 %
ElastiCache	cache.r6g.large	cache.r6g.xlarge	Memoria sobre 75 %
DynamoDB	Bajo demanda	Bajo demanda	Sin gestión de capacidad
IoT Core	270 dispositivos	300 dispositivos	Concurrencia de terreno
Keycloak	1 tarea	2 tareas en 2 zonas	CPU sobre 60 %

Tabla 19 Capacidad de los servicios en nube

Fuente: elaboración propia; decisión ADR-12.

El paso de base a peak triplica la aplicación y duplica los workers y la base, que es la proporción del factor 3 de la Tabla 11. El escalado combina un componente predictivo, que en agosto precalienta las tareas y reserva la concurrencia de Lambda, con uno reactivo que responde en menos de 2 minutos y aprovisiona en menos de 3. DynamoDB y Lambda escalan sin configuración, y la capacidad se paga por uso.

4.2.4.12 Plan de capacidad y crecimiento de 3 veces

El crecimiento se absorbe con el mismo diseño, sin cambiar la topología, las VLAN, la réplica ni la nube. La Tabla 20 muestra la acción para cada recurso on-premise.

Recurso	Diseño	Con 3 veces	Acción
vCPU del clúster	30 de 64, 47 %	90 asignadas	Cuarto servidor idéntico en el gabinete R04: 96 hilos con N+1
Memoria	68 de 256 GB, 27 %	205 GB	Cabe en los 256 GB con N+1, 80 %
Pool Ceph	1.890 de 5.760 GB	5.670 GB	El cuarto nodo lleva el pool a 7,68 TB, 74 %
Enlaces de Talca y Concepción	20 y 10 Mbps	50 y 20 Mbps	Contrato escalonado de los enlaces
TPS de VM-02	105	315	Escala de 8 a 12 vCPU y de 32 a 64 GB, con particionado mensual

Tabla 20 Plan de capacidad para el crecimiento de 3 veces

Fuente: elaboración propia.

El cuarto servidor es la única compra adicional que exige el crecimiento de 3 veces, y resuelve a la vez el cómputo y el almacenamiento. Como el gabinete R04 de la sala técnica está reservado para ese crecimiento, la ampliación no requiere obras. En nube, el mismo factor se absorbe con el escalado automático de la Tabla 19, sin cambios de arquitectura.

4.2.4.13 Umbrales de desempeño

La Tabla 21 fija el umbral de respuesta, en percentil 95, de cada operación que el caso y las Bases declaran crítica.

Operación	Umbral
Confirmación de una línea de preparación de pedidos	1 s
Registro de una entrega en el local del cliente	2 s
Registro de una línea en la toma de pedido de preventa	1,5 s

Tabla 21 — continuación

Operación	Umbral
Consulta de stock y crédito en preventa	2 s
Transacción operacional crítica de terreno, de extremo a extremo	3 s
Carga inicial de una página del portal	2 s
Navegación entre vistas ya cargadas	1 s
Interfaz de programación de consulta simple	500 ms
Interfaz de programación de escritura transaccional	800 ms
Búsqueda con criterios compuestos	3 s
Informe estándar en línea	30 s

Tabla 21 Umbrales de desempeño en percentil 95

Fuente: Caso, Cap. 15, RT-09.01, para las cuatro primeras filas; Bases Técnicas Transversales, numeral 9.1, para las demás.

Las cuatro primeras operaciones son las que fija el caso, y tres de ellas se resuelven sin atravesar la WAN: la confirmación de preparación contra la base local del sitio y los dos registros de terreno contra el almacén local del dispositivo. La consulta de stock y crédito es la única que depende de la nube, y por eso se atiende desde la caché. Los umbrales se miden con CloudWatch y se verifican en Pre-Producción con las pruebas de carga.

4.2.4.14 Primer cuello de botella

El primer recurso que se satura al crecer la carga es VM-02, la base transaccional del maestro de bodega, porque toda la preparación nocturna y todo el despacho pasan por su único punto de escritura. Se detecta cuando el percentil 95 de escritura supera 800 ms, cuando el tiempo de confirmación se triplica, cuando la espera de disco supera 15 % o cuando la cola de conexiones supera entre 5 y 10. La mitigación es progresiva: primero, escalar VM-02 de 8 a 12 vCPU y de 32 a 64 GB dentro del margen N+1; luego, particionar las tablas por mes y agregar un gestor de conexiones; después, una réplica de solo lectura para las consultas; y por último, el cuarto nodo o la partición de la base

al agotar el margen. En nube, el equivalente es Aurora, que escala con lectores, y SQS FIFO absorbe el pico de sincronización de las 17:00 a las 20:00 (ADR-05).

4.2.4.15 Degradación controlada

Cuando la carga o la red exceden lo previsto, la solución degrada en orden y sin perder transacciones. En el enlace, la calidad de servicio prioriza el broker y el registro de escritura anticipada, las colas no críticas se difieren fuera de la ventana de despacho y la conmutación entre caminos ocurre en menos de 30 segundos. Sin enlace, los brokers y los colectores guardan hasta 24 horas y reconcilian en orden al reconectar. En la nube, API Gateway limita la tasa de solicitudes, Celery aplica tiempos de espera y reintentos con espera creciente, y los mensajes que fallan pasan a una cola de mensajes fallidos para su reproceso. Cuando una solicitud se encola o se limita, la persona usuaria recibe un mensaje explícito con el estado de su operación, nunca un error genérico (RT-09.08).

4.2.4.16 Pruebas de carga y estrés

Los valores de esta sección se verifican con pruebas en Pre-Producción, que opera con el dimensionamiento completo de Producción durante esas pruebas. La Tabla 22 declara las tres pruebas.

Prueba	Carga	Resultado esperado
Carga	1,5 veces la carga de diseño: 5.850 entregas diarias, unas 160 TPS sostenidas	Umbrales de la Tabla 21 cumplidos con perfiles horarios reales
Estrés	Incremento hasta el punto de quiebre, al menos 3 veces	Curva de tiempo de respuesta frente a la carga
Informe de carga	Curvas, saturación y uso de CPU, memoria, disco, enlace y colas	Insumo del hito de producción del mes 16

Tabla 22 Pruebas de carga y estrés

Fuente: elaboración propia.

La prueba de carga multiplica por 1,5 una carga de diseño que ya incluía ese margen,

de modo que $105 \times 1,5 \approx 160$ transacciones por segundo verifican la solución por encima de cualquier volumen que el caso proyecta. Las pruebas usan k6 y Gatling con controladores propios contra las API de integración y del broker, se ejecutan al cierre de la Etapa 1 (mes 13) y de la Etapa 2 (mes 19), y se repiten cada trimestre. Su calendario formal está en el Formulario T-13.

4.2.4.17 Actualización del plan de capacidad

Durante la operación, la capacidad se revisa cada trimestre comparando el consumo real con el proyectado en cómputo, memoria, almacenamiento, enlace, colas y transacciones por segundo. Una alerta anticipada se dispara cuando un recurso alcanza el 70 % o cuando la tendencia indica que se agotará en dos semanas, y cada alerta produce una propuesta de ajuste de dimensionamiento y de costo. La ampliación sigue el orden de la Tabla 20: vCPU y discos dentro del equipamiento físico, contrato escalonado de enlaces y, al acercarse al margen, el cuarto nodo. En nube, los umbrales del escalado automático y la concurrencia reservada se revisan al menos 30 días antes de cada peak de septiembre.

4.2.5 Especificaciones Implementos a proveer (Hardware y Software)

Esta sección resume y analiza el equipamiento y el software que la solución requiere en las instalaciones del CLIENTE, en el terreno y en la plataforma de nube. El detalle de cada elemento, con su producto ofertado, su ubicación, su cantidad y su justificación, se entrega en el Formulario T-11, que acompaña a esta parte como anexo. El equipamiento físico lo adquiere el CLIENTE, y el adjudicatario lo especifica, instala, integra y mantiene durante el contrato (Art. 14.2).

4.2.5.1 Síntesis del equipamiento por familia

La Tabla 23 agrupa el equipamiento en ocho familias, con sus cantidades y los sitios donde se instala.

Familia	Equipamiento y cantidad	Sitios
Cómputo	3 servidores del clúster, 1 servidor de borde y 3 mini-PC industriales	Talca, Concepción y cross-docking
Almacenamiento de respaldo	1 NAS WORM cifrado, D-05	Talca
Red y seguridad	3 firewalls, 6 switches de sitio, 1 switch de gestión y 9 puntos de acceso Wi-Fi 6E	Los cinco sitios con cómputo
Enlaces	2 enlaces de fibra, 5 enlaces LTE y 3 kits Starlink	CD y cross-docking
Terreno	62 terminales EC55 más 20 % de reserva, cerca de 200 terminales TC58e, 200 impresoras de cabina y 200 terminales de pago	Calle y camiones
Bodega	174 terminales de cámara, 6 impresoras de andén, 3 balanzas y 6 escáneres GS1	CD y cross-docking
Cadena de frío	7 módulos de sensores con 28 puntos, 2 gateways IoT y 18 termógrafos	CD, cámaras y camiones
Puestos y sala técnica	8 estaciones de trabajo y la infraestructura de sala de Talca: UPS, generador, 2 unidades de clima de precisión, 4 gabinetes y 7 cámaras	Talca y Concepción

Tabla 23 Síntesis del equipamiento a proveer por familia

Fuente: elaboración propia; detalle en el Formulario T-11.

Más de nueve de cada diez unidades están en el terreno y en la bodega, no en la sala técnica: son unos 860 dispositivos de trabajo frente a menos de 50 equipos de cómputo, red y sala. Esa proporción refleja el caso, donde la operación ocurre en la calle, en la cámara y en el andén, y explica por qué la gestión de dispositivos (N-13) es un componente con emplazamiento propio y no un accesorio.

4.2.5.2 Criterios de selección

Cada familia se especifica contra una condición del caso que el equipamiento de oficina no resiste. Los 174 terminales de cámara están certificados para trabajar a -30°C con guantes gruesos y batería de recambio en caliente, porque la preparación de congelados

ocurre a -22°C (Caso, Cap. 4.5); su número cubre los 120 preparadores simultáneos de Talca con 20 % de reserva por la rotación de 38 %, más 30 en Concepción. Los terminales de terreno operan un turno completo sin señal, a una mano y bajo sol directo (RT-13.08). Los mini-PC de los cross-docking son de rango industrial, porque las naves no tienen climatización y el supuesto de diseño es de hasta 50°C bajo la techumbre en verano. Y los termógrafos están calibrados contra un patrón NIST en dos puntos, porque su registro es la prueba de la cadena de frío ante un cliente o ante la autoridad sanitaria.

En la sala técnica el criterio es la redundancia sin sobrecompra. Los tres servidores del clúster son idénticos, de modo que la pérdida de cualquiera deja capacidad para todas las máquinas virtuales, y la cuarta unidad solo se agrega con el crecimiento de 3 veces, en el gabinete R04 ya reservado. Los firewalls de Talca van en par y el de Concepción es único, porque en ese sitio la contingencia ante la falla es la misma autonomía que cubre los cortes de enlace.

4.2.5.3 Software y licenciamiento

El software de base es de código abierto en todos los componentes que el adjudicatario opera: PostgreSQL, RabbitMQ, Keycloak, Proxmox VE, Ceph y Docker, además de la aplicación, escrita en Django y Python y, en el terreno, en Kotlin. Los únicos elementos con suscripción son los servicios de la plataforma de nube, descritos en la sección 4.2.2, la gestión de dispositivos y los agentes de detección en endpoints. Esta composición mantiene la reversibilidad de la solución y evita que el CLIENTE quede atado a un licenciamiento propietario. El Formulario T-11 detalla, además del equipamiento, cada servicio de nube y cada componente de software con su cantidad y su justificación.

Tecnologías de software ofertadas

Las tecnologías se eligen bajo los criterios de neutralidad tecnológica, soporte vigente por los 56 meses contractuales y preferencia por servicios administrados y componentes de código abierto con estándares abiertos, de modo que el CLIENTE conserve la reversibilidad de la solución:

- **B1 — Aplicación.** Django monolito modular (Python) + Celery sobre AWS ECS Fargate (2–6 tareas con escala automática). La misma imagen se reutiliza en modo wms_only dentro del ambiente on-premise.
- **B2 — BD transaccional nube (maestro).** Amazon Aurora PostgreSQL en sa-east-1 (Multi-AZ), con réplica pasiva promueble en us-east-1 para recuperación ante desastres ($RTO \leq 4 \text{ h}$ / $RPO \leq 15 \text{ min}$).
- **B3 — BD transaccional on-premise.** PostgreSQL 16 (VM-02 Talca / VM-C02 Concepción): sistema de verdad de la bodega durante cortes de enlace, con flujo continuo hacia la réplica en nube por AWS DMS CDC sobre el WAL lógico (registro de escritura anticipada que permite replicar cambios en tiempo real) ($RPO \leq 15 \text{ min}$).
- **B4 — Broker de mensajería.** RabbitMQ local (colas offline por sitio) + SQS FIFO en nube (reconciliación): cada sitio absorbe hasta 24 h de operación sin enlace con vuelco en orden estricto e idempotencia (D-AL-03). Las tareas derivadas de cada evento las despacha Celery desde el monolito.
- **B5 — Identidad (IdP maestro).** Keycloak en ECS/Fargate (OIDC/OAuth 2.1, MFA, SSO), autoridad única en sa-east-1 con cachés locales de solo lectura (ADR-06); el modelo completo se describe en la sección de seguridad.
- **B6 — Telemetría IoT.** AWS IoT Core + Greengrass v2 + sensores Ebyte ME31 (B-01/B-02): registro continuo de cadena de frío con decisión de bloqueo por excursión térmica 100 % en el borde.
- **B7 — Observabilidad.** Plataforma única: instrumentación OpenTelemetry con colectores ADOT on-premise (VM-06, VM-C04, cross-dock; buffer en disco 24 h) que emiten a CloudWatch (logs, métricas y trazas) en sa-east-1 (ADR-14); sin herramientas duplicadas por ambiente ni infraestructura de monitoreo que operar.
- **B8 — Virtualización on-premise.** Proxmox VE/KVM + Ceph (12 OSD, réplica 2, 3 monitores): tolera la pérdida de cualquier nodo con quórum real; respaldo único

3-2-1-1-0 con NAS D-05 y pierna inmutable en nube.

- **B9 — Orquestación de contenedores de borde.** Docker/Docker Compose + WMS en los 3 cross-docking (E-01) y en el borde de Concepción: instalación y parcheo sin dependencia de la red, con paridad de versiones.
- **B10 — Gestión y configuración.** Ansible (F-02, parches/CIS) + Terraform/CDK IaC (multi-zona): configuración declarada como código versionado en el repositorio del CLIENTE.
- **B11 — Gestión de dispositivos de terreno (MDM).** N-13 — Android Enterprise / Zebra DNA (servicio gestionado): enrolamiento por IMEI contra el usuario, política (cifrado local, PIN, modo quiosco), actualización Over-The-Air de la aplicación y de la caché de turno, inventario del parque y borrado remoto selectivo; sin infraestructura on-premise (equipo de TI de 4 personas).
- **B12 — Gestión de secretos.** AWS Secrets Manager + SSM Parameter Store (N-12): rotación automática, sin credenciales embebidas; consumo saliente por VPC Endpoint desde los nodos on-premise (ADR-15); credencial de emergencia en sobre sellado en el recinto de custodia.
- **B13 — Seguridad lógica.** WAF v2 + Shield + API Gateway + SIEM/Security Lake + EDR (F-03) + Macie: superficie expuesta mínima y detección concentrada en un solo registro, bajo política Zero Trust.
- **B14 — Analítica / BI.** Redshift Serverless (OLAP, 5 años) + QuickSight: separación OLTP/OLAP con latencia máxima de 4 h para los tableros del CLIENTE.
- **B15 — Licenciamiento.** Servicios AWS por servicio + OSS sin licencia (Keycloak, PostgreSQL, Proxmox VE, RabbitMQ): reversibilidad y ausencia de dependencia propietaria.

3.1 Integración con el ERP y documentos tributarios

El ERP de 2017 no se reemplaza ni se modifica (Cap. 10 del caso): permanece como única fuente de verdad tributaria. La solución entrega los datos de operación a través de la capa anticorrupción (ACL, VM-04) y el ERP emite los documentos tributarios (guía de despacho electrónica, factura, boleta y nota de crédito con folios SII), con acuse de recibo con efectos legales —una sola verdad, un solo emisor. El acceso desde la nube a este ERP ocurre únicamente vía la ACL (celery-erp-sync → ACL, nunca escritura directa).

Especificaciones del sitio principal on-premise (CD Talca)

Tipología declarada (numeral 6.1 de las Transversales): sala técnica principal.. El CD Talca aloja el núcleo del componente on-premise, es decir cómputo, almacenamiento y procesamiento sustantivos en instalaciones del CLIENTE. Concentra el motor WMS, la base transaccional del maestro de bodega, el broker de colas, la capa anticorrupción del ERP, la caché de identidad, la telemetría y el respaldo local. Por eso se le aplican íntegramente los requisitos RT-06.01 a RT-06.34, y no el régimen proporcional de una sala de sitio.

Disponibilidad de infraestructura comprometida: 99,95 % mensual, conforme al numeral 6.1 y a la tabla del numeral 7.2 de las Transversales, medida por componente: energía del recinto, climatización, red y comunicaciones, servidores y cómputo, y motor de base de datos. El compromiso se sostiene con redundancia N+1 en energía y climatización, doble acometida con transferencia automática, generación autónoma propia y monitoreo continuo con alertamiento; no se invoca ninguna clasificación de instalación de tercero, porque las Bases no exigen certificación de nivel sino el cumplimiento verificable de cada requisito técnico individual. Este valor es el nivel de la infraestructura del recinto y es distinto del compromiso contractual penalizable del Artículo 78°, que recae sobre la transacción de negocio de extremo a extremo ($\geq 99,9$ % mensual, RT-10.01).

El programa arquitectónico propuesto considera ≈ 173 m² y 14 recintos: sala blanca de 32 m², NOC de 14 m², sala de sistemas de alimentación ininterrumpida y baterías, sala de climatización, sala de extinción, distribuidor principal y acometidas, recinto de custodia de medios de 10 m², patio de generador y recintos de apoyo. La disposición interna, la separación de zonas y la elevación de gabinetes constan en los planos del recinto que acompañan a esta parte.

Energía: UPS doble conversión on-line 6 kVA con configuración N+1 y banco VRLA con autonomía ≥ 30 min a plena carga; grupo electrógeno de 12 kVA con estanque para 24 h y contrato de reabastecimiento; transferencia automática red↔generador con prueba mensual con carga real; PDU verticales A/B por gabinete con medidor; factor de potencia $\geq 0,95$.




Figura 3 Plano de distribución interna del recinto técnico, con la separación de las zonas de generador, baterías, climatización, servidores, comunicaciones y custodia de medios




Figura 4 Cadena eléctrica del recinto: acometida, transferencia automática, generación autónoma, alimentación ininterrumpida y distribución A/B por gabinete

Climatización: 2 CRAC de precisión ≈ 12.000 BTU/h en N+1, con free cooling, pasillo frío confinado y rango ASHRAE TC 9.9 de 18–27 °C y 40–60 % HR medido a la toma de aire del equipo; PUE objetivo de diseño 1,7 (valor conservador para sala de servidores pequeña con climatización de precisión N+1) con medición continua en 2 puntos y reporte trimestral.


Incendios: detección temprana por aspiración AnaLASER; extinción con agente limpio FM-200 conforme NFPA 75/2001 con botón de aborto; extintores ABC y CO₂ por recinto.

Seguridad física: 4 capas de acceso con biometría facial y resguardo AFIS, esclusa antipassback y bitácora electrónica, una persona a la vez y acompañada; 12 puertas controladas y 7 cámaras IP con retención ≥ 30 días integradas al control de acceso; NOC de 14 m² contiguo a la sala con ventana interior («ver sin entrar»); sensores ambientales DCIM/BMS.

Custodia de medios: recinto de 10 m² en la segunda línea, sin luz UV (≤ 300 lux), 40–60 % HR, ventilación forzada y 18–27 °C; medio cifrado transportable rotado semanalmente a bóveda externa bajo custodia acreditada con cadena de custodia y bitácora; la pierna inmutable S3 es complementaria, no la reemplaza.

Cableado y comunicaciones: cableado estructurado Cat6A F/UTP + fibra OM4 certificado enlace por enlace sobre piso técnico de 40 cm, jerarquía ANSI/TIA-942 ENI→MDA→HDA→ZDA→EDA, con dos ductos de ingreso independientes; 4 racks 42U en gabinete de servidores y comunicaciones separados, con el cuarto (R04) reservado al crecimiento a 3 años.

Los componentes de infraestructura de sala del CD Talca (UPS, generador, transferencia automática, climatización, seguridad física, extinción, cableado y gabinetes) se detallan en la Tabla 49 del Formulario T-11, que acompaña a esta parte como anexo. El equipamiento de cómputo, red y comunicaciones que se aloja en estos gabinetes se resume en la sección 4.2.5.



Fuente: Sala Servidores OnPremise v02 56.2/56.3 (R01-R04) y 61.3 (borde); T-11 C1/C2/C3/C5/C6/C7/C8/C13/C14; D-06 Starlink

Figura 5 Elevación de los cuatro gabinetes, con la ocupación proyectada de cada uno y el margen de crecimiento reservado en R04

Especificaciones del sitio secundario

Cómo se satisface el numeral 7.1.. Las Transversales exigen un sitio secundario en dependencias distintas del principal, en modalidad activo-activo o activo-pasivo, con replicación en línea del ambiente de producción y características tecnológicas equivalentes a las del sitio principal en lo que respecta a los servicios críticos. La solución lo satisface con dos sitios secundarios, uno por cada dominio del despliegue híbrido, porque la carga crítica vive en ambos:

- **Para el componente on-premise, el CD Concepción:** es una dependencia física distinta, a 340 km del extremo opuesto de la red y sin amenazas comunes con Talca, y opera el motor de almacenes con su propia base local y autonomía de 24 horas. No es un sitio en espera: opera de forma autónoma todos los días y asume la carga de bodega de Talca mediante promoción controlada.
- **Para la carga principal en nube, la región AWS us-east-1:** aloja la réplica pasiva promovible del núcleo transaccional, a ≈ 7.700 km de la región primaria y ≈ 8.500 km de Talca, sin amenazas comunes.


El mecanismo de recuperación ante desastres (modalidad activo-pasiva, $RTO \leq 4$ h, $RPO \leq 15$ min), el procedimiento de conmutación y retorno, las pruebas semestrales, la tabla de componentes de la réplica y el esquema de respaldos 3-2-1-1-0 se declaran en el capítulo de arquitectura de despliegue.

El gabinete de borde con que se habilitan el sitio secundario on-premise y las tres plataformas de cross-docking es el siguiente:


SITIO SECUNDARIO - GABINETES DE BORDE (T-21 4.2.e / RT-06.01 / 4 requisitos 6.1)

CD Concepcion (site secundario activo aut.onoma) + cross-docks x3 (Curico, Chillan, Los Angeles). Equipo real T-11 C3/C4/C13/C14/C15/D-06.

GABINETE DE BORDE - CD CONCEPCION (12U. 600x1200) - activo autonoma



GABINETE DE BORDE - CROSS-DOCKING x3 (12U) - Curico/Chillan/Los Angeles



Concepción en gabinete, junto a firewall (C13), switch core (C14), servidor borde (C3) y Starlink (D-06); UPS interna para autonomía >= 30 minutos; configuración vía Starlink (D-06) con LTE dual de respaldo automático (RT-03.17); switch compacto (C15)

4 REQUISITOS GABINETE DE BORDE (BTT sect.6.1):

PROTECCION ELECTRICA

UPS/supresor de transitorios + puesta a tierra; doble fuente A/B; autonomia ≥ 30 min (cubre corte y conmutacion de enlace).

CONTROL DE ACCESO FISICO

Cerradura de gabinete con control y registro de aperturas; acceso a gabinete restringido; coherente con 4a capa de seguridad.

MONITOREO REMOTO

Sensores T/HR y apertura integrados al DCIM/BMS del NOC (CD Talca); alertas con destinatario y procedimiento (profe sect.4).

Figura 6 Gabinete de borde industrializado del CD Concepción y de las tres plataformas de cross-docking: alimentación protegida, control de acceso y monitoreo remoto dimensionados al sitio (numeral 6.1, tipología de borde operacional)

Arquitectura de integración

Vista física de las integraciones: emplazamiento de las superficies, mensajería y costuras con la arquitectura lógica. El catálogo de integraciones, los principios, los contratos, los eventos canónicos, la capa anticorrupción y el versionado se declaran en la arquitectura lógica (Subdocumento 4.1). El volumen de mensajes por integración se declara en el capítulo de dimensionamiento (Tabla 13).

6.1 Vista de integración

La vista de integración se organiza en cuatro dominios físicos:

- **Terreno (offline-first):** C-01 App Preventa (62 preventistas), C-02 App Reparto ($\approx$ 200 conductores) y C-03 HHT bodega (120 concurrentes).
- **On-premise (5 sitios con cómputo):** A-01 Motor WMS (M1, M2 y M5 en modo wms_only), A-03 RabbitMQ (buffer 24 h), A-04 capa anticorrupción (frontera única del ERP), B-02 Greengrass (buffer 14 h) y E-01 WMS del cross-dock (ventana de 3 h).
- **Nube AWS sa-east-1:** Amazon API Gateway (Capa 3), Capa 4 con M1-M12 en Django + workers Celery, N-09 SQS FIFO, M11 Hub EDI GS1 (EANCOM, GS1 XML y EPCIS) y N-08 IoT Core.
- **Terceros:** ERP 2017 (sin documentación de interfaces), SII (DTE y guía electrónica), cadenas de supermercados (hito enero 2029), Transbank Webpay/POS, GIS/mapas y notificaciones.

Flujo del tráfico entre estos dominios: el terreno de calle llama directo a la puerta de enlace (API Gateway) por la red celular, sin pasar por el on-premise; los HHT de bodega se comunican por WLAN local con el WMS del sitio; el WMS publica al broker local (A-03) que reenvía a SQS FIFO en la nube; el cross-dock (E-01) publica sus eventos críticos directo a SQS FIFO y solo el detalle del WMS del cross-dock viaja a Talca, de modo que lo crítico no depende de Talca (D-AL-04); Greengrass envía por IoT Core; y la Capa 4 consume las colas y alcanza el ERP únicamente a través de la capa anticorrupción

(A-04), con una sola puerta hacia el legado.

6.2 Mensajería (ADR-05)

Los planos de mensajería y su emplazamiento físico se describen en la Tabla 24:

Plano	Tecnología	Emplazamiento	Rol
Buffer local de sitio	RabbitMQ (A-03)	VM-03 Talca (≈ 3 M mensajes) · VM-C04 Concepción · broker en E-01	Sostiene la autonomía de 24 h del centro de distribución. Es lo que permite que la bodega reciba, prepare y despache con el enlace caído.
Trabajo y reconciliación	SQS FIFO (N-09)	Nube	Orden garantizado por partición (Message-GroupId = sitio) y deduplicación; alimenta a celery-reconciliation y celery-erp-sync.
Tareas derivadas de eventos	Celery workers (Far-gate)	Nube	Cada evento de negocio despacha tareas asíncronas: notificaciones, actualización analítica, emisión de DTE y transmisión EDI.
Transporte hacia la nube	Shipper en VM-03 (modo wms_only)	On-premise → nube	HTTPS 443 sobre VPC Endpoint SQS/Private-Link (D-AL-03). AMQPS 5671 queda reservado a broker con broker on-premise.

Tabla 24 Mensajería: planos y emplazamiento físico

6.3 Costuras híbridas: amarre con la arquitectura física

La vista de integración y la vista física describen los mismos puntos de contacto. La Tabla 25 amarra ambas: cada costura física se cruza con la integración lógica que la usa, su contrato y sus extremos.

Costura física	Integración lógica	Contrato	Extremos
C1 — VPN corporativa	portadora de INT-06 e INT-12	IPsec/IKEv2, BGP, MTU 1436	D-01 ↔ VGW
C2 — Réplica WMS → Aurora	INT-12	WAL lógico / DMS CDC	VM-02 ↔ Aurora
C4 — Broker → SQS FIFO	INT-03	AsyncAPI 2.6	VM-03 ↔ N-09
C5 — ERP por la ACL	INT-06	OpenAPI 3.1 de Puelche	VM-04 ↔ celery-erp-sync
C6 — Identidad	INT-13	Realm cifrado por S3	Keycloak maestro ↔ A-05 / VM-C03
C7 — IoT Greengrass	INT-05	MQTTS 8883, X.509	B-02 ↔ N-08
C8 — Observabilidad	INT-14	OTLP	F-01 ↔ CloudWatch
C10 — Apps de terreno	INT-01 / INT-02	OpenAPI 3.1	C-01 / C-02 ↔ Capa 3
C13 — Cross-dock	INT-04	AsyncAPI 2.6 / AMQPS	E-01 ↔ VM-03 y ↔ N-09
C14 — Notificaciones y EDI	INT-08 / INT-11	GS1 / API de notificaciones	Celery workers ↔ terceros
C15 — Portales de la DMZ	INT-01 (lectura de stock, crédito y cobranza)	OpenAPI 3.1	N-01/N-02/N-03 ↔ Capa 3
C16 — Pago Transbank	INT-09	API de la pasarela	Módulo integraciones ↔ Webpay

Tabla 25 Costuras híbridas: amarre con la arquitectura física

6.4 Carga y descarga masiva de datos

- **Carga inicial de maestros e históricos (ERP y WMS):** proceso ETL por lotes con inserción idempotente por UUID, en ventana sin operación. Control: conteo previo y posterior por lote, conciliación de totales y bitácora de carga (quién, cuándo, lote, resultado); los rechazados van a cuarentena con reproceso.
- **Descarga regulatoria (traza de lote, temperaturas, DTE, geolocalización):** exportación asíncrona a CSV o Parquet, firmada y con suma de verificación. Control: registro de la extracción (solicitante, filtro, resultado) y control de acceso a datos sensibles (RT-16.09).
- **Sincronización masiva de turno (terreno):** sincronizadores con partición y reanudación más deduplicación; los medios van a S3 por objeto. Control: turno completo $\leq$ 10 min; métricas de sincronización en la Capa 8.
- **Interfaces periódicas con terceros:** colas con batch_id y confirmación por lote. Control: monitoreo de DLQ y acuse por lote en la bandeja de excepciones.

Regla: ninguna carga masiva se ejecuta dentro de la ventana crítica 05:30–07:00, y toda carga queda registrada y es auditable.

Arquitectura de seguridad

Esta solución de seguridad se estructura sobre: Zero Trust, capa expuesta, identidad y accesos, cifrado y controles, esto debido a que el perímetro de esta solución no es un edificio corporativo sino un entorno distribuido con alta rotación de personal externo y dispositivos compartidos en terreno.

7.1 Principios rectores

1. **Zero Trust conforme a NIST SP 800-207.** Verificación explícita de cada solicitud, privilegio mínimo y presunción de compromiso. La red interna no confiere confianza.
2. **Seguridad desde el diseño y por defecto.** Modelado de amenazas STRIDE documentado por cada componente y por cada integración externa, antes de implementar.
3. **La identidad es el perímetro.** Autoridad única de identidad mediante Keycloak y toda decisión de acceso se toma sobre el token, no sobre la dirección de red de origen.
4. **Sin conexiones entrantes al on-premise.** Todo tráfico desde on-premise hacia la nube es saliente. Las dos únicas excepciones son las conexiones entrantes de DMS hacia PostgreSQL y de celery-erp-sync hacia ACL, declaradas, acotadas al túnel IPsec autenticado y auditadas.
5. **Cifrado en tránsito y en reposo sin excepciones.** TLS 1.3 mínimo para el tránsito, cifrado en reposo del 100 % de los datos con claves gestionadas en KMS/HSM y separación de funciones en su custodia.
6. **La seguridad no puede detener la ventana crítica.** Ningún control de seguridad puede introducir una dependencia en línea dentro de 05:30 hasta las 07:00 ni en las 14 h de terreno sin señal. La autenticación de terreno se resuelve sin red por diseño.
7. **Operable por cuatro personas.** El CLIENTE tiene 4 personas de TI, por lo que se privilegian servicios administrados y un SOC contratado 24/7 por sobre plataformas que exijan operación local especializada.
8. **Evidencia inalterable.** Todo evento de seguridad y toda acción de negocio quedan en un registro inalterable y con retención declarada; ni un administrador puede modificarlo.

7.2 Modelo Zero Trust aplicado

7.2.1 Zonas y flujos

En el texto las zonas y su flujo son la zona pública como los clientes del canal moderno, transportistas para los 160 conductores y 180 proveedores que ingresan únicamente por la DMZ en nube en CloudFront más AWS WAF v2 más Shield Advanced hacia el Amazon API Gateway con OIDC, cuotas, esquema y validación de carga útil, para la zona de aplicación se usa ECS Fargate más workers y Keycloak IdP maestro como autoridad única que sirve a las zonas de datos como Aurora PostgreSQL, DynamoDB y S3 con Object Lock, en subredes privadas sin salida, para la zona on-premise se usa VLAN 10 MGT, 20 SRV, 30 OPS, 40 WKS, 50 IOT, firewall D-01 UTM en HA como Customer Gateway y caché Keycloak de solo lectura TTL 8 h que se conecta con la nube por VPN/IPsec saliente, por último para la zona de terreno se usa apps Kotlin offline-first más MDM; HHT compartidos en cámara a -22°C que no tiene perímetro.

Reglas de zona declaradas:

- La única exposición pública es la DMZ en nube ya sea CloudFront hacia el WAF y hacia el API Gateway. Las consolas internas no pasan por ahí, por lo que entran por intranet o VPN.
- La zona de datos no tiene salida a internet y se consume por VPC Endpoints o PrivateLink.
- Desde la zona on-premise no se acepta ninguna conexión entrante salvo las dos excepciones D-AL-05.
- La zona de terreno no tiene perímetro, por lo que se protege con identidad, cifrado local, MDM y borrado remoto.

7.3 Capa expuesta

- **Publicación exclusiva por capa de borde.** CloudFront como único origen público ya que los orígenes están restringidos y no se alcanzan directamente.
- **WAF con reglas gestionadas y personalizadas.** se usará AWS WAF v2 que es un conjunto gestionado OWASP que contiene Top 10 más reglas propias por API.
- **Protección DDoS en capas 3, 4 y 7.** AWS Shield Advanced con respuesta gestionada.
- **Gestión automatizada de certificados.** Inventario centralizado, renovación automática y alerta anticipada a 30 días del vencimiento.

- **Puerta de enlace con controles completos.** API Gateway con autenticación OIDC, autorización por rol, cuotas y límites de tasa por cliente, validación de esquema e inspección de carga útil.
- **Protección contra bots y abuso automatizado.** Reto progresivo en los puntos de entrada públicos sin degradar la accesibilidad.
- **Superficie de exposición declarada.** Inventario completo de servicios, protocolos, puertos por sitio y por zona.

7.4 Desarrollo seguro y cadena de suministro

- **Matriz de controles.** Matriz trazable con control, implementación concreta y evidencia.
- **Firma y procedencia.** Artefactos firmados y verificados.
- **Entornos de prueba.** Prohibido el uso de datos productivos reales sin anonimización.
- **Dependencias de terceros.** Proceso de aprobación con criterios de licencia, mantenimiento activo y ausencia de vulnerabilidades conocidas.

7.4.1 Superficie de exposición completa

Zona / sitio	Servicios expuestos	Protocolos y puertos	¿Alcanzable desde internet?
DMZ pública en nube	Portales N-01, N-02 y N-03 sobre Puelche	HTTPS (TLS 1.3)	Sí, por CloudFront con WAF y Shield
Zona de aplicación en nube	ECS Fargate y Keycloak maestro	Solo desde el ALB y la puerta de enlace	No
Zona de datos en nube	Aurora, DynamoDB y S3	Solo por VPC Endpoint y PrivateLink	No
Talca (red interna)	Portal WMS, API WMS, PostgreSQL, broker AMQP y gestión SSM	HTTPS (TCL 1.3), TCP	No, solo por VPN Zero Trust
Talca (borde)	Clúster de firewall en HA	IPsec 500/4500 UDP	Solo terminación IPsec

Tabla 26 — continuación

Zona / sitio	Servicios expuestos	Protocolos y puertos	¿Alcanzable desde internet?
Concepción (borde)	Greengrass hacia IoT Core (MQTT saliente)	MQTTS 8883 (X.509)	No; sin puertos entrantes
Concepción y cross-docking	Gabinete de borde (mini-PC)	IPsec 500/4500 UDP	Solo por VPN IPsec
Estaciones de trabajo	NA	MQTTS 8883 (X.509) por proxy	No

Tabla 26 Superficie de exposición completa (RT-11.13)

Regla declarada: ningún nodo on-premise abre puertos entrantes. Toda gestión remota entra por el agente SSM sobre MQTTS 8883 (X.509) o por la VPN, nunca por un puerto publicado.

7.5 Identidad, acceso y sesiones

7.5.1 Modelo de identidad

Como autoridad única en nube y cachés locales de solo lectura el Keycloak IdP maestro vive en ECS Fargate ubicado en sa-east-1 respaldado en Aurora y concentra todas las escrituras ya sean altas, bajas, cambios de rol, políticas y revocaciones. Para el VM-05 de Talca y el VM-C03 de Concepción operan cachés locales de solo lectura con TTL de 8 h que validan la firma OIDC de forma local. No existe un maestro on-premise ni promoción local a escritura.

- **Keycloak IdP maestro en la nube (autoridad única)** Integración mediante SCIM con el directorio corporativo del CLIENTE por VPN saliente.
- **Caché local para Talca y Concepción (solo lectura por 8 horas)** Validación local de firma y emisión de sesiones sin conexión.

7.5.2 Federación, SSO y factores

- **SSO con cierre propagado.** Inicio de sesión único para todos los módulos con cierre de sesión propagado a todos en tiempo real.
- **Factores.** MFA obligatoria para administradores, privilegios y todo acceso externo.
- **RBAC + ABAC.** Control por roles complementado con atributos donde el proceso lo exija.
- **Credenciales firmadas y de vida breve.** Sin identificadores de sesión en la URL.
- **Ciclo de vida auditado.** Creación, modificación, elevación, bloqueo y baja de cuentas.
- **Aprovisionamiento automatizado.** Alta/baja ligadas al ciclo laboral.
- **Perfil operacional.** Autenticación adecuada al caso: guantes térmicos, uso a una mano, dispositivos compartidos y sin correo electrónico.

7.5.3 Política de sesión

- **Duración.** La credencial de acceso dura 30 minutos y la credencial de identidad dura 1 hora.
- **Renovación.** Credencial de refresco rotatoria por 30 días.
- **Inactividad.** Caducidad por inactividad según perfil.
- **Revocación y concurrencia.** Revocación inmediata ante baja, compromiso o suspensión.
- **Operación desconectada.** Token de turno de 8 horas en bodega o 14 horas en terreno que son preventa y reparto.

7.5.4 Autenticación en terreno

Las condiciones estipuladas son los guantes térmicos a -22°C , operación a una mano durante la descarga, uso de pie y a la intemperie en la puerta del local, dispositivos compartidos entre turnos en bodega y 38 % de rotación anual en preparación.

- El operador autentica con conexión al inicio de turno ya sea con un PIN de 6 dígitos y descarga un token cifrado de vida acotada al turno.
- Durante el turno el PIN desbloquea el token local que no se autentica contra el IdP por transacción.
- El dispositivo es un factor de posesión enrolado por MDM y el PIN es el segundo factor.

- Los datos locales están cifrados y admiten borrado remoto selectivo por lo que se borra la aplicación y su caché.

7.6 Cifrado y gestión de claves

7.6.1 En tránsito

El cifrado en tránsito se declara por trayecto:

- **TLS 1.3 mínimo y obligatorio.** Prohibición expresa de TLS 1.0 y 1.1, conjuntos de cifrado modernos y HSTS con precarga en las superficies web.
- **Tráfico interno cifrado.** Capa de aplicación hacia la base de datos, broker y caché, mediante mTLS o cifrado nativo del protocolo.
- **On-premise desde o hacia la nube.** IPsec/IKEv2 cifrado, BGP y MTU 1436.
- **Respaldos y replicación.** TLS 1.3 en tránsito, incluida la replicación hacia us-east-1.
- **Gestión de certificados.** Inventario centralizado, renovación automática y alerta anticipada a 30 días del vencimiento.

7.6.2 En reposo

Elemento	Cifrado	Gestión de claves
Almacenamiento del clúster	LUKS con NVMe con autocifrado	CMK dedicada on-premise
NAS de respaldo	LUKS	CMK independiente de la de producción
PostgreSQL on-premise	Cifrado del sistema de archivos subyacente	CMK dedicada
Aurora, DynamoDB y S3	KMS	AWS KMS con CMK
Estaciones de trabajo	LUKS	Servidor de claves corporativo
Terminales de terreno	Cifrado del dispositivo	MDM

Tabla 27 Cifrado en reposo por componente

Las claves de datos se rotan anualmente y las claves maestras siguen el calendario del proveedor de KMS/HSM. La rotación es en línea y no degrada el servicio, y los respaldos conservan la versión de clave necesaria para permitir una restauración auditable.

7.6.3 Cifrado a nivel de campo

El cifrado a nivel de campo se declara por conjunto de datos:

- **Comportamiento de pago y antecedentes comerciales del cliente.** Cifrado a nivel de campo con clave en KMS.
- **Datos de geolocalización de personas.** Cifrado a nivel de campo, retención de 12 meses y registro de consultas.
- **RUT de clientes en bases y registros.** Pseudonimización mediante cifrado a nivel de campo.

7.7 Clasificación de la información y controles por nivel

Nivel	Ejemplos en Puelche	Controles mínimos
Restringido	Claves KMS/HSM, credenciales de servicio y firma privada de DTE	Cifrado a nivel de campo, KMS/HSM, MFA, acceso nominativo con aprobación y registro de consultas
Confidencial	Base del WMS	Cifrado en reposo y a nivel de campo, RBAC/ABAC, registro de consultas, retención declarada
Interno	Registros de operación, métricas y configuraciones	Acceso por rol y segregación de funciones
Público	Catálogo público de productos sin precios	Sin controles de confidencialidad, integridad vía CI/CD

Tabla 28 Clasificación de la información y controles por nivel (RT-11.03)

7.8 Detección, respuesta y evidencia

- **Registro centralizado e inalterable.** Todos los eventos de seguridad se centralizan con ingesta continua.
- **Retención de eventos de seguridad.** 12 meses en línea + 24 meses en archivo recuperable que corresponden a 36 meses en total.
- **Auditoría de negocio.** 7 años en CloudWatch Logs con exportación periódica a S3 Glacier.
- **SIEM con casos de uso del negocio.** Security Lake con 6 casos de uso propios de la operación logística que corresponde a la alerta nocturna fuera de patrón, acceso remoto anómalo, MFA en TI en la sombra, exfiltración de datos de stock, escalada de privilegios y respuesta a incidente reglamentario.
- **EDR en nube y on-premise.** Agentes en todos los nodos on-premise, estaciones y cargas en nube.
- **SOC 24/7.** Cobertura contractual de ambos dominios con dotación mínima declarada.
- **Gestión de vulnerabilidades.** Plazos contractuales con crítica de 7 días, alta de 15 días, media de 30 días.
- **Respuesta a incidentes.** Plan con clasificación, cadena de escalamiento, plazos y responsables.
- **Simulación de incidentes.** Ejercicios al menos una vez al año con participación del CLIENTE.
- **Pruebas de intrusión.** Anuales por un tercero independiente del adjudicatario y previas a cada paso a producción.

7.9 Datos personales, residencia y transferencia internacional

- **Residencia primaria.** Toda la operación productiva reside en AWS sa-east-1. El dominio on-premise reside en las instalaciones del CLIENTE en Chile.
- **Región secundaria.** us-east-1 es exclusivamente como ambiente de recuperación ante desastres.
- **Transferencia internacional.** La replicación hacia us-east-1 constituye una transferencia internacional de datos personales en el sentido de la Ley 21.719.
- **Resguardos declarados.** Se cuenta con un cifrado en reposo con CMK gestionada por el CLIENTE y en tránsito extremo a extremo, luego un acuerdo de tratamiento de datos con el proveedor de nube con cláusulas de transferencia, luego la minimización

que la región secundaria no se usa para explotación analítica ni para consultas de negocio, solo para continuidad, luego los datos de geolocalización de personas quedan excluidos de la replicación transfronteriza y se conservan solo en sa-east-1 con retención de 12 meses y por último el registro de la transferencia en el inventario de tratamientos.

- **Aprobación del CLIENTE.** Si el CLIENTE no aprueba la transferencia a us-east-1, la alternativa declarada es la continuidad intrarregional en sa-east-1 entendida como no salir de la región AWS sa-east-1.
- **Eliminación segura.** Procedimiento verificable de eliminación al vencimiento, con registro inalterable.
- **Exportabilidad.** Capacidad de exportar la totalidad de la información del CLIENTE en formatos abiertos y documentados, en cualquier momento del contrato y sin costo adicional.
- **Derechos de los titulares.** Acceso, rectificación, cancelación, oposición, portabilidad y bloqueo temporal.

Dos de los resguardos de esta tabla son decisiones de diseño y no solo cláusulas contractuales, y se propagan a la sección de arquitectura de despliegue de este capítulo y a la arquitectura lógica, por la que la región secundaria sostiene continuidad y no se explota analíticamente, y la exclusión de los datos de geolocalización de personas de la replicación transfronteriza.

7.9.1 Derechos de los titulares, política de privacidad y EIPD

EIPD. Evaluación de impacto obligatoria por tratamiento masivo con 14.200 clientes y con monitoreo sistemático. **Vigencia.** La Ley 21.719 rige desde el 01 de diciembre de 2026 y un proyecto de ley del Boletín 18.623-07 postergaría la vigencia al 01 de diciembre de 2027.

7.9.2 Base de licitud por tratamiento

Tratamiento	Base de licitud	Garantías clave
Geolocalización de trabajadores	Ejecución contrato más interés legítimo	finalidad operativa, sin control de jornada y cifrado de campo
Comportamiento de pago / crédito	Ejecución contrato más interés legítimo	Cifrado de campo con acceso restringido
Datos laborales	Obligación legal más ejecución contrato	acceso restringido a RRHH
Clientes como preventa, DTE y portal	Ejecución contrato más obligación legal	Sin marketing sin consentimiento
firma y foto	Ejecución contrato	Retención 6 años
Conductores externos	Consentimiento del titular	Datos mínimos más OTP

Tabla 29 Base de licitud por tratamiento (Ley 21.719, Art. 12 y 13)

Arquitectura de despliegue

Arquitectura de despliegue de la solución: ambientes, redes y segmentación, alta disponibilidad, recuperación ante desastres y respaldos. Es autocontenida: los valores que declara se sostienen en los componentes especificados en las secciones anteriores de este capítulo.

Tres mecanismos distintos atienden tres amenazas distintas y ninguno sustituye a otro: la **alta disponibilidad** cubre la falla de un componente dentro del sitio o de la región; la **recuperación ante desastres** cubre la pérdida de un sitio o de una región completa; y el **respaldo** cubre el daño al dato —eliminación accidental, corrupción o cifrado malicioso—. Esta sección los declara y los dimensiona por separado.

8.1 Ambientes de despliegue

Los cinco ambientes obligatorios están habilitados como condición del hito H3, aislados entre sí mediante cuentas AWS separadas bajo una organización centralizada de AWS Control Tower (aislamiento estricto + SCP). La organización incorpora además las cuentas de gestión, de archivo de registros y de auditoría propias de AWS Control Tower, que no constituyen ambientes de despliegue. Cada ambiente ocupa una cuenta propia y un bloque de direccionamiento exclusivo, según la Tabla 30:

Ambiente	VPC	Región	Uso
Desarrollo	10.104.0.0/16	sa-east-1	Integración continua y pruebas unitarias
Calidad (QA)	10.103.0.0/16	sa-east-1	Pruebas funcionales, DAST y SAST
Pre-Producción	10.102.0.0/16	sa-east-1	Marcha blanca, aceptación y carga

Tabla 30 — continuación

Ambiente	VPC	Región	Uso
Producción	10.101.0.0/16	sa-east-1	Operación real, Multi-AZ
Recuperación ante Desastres	10.201.0.0/16	us-east-1	5.º ambiente obligatorio (RT-04.01)

Tabla 30 Ambientes de despliegue. Fuente: elaboración propia sobre RT-04.01

Los cinco bloques no se solapan entre sí ni con los de los sitios on-premise (Tabla 33), y todos los ambientes residen en la región primaria salvo el de recuperación, único en us-east-1. Pre-Producción concentra la marcha blanca y las pruebas de carga, por lo que es el ambiente cuya equivalencia con Producción se exige en detalle.

Reglas que gobiernan el modelo de ambientes:

- **Paridad Pre-Producción = Producción (RT-04.02).** topología, versiones de componentes y configuración equivalentes, con las dos únicas diferencias que se declaran en la subsección siguiente.
- **On-premise como producción.** el despliegue on-premise es producción con la imagen única wms_only; esa misma imagen recorre Dev→QA→PreProd en la nube antes del cutover en Talca (ventana de 24 h) y en Concepción. No se mantienen ambientes on-premise separados: la paridad la garantizan la imagen única y el laC versionado.
- **Gobierno del repositorio (RT-04.03, RT-04.04).** control de versiones con ramas protegidas, revisión obligatoria por pares y prohibición de escritura directa sobre la rama principal, con trazabilidad entre requerimiento, incidencia, cambio de código, prueba y despliegue. Su desarrollo corresponde al plan de calidad (Subdocumento 9).
- **Entrega continua (RT-04.05, RT-04.11).** el pipeline CI ejecuta compilación, pruebas unitarias, análisis estático, análisis de composición, escaneo de secretos, escaneo de imágenes de contenedor y medición de cobertura de pruebas de la lógica de negocio, con bloqueo automático del despliegue ante hallazgos críticos o altos y ante cobertura inferior al 70 %.
- **Migraciones de esquema (RT-04.10).** versionadas, reversibles y ejecutadas por el

pipeline, con estrategia de expandir y contraer: la migración de un release solo agrega estructuras, de modo que la versión anterior y la nueva de la aplicación conviven sobre el mismo esquema durante el despliegue; la eliminación de estructuras obsoletas se ejecuta en un release posterior. Es la condición que permite que la reversión del código no exija revertir el esquema. Su desarrollo corresponde al plan de calidad (Subdocumento 9).

- **Despliegue sin interrupción (RT-04.07, RT-10.06).** estrategia azul-verde con canario (despliegue gradual a un porcentaje pequeño de tráfico) en etapas, demostrada en PreProducción antes de cada paso a producción; reversión automatizada. La puesta en producción avanza por proceso, por sitio o por zona comercial, nunca como un evento único que afecte simultáneamente a la bodega, la preventa, el reparto y la facturación (Caso, Cap. 13.3).
- **Configuración externalizada (RT-04.08, RT-04.09).** un mismo artefacto se promueve QA→PreProd→Prod sin recompilación; los secretos viven en AWS Secrets Manager y SSM Parameter Store (N-09, ADR-15) con rotación automática, sin credenciales embebidas.
- **Datos no productivos.** Dev, QA y PreProd usan datos sintéticos generados desde la volumetría del Cap. 14 del caso; las plantillas próximas a producción pasan por anonimización y seudonimización, verificadas con Amazon Macie.
- **Sin acceso interactivo a producción.** los despliegues son exclusivamente por pipeline; el acceso administrativo excepcional es just-in-time vía AWS Systems Manager Session Manager con MFA, aprobación y sesión grabada.
- **Reducción de ambientes no productivos fuera de horario (RT-04.13).** Dev/QA/Pre-Prod se apagan o reducen fuera del horario de uso, con el ahorro reflejado en la estructura de costos. Las prácticas FinOps (RT-03.06) se declaran en la Subparte 4.1.
- **Portales de clientes, transportistas y proveedores.** la SPA Angular se publica por ambiente en S3+CloudFront (bucket y distribución por cuenta AWS) y su backend es la misma imagen Django del ambiente; entra a producción con el hito de enero 2029.

8.1.1 Diferencias entre Pre-Producción y Producción

RT-04.02 exige equivalencia en topología, versiones y configuración, y que toda diferencia que subsista por costo se declare y se justifique. Pre-Producción difiere de Producción en solo dos aspectos. El primero es la disponibilidad horaria: Producción opera en forma continua, mientras Pre-Producción se reduce o apaga fuera del horario de uso, con el ahorro reflejado en la estructura de costos (RT-04.13). El segundo son

los datos: Pre-Producción opera con datos sintéticos generados desde la volumetría del Cap. 14 del caso, para no exponer datos personales fuera de producción. En todo lo demás, incluido el dimensionamiento de la Tabla 19, es igual a Producción, y durante las pruebas de carga y estrés de la Tabla 22, que se ejecutan con 1,5 veces la carga de diseño (RT-09.06), opera con el dimensionamiento completo de Producción.

8.1.2 Calendario de despliegue

El caso fija ventanas en las que está prohibido intervenir los sistemas y ventanas operacionales que el despliegue debe proteger. La Tabla 31 cruza cada período con lo que admite: si se puede desplegar y si se tolera indisponibilidad programada.

Período	Despliegue	Indisponibilidad programada
1 al 25 de septiembre	No	No
Todo diciembre	No	No
Tres primeros días hábiles de cada mes	No	No
05:30–07:00, lunes a sábado	No	No; tolerancia cero
22:00–06:00, preparación nocturna	Sí, sin interrupción	No
08:00–18:00, recepción de proveedores	Sí, sin interrupción	No
Resto del calendario	Sí, sin interrupción	Solo excepcional, con aviso previo de 10 días hábiles

Tabla 31 Calendario de despliegue. Fuente: Caso 02, Cap. 10 (restricción 8) y Cap. 13.3; RT-10.05 y RT-10.06

Ningún período admite indisponibilidad programada salvo el resto del calendario, y solo por excepción: el despliegue sin interrupción es la regla y no una capacidad opcional. En las ventanas de preparación nocturna y de recepción, toda intervención en bodega considera el turno de noche (Caso, Cap. 13.3). De doce meses, aproximadamente diez admiten despliegue, y de cada mes desplegable se excluyen además sus tres primeros días hábiles: la frecuencia de despliegue comprometida (Tabla 32) se deriva de ese

margen.

8.1.3 Reversión de un paso a producción fallido

La reversión es un cambio de enrutamiento del balanceador hacia la versión anterior, que en la estrategia azul-verde permanece desplegada durante la etapa de canario; no requiere recompilar ni redesplegar. Se dispara automáticamente cuando, durante el canario, el percentil 95 de una transacción supera el umbral comprometido en la Tabla 21, o cuando la tasa de error de la versión nueva supera la de la versión estable medida en la misma ventana de observación.

En cuánto tiempo. El tiempo efectivo de reversión se mide en cada ensayo en Pre-Producción exigido por RT-04.07 y se reporta como tiempo de restauración del servicio (Tabla 32), cuyo máximo contractual es de 4 horas (Art. 78.3).

Qué se pierde. Ninguna transacción confirmada. Las operaciones en curso quedan retenidas en los buffers locales —24 h por sitio en el broker y la caché de turno en los dispositivos de terreno— y se reprocesan contra la versión restituida con sincronización idempotente y determinista. El esquema no se revierte, porque la migración del release es solo aditiva. Lo que se pierde es el release, no la operación.

Si la falla se manifiesta en la ventana 05:30–07:00. El calendario prohíbe desplegar en esa ventana. Si un despliegue anterior manifiesta su falla dentro de ella, la bodega y el reparto continúan con su autonomía local (Tabla 4) y la reversión se ejecuta sin detener el despacho (Caso, Cap. 17.6).

8.1.4 Métricas del proceso de despliegue

RT-04.12 exige declarar y medir cuatro indicadores; dos de ellos son además contractuales conforme al Artículo 78.3. La Tabla 32 fija el compromiso de cada uno y el dato que lo sostiene:

Indicador	Compromiso	Fundamento
Frecuencia de despliegue	Quincenal	Calendario de la Tabla 31
Tiempo desde el compromiso de código hasta producción	≤ 5 días hábiles	Plazo de 7 días de remediación de vulnerabilidades críticas

Tabla 32 — continuación

Indicador	Compromiso	Fundamento
Tasa de cambios fallidos en pro-ducción	≤ 5 % mensual	Art. 78.3
Tiempo de restauración del ser-vicio	≤ 4 h	Art. 78.3

Tabla 32 Métricas del proceso de despliegue. Fuente: RT-04.12; Art. 78.3 de las Bases Administrativas; elaboración propia

Los dos indicadores contractuales se comprometen en el valor que fija el Artículo 78.3, y los otros dos se derivan de restricciones ya declaradas —el calendario y el plazo de remediación de vulnerabilidades de la arquitectura de seguridad— y no de una aspiración de método. Los cuatro se miden sobre la plataforma de observabilidad y se reportan en el informe mensual de nivel de servicio (Art. 79). Las correcciones de incidentes de severidad crítica siguen el mismo pipeline, con prioridad y fuera de la cadencia quincenal, dentro del tiempo máximo de resolución de 4 horas del Artículo 78.2.

8.2 Redes (topología, segmentación y conectividad)

8.2.1 WAN — doble camino con conmutación automática

Cada instalación dispone de dos caminos físicamente independientes con conmutación automática en < 30 s: fibra óptica más LTE empresarial en los CDs (Talca y Concepción), y Starlink más LTE empresarial en los cross-docks (Curicó, Chillán y Los Ángeles) (ADR-02). El requisito exige ≤ 5 min declarados; el diseño opera en < 30 s. Los anchos de banda por sitio, en régimen y en peak, se declaran en la sección de dimensionamiento (Tabla 14). En el CD Talca el acceso de comunicaciones ingresa por dos ductos independientes (RT-06.32).

Los cross-docks salen directo por Starlink a SQS/IoT/SSM y sincronizan detalle a Talca por AMQPS entre brokers (costura C13, Tabla 25). La pérdida total del enlace se cubre con la autonomía local de 24 h (CD) / 14 h (terreno), por lo que la redundancia de conectividad reduce la frecuencia de desconexión pero no es condición para operar.

Punto único de falla declarado (RT-02.11). En Los Ángeles la señal móvil es intermitente en la madrugada, que es justamente su ventana de operación (Caso, Cap. 6). En ese tramo el respaldo LTE no es un camino confiable y el enlace Starlink opera como camino único. Se mitiga con la autonomía local del nodo de cómputo: la ventana de 3 h del cross-dock es 100 % local (Tabla 4) y la sincronización hacia Talca es diferida.

8.2.2 VPN Site-to-Site (costura C1)

Extremos: en el lado on-premise, el par de firewall de Talca (D-01, HA activo-pasivo) y el firewall de borde de Concepción, como Customer Gateway de cada CD; en el lado nube, AWS VPN Gateway adjunto a la VPC de Producción, con 2 túneles por CD (H-06).

Protocolo: IPsec/IKEv2 cifrado, BGP, MTU 1436; 2 túneles (activo + standby). Conmutación < 30 s entre los dos caminos del sitio (RT-03.21). En Talca, ante falla del firewall activo, el pasivo asume las direcciones y los túneles en menos de 30 s, alimentado desde un circuito eléctrico distinto.

8.2.3 Segmentación de red (sin solapamiento)

El direccionamiento de los sitios y de la VPC de Producción se asigna sin solapamiento, según la Tabla 33; las VPC de los demás ambientes constan en la Tabla 30.

Dominio	Bloque	Segmentación
Talca	10.1.0.0/16	VLAN 10 MGT, 20 SRV, 30 OPS, 40 WKS y 50 IOT
Concepción	10.2.0.0/16	Mismas VLAN que Talca
Cross-docks	10.3.0.0/16 a 10.5.0.0/16	Red plana con salida a SSM e IoT
Sitio adicional (RT-02.12)	10.6.0.0/16	Reservado; VLAN estándar al incorporarse
VPC Producción: DMZ pública	10.101.1.0/24 y 10.101.2.0/24	Una subred por zona: balanceador, origen CloudFront, NAT y portales

VPC Producción: aplicación y datos	Subredes privadas de 10.101.0.0/16	Sin exposición a Internet; VPN Gateway de los CD
------------------------------------	------------------------------------	--

Tabla 33 Segmentación de red sin solapamiento. Fuente: elaboración propia; RT-02.12 y RT-03.04

Cada sitio con cómputo tiene un bloque propio y el sitio previsto hacia 2030 ya tiene el suyo reservado, de modo que su incorporación es una parametrización del IaC y no un rediseño. En la nube solo la DMZ es pública: la aplicación y los datos residen en subredes privadas y consumen los servicios AWS (S3, SQS, DynamoDB, KMS, SSM) por VPC Endpoints/PrivateLink sin tráfico por internet, de modo que ningún componente de datos es alcanzable desde Internet (RT-03.04). La conectividad con el on-premise termina en la VPC de Producción, coherente con que el on-premise es producción: los ambientes no productivos no tienen enlace con los sitios.

8.2.4 Zero Trust — flujos permitidos

Todo el tráfico on-premise → nube es outbound (HTTPS/443, MQTTS/8883) sin conexiones entrantes, salvo las dos excepciones declaradas en la arquitectura de seguridad, ambas sobre el túnel IPsec autenticado. Los flujos permitidos, con su protocolo y destino, se listan en la Tabla 34:

Flujo	Protocolo	Destino
Broker (shipper VM-03) → SQS FIFO	HTTPS 443 por VPC Endpoint	AWS
Telemetría ADOT → CloudWatch	HTTPS 443	AWS
Greengrass → IoT Core	MQTTS 8883 con X.509	AWS
SSM Agent (todos los nodos)	HTTPS 443 saliente	SSM Endpoint regional
Caché Keycloak VM-05/VM-C03 → S3 (import Realm)	HTTPS 443 por VPC Endpoint	AWS (objeto cifrado)
Sync WMS Concepción → Talca	TCP 8080 / 5432 con TLS sobre VPN IPsec	SRV-TALCA (on-prem)
Sync cross-dock → Talca (broker a broker)	AMQPS 5671	SRV-TALCA (on-prem)

Tabla 34 — continuación

Flujo	Protocolo	Destino
Excepción: AWS DMS → PostgreSQL WMS (CDC)	TCP 5432 sobre VPN	VM-02 SRV-TALCA
Excepción: celery-erp-sync → ACL ERP	HTTPS 443 sobre VPN	VM-04 SRV-TALCA

Tabla 34 Flujos permitidos entre dominios. Fuente: elaboración propia sobre el emplazamiento y la arquitectura de seguridad de este documento

De los nueve flujos, cinco salen del on-premise hacia la nube, dos conectan sitios on-premise entre sí y dos son las excepciones entrantes, que viajan por el túnel IPsec autenticado. Ninguno circula sin cifrado, conforme al principio de cifrado en tránsito sin excepciones de la arquitectura de seguridad. El acceso remoto de las personas trabajadoras del CLIENTE se rige por el mismo modelo de confianza cero (RT-03.22).

8.2.5 Capa pública (DMZ) y DNS

Primera línea: CloudFront + AWS WAF v2 (OWASP Top 10 + reglas personalizadas) + Shield Advanced; autenticación API Gateway con Keycloak OIDC, cuotas por cliente y validación de esquema.

DNS: Route 53 con enrutamiento de conmutación por falla y verificaciones de salud activas: la región primaria sa-east-1 recibe todo el tráfico en operación normal y la conmutación hacia us-east-1 es automática ante falla, coherente con la modalidad activo-pasiva del ADR-09.

8.2.6 Autonomía y resincronización tras un corte

Cada ámbito mantiene autonomía local con su propia base de datos, broker y caché de identidad (RT-03.10, RT-03.11): 24 h en centro de distribución, 14 h de turno completo en terreno y 3 h 100 % locales en cross-dock (Tabla 4). Al reconectar, la sincronización es automática, idempotente y determinista, con reconciliación de conflictos y bitácora auditable (RT-03.12), en ≤ 10 min para la flota y ≤ 2 h para un centro de distribución tras un corte de 24 h. La sincronización tras la reconexión se responde contra RT-03.12,

que es el código transversal que la regula; el Cap. 15 del caso la cita como RT-03.13, que en las Transversales corresponde a la declaración de funciones no disponibles sin conexión.

El compromiso de 2 h se verifica con los volúmenes declarados en la sección de dimensionamiento. Como cota superior se toma el volumen anual de almacenamiento transaccional de toda la solución (≈ 375 GB/año, Tabla 15), se atribuye íntegro a un solo centro de distribución y se duplica por el peak de septiembre, lo que da $\approx 2,1$ GB acumulados en 24 h. La evidencia de entrega no se incluye, porque los dispositivos de terreno se comunican con la nube por la red celular sin atravesar el centro de distribución. El tiempo de drenaje de ese volumen por cada enlace consta en la Tabla 35:

Escenario de retorno	Enlace	Tiempo de drenaje
Talca por fibra	20 Mbps	≈ 14 min
Talca por LTE de respaldo	5 Mbps	≈ 55 min
Concepción por fibra	10 Mbps	≈ 27 min
Concepción por LTE de respaldo	3 Mbps	≈ 1 h 31 min

Tabla 35 Drenaje del acumulado de 24 h en el peak de septiembre. Fuente: elaboración propia con los volúmenes y enlaces de la sección de dimensionamiento

Aun en el escenario más desfavorable —Concepción de regreso por su enlace de respaldo en el peak, con el volumen de toda la solución atribuido a ese sitio— el acumulado se drena dentro del compromiso de 2 h. Al restablecerse el enlace, la calidad de servicio prioriza el broker y el registro de escritura anticipada, y las colas diferidas se vacían fuera de la ventana crítica.

8.3 Alta disponibilidad

8.3.1 Clasificación de servicios por criticidad

RT-10.02 exige clasificar cada servicio y aplicarle el nivel de servicio del Artículo 78.2. La Tabla 36 asigna cada servicio a su nivel, con la disponibilidad y el plazo de resolución que le corresponden:

Nivel	Disponi- bilidad	Reso- lución	Servicios
Crítico	99,9 %	4 h	Preparación y despacho · registro de entrega · toma de pedido · consulta de stock y crédito · bloqueo por excur- sión térmica · identidad
Alto	99,5 %	8 h	Planificación de rutas · cobranza y rendición · integración con el ERP · documentos tributarios · registro de tempera- tura · evidencia de entrega
Medio	99,0 %	24 h	Portales · notificaciones · canal moderno · consultas de geolocalización · registros de auditoría y seguridad
Bajo	98,0 %	48 h	Análítica y tableros · reportería

Tabla 36 Clasificación de servicios por criticidad. Fuente: Art. 78.1 y 78.2 de las Bases Administrativas; RT-10.02; Caso 02, RT-09.01

La clasificación aplica las definiciones de severidad del Artículo 78.1. Son críticos los servicios cuya falla detiene un proceso de negocio sin alternativa operativa: los cuatro primeros son las transacciones operacionales críticas que fija el caso (RT-09.01), la ventana de despacho no admite ejecución manual (Caso, Cap. 10, restricción 1), el bloqueo por excursión es exigencia sanitaria y sin identidad no opera ningún otro servicio. Los altos tienen una alternativa operativa costosa: la ruta puede planificarse a mano en 3,5 h (Caso, Cap. 18, criterio 7), la cola hacia el ERP retiene 24 h y el bloqueo de despacho por excursión opera localmente aunque el registro central no esté disponible. Los medios tienen alternativa disponible, y los bajos no impiden operar, coherente con la latencia de 4 h admitida para los indicadores de gestión (Caso, Cap. 15, RT-05.29). Del cuadro se sigue que el compromiso penalizable del 99,9 % recae sobre seis servicios, todos ejecutados en el on-premise o con un camino local en el dispositivo, lo que ordena el resto de esta sección.

8.3.2 Capa cloud (sa-east-1) — Multi-AZ

La distribución por zona de disponibilidad de los servicios en nube y su tiempo de conmutación se resumen en la Tabla 37:

Componente	AZ primaria	AZ secundaria	Conmutación automática
Aurora PostgreSQL	sa-east-1a (escritor)	sa-east-1b y sa-east-1c (lectores)	< 30 s
DynamoDB	Multi-AZ nativo	—	Transparente
ECS Fargate	sa-east-1a y sa-east-1b	—	Reprogramación automática de tareas
ElastiCache Redis	sa-east-1a (primario)	sa-east-1b (réplica)	< 60 s
ALB	sa-east-1a	sa-east-1b	Transparente
NAT Gateway	sa-east-1a	sa-east-1b	Enrutamiento automático

Tabla 37 Distribución Multi-AZ en sa-east-1. Fuente: elaboración propia

Todos los componentes con requisito de alta disponibilidad operan en al menos dos zonas (RT-03.02) y ninguna conmutación supera un minuto; la base de datos, único componente con escritor único, conmuta en menos de 30 segundos. Sobre esa base se compromete el nivel de servicio de extremo a extremo de la transacción crítica de negocio: $\geq 99,9$ % mensual, menos de 8,76 h al año, que es el compromiso contractual penalizable (Art. 78) y es distinto de la disponibilidad de la infraestructura del recinto, que es un medio para alcanzarlo.

8.3.3 Niveles de servicio de la infraestructura

El numeral 7.2 de las Transversales fija una disponibilidad mensual mínima de 99,95 % para la energía del recinto, la climatización, la red y las comunicaciones, los servidores y el cómputo, el motor de base de datos, y el portal y los canales de atención. Se sostiene con redundancia N+1 en energía y climatización, doble acometida con transferencia automática, generación autónoma propia y monitoreo continuo con alertamiento, sin invocar clasificaciones de instalación de terceros, porque las Bases exigen el cumplimiento verificable de cada requisito y no una certificación de nivel.

8.3.4 Cómo se sostiene el 99,9 % de extremo a extremo

Los valores del numeral 7.2 son mínimos por subsistema. El objetivo de extremo a extremo no se obtiene multiplicándolos —su producto, con los subsistemas en serie, quedaría por debajo del 99,9 %—, sino de la redundancia interna de cada subsistema, que lo hace operar por sobre su mínimo. Dos estructuras lo sostienen:

- **Transacciones de bodega.** La confirmación de preparación de pedidos, la más estricta (≤ 1 s, Tabla 21) y la que ocurre en la ventana de tolerancia cero, se ejecuta contra la base local del centro de distribución y no atraviesa la WAN ni la nube. Su ruta física descansa en elementos redundantes —energía N+1, climatización N+1, par de firewall en HA, dos switches core en stack, clúster de 3 nodos N+1 y almacenamiento Ceph réplica 2 sobre RAID 10—, con un único elemento en serie: la instancia de escritura VM-02, que se reinicia en otro nodo del clúster ante la falla del suyo y cuya mitigación progresiva se declara en la sección de primer cuello de botella.
- **Transacciones de terreno.** La toma de pedido, el registro de entrega y la consulta de stock y crédito disponen de dos caminos en paralelo: la nube y la caché de turno del dispositivo. Cuando la nube no responde, la transacción se completa contra la caché y se sincroniza al reconectar.

La disponibilidad efectiva se mide sobre la plataforma de observabilidad y se reporta mensualmente (Art. 79), y el comportamiento ante la falla de cada elemento se verifica con las pruebas de resiliencia de la Tabla 38.

8.3.5 Capa on-premise

En el on-premise, el cómputo corre sobre un clúster virtualizado de tres nodos con replicación síncrona Ceph de factor 2 y quórum propio, que elimina el punto único de falla de un par sin quórum. El almacenamiento combina RAID 10 NVMe para la base transaccional, con más de 100.000 IOPS, y RAID 6 con disco de reserva para evidencia y registros (ADR-10, RT-03.14). La red se apoya en un par de firewall UTM en alta disponibilidad activo-pasivo, dos switches core y uno de gestión; la WAN, en el doble camino del ADR-02. La sala técnica principal de Talca, con sala blanca de 32 m² y cuatro gabinetes, dispone de UPS de doble conversión de 6 kVA en N+1 con autonomía de al menos 30 minutos a plena carga (RT-06.07), generador de 12 kVA con estanque de 24 h (RT-06.08), transferencia automática y climatización de precisión N+1 con PUE de diseño de 1,7, según la sección del sitio principal. Las VMs se dimensionan con un margen de $\times 1,5$ (RNF-19.04) para tolerar 3.900 entregas diarias en el peak de

septiembre.

Puntos únicos de falla declarados y mitigados (RT-02.11): periféricos de andén (respaldo manual); instancia de escritura VM-02 (reinicio en otro nodo del clúster y plan de mitigación del primer cuello de botella); Concepción, con nodo y firewall de borde únicos (autonomía 24 h + DRP local); cross-dock con mini-PC único (ventana de 3 h + sincronización diferida); y Los Ángeles con camino Starlink único en su ventana de operación (ventana 100 % local + sincronización diferida).

8.3.6 Escalamiento y degradación controlada

El escalamiento en nube es predictivo y reactivo, con seguimiento de objetivo en < 2 min, aprovisionamiento en < 3 min y enfriamiento de 60 s (RT-09.04, ADR-12). Superada la capacidad, la solución degrada de forma controlada (RT-09.08): en el enlace WAN, la calidad de servicio prioriza broker y WAL y la conmutación entre caminos ocurre en < 30 s; sin conexión, los buffers de 24 h del broker y del colector de telemetría sostienen la operación con reconciliación cronológica e idempotente; en nube, la puerta de enlace limita la tasa y los workers aplican tiempos de espera, reintentos con retroceso y colas de mensajes fallidos.

8.3.7 Pruebas de resiliencia con inyección de fallas

RT-10.07 exige inyección controlada de fallas antes de cada paso a producción y al menos una vez por semestre durante la Operación. La Tabla 38 cruza cada falla que enumera el requisito con el mecanismo que responde y el criterio con que se verifica:

Falla inyectada	Mecanismo que responde	Criterio verificable
Caída de instancia	Reprogramación de tareas Fargate; reinicio de VMs en los nodos restantes	Sin pérdida de transacciones en curso
Caída de zona	Conmutación de Aurora y de ElastiCache	< 30 s y < 60 s
Caída del ERP	Aislamiento tras la capa anticorrupción	Cola retiene hasta 24 h
Pérdida de ambos caminos WAN	Autonomía local del sitio	24 h; resincronización ≤ 2 h
Latencia elevada	Tiempos de espera, reintentos y limitación de tasa	Operación no bloqueada

Tabla 38 — continuación

Falla inyectada	Mecanismo que responde	Criterio verificable
Saturación de disco	Alerta anticipada de capacidad	70 % de ocupación

Tabla 38 Pruebas de resiliencia por inyección de fallas. Fuente: RT-10.07 y RT-10.08; elaboración propia

Cada falla tiene un mecanismo automático y un criterio cuantificable, de modo que la prueba no evalúa si el sistema resiste, sino si cumple un valor declarado. Las pruebas se ejecutan sobre Pre-Producción antes de cada paso a producción, y al menos una vez por semestre durante la Operación sobre el ambiente productivo, fuera de la ventana crítica de despacho y de los períodos de congelamiento. Cada ejecución produce un informe con el comportamiento observado frente al declarado y el plan de corrección de las desviaciones.

8.4 Recuperación ante desastres

8.4.1 Modalidad, objetivos y mecanismo por dominio de datos

Modalidad activo-pasiva en caliente (RT-07.01, ADR-09): activo-activo duplicaría la infraestructura transaccional (~105 TPS peak) con reconciliación de doble escritura sin beneficio frente al RTO comprometido. La región secundaria mantiene una réplica reducida pero funcional de la plataforma, escalable a carga completa en menos de 30 minutos. Objetivos: $RTO \leq 4\text{ h}$ y $RPO \leq 15\text{ min}$ para los servicios críticos (RT-07.04). El mecanismo que sostiene el RPO de cada dominio consta en la Tabla 39:

Dominio	Mecanismo	RPO
Transaccional en nube	Aurora Global Database hacia us-east-1	< 1 s
Telemetría IoT	DynamoDB Global Tables	Continuo
Objetos: evidencia, documentos y respaldos	S3 Cross-Region Replication con control de tiempo	< 15 min

Tabla 39 — continuación

Dominio	Mecanismo	RPO
WMS on-premise	AWS DMS CDC sobre el WAL lógico, por la VPN	≤ 15 min con enlace
Mensajes críticos	Patrón outbox con escritura en base y cola	≤ 15 min
Mensajes no críticos	Cola con reposición diferida	≤ 24 h

Tabla 39 Mecanismo de replicación y RPO por dominio de datos. Fuente: ADR-09; elaboración propia

Todos los dominios críticos cumplen el RPO de 15 minutos mediante un mecanismo continuo; el único cuyo RPO depende de una condición externa es el WMS on-premise, porque su réplica viaja por la WAN. Si caen los dos caminos WAN, DMS encola en origen y reanuda sin pérdida de datos, pero la réplica en nube queda desactualizada durante el corte: el RPO de ese dominio pasa a ser la duración del corte, acotada por la autonomía local de 24 h. El retraso de replicación se mide de forma continua y se alarma a los 5 y a los 15 minutos (RT-07.03). Restablecido cualquier camino, la réplica alcanza el RPO comprometido dentro de la resincronización de ≤ 2 h.

8.4.2 Procedimiento de conmutación

La conmutación separa lo automático de lo manual según su reversibilidad: el enrutamiento se conmuta automáticamente, porque vuelve solo si la verificación de salud se recupera; la promoción de la base de datos requiere decisión humana, porque rompe la replicación y obliga a reconciliar en el retorno. La secuencia de ocho pasos consta en la Tabla 40:

Pa- so	Acción	Ejecución	Tiempo
1	Detección por verificación de salud de la región primaria	Route 53	< 5 min
2	Conmutación del enrutamiento hacia us-east-1	Automática, Route 53	—

Tabla 40 — continuación

Pa- so	Acción	Ejecución	Tiempo
3	Confirmación y autorización de la promoción	Manual: SNS y CLIEN-TE	—
4	Promoción de Aurora en us-east-1	Systems Manager Automation	15–20 min
5	Escalado de ECS a carga completa	Systems Manager Automation	< 30 min
6	Actualización DNS	Systems Manager Automation	45–60 min
7	Reconexión del broker y sincronización diferida del borde	Systems Manager Automation	—
8	Validación funcional de extremo a extremo	Operación	—

Tabla 40 Secuencia de conmutación regional. Fuente: elaboración propia sobre ADR-09

Los pasos con tiempo declarado suman, en el peor caso y ejecutados en serie, cerca de 2 horas más el tiempo de decisión, dentro del RTO de 4 horas; el RTO se cumple porque la réplica es legible y la región de recuperación está en caliente. De la tabla se sigue también que solo un paso requiere intervención humana, el tercero, y que la protección contra conmutaciones innecesarias recae precisamente en él.

Ejecutabilidad por el CLIENTE (RT-07.05). El procedimiento está documentado y automatizado en sus pasos 4 a 7; la decisión y la autorización corresponden al CLIENTE, cuya área de tecnologías de información es de cuatro personas (Caso, Cap. 10, restricción 9). El procedimiento es ejecutable por su personal tras la transferencia de conocimiento, que se valida en los ensayos semestrales, y el acompañamiento técnico forma parte del servicio gestionado de NOC y confiabilidad declarado en el dimensionamiento de la operación.

Retorno (failback, RT-07.06): procedimiento documentado en 6 pasos — re-sincronización con catch-up verificado, reconciliación de transacciones de la contingencia contra la bitácora (RT-03.12), transferencia de eventos pendientes, conmutación coordinada de DNS, validación funcional e informe con tiempo real.

Pruebas (RT-07.07): conmutación real ≥ 2 veces/año con informe de RTO/RPO efectivos y plan de corrección de brechas. El cumplimiento del RPO y del RTO en cada prueba semestral es del 100 % (Art. 78.3).

8.4.3 Emplazamiento de los sitios secundarios y amenazas comunes

RT-07.02 exige declarar la distancia y el análisis de amenazas comunes considerado. La Tabla 41 lo presenta para cada par de sitios:

Par de sitios	Distancia	Amenazas comunes
Talca ↔ Concepción	≈ 250–400 km	Terremoto o maremoto de zona costera · corte de la malla eléctrica nacional
Talca ↔ región primaria sa-east-1	≈ 2.300 km	Sin eventos sísmicos ni eléctricos en común
Región primaria ↔ us-east-1	≈ 7.700 km	Sin amenazas comunes
Talca ↔ us-east-1	≈ 8.500 km	Sin amenazas comunes

Tabla 41 Distancia y amenazas comunes entre sitios. Fuente: análisis de emplazamiento del proponente; RT-21.16

El único par que comparte amenazas es el on-premise: Talca y Concepción están expuestos a los mismos eventos, y esa dependencia no se resuelve con la distancia disponible dentro del área de operación del CLIENTE, cuya red abarca 340 km entre sus extremos (RT-21.16). La cobertura combina dos medidas. La primera es la independencia operacional: cada sitio opera de forma autónoma 24 h sin dependencia de red del otro, Talca con generación propia con estanque de 24 h y Concepción con alimentación protegida en su gabinete de borde. La segunda es la nube: ante un evento que afecte simultáneamente a ambos centros, el dato transaccional permanece en la región primaria con un RPO de ≤ 15 min, y la operación de bodega se suspende por la indisponibilidad física de los recintos, no por pérdida de información.

8.4.4 Componentes del sitio secundario y de la réplica

Los componentes que sostienen la recuperación, su ubicación y el requisito que atienden se detallan en la Tabla 42:

Componente	Producto ofertado	Ubicación	Requisito
E1 — Réplica DRP Aurora	Aurora PostgreSQL pasiva promovible + AWS DMS CDC	AWS us-east-1	RT-07.02 · RT-07.03
E2 — Respaldos inmutables	S3 Object Lock + Backup Vault Lock	sa-east-1 y us-east-1	RT-07.09 · RT-07.11
E3 — Bóveda externa física	Custodia acreditada con medio cifrado rotado semanalmente	Fuera de Talca	RT-06.26 · RT-06.28
E4 — Copia local de recuperación rápida	NAS D-05 con WORM y cifrado independiente	CD Talca	RNF-20.06 · RNF-20.07
E5 — Conmutación y retorno	Runbook de 8 pasos (Tabla 40) y retorno en 6	Talca y AWS	RT-07.05 a RT-07.07

Tabla 42 Componentes del sitio secundario y de la réplica. Fuente: elaboración propia

La réplica se reparte entre dos dominios y cuatro ubicaciones: us-east-1 aloja la base promovible y la copia inmutable replicada, Talca conserva la copia de recuperación rápida y una bóveda externa guarda el medio físico. La pérdida de una sola ubicación no deja al dato sin copia, y la restauración del WMS no depende del enlace. La réplica se ensaya dos veces al año y se verifica mensualmente con cero errores.

8.4.5 Capacidades durante una contingencia regional

Dos resguardos declarados tienen por efecto que no todas las capacidades operen igual en contingencia: la región secundaria no se explota analíticamente, y los datos de geolocalización de personas no se replican fuera de sa-east-1. La Tabla 43 indica el estado de cada capacidad durante una contingencia regional:

Capacidad	Estado	Fundamento
Recepción, preparación, despacho y conteo en bodega	Normal	Se ejecutan contra la base local
Preventa y reparto en terreno	Normal	Caché y buffer de turno en el dispositivo

Tabla 43 — continuación

Capacidad	Estado	Fundamento
Backend de terreno, portales e integraciones	Tras la promoción	Réplica en caliente, dentro del RTO
Consultas sobre geolocalización de personas	No disponible	Dato no replicado fuera de sa-east-1
Analítica y tableros de gestión	No disponible	Región secundaria sin explotación analítica

Tabla 43 Capacidades durante una contingencia regional. Fuente: elaboración propia sobre los resguardos de la arquitectura de seguridad

Ningún servicio clasificado como crítico (Tabla 36) depende de los dos resguardos: las capacidades que quedan fuera son de nivel medio y bajo. Al retornar al sitio principal, ambas se restituyen desde la región primaria sin pérdida de información.

8.4.6 Residencia y transferencia internacional de datos

La replicación hacia us-east-1 constituye una transferencia internacional de datos personales y se rige por los resguardos declarados en la sección de arquitectura de seguridad de este documento, en la subsección de datos personales, residencia y transferencia internacional: cifrado con CMK gestionada por el CLIENTE, acuerdo de tratamiento con cláusulas de transferencia, minimización (la región secundaria no se explota analíticamente, solo sostiene continuidad), exclusión de los datos de geolocalización de personas de la replicación transfronteriza (permanecen solo en sa-east-1 con retención de 12 meses) y registro en el inventario de tratamientos. La residencia queda sujeta a aprobación expresa del CLIENTE. Si no la aprueba, la alternativa declarada es la continuidad intrarregional dentro de sa-east-1, que consiste en una tercera AZ ampliada más respaldo inmutable regional. Esta alternativa no es un segundo sitio geográfico ni usa Talca o Concepción para la carga cloud, ya que AWS no tiene región en Chile. Cubre falla de AZ y corrupción de datos, pero degrada el RTO ante una caída de toda la región sa-east-1 a 24–72 h desde el respaldo inmutable (alternativa D del ADR-09).

8.4.7 DRP local (Talca → Concepción)

Promoción controlada del WMS edge (VM-C01) mediante procedimiento de 5 pasos; Concepción ya opera autónoma (latencia ≤ 1 s de picking, RNF-05.01). RTO +1-2 h para la bodega.

Identidad sin conmutación local: el maestro Keycloak está en la nube y las cachés VM-05/VM-C03 siguen validando firmas offline — el DRP de identidad es la misma autoridad en nube, sin promoción local a maestro (elimina una clase entera de riesgos de DR).

8.4.8 DRP de la identidad (ADR-06)

El maestro vive en la nube (Multi-AZ) con réplica DR us-east-1; las cachés locales son de solo lectura. No existe maestro local a promover, por lo que la identidad no depende del switchover.

8.5 Respaldos — esquema 3-2-1-1-0

Esquema único para toda la arquitectura híbrida (nube + on-premise):

- **3 copias de los datos.** (1) Datos activos sa-east-1 + WMS activo Talca; (2) Snapshot automatizado Aurora + respaldo local on-premise (D-05); (3) Backup exportado a S3.
- **2 medios.** PostgreSQL/Aurora y S3 (almacenamiento de objetos).
- **1 copia fuera del sitio.** S3 Cross-Region Replication → bucket en us-east-1.
- **1 copia inmutable.** S3 Object Lock (WORM, Compliance Mode) + AWS Backup Vault Lock (ni el root puede eliminarla); s3-documents-legal y s3-audit-logs en Compliance, no Governance.
- **0 errores.** Restore testing automatizado mensual (Lambda) + verificación de restauración local + prueba DR semestral.

La pierna inmutable es el control frente al cifrado malicioso con credenciales administrativas comprometidas (RT-07.11): en modo Compliance, ni un administrador ni la cuenta raíz pueden eliminar o modificar las copias durante su período de retención.

D-05 (NAS local con WORM) es la copia local de recuperación rápida y NO cuenta como la pierna inmutable; permite restaurar el WMS en ≤ 4 h sin depender del enlace WAN,

con cifrado independiente del de producción (RT-07.10). $RPO \leq 15$ min por AWS DMS CDC del WAL lógico (wal_level=logical) hacia la nube antes de la copia local.

Custodia física: medio de respaldo transportable, cifrado y rotado semanal, trasladado bajo custodia acreditada a bóveda externa distinta del sitio primario; la pierna inmutable S3 es complementaria, no reemplaza la custodia física.

8.5.1 Frecuencia, retención y restauración por dominio de datos

RT-07.13 exige declarar, por dominio de datos, la frecuencia de respaldo, la retención y el tiempo estimado de restauración completa. Los tres valores de cada dominio constan en la Tabla 44:

Dominio	Frecuencia	Retención	Restauración
Transaccional de bodega	Continua (CDC) y copia local D-05	35 días	≤ 4 h
Transaccional en nube	Diaria y PITR continua	35 días	≤ 4 h
Identidad	Diaria y PITR continua	35 días	≤ 4 h
Trazabilidad sanitaria de lote	Continua	Vida útil + 5 años	< 2 h
Registros de temperatura	Diaria (crudo) y continua (consolidado)	5 años	≤ 8 h
Evidencia de entrega	Continua con versionado	6 años	≤ 8 h
Respaldo de documentos tributarios	Continua con versionado	6 años	≤ 8 h
Geolocalización de personas	Continua	12 meses	≤ 24 h
Registros de seguridad y auditoría	Continua	7 años	≤ 24 h

Tabla 44 Respaldo y restauración por dominio de datos. Fuente: RT-07.13; Art. 78.2 de las Bases Administrativas; Caso 02, Cap. 15 y Cap. 18

Cada tiempo de restauración es el plazo de resolución del Artículo 78.2 que corresponde a la criticidad del servicio que usa el dato (Tabla 36), con una excepción más exigente: la trazabilidad sanitaria se restaura en menos de 2 h, porque el retiro sanitario debe

responderse en ese plazo (Caso, Cap. 18, criterio 1). El transaccional de bodega se restituye desde la copia local D-05, sin depender del enlace. Las retenciones cumplen o superan las del Cap. 15 del caso; la de trazabilidad supera el mínimo de vida útil más 6 meses, con 5 años. La restauración es además granular (RT-07.14): la recuperación a un instante específico de Aurora sobre una instancia temporal permite restituir un registro, una tabla, un módulo o el sistema completo sin intervenir el ambiente productivo, y cada reincorporación queda registrada en la bitácora de auditoría.

8.5.2 Plan AWS Backup

El plan de AWS Backup por recurso de infraestructura, que materializa la tabla anterior, se detalla en la Tabla 45:

Recurso	Frecuencia	Retención	Destino
Aurora PostgreSQL	Diaria y PITR continua	35 días	Backup Vault cifra- do CMK
DynamoDB	Diaria (On-Demand)	35 días	Backup Vault
EFS	Diaria	30 días	Backup Vault
EBS	Diaria (snapshots)	14 días	Backup Vault
S3 documentos le- gales	Continua (versioning + Object Lock)	6 años	S3 + réplica CRR
Logs de seguridad y auditoría	Continua	7 años	S3 archivo, Object Lock

Tabla 45 Plan AWS Backup por recurso. Fuente: elaboración propia

Los recursos transaccionales conservan 35 días para la recuperación operativa, mientras los documentos legales y los registros de auditoría se retienen por plazos legales bajo Object Lock. Todos los destinos son bóvedas cifradas o almacenamiento inmutable: con el bloqueo de la bóveda, de 3 días de enfriamiento y retención mínima de 1 año, ni la cuenta raíz puede eliminar respaldos. La retención sanitaria de trazabilidad de 5 años más la vida útil es consistente con el lago analítico S3 y el repositorio de datos históricos (RT-16.10).

8.5.3 Distinción entre réplica y respaldo

Las réplicas —Aurora Global Database, DynamoDB Global Tables, S3 Cross-Region Replication y la replicación Ceph del clúster— protegen frente a la pérdida de una instancia, de un nodo o de una región, no frente al daño lógico del dato: una eliminación accidental o un cifrado malicioso se replican con la misma fidelidad que una escritura legítima. El respaldo, y en particular su pierna inmutable, es el único control frente a ese escenario.

Registro de decisiones de arquitectura

Registro consolidado de las quince decisiones de arquitectura que condicionan esta propuesta. Es entregable contractual conforme a RT-02.04 y se mantiene actualizado durante toda la ejecución. Para cada decisión se indica la alternativa escogida, las alternativas descartadas con el motivo de rechazo, y el criterio de selección. Todas las decisiones fueron aprobadas entre el 05 y el 06 de septiembre de 2026.

9.1 ADR-01 · Estilo arquitectónico

Decisión adoptada. Monolito modular Django 5.x LTS / Python 3.12, desplegado en ECS Fargate con apps por dominio y límites de contexto DDD. Módulos críticos (WMS offline, shipper, workers, portal) en procesos separados.

Alternativas descartadas. *Microservicios EKS:* volumen (~105 TPS) dos órdenes bajo el umbral que los justifica; 4 personas no operan 9–13 componentes de plano de control; TCO estimado en +USD 40–70 K / 56 m (estimación interna basada en la operación de EKS con el equipo del CLIENTE). *Monolito clásico WMS 2013:* sin fronteras de módulo, proveedor desaparecido; viola RT-02.02.

Criterio de selección. Pertinencia al volumen real (BTT §2.3); operabilidad por 4 personas; TCO 56 meses; despliegue independiente sin particionar el dominio. Normativa: RT-02.01/02.02/02.03, RT-09.05, BA Art. 16, RNF-19.01–04. Relacionada: D5, D8, D14 (Arq. Lógica).

9.2 ADR-02 · Conectividad WAN

Decisión adoptada. Doble camino por sitio: fibra + LTE en los centros de distribución, Starlink + LTE en los cross-docking. Conmutación automática < 30 s.

Alternativas descartadas. *Fibra en cross-docks:* naves industriales sin cobertura de

fibra; costo de obra desproporcionado. *VSAT GEO*: latencia 500–700 ms RTT; penaliza RNF-05.01 y costo superior. *Tri-camino (fibra + Starlink + LTE)*: tercer camino no aporta disponibilidad significativa dado que cada sitio opera autónomamente ante pérdida total de enlace (24 h CD, 14 h terreno).

Criterio de selección. Dos caminos de física distinta satisfacen RT-03.17 sin punto único de fallo; la autonomía local cubre la pérdida total de enlace, por lo que un tercer camino es innecesario; cero mantención de radio para el equipo de 4 personas del CLIENTE. Normativa: RT-03.10/03.17, RT-10.05, RNF-13.01/13.07/13.08. Relacionada: Decisión 16.1 N° 26.

9.3 ADR-03 · Modelo de despliegue híbrido

Decisión adoptada. Borde operacional on-premise (WMS maestro Talca, edge Concepción, WMS en cross-docks) + carga principal en AWS. 11 componentes on-prem, 12 híbridos, 13 nube pura.

Alternativas descartadas. *Solo nube*: inadmisible (Art. 16); sin enlace la bodega muere en minutos; picking en cámara –22 °C inviable con RTT 40–80 ms. *Solo on-premise*: inadmisible (Art. 16).

Criterio de selección. Único modelo que satisface Art. 16 en sus 4 numerales; latencia ≤ 1 s en cámara resuelta localmente; autonomía 24 h CD / 14 h terreno; TCO contenido con servicios administrados AWS. Normativa: BA Art. 16.1–16.4, RT-03.01/03.02/03.10/03.19, RNF-02.01/05.01/05.02. Relacionada: D7, Decisión 16.1 N° 17.

9.4 ADR-04 · Persistencia políglota

Decisión adoptada. PostgreSQL+PostGIS (transaccional WMS, CP), Aurora (OLTP cloud + DRP), DynamoDB (IoT raw, AP, TTL 30 d), S3+Redshift Serverless (OLAP + series de temperatura), S3 Object Lock/Glacier (retención legal 5 años).

Alternativas descartadas. *Motor único relacional*: no escala ingesta IoT sin degradar picking (RNF-11.02). *InfluxDB*: segundo motor exótico a operar; serie de tiempo cabe en capa OLAP. *DynamoDB para todo*: no ofrece ACID cross-tabla para reconciliación determinista.

Criterio de selección. Posición CAP declarada por dominio (RT-05.02); 3 motores admi-

nistrados operables por el equipo de TI del CLIENTE; retención sanitaria D.S. 977/96 con inmutabilidad; $RPO \leq 15$ min por réplica Aurora. Normativa: RT-05.01/05.02/05.11-15, RNF-09.01/09.02/11.02. Relacionada: D2, D4, Decisión 16.1 N° 18.

9.5 ADR-05 · Mensajería asíncrona

Decisión adoptada. RabbitMQ local por sitio (buffer 24 h) + shipper idempotente → SQS FIFO (VPC Endpoint outbound) + Celery workers (tareas derivadas de eventos) + IoT Core MQTT (ingesta edge).

Alternativas descartadas. *REST síncrono*: no sobrevive corte a mitad de ventana; rompe reconciliación. *Kafka/MSK*: operar clústeres en 5 sitios es desproporcionado para el equipo disponible y 105 TPS.

Criterio de selección. Resiliencia offline (buffer local + reproducción idempotente); reconciliación determinista RT-03.12; Zero Trust (todo outbound); TCO proporcional al volumen. Normativa: RT-02.06/02.07, RT-03.10/03.12, RNF-07.01/13.01, BA Art. 21. Relacionada: D4.

9.6 ADR-06 · Identidad híbrida (Modelo B)

Decisión adoptada. Keycloak IdP maestro en AWS (ECS Fargate, 2 tareas Multi-AZ, backend Aurora) + caché local solo lectura (TTL 8 h) en Talca y Concepción. Tokens offline por perfil (8 h bodega, 14 h reparto). OTP para conductores externos.

Alternativas descartadas. *IdP solo nube*: paraliza bodega ante corte. *AD maestro local*: duplica administración, crea maestro a promover en DR. *Keycloak maestro local*: nube no puede autenticar si el enlace cae.

Criterio de selección. Autonomía offline sin maestro local a promover; autoridad única en nube; OTP sin correo para externos (RT-12.12); MFA Art. 22; operado por el equipo reducido del CLIENTE sin directorio propietario. Normativa: RT-12.10/12.11/12.12, RT-03.10, RNF-13.01, BA Art. 22, RF-15.01-05, RF-06.08. Relacionada: D6, Decisión 16.1 N° 34.

9.7 ADR-07 · Movilidad de terreno

Decisión adoptada. App nativa Android Kotlin para preventa, reparto y picking. SQLite/Room, SDK Zebra DataWedge (GS1 + QR), impresión BT (ZQ620), POS PAX. Dispositivos Rugged: EC55, TC58e, MC9400 Cold Storage.

Alternativas descartadas. *PWA*: no controla SDK Zebra de forma fiable ni persiste turno completo sin capa nativa. *Híbrida Flutter*: runtime intermedio degrada interacción con periféricos industriales.

Criterio de selección. Control nativo de periféricos (DataWedge intents); offline total 14 h con sincro < 10 min; UI para guantes -22 °C, una mano, lluvia; curva de aprendizaje ≤ 2 h; un artefacto para 3 perfiles. Normativa: RT-13.08, RT-12.11, RT-03.19, RNF-05.02/05.03/06.01, RF-06.11-13. Relacionada: Decisión de proyecto N° 19.

9.8 ADR-08 · Destino del WMS legado 2013

Decisión adoptada. Reemplazo total en Etapa 1 por módulo WMS del monolito (ADR-01): Talca maestro, Concepción edge, cross-docks sobre E-01. Migración por dominio, oleadas por sitio, reversión azul-verde.

Alternativas descartadas. *Mantener e integrar*: proveedor desaparecido, sin soporte; no soporta multi-sitio, picking FEFO (primero en expirar, primero en salir), SSCC GS1 ni conteo cíclico ciego. *Extender a otros sitios*: arrastra riesgo de soporte inexistente en ventana crítica.

Criterio de selección. Requisitos RF-02.x que el WMS 2013 no contempla; riesgo operacional inaceptable; TCO amortizado con reducción conteo 2,3 % → ~0,3 % y merma 1,7 % → < 1 %; reversión azul-verde garantizada. Normativa: RT-05.11-15, RT-03.10, RNF-02.01/05.01, Caso 16.1 N° 14. Relacionada: Decisión 16.1 N° 14 (delegada por el CLIENTE).

9.9 ADR-09 · Estrategia DR

Decisión adoptada. Activo-pasivo warm standby multi-región: DMS CDC + Aurora WAL hacia us-east-1; DRP local Talca → Concepción (RTO +1-2 h); pruebas 2×/año; respaldo 3-2-1-1-0 con S3 Object Lock.

Alternativas descartadas. *Activo-activo*: duplica infraestructura y exige reconciliación

de doble escritura sin beneficio medible. *Backup + restore frío*: RTO 24–72 h, incumple RNF-20.06. *Solo intrarregional*: postura mínima si CLIENTE no aprueba Art. 23; aceptando RTO 24–72 h ante caída de región.

Criterio de selección. $RTO \leq 4 \text{ h}$ / $RPO \leq 15 \text{ min}$; proporcionalidad al volumen; DR de identidad resuelto en nube (ADR-06); pruebas semestrales reales. Normativa: RT-07.01/07.07, RNF-20.06/20.07, BA Art. 20. Relacionada: Decisión 16.1 N° 27.

9.10 ADR-10 · Almacenamiento on-premise y RAID

Decisión adoptada. RAID 10 NVMe para BD transaccional del WMS (VM-02); RAID 6 con hot-spare para evidencia POD, logs y rollups; hipervisor Ceph N+1.

Alternativas descartadas. *RAID 5*: probabilidad de URE durante rebuild en discos 8–16 TB; solo tolera 1 fallo. *RAID 1 puro para todo*: sobre-costeo 50 % aplicado a datos no críticos sin beneficio proporcional.

Criterio de selección. IOPS deterministas en ventana de despacho ($>100 \text{ K}$ vs. ~ 840 necesarios); tolerancia a fallo de disco (RNF-13.04) con justificación (RNF-13.05); TCO contenido con RAID 10 solo en lo transaccional. Normativa: RT-03.14, RNF-13.03/13.04/13.05. Relacionada: Decisión 16.1 N° 28.

9.11 ADR-11 · Integración B2B/EDI canal moderno

Decisión adoptada. Hub EDI centralizado GS1 (EANCOM/GS1 XML + EPCIS) en nube, con conector configurable por cadena, equivalencias GTIN (RF-12.03), bandeja de excepciones (RF-12.06) y ACL hacia ERP/GDE. Canal moderno operativo $\leq$ enero 2029.

Alternativas descartadas. *Punto-a-punto por cadena*: multiplica adaptadores; mantenimiento desproporcionado ante cambios de cadena. *EDI delegado al ERP*: expone frontera frágil; viola Zero Trust (escritura directa desde cadena).

Criterio de selección. Estandarización GS1 (Cap. 16.2); esfuerzo marginal por cadena nueva; aislamiento ERP por ACL (Zero Trust); plazo enero 2029. Normativa: RT-05.23, RT-16.16/16.17, RNF-12.01, RF-12.03/12.06. Relacionada: RF-12, RF-01.10.

9.12 ADR-12 · Absorción del peak de septiembre

Decisión adoptada. Cómputo elástico: Fargate 2→6, Celery 2→4, Lambda 100→500, Aurora large→xlarge +2 readers, DynamoDB on-demand. Escala predictiva + reactiva. Base con Savings Plan, peak con cómputo efímero.

Alternativas descartadas. *Capacidad fija al peak:* paga 12 meses la capacidad de 3 semanas. *Solo escala reactiva:* burst predecible de septiembre; la reactiva sola introduce lag en ventana crítica.

Criterio de selección. Perfil no plano al peak $\times 1,5$ (RNF-19.04); cuello de botella identificado (RT-09.05); FinOps (RT-03.06): base reservada + peak efímero; congelamiento 1-25 sept y diciembre (RT-10.05). Normativa: RT-09.05, RT-03.06/03.08/03.09, RNF-19.01-04, RT-10.05. Relacionada: Decisión 16.1 N° 30.

9.13 ADR-13 · Puerta de enlace de servicios

Decisión adoptada. Amazon API Gateway como Capa 3 única: autorizador OIDC (Keycloak), validación de esquema OpenAPI, cuotas y límites de tasa por actor/ruta, versionado /v{major}, propagación de transaction_id a Capa 8.

Alternativas descartadas. *Kong autoadministrado:* agrega componente crítico a parchar en ruta de la venta; riesgo en ventana 05:30-07:00 con el equipo disponible. *Desarrollo propio (middleware Django):* sin cuotas/rate-limit nativos; viola Art. 21.2.

Criterio de selección. Cumplimiento literal Art. 21.2 sin desarrollo propio; servicio administrado para 4 personas; coherencia entre vistas (Art. 16.4); reversibilidad por contratos OpenAPI/AsyncAPI estándar. Normativa: BA Art. 21.2, RT-02.01/02.02, RT-11.11, RT-05.16/05.18, Art. 16.3. Relacionada: D8.

9.14 ADR-14 · Plataforma de observabilidad

Decisión adoptada. Plataforma única en nube: instrumentación OTel, colectores ADOT on-premise con buffer 24 h, logs en CloudWatch Logs (12+24 m), métricas en CloudWatch Metrics (13 meses) y trazas en CloudWatch con retención declarada. Tableros nativos de CloudWatch para operación.

Alternativas descartadas. *Prometheus+Grafana+Loki local + cloud:* dos plataformas (viola Art. 16.4 y RT-03.16); VM-06 sin capacidad. *AMP + X-Ray + Grafana:* cua-

tro servicios de observabilidad para un equipo de 4 personas; complejidad operativa desproporcionada sin ganancia funcional sobre CloudWatch nativo.

Criterio de selección. Art. 16.4 y RT-03.16 piden una plataforma; buffer ADOT resuelve «sin puntos ciegos» durante corte; ninguna decisión 05:30–07:00 depende de tablero; CloudWatch es nativo de AWS y no requiere infraestructura adicional; el equipo del CLIENTE no opera servidores de observabilidad. Normativa: BA Art. 16.4, RT-03.16, RT-14.01–09, RT-09.01. Relacionada: D14.

9.15 ADR-15 · Gestión de secretos

Decisión adoptada. AWS Secrets Manager (secretos con rotación: ERP, SII, Transbank, certificados AS2/EDI) + SSM Parameter Store (config no sensible). Consumo outbound por VPC Endpoint. Cifrado CMK KMS, separación de funciones. Cuenta de emergencia en sobre sellado offline.

Alternativas descartadas. *HashiCorp Vault autoadministrado:* modo sellado tras reinicio exige intervención humana de madrugada; agrega infraestructura. *Sin gestor centralizado:* prohibido por Art. 21.4.

Criterio de selección. Servicio administrado sin desellado manual; Zero Trust (consumo outbound); separación de funciones Art. 21.2 vía IAM/CloudTrail; contingencia offline independiente de la nube. Normativa: BA Art. 21.4/21.2, Art. 16.2/16.3, RT-04.09, RT-11.09. Relacionada: D13, SEC-01.

Anexo — Formulario T-11:

Especificaciones técnicas ofertadas

Este formulario detalla los componentes de infraestructura, plataforma, licenciamiento y hardware especificados para la solución, con su ubicación, su cantidad y su justificación, conforme al Formulario T-11 de las Bases Administrativas. Su resumen y análisis están en la sección 4.2.5, y los servicios de nube se agrupan por función en la sección 4.2.2. El equipamiento físico lo adquiere el CLIENTE, y el adjudicatario lo especifica, instala, integra y mantiene (Art. 14.2).

Infraestructura de cómputo y almacenamiento

La Tabla 46 detalla los servidores y el almacenamiento de respaldo de los cinco sitios con cómputo.

Componente	Producto ofertado	Ubicación	Cant.	Justificación
C1 — Servidor del clúster	Dell PowerEdge R6615 o HPE DL325 Gen11: EPYC 9124 de 16 núcleos, 128 GB DDR5 ECC, RAID 1 para el sistema y RAID 10 con 4 NVMe de 1,92 TB y repuesto en caliente, 2 puertos de 10 GbE y doble fuente	CD Talca, gabinete R01	3	Tres nodos iguales dejan capacidad para todas las máquinas virtuales si falla uno (RT-08.03), y los discos NVMe en RAID 10 superan con holgura las operaciones de disco del peak de septiembre.

Tabla 46 — continuación

Componente	Producto ofertado	Ubicación	Cant.	Justificación
C2 — NAS de respaldo local	NAS con bloqueo de escritura WORM y cifra- do de disco	CD Talca, gabinete R01	1	Es la copia local de recuperación rápida del esquema 3-2-1-1-0: restaura el WMS en hasta 4 h sin depender del enlace (RNF-20.06), y complementa la copia inmutable en nube sin reemplazarla.
C3 — Servi- dor de borde de Concep- ción	Dell R250 o HPE DL20 Gen11: Xeon E-2300 de 6 núcleos, 32 GB y RAID 10 con 4 NVMe de 960 GB y repuesto en caliente	CD Con- cepción, gabinete de borde	1	Sostiene el WMS con 24 h de operación au- tónoma, con 12 vCPU y 24 GB asignados para el volumen de Concepción y doble fuente.
C4 — Nodo de cross- docking	Mini-PC industrial Ad- vantech ARK-2250 o NUC Pro 12: i5 o i7 de 12.ª generación, 16 GB, NVMe de 512 GB y mó- dem LTE Cat-12 con doble SIM	Curicó, Chi- llán y Los Ángeles	3	Opera en naves sin climatización, con un supuesto de diseño de hasta 50 °C en verano, y sin fibra (RT-03.17); usa Starlink por Ethernet como enlace principal y LTE de dos proveedores como respaldo, con conmutación en menos de 30 s.

Tabla 46 Formulario T-11: infraestructura de cómputo y almacenamiento

Red y seguridad

La Tabla 47 detalla los equipos de red, los enlaces y la VPN.

Componente	Producto ofertado	Ubicación	Cant.	Justificación
C5 — Firewall y Customer Gateway	Clúster activo/pasivo de firewalls UTM de grado empresarial con sincronización de sesiones, D-01	CD Talca, gabinete R02	2	El sitio principal no admite un perímetro de equipo único (RT-08.03): la unidad pasiva asume direcciones y túneles en menos de 30 s, en circuitos eléctricos distintos (RT-08.04). Es el punto de terminación de la VPN Site-to-Site.
C6 — Switch core	Cisco Catalyst 9300-48P o equivalente en stack, D-02	CD Talca, gabinete R02	2	Los dos equipos forman un único plano de distribución, de modo que la falla de uno no interrumpe el tráfico (RT-08.03).
C7 — Switch de gestión	Switch de capa 2 para la VLAN de gestión y consola KVM	CD Talca, gabinete R02	1	Aísla los puertos de administración de los servidores en una VLAN dedicada con MFA, y permite recuperar los equipos aunque la red de producción esté caída.
C8 — Distribución horizontal	Paneles de fibra OM4 y cobre Cat6A certificado	CD Talca, gabinete R03	1	Cableado certificado enlace por enlace (RT-06.04), con dos ductos de ingreso independientes a la sala (RT-06.32).

Tabla 47 — continuación

Componente	Producto ofertado	Ubicación	Cant.	Justificación
C9 — Red inalámbrica industrial	Puntos de acceso Wi-Fi 6E industriales en la VLAN de operaciones, con estudio de cobertura en bodega y cámara	Bodegas de Talca y Concepción	9	Da cobertura a 120 terminales en Talca y 30 en Concepción, con segmentación por tipo de dispositivo y cobertura verificada dentro de las cámaras (RT-03.23).
C10 — Enlace principal	Fibra óptica simétrica: Talca de 20 a 50 Mbps y Concepción de 10 a 20 Mbps, D-03	CD Talca y CD Concepción	2	Dimensionado sobre la replicación de la base, el vuelco de los brokers y la telemetría, de unos 0,2 Mbps en promedio, y sobre el respaldo semanal a la nube, de 40 a 120 GB en la ventana nocturna, unos 33 Mbps (RT-03.20); los valores cubren el crecimiento de 3 veces sin rediseño (RT-09.03).
C11 — Enlace de respaldo	LTE empresarial con SIM dedicada: Talca de 5 a 10 Mbps, Concepción de 3 a 5 Mbps y cross-docking de 2 a 5 Mbps con dos proveedores, D-04	CD Talca, CD Concepción y los tres cross-docking	5	Evita depender de un solo camino o proveedor (RT-03.17), con conmutación en menos de 30 s: en los centros de distribución respaldada a la fibra y en los cross-docking respalda a Starlink.

Tabla 47 — continuación

Componente	Producto ofertado	Ubicación	Cant.	Justificación
C12 — VPN	AWS Site-to-Site VPN IPsec IKEv2 con BGP	Talca y Concepción hacia sa-east-1	2 túneles por CD	Replica la base, sincroniza los brokers y transmite telemetría cifrado y con enrutamiento dinámico (RT-03.21), con una MTU de túnel de 1.436 bytes.
C13 — Firewall de borde	Firewall de borde de grado empresarial, D-01	CD Concepción, gabinete de borde	1	Es el Customer Gateway del túnel hacia AWS y conmuta entre fibra y LTE en menos de 30 s (RT-08.03, RT-03.17).
C14 — Switch de borde	Cisco Catalyst 9300 o equivalente, D-02	CD Concepción, gabinete de borde	1	Sostiene la red de bodega del sitio secundario durante 24 h de autonomía, sin depender del sitio principal (RT-08.03).
C15 — Switch de cross-docking	Netgear GS308E o equivalente, de 8 puertos Gigabit gestionables, D-02	Curicó, Chillán y Los Ángeles	3	Equipo compacto para una nave sin sala técnica: conecta el mini-PC, el router Starlink, los escáneres y los terminales.

Tabla 47 Formulario T-11: red y seguridad

Dispositivos de terreno y de operación

La Tabla 48 detalla los dispositivos que usan las personas en la calle, en la bodega y en la cadena de frío.

Componente	Producto ofertado	Ubicación	Cant.	Justificación
C16 — Terminal de pre-venta	Zebra EC55: Android, IP67, uso con guantes y lector 2D SE4100	Preventistas en cinco regiones	62 más 20 %	Opera sin señal, dura la jornada con una carga, funciona con guantes y su pantalla se lee a pleno sol (RT-08.11).
C17 — Terminal de reparto	Zebra TC58e: 5G, lector SE55, batería de 7.000 mAh, GPS L1/L5, IP65/68 y -30 °C	42 conductores propios y cerca de 160 externos	200 más reserva	Un solo modelo para conductores propios y externos: mismo repuesto, misma capacitación y misma integración.
C18 — Impresora de cabina	Zebra ZQ620 Plus: 3 pulgadas, ZPL, IP54 y Link-OS	Una por conductor	200	Imprime la evidencia de entrega y los comprobantes en la cabina, con batería de reemplazo.
C19 — Terminal de pago	PAX A920 Pro: Android 14, PCI PTS 7.x y EMV L1/L2	Una por conductor	200	Cobra con tarjeta en el local del cliente con certificación PCI PTS y EMV, integrado por Bluetooth con la aplicación de reparto.
C20 — Terminal de cámara	Zebra MC9400 Cold Storage Freezer: -30 °C, lector SE58 de 100 pies, batería de 5.000 mAh y Wi-Fi 6E	Talca 144 y Concepción 30	174	Prepara pedidos en la cámara a -22 °C con guantes gruesos, lee a distancia y recambia la batería en caliente (RT-08.11, RT-08.12, RT-13.08).
C21 — Impresora de andén	Zebra ZT411: 203 dpi, 14 ips, Ethernet y ZPL	Talca 4 y Concepción 2	6	Imprime la etiqueta SSCC GS1-128 al armar la unidad logística (RF-01.07), legible a lo largo de toda la cadena (RT-05.23).

Tabla 48 — continuación

Componente	Producto ofertado	Ubicación	Cant.	Justificación
C22 — Balanza de recepción	Dibal BEV con placa-forma ME e indicador DMI-610 inoxidable, RS-232 y Ethernet	Talca 2 y Concepción 1	3	Captura el peso de recepción en línea hacia el WMS (RF-01.01), sin digitación, con calibración certificada.
C23 — Escáner de cross-docking	Zebra DS2208: 1D, 2D y GS1 DataBar, garantía de 60 meses	Curicó, Chillán y Los Ángeles	6	Lee los códigos GS1 en la desconsolidación y el re-despacho; dos por plataforma cubren dos muelles simultáneos.
C24 — Sensor de temperatura	Módulo Ebyte ME31-XDXX0400: 4 canales PT100, Modbus RTU/TCP, de -40 a +85 °C, con sondas de 3 hilos	Cámaras de Talca y Concepción	7 módulos, 28 puntos	Alimenta el registro continuo de la cadena de frío, con una exactitud de $\pm 1,1$ °C a -22 °C que distingue una excursión real de la variación del instrumento.
C25 — Termógrafo de camión	Onset InTemp CX450: Bluetooth, de -30 a +70 °C con $\pm 0,5$ °C y calibración NIST en dos puntos	Camiones propios con equipo de frío	18	Registra la temperatura del transporte de forma independiente y la descarga al sistema por Bluetooth al volver al centro.
C26 — Estación de trabajo	PC i5 o i7, 16 GB, SSD NVMe de 512 GB cifrado y 2 monitores de 24 pulgadas	Talca 5 y Concepción 3	8	Puestos de despacho, administración, planificación, calidad y TI (RNF-23.04), con disco cifrado gestionado desde el EDR y doble monitor (RT-08.08).

Tabla 48 — continuación

Componente	Producto ofertado	Ubicación	Cant.	Justificación
C27 — Kit satelital	Starlink Enterprise fijo, antena en techumbre y router, plan de 500 GB por 56 meses, D-06	Curicó, Chillán y Los Ángeles	3	Es el enlace principal de los cross-docking, que no tienen fibra, con LTE como respaldo automático (RT-03.17, RT-08.13); reposición de hardware estimada en 15 % durante el contrato.
C28 — Gateway IoT	Advantech ADAM-6000 con AWS IoT Greengrass Core, B-02	CD Talca y CD Concepción	2	Detecta la excursión térmica y bloquea el despacho en el borde, con un buffer local de 14 h si cae el enlace.

Tabla 48 Formulario T-11: dispositivos de terreno y de operación

Infraestructura de la sala técnica de Talca

La Tabla 49 detalla la infraestructura de la sala técnica principal. Las especificaciones del recinto se desarrollan en el capítulo del sitio principal.

Componente	Producto ofertado	Ubicación	Cant.	Justificación
D1 — UPS	Doble conversión en línea de 6 kVA, N+1, con banco VRLA de 30 min o más	Sala de UPS y baterías	1	Sin interrupción entre la caída de la red y la partida del generador, con 30 min o más a plena carga (RT-06.07).

Tabla 49 — continuación

Componente	Producto ofertado	Ubicación	Cant.	Justificación
D2 — Gene- rador	Grupo electrógeno de 12 kVA con estanque para 24 h y contrato de reabastecimiento	Patio del generador	1	Toma la carga de TI y clima en 8 a 15 s, y el estanque garantiza 24 h (RT-06.08).
D3 — Trans- ferencia auto- mática	Transferencia red - generador con tablero de protecciones selectivas	Acometida, accesible desde el exterior	1	Se prueba cada mes con carga real y admite termografía periódica (RT-06.10).
D4 — Clima- tización	2 unidades de precisión de 12.000 BTU/h en N+1, con free cooling, de 18 a 27 °C y de 40 a 60 % HR	Sala de cli- matización	2	Mantiene el rango ASH-RAE en la toma de aire del equipo (RT-06.13, RT-06.14), con pasillo frío confinado.
D5 — Distri- bución eléc- trica	2 PDU verticales A/B por gabinete, con medi- dor	Cuatro ga- binetes de la sala	8	Dos caminos eléctricos por gabinete (RT-08.04); el medidor es el denominador del PUE.
D6 — De- tección de incendio	Detección por aspi- ración AnaLASER o equivalente	Sala blanca	1	Detecta antes de que exista llama visible (RT-06.16).
D7 — Extin- ción	FM-200 o equivalente según NFPA 75 y 2001, con botón de aborto	Sala blanca	1	Agente limpio sobre equipos energizados (RT-06.17), y extintores ABC y CO ₂ por recinto (RT-06.18).
D8 — Control de acceso	Biometría facial con resguardo AFIS, esclusa y bitácora electrónica	Acceso a la sala, en cuatro capas	1	Doble factor con re- verificación biomé- trica y antipassback (RT-06.20, RT-06.21, RT-06.23).

Tabla 49 — continuación

Componente	Producto ofertado	Ubicación	Cant.	Justificación
D9 — Video-vigilancia	Cámaras IP con retención de 30 días o más y respaldo auditable	Sala y perímetro	7	Cubre cada puerta controlada e integra el video con el control de acceso (RT-06.24).
D10 — Recinto de custodia	Sala de 10 m ² con iluminación LED sin UV de hasta 300 lux, 40 a 60 % HR, ventilación forzada y 18 a 27 °C	Segunda línea de la sala	1	Conserva los medios de respaldo sin degradarlos (RT-06.27), con acceso sin cruzar la sala blanca (RT-06.26).
D11 — Gabinetes	4 racks de 42U: R01 servidores, R02 red, R03 distribución y respaldo, R04 crecimiento	Sala blanca	4	Separa servidores y comunicaciones (RT-06.05); R04 absorbe el crecimiento a tres años sin obras.
D12 — Cableado estructurado	Cat6A y fibra OM4 certificados por enlace, sobre piso técnico de 40 cm	Sala	1	Cumple la norma por enlace (RT-06.04) con recorridos verificados para 10 GbE.

Tabla 49 Formulario T-11: infraestructura de la sala técnica de Talca

Plataforma de nube y servicios gestionados

La Tabla 50 detalla los servicios contratados en la plataforma de nube y en servicios gestionados de terceros, ordenados por componente del catálogo.

Componente	Servicio ofertado	Ubicación	Cant.	Justificación
N-01 a N-03 — Portales	S3, CloudFront, AWS WAF, API Gateway y la tarea portal en ECS Fargate	sa-east-1, DMZ pública	1 aplicación para 3 portales	Publica los portales de clientes, transportistas y proveedores sin exponer los sitios del CLIENTE (RT-03.04).
N-04 — Plataforma de aplicación	ECS Fargate, Application Load Balancer, Elastic Container Registry y CodeBuild	sa-east-1 en 2 zonas; réplica reducida en us-east-1	2 a 6 tareas y 2 a 4 workers	Ejecuta el monolito Django y los workers Celery con escalado automático para el peak de septiembre (ADR-01, ADR-12).
N-05 — Base de datos en nube	Aurora PostgreSQL con Aurora Global Database y AWS DMS	sa-east-1 y us-east-1	1 clúster	Transaccional de los módulos en nube y réplica del WMS, con conmutación entre zonas en menos de 30 s y RPO de 15 min (ADR-04, ADR-09).
N-06 — Telemetría cruda	DynamoDB bajo demanda con Global Tables	sa-east-1 y us-east-1	1 tabla por serie	Recibe las lecturas de IoT sin gestión de capacidad y las expira a los 30 días (ADR-04).
N-07 — Caché	ElastiCache for Redis con primario y réplica	sa-east-1 en 2 zonas	1 clúster	Responde la consulta de stock y crédito de preventa en menos de 2 s.
N-08 — Ingesta de IoT	IoT Core, Lambda e IoT Greengrass	sa-east-1 y gateways de borde	2 gateways y 18 ter-mógrafos	Recibe, valida y alerta la telemetría de cadena de frío, y gestiona la flota de gateways.
N-09 — Mensajería	SQS FIFO y SNS	sa-east-1	1 cola por sitio	Reconcilia los sitios en orden y sin duplicados, y difunde las alertas de frío (ADR-05).

Tabla 50 — continuación

Componente	Servicio ofertado	Ubicación	Cant.	Justificación
N-10 — Plataforma analítica	S3, Glue, Redshift Serverless y QuickSight	sa-east-1	1 lago de 5 años	Separa la analítica del transaccional y publica los tableros del CLIENTE.
N-11 — Respaldo y réplica	AWS Backup con Vault Lock, S3 Object Lock y replicación de S3 entre regiones	sa-east-1 y us-east-1	1 política	Mantiene la copia inmutable del esquema 3-2-1-1-0 y la réplica de recuperación (ADR-09).
N-12 — Seguridad y gobierno	KMS, Secrets Manager, Parameter Store, IAM Identity Center, Shield Advanced, GuardDuty, Security Hub, Inspector, Macie, Security Lake, CloudTrail, Config, CloudWatch, Systems Manager, Control Tower, Organizations, Cost Explorer y Budgets	sa-east-1; claves y secretos también en us-east-1	5 cuentas	Cumple los controles del Artículo 21 y el gobierno de costos como servicios administrados (ADR-14, ADR-15).
D-01 — Red en nube y terminación de la VPN	VPC, Transit Gateway, Site-to-Site VPN, NAT Gateway, VPC Endpoints y Route 53	sa-east-1 y us-east-1	2 túneles por CD	Conecta los sitios con la nube sin tráfico de datos por Internet (RT-03.03, RT-03.04).
N-13 — Gestión de dispositivos	Android Enterprise y Zebra DNA como servicio gestionado	Servicio en nube y agente en el dispositivo	462 dispositivos	Enrola, configura, actualiza y borra de forma selectiva el parque de terreno y de bodega (RT-03.18).

F-03 — De-tección en endpoints	Consola EDR gestionada y agentes	Servicio en nube y agente en cada nodo y estación	1 por endpoint	Detecta y responde en nube y on-premise desde una sola consola (RT-11.16).
--------------------------------	----------------------------------	---	----------------	--

Tabla 50 Formulario T-11: plataforma de nube y servicios gestionados

Software de base y licenciamiento

La Tabla 51 detalla el software que opera sobre el equipamiento y la plataforma anteriores.

Componente	Producto ofertado	Ubicación	Cant.	Justificación
Aplicación	Monolito modular en Django y Python con workers Celery, en una imagen única con modo wms_only	Nube, VM-01, VM-C01 y E-01	1 imagen	Una sola base de código para nube y sitios, con paridad de versiones (ADR-01).
Aplicación de terreno	Aplicación nativa Android en Kotlin, con SQLite y Zebra DataWedge	EC55, TC58e y MC9400	1 artefacto para 3 perfiles	Controla los periféricos industriales y opera un turno completo sin señal (ADR-07).
Base de datos	PostgreSQL 16 con PostGIS, código abierto	VM-02, VM-C02 y los tres E-01	5 instancias	Registro de la bodega durante los cortes, replicado a Aurora por DMS.
Broker	RabbitMQ, código abierto	VM-03, VM-C04 y los tres E-01	5 instancias	Buffer de 24 h por sitio con vuelco ordenado a SQS FIFO (ADR-05).
Identidad	Keycloak, código abierto	Fargate, VM-05 y VM-C03	1 maestro y 2 cachés	Autoridad única en nube con cachés de solo lectura (ADR-06).
Virtualización	Proxmox VE con Ceph, código abierto	Clúster de Talca	1 clúster de 3 nodos	Tolera la pérdida de un nodo sin detener la bodega.

Tabla 51 — continuación

Componente	Producto ofertado	Ubicación	Cant.	Justificación
Contenedores de borde	Docker y Docker Compose, código abierto	Concepción y los tres cross-docking	4 sitios	Instalación y parcheo sin dependencia de la red.
Observabilidad de sitio	AWS Distro for OpenTelemetry y agente SSM	VM-06, VM-C04 y los tres E-01	5 colectores	Buffer de 24 h y envío a CloudWatch al reconectar (ADR-14).
Configuración	Ansible y Terraform con CDK, código abierto	Repositorio del CLIENTE	1 repositorio	Infraestructura y configuración declaradas como código versionado.

Tabla 51 Formulario T-11: software de base y licenciamiento