

LICITACIÓN PÚBLICA

Licitación N.º TFEP-01/2026

Proyecto de Plataforma Digital de Misión Crítica

Caso 02 — Logística

Sobre N.º 2 — Oferta Técnica

Propuesta Técnica

Subdocumento 4 — Arquitectura de la solución

Parte 4.2 — Arquitectura física y de despliegue · Formularios T-7 y T-21

MANDANTE

Distribuidora Puelche S.A.

PROPONENTE

LafroX SpA

RUT 77.418.902-K

Av. Brasil 2241, Valparaíso

REPRESENTANTE LEGAL

Alex Aravena

Jefe de Proyecto y Apoderado

contacto@lafrox.cl

+56 32 250 4100

VERSIÓN	FECHA DE EMISIÓN	ESTADO	TOTAL DE FOLIOS
2.0	05 de octubre de 2026	Versión final para entrega	85

FIRMA DEL REPRESENTANTE LEGAL

Alex Aravena

Jefe de Proyecto y Apoderado · LafroX SpA

Índice general

Índice general	2
Lista de figuras	6
Lista de tablas	7
Arquitectura física y de despliegue de la solución	9
4.1 Visión general de la arquitectura física	10
4.2 Arquitectura física	11
4.2.1 Emplazamiento de cada componente	11
4.2.1.1 Instalaciones y dominios	12
4.2.1.2 Síntesis del emplazamiento por dominio y criterio	14
4.2.1.3 Componentes de nube pura	15
4.2.1.4 Componentes on-premise	16
4.2.1.5 Componentes híbridos	17
4.2.1.6 Autonomía de cada ámbito sin enlace	18
4.2.2 Servicios contratados en la plataforma de nube	19
4.2.2.1 Servicios por función	20
4.2.2.2 Región secundaria y residencia de los datos	21
4.2.2.3 Servicios que no se contratan	22
4.2.2.4 Modelo de contratación	22
4.2.3 Arquitectura de despliegue	22
4.2.3.1 Ambientes y ciclo de entrega	23
4.2.3.1.1 Liberación y reversión	24
4.2.3.1.2 Calendario y cadencia	25

4.2.3.2 Red de despliegue	26
4.2.3.3 Alta disponibilidad	28
4.2.3.4 Recuperación ante desastres	29
4.2.3.4.1 Conmutación y retorno	30
4.2.3.4.2 Sitios secundarios y amenazas comunes	32
4.2.3.4.3 Operación durante una contingencia regional	32
4.2.3.5 Respalos	33
4.2.3.6 Verificación de la continuidad	34
4.2.4 Conexiones, puntos de falla y contingencia	35
4.2.4.1 Conexiones entre sitios, terreno y nube	35
4.2.4.2 Puntos de falla en los sitios y en los enlaces	38
4.2.4.3 Puntos de falla en la nube, el terreno y las integraciones	39
4.2.5 Dimensionamiento y plan de capacidad	41
4.2.5.1 Criterios y método	41
4.2.5.2 Volumetría de referencia	41
4.2.5.3 Transacciones por segundo	43
4.2.5.4 Usuarios, concurrencia y dispositivos	44
4.2.5.5 Almacenamiento y datos a migrar	45
4.2.5.6 Integraciones y volumen de mensajes	46
4.2.5.7 Ancho de banda, dispositivos de reparto y sincronización	47
4.2.5.8 Mesa de ayuda y equipo de operación	48
4.2.5.9 Síntesis de las dieciséis dimensiones	49
4.2.5.10 Dimensionamiento on-premise	50
4.2.5.11 Dimensionamiento en nube	52
4.2.5.12 Plan de capacidad y crecimiento de 3 veces	53
4.2.5.13 Umbrales de desempeño	54
4.2.5.14 Primer cuello de botella	55
4.2.5.15 Degradación controlada	56
4.2.5.16 Pruebas de carga y estrés	56

4.2.5.17 Actualización del plan de capacidad	57
4.2.6 Especificaciones Implementos a proveer (Hardware y Software)	57
4.2.6.1 Síntesis del equipamiento por familia	57
4.2.6.2 Criterios de selección	58
4.2.6.3 Software y licenciamiento	59
4.3 Especificaciones del sitio principal on-premise (CD Talca)	60
4.4 Especificaciones del sitio secundario	62
4.5 Tecnologías de software ofertadas	63
4.5.1 Integración con el ERP y documentos tributarios	64
4.6 Registro de decisiones de arquitectura	65
4.6.1 ADR-01 · Estilo arquitectónico	65
4.6.2 ADR-02 · Conectividad WAN	65
4.6.3 ADR-03 · Modelo de despliegue híbrido	66
4.6.4 ADR-04 · Persistencia políglota	66
4.6.5 ADR-05 · Mensajería asíncrona	67
4.6.6 ADR-06 · Identidad híbrida (Modelo B)	67
4.6.7 ADR-07 · Movilidad de terreno	68
4.6.8 ADR-08 · Destino del WMS legado 2013	68
4.6.9 ADR-09 · Estrategia DR	68
4.6.10 ADR-10 · Almacenamiento on-premise y RAID	69
4.6.11 ADR-11 · Integración B2B/EDI canal moderno	69
4.6.12 ADR-12 · Absorción del peak de septiembre	70
4.6.13 ADR-13 · Puerta de enlace de servicios	70

4.6.14 ADR-14 · Plataforma de observabilidad	70
4.6.15 ADR-15 · Gestión de secretos	71
Anexo 4.A — Formulario T-11: Especificaciones técnicas ofertadas	72

Lista de figuras

Figura 1	Ubicación de los componentes por dominio y por sitio	13
Figura 2	Conexiones entre los sitios, el terreno y la nube	36

Lista de tablas

Tabla 1	Distribución de los componentes por dominio y criterio de emplazamiento	14
Tabla 2	Autonomía por ámbito ante la pérdida del enlace	19
Tabla 3	Servicios contratados en la plataforma de nube, por función	21
Tabla 4	Ambientes de despliegue	23
Tabla 5	Ventanas de despliegue	26
Tabla 6	Direccionamiento y segmentación	27
Tabla 7	Clasificación de servicios por nivel de servicio	28
Tabla 8	Replicación y RPO por dominio de datos	30
Tabla 9	Secuencia de conmutación de región	31
Tabla 10	Respaldo y restauración por dominio de datos	34
Tabla 11	Conexiones de la solución y su camino alternativo	37
Tabla 12	Puntos de falla en los sitios y en los enlaces	39
Tabla 13	Puntos de falla en la nube, el terreno y las integraciones	40
Tabla 14	Valores base de dimensionamiento	42
Tabla 15	Proyección de la volumetría a tres años	43
Tabla 16	Transacciones por segundo de diseño	44
Tabla 17	Usuarios y terminales concurrentes	45
Tabla 18	Volumen de mensajes por integración	47
Tabla 19	Ancho de banda por sitio	48

Tabla 20	Las dieciséis dimensiones del numeral 14.2 del caso	50
Tabla 21	Utilización del clúster de Talca con un nodo caído	51
Tabla 22	Máquinas virtuales del clúster de Talca	51
Tabla 23	Almacenamiento y rendimiento de la base transaccional	52
Tabla 24	Capacidad de los servicios en nube	53
Tabla 25	Plan de capacidad para el crecimiento de 3 veces	54
Tabla 26	Umbrales de desempeño en percentil 95	55
Tabla 27	Pruebas de carga y estrés	56
Tabla 28	Síntesis del equipamiento a proveer por familia	58
Tabla 29	Formulario T-11: infraestructura de cómputo y almacenamiento	73
Tabla 30	Formulario T-11: red y seguridad	76
Tabla 31	Formulario T-11: dispositivos de terreno y de operación	79
Tabla 32	Formulario T-11: infraestructura de la sala técnica de Talca	81
Tabla 33	Formulario T-11: plataforma de nube y servicios gestionados	84
Tabla 34	Formulario T-11: software de base y licenciamiento	85

Arquitectura física y de despliegue de la solución

| Parte 4.2 del subdocumento 4. La arquitectura lógica es la parte 4.1 y se entrega por separado; ambas comparten el registro de decisiones y la volumetría, y se leen juntas.

Visión general de la arquitectura física

La arquitectura física materializa el despliegue híbrido obligatorio del Artículo 16° de las Bases Administrativas. La carga principal corre en nube pública AWS, con la región primaria en sa-east-1 (São Paulo, Brasil) y la recuperación ante desastres en us-east-1 (Norte de Virginia, EE. UU.). Los componentes on-premise garantizan la continuidad de la operación de bodega, plataformas y terreno durante cortes del enlace.

La red de instalaciones de la solución son 5 instalaciones en cuatro regiones. La proyección del caso a tres años incorpora una sexta instalación, sin requerir cambios en desarrollo o en crecimiento de servidores en CD Talca.

Los principios que gobiernan el diseño son los siguientes:

- **Carga principal en nube:** El núcleo transaccional de preventa, reparto y canal moderno, la analítica, la integración y el almacenamiento consolidado se ejecutan en AWS sa-east-1, con escalado elástico para el peak de septiembre.
- **Autonomía total de la operación de bodega:** El picking, despacho, recepción y conteo corren siempre contra los servidores del centro de distribución, no contra la nube. La conexión a internet no interviene en la operación de bodega.

Arquitectura física

La arquitectura física declara dónde vive cada componente de la solución, qué servicios se contratan en la nube, cómo se conectan los sitios entre sí y con la nube, qué ocurre cuando falla cada conexión y cuánta capacidad se provee.

La correspondencia con la arquitectura lógica (Subdocumento 4.1) es total porque ambas usan el mismo catálogo de componentes, con los mismos identificadores: A-01 a A-05 para el núcleo de bodega, B-01 a B-03 para la cadena de frío, C-01 a C-05 para los dispositivos de operación, D-01 a D-06 para la red, E-01 para los cross-docking, F-01 a F-03 para observabilidad y seguridad de los nodos, y N-01 a N-13 para la nube. Un componente que aparece en una vista aparece con el mismo nombre en la otra.

Este capítulo se ordena en seis partes. La sección 4.2.1 justifica el emplazamiento de cada componente conforme a los criterios del Artículo 16.2. La sección 4.2.2 enumera los servicios contratados en la plataforma de nube. La sección 4.2.3 describe cómo la solución se pone en marcha y se mantiene en operación: ambientes y ciclo de entrega, red de despliegue, alta disponibilidad, recuperación ante desastres, respaldos y su verificación. La sección 4.2.4 describe las conexiones, sus puntos de falla y la contingencia de cada uno. La sección 4.2.5 deriva el dimensionamiento y el plan de capacidad desde la volumetría del caso. La sección 4.2.6 resume el equipamiento a proveer, cuyo detalle se entrega en el Anexo 4.A (Formulario T-11), que acompaña a esta parte como anexo. Las especificaciones de los sitios principal y secundario se desarrollan en los capítulos correspondientes al cierre de esta parte.

4.2.1 Emplazamiento de cada componente

El emplazamiento de cada componente se decide con los seis criterios del Artículo 16.2 de las Bases Administrativas: latencia tolerada, criticidad operacional, volumen de datos, restricciones regulatorias, disponibilidad de conectividad y costo total de propiedad. En este caso la conectividad y la latencia pesan más que en una operación de oficina, porque el caso describe una red que se corta: la fibra de Talca tiene en promedio cuatro cortes al año de hasta seis horas, Concepción no tiene respaldo, los cross-docking solo tienen red móvil y en Los Ángeles la señal es intermitente justo en su ventana de

mañana, las cámaras no tienen cobertura en su interior y hay rutas sin señal durante dos horas o durante el turno completo (Caso, Cap. 6).

De esos hechos se desprende la regla que ordena todo el emplazamiento: lo que debe funcionar sin enlace vive en el sitio, y lo que escala, se comparte o está expuesto a Internet vive en la nube. Los 36 componentes del catálogo se reparten en 13 de nube pura, 11 on-premise y 12 híbridos, que tienen una parte en cada dominio (ADR-03). Los identificadores son los mismos de la arquitectura lógica.

4.2.1.1 Instalaciones y dominios

La solución cubre las seis instalaciones que declara la volumetría del caso (Caso, Tabla 14.1), más la calle y los 14.200 puntos de entrega. El cómputo on-premise se despliega en los cinco recintos que la operación nombra y a los que se asigna tipología (RT-06.01): el CD Talca es la sala técnica principal, con un clúster de tres nodos con Proxmox VE y almacenamiento Ceph que aloja las máquinas virtuales VM-01 a VM-06; el CD Concepción opera con un servidor de borde que replica la misma pila en formato reducido, en las máquinas VM-C01 a VM-C04; y las plataformas de cross-docking de Curicó, Chillán y Los Ángeles operan cada una con un mini-PC industrial que ejecuta el WMS en contenedores. La volumetría declara seis instalaciones (Tabla 14.1) y RT-21.16 señala «seis instalaciones en cuatro regiones», mientras que el §8 del caso habla de una «red de cinco instalaciones»; el relato no identifica la sexta, por lo que esa divergencia se registra como consulta al mandante (Art. 43.3) y como supuesto, sin afectar el dimensionamiento, que se calcula sobre los cinco recintos que alojan cómputo. La séptima instalación que proyecta el caso a tres años se incorpora parametrizando la infraestructura como código y ocupando el gabinete de crecimiento R04 de la sala principal, sin obras adicionales (RT-02.12).

En la nube, la región primaria es sa-east-1 y cada servicio se despliega en al menos dos zonas de disponibilidad. La región us-east-1 solo aloja la recuperación ante desastres. La Figura 1 ubica cada componente en su sitio.

La figura muestra que ninguna instalación depende de otra para operar. Talca y Concepción tienen cada uno su WMS, su base, su broker y su caché de identidad; los cross-docking reúnen esas mismas funciones en un solo equipo; y el terreno lleva su propio almacén local en el dispositivo. La nube concentra lo que es común a todos los sitios: los portales, el transaccional compartido, la analítica y los servicios de seguridad. Los doce componentes híbridos aparecen en los dos dominios porque cada uno tiene una parte que debe seguir operando en el sitio y otra que consolida en la nube.




Figura 1 Ubicación de los componentes por dominio y por sitio

Fuente: elaboración propia a partir del catálogo de componentes de la arquitectura lógica y de la volumetría del caso (Caso, Tabla 14.1).

4.2.1.2 Síntesis del emplazamiento por dominio y criterio

La Tabla 1 resume cómo se distribuyen los 36 componentes entre los tres dominios y los seis criterios del Artículo 16.2 que deciden cada emplazamiento. La justificación de cada componente, con su producto, su ubicación, su cantidad y su fundamento, se detalla en el Anexo 4.A (Formulario T-11), que acompaña a esta parte como anexo, y se recorre dominio por dominio en los apartados siguientes.

Criterio (Art. 16.2)	Nube pura	On-premise	Híbridos	Total
Latencia tolerada	1	4	1	6
Criticidad operacional	2	2	3	7
Volumen de datos	3*	—	—	3
Conectividad	—	4	7	11
Regulación	5	—	1	6
Costo total de propiedad	3*	1	—	4
Total de componentes	13	11	12	36

Tabla 1 Distribución de los componentes por dominio y criterio de emplazamiento

Fuente: elaboración propia; criterios conforme al Art. 16.2 de las Bases Administrativas.

El emplazamiento no obedece a una preferencia sino a cuatro hechos del caso. La conectividad decide once componentes y domina el on-premise y los híbridos, porque el caso describe enlaces que se cortan y terreno sin señal. La regulación decide seis y domina la nube pura, porque el Artículo 21 impide exponer los sitios a Internet y separa los públicos externos en la DMZ. El costo y el volumen concentran en la nube lo que escala y se paga por uso, y la latencia y la criticidad dejan en el sitio lo que debe responder sin enlace. La columna Total suma 37 en las filas de criterios porque la plataforma analítica (N-10) se contabiliza en los dos criterios que deciden su emplazamiento, volumen de datos y costo total de propiedad; la fila final suma los 36 componentes efectivos.

4.2.1.3 Componentes de nube pura

Los trece componentes de nube pura viven solo en la nube. La justificación de cada uno y el criterio del Artículo 16.2 que la determina son los siguientes:

- **N-01 Portal de Clientes** (regulación): atiende el catálogo, la autoatención y el pago de los clientes desde Internet, por lo que se publica solo en la DMZ de la nube y ningún tráfico externo llega a los sitios del CLIENTE.
- **N-02 Portal de Transportistas** (regulación): los conductores externos entran con una clave de un solo uso y sin cuenta corporativa (RF-06.08), y ese acceso se resuelve en la DMZ de la nube.
- **N-03 Portal de Proveedores** (regulación): los 180 proveedores consultan órdenes de compra, recepciones y devoluciones desde Internet, aislados de la red de bodega.
- **N-04 Plataforma de aplicación** (costo): el monolito Django y sus workers Celery corren en ECS Fargate y escalan de 2 a 6 tareas en el peak de septiembre, sin servidores permanentes que mantener.
- **N-05 Base de datos en nube** (criticidad): Aurora PostgreSQL guarda el transaccional de los módulos en nube y la réplica del WMS, conmuta entre zonas en menos de 30 s y se replica a us-east-1.
- **N-06 Telemetría cruda** (volumen): DynamoDB recibe las lecturas de temperatura sin gestión de capacidad y las expira a los 30 días, cuando ya están consolidadas en la capa analítica.
- **N-07 Caché** (latencia): ElastiCache mantiene en memoria el stock, el crédito y las sesiones para que la consulta de preventa responda en menos de 2 s.
- **N-08 Ingesta de IoT** (volumen): IoT Core y Lambda reciben los 16.100 mensajes diarios de cadena de frío por MQTTs, validan cada lectura y gestionan los gateways del borde.
- **N-09 Mensajería** (criticidad): SQS FIFO recibe la reconciliación de los sitios en orden y sin duplicados, y SNS difunde las alertas de excursión térmica.
- **N-10 Plataforma analítica** (volumen y costo): S3, Glue, Redshift Serverless y Quick-Sight conservan 5 años de datos separados del transaccional y publican los tableros del CLIENTE.
- **N-11 Respaldo inmutable y réplica** (regulación): S3 Object Lock, AWS Backup y la réplica en us-east-1 guardan la copia que ni un administrador puede borrar y sostienen el RTO de 4 h y el RPO de 15 min.
- **N-12 Seguridad y gobierno** (regulación): KMS, Secrets Manager, WAF, Shield, Security Lake y CloudWatch cumplen los controles del Artículo 21 como servicios que

un equipo de TI de cuatro personas puede operar.

- **N-13 Gestión de dispositivos** (costo): Android Enterprise y Zebra DNA gestionan como servicio los 462 dispositivos del parque, con borrado remoto selectivo y sin infraestructura en los sitios (RT-03.18).

Ningún componente de nube pura participa en las transacciones que el caso exige resolver sin enlace: la confirmación de preparación, el despacho y el registro de entrega se ejecutan en el sitio o en el dispositivo. Lo que sube a la nube lo hace por tres razones. Los portales y la gestión de identidades externas lo hacen por regulación, porque el Artículo 21 impide exponer los sitios a Internet. La plataforma de aplicación, la analítica y la telemetría lo hacen por volumen y costo, porque su carga varía con la estación y se paga por uso. Y la seguridad y el respaldo lo hacen porque un equipo de TI de cuatro personas no puede operar esos controles en sus propios servidores.

4.2.1.4 Componentes on-premise

Los once componentes on-premise viven solo en las instalaciones del CLIENTE. La justificación de cada uno y su criterio:

- **B-01 Sensores de temperatura** (latencia): los 28 puntos de medición de las cámaras se leen por Modbus en el mismo sitio, porque dentro de la cámara no hay señal y la lectura no puede esperar al enlace.
- **B-02 Gateway IoT** (latencia): los gateways de Talca y Concepción detectan la excursión térmica y bloquean el despacho en menos de 5 s, con un buffer de 14 h si cae el enlace.
- **C-03 Terminales de bodega** (conectividad): los 174 terminales MC9400 trabajan en la cámara a -22 °C, sin señal móvil, contra el WMS del sitio por la red inalámbrica de la bodega.
- **C-04 Impresoras de andén** (latencia): las seis impresoras ZT411 imprimen la etiqueta SSCC en el andén al armar la unidad logística, sin salir de la red local.
- **C-05 Balanzas de recepción** (latencia): las tres balanzas envían el peso de recepción al WMS del sitio en línea, sin digitación y sin depender del enlace.
- **D-02 Switching** (críticidad): los switches de cada sitio segmentan la red local por VLAN (RT-03.23) y la mantienen operativa aunque caiga la WAN.
- **D-03 Enlace de fibra** (conectividad): es el camino principal de la VPN en Talca y Concepción, con 20 y 10 Mbps en régimen.
- **D-04 Enlace LTE** (conectividad): respalda la fibra en los CD y, con dos proveedores,

respalda a Starlink en los cross-docking, con conmutación en menos de 30 s.

- **D-06 Enlace satelital** (conectividad): Starlink es el camino principal de los cross-docking, que no tienen fibra y cuya red móvil falla en la madrugada de Los Ángeles.
- **E-01 WMS de cross-docking** (criticidad): el mini-PC de cada plataforma opera 100 % en local la ventana de 3 h de recepción, desconsolidación y re-despacho, con su propio broker y su propia base.
- **F-02 Gestión de parches** (costo): Ansible aplica los parches y las líneas base CIS a los nodos de los cinco sitios por la red de gestión, sin licencia de plataforma.

En el on-premise dominan la latencia y la conectividad. Los sensores, las impresoras, las balanzas y los terminales de cámara son periféricos que trabajan donde está la mercadería, y ninguno puede depender de un enlace que el caso describe como intermitente. Los tres enlaces y el switching tampoco podrían emplazarse en otro lugar: son la infraestructura que conecta el sitio con la nube y sostiene su red interna cuando esa conexión falla.

4.2.1.5 Componentes híbridos

Los doce componentes híbridos tienen una parte en cada dominio. Para cada uno, la justificación explica qué parte vive en el sitio, qué parte vive en la nube y por qué se reparten así:

- **A-01 Motor WMS** (latencia): corre en VM-01, VM-C01 y E-01 porque la confirmación de preparación debe responder en 1 s sin depender del enlace, y su réplica en Aurora sostiene la continuidad.
- **A-02 Base transaccional del WMS** (criticidad): PostgreSQL 16 en VM-02 y VM-C02 es el registro de la bodega durante un corte, y DMS replica sus cambios a Aurora con un RPO de 15 min.
- **A-03 Broker de colas** (conectividad): RabbitMQ en VM-03, VM-C04 y E-01 guarda hasta 24 h de transacciones sin enlace y las entrega en orden a SQS FIFO, donde Celery las reconcilia.
- **A-04 Capa anticorrupción del ERP** (criticidad): corre en VM-04 junto al ERP de 2017, que no se modifica, y el worker celery-erp-sync de la nube la consulta por la VPN como única puerta al legado.
- **A-05 Identidad** (conectividad): el IdP maestro Keycloak corre en Fargate y sus cachés de solo lectura en VM-05 y VM-C03 validan las sesiones de bodega sin enlace.
- **B-03 Termógrafos de camión** (conectividad): los 28 termógrafos —18 en los ca-

miones propios y 10 en los de los transportistas— registran la temperatura durante toda la ruta sin señal y sincronizan por Bluetooth con el terminal del conductor, que alerta la excursión térmica en el momento y la reenvía a la nube cuando recupera cobertura; al volver el camión, el registro completo se descarga al gateway para que IoT Core la valide.

- **C-01 App de preventa** (conectividad): toma pedidos contra el almacén local del terminal cuando no hay señal y sincroniza con API Gateway al reconectar, sin duplicar pedidos.
- **C-02 App de reparto** (conectividad): registra entregas, evidencia y cobros durante 14 h sin señal y los sincroniza con la nube al recuperar cobertura.
- **D-01 Firewall y Customer Gateway** (criticidad): el par de Talca y el firewall de Concepción terminan los túneles IPsec hacia el VPN Gateway de AWS y conmutan de enlace en menos de 30 s.
- **D-05 Respaldo local** (conectividad): el NAS WORM de Talca restaura el WMS en 4 h sin depender del enlace, y su complemento inmutable vive en S3 Object Lock.
- **F-01 Telemetría de observabilidad** (conectividad): los colectores ADOT de VM-06, VM-C04 y E-01 guardan hasta 24 h de métricas y trazas en disco y las envían a CloudWatch al reconectar.
- **F-03 Detección en endpoints** (regulación): los agentes EDR de cada nodo y estación reportan a una consola central, lo que cumple RT-11.16 en nube y on-premise con una sola respuesta.

Los componentes híbridos siguen todos el mismo patrón: la parte que atiende la operación queda en el sitio y la parte que consolida queda en la nube, unidas por un mecanismo que tolera el corte. En el núcleo de bodega ese mecanismo es la réplica por DMS y las colas; en el terreno, el almacén local del dispositivo; y en la observabilidad, el buffer en disco de los colectores. Por eso la conectividad es el criterio dominante en siete de los doce: cada uno existe en dos lugares precisamente porque el enlace entre ellos no es confiable.

4.2.1.6 Autonomía de cada ámbito sin enlace

El emplazamiento anterior se verifica en lo que cada ámbito puede hacer cuando pierde el enlace. La Tabla 2 declara esa autonomía y el tiempo en que cada ámbito vuelve a quedar sincronizado.

Ámbito	Autonomía sin enlace	Norma de operación
Centro de distribución y Concepción	24 h o más	RT-03.12, reconciliación determinista
Terreno	14 h, un turno completo	RT-03.10
Cross-docking	3 h, 100 % local	RT-03.11
Sincronización al reconectar	CD en 2 h; flota en 10 min	RT-03.13 y RNF-07.01

Tabla 2 Autonomía por ámbito ante la pérdida del enlace

Fuente: elaboración propia a partir de los compromisos de operación desconectada del caso (Caso, Cap. 6).

Durante la autonomía, cada ámbito mantiene su operación completa contra sus datos locales. El centro de distribución sigue con recepción, preparación, despacho, conteo cíclico y trazabilidad contra la base local (RT-03.12). El terreno sigue con toma de pedido, entrega, evidencia, devoluciones y cobros contra el almacén local del dispositivo (RT-03.10). El cross-docking mantiene recepción, desconsolidación, validación de frío y re-despacho (RT-03.11). Al reconectar, el vuelco ocurre en orden estricto, sin duplicados y con reconciliación determinista (RT-03.13, RNF-07.01).

La autonomía de cada ámbito cubre el corte más largo que describe el caso para ese lugar. Las seis horas del peor corte de fibra de Talca quedan dentro de las 24 horas del centro de distribución, y la ruta rural que recupera cobertura solo al regresar queda dentro del turno de 14 horas del terreno. Los tiempos de sincronización se sostienen con los enlaces dimensionados en la sección 4.2.5, y lo que ocurre ante cada falla se desarrolla en la sección 4.2.4.

4.2.2 Servicios contratados en la plataforma de nube

La plataforma de nube es Amazon Web Services. Todos los servicios se contratan en cuentas del CLIENTE, organizadas bajo AWS Control Tower con una cuenta por ambiente, de modo que la propiedad de los datos y de la infraestructura es del CLIENTE desde el primer día. La selección sigue tres reglas: preferir el servicio administrado cuando existe, porque el área de TI del CLIENTE es de cuatro personas (Caso, Cap. 2.4); preferir servicios compatibles con estándares abiertos, para que salir de la plataforma no exija

reescribir la solución; y contratar en la región secundaria solo lo que la recuperación ante desastres necesita.

4.2.2.1 Servicios por función

La Tabla 3 agrupa los servicios contratados por la función que cumplen en la arquitectura y los asocia a los componentes del catálogo que los usan. El listado servicio por servicio, con su justificación y su cantidad, se entrega en el Anexo 4.A (Formulario T-11).

Función	Servicios contratados	Componentes	Región
Entrada pública y borde	Route 53, CloudFront, AWS WAF, Shield Advanced, API Gateway	N-01, N-02, N-03, N-12	Global y sa-east-1
Cómputo de aplicación	ECS Fargate, Application Load Balancer, Lambda	N-04, N-08, A-05	sa-east-1 y us-east-1
Datos operacionales	Aurora PostgreSQL, Database Migration Service, DynamoDB, ElastiCache	N-05, A-02, N-06, N-07	sa-east-1 y us-east-1
Mensajería	SQS FIFO, SNS	N-09, A-03	sa-east-1
Internet de las cosas	IoT Core, IoT Greengrass	N-08, B-02, B-03	sa-east-1 y borde
Analítica	S3, Glue, Redshift Serverless, QuickSight	N-10	sa-east-1
Respaldo y recuperación	AWS Backup, S3 Object Lock, replicación de S3 entre regiones	N-11, D-05	sa-east-1 y us-east-1
Red y conectividad	VPC, Transit Gateway, Site-to-Site VPN, NAT Gateway, VPC Endpoints	D-01	sa-east-1 y us-east-1
Identidad, claves y secretos	KMS, Secrets Manager, Parameter Store, IAM Identity Center	A-05, N-12	sa-east-1 y us-east-1
Detección y cumplimiento	Security Lake, GuardDuty, Security Hub, Inspector, Macie, CloudTrail, Config	N-12, F-03	sa-east-1
Operación y gobierno	CloudWatch, Systems Manager, Control Tower, Organizations, Cost Explorer, Budgets	F-01, F-02, N-12	sa-east-1

Tabla 3 — continuación

Función	Servicios contratados	Componentes	Región
Construcción y registro de imágenes	CodeBuild, Elastic Container Registry	N-04, A-01	sa-east-1
Servicios de terceros en nube	Android Enterprise y Zebra DNA; consola del EDR	N-13, F-03	Servicio gestionado

Tabla 3 Servicios contratados en la plataforma de nube, por función

Fuente: elaboración propia a partir del catálogo de componentes y de los registros de decisión ADR-01 a ADR-15.

La tabla deja ver que la solución no opera servidores en la nube: todo el cómputo corre en contenedores administrados o en funciones, y todos los datos viven en motores administrados. Las únicas piezas de software que el adjudicatario mantiene sobre esa plataforma son la aplicación Django y el IdP Keycloak, ambos desplegados como contenedores que se promueven por el pipeline. Los servicios de detección, cumplimiento y gobierno se concentran en la región primaria porque vigilan la operación productiva, mientras que los datos operacionales y el respaldo tienen presencia en las dos regiones porque son lo que la recuperación ante desastres debe restituir.

4.2.2.2 Región secundaria y residencia de los datos

La región us-east-1 no es una segunda producción. Solo contiene la réplica de Aurora mediante Aurora Global Database, la réplica de DynamoDB mediante Global Tables, la copia de los buckets de S3, las copias de AWS Backup y una réplica reducida de ECS que escala a carga completa en menos de 30 minutos durante una conmutación (ADR-09). Dos capacidades quedan fuera de esa región por diseño: la analítica, porque la región secundaria no se explota analíticamente, y los datos de geolocalización de personas, que no se replican fuera de sa-east-1 conforme a los resguardos de la arquitectura de seguridad. Así, la transferencia internacional de datos que exige la continuidad queda acotada a lo estrictamente necesario para reanudar la operación.

4.2.2.3 Servicios que no se contratan

Los registros de decisión descartan de forma expresa varios servicios de la misma plataforma, y ninguno de ellos aparece en la arquitectura. No se contrata un clúster de Kubernetes (EKS), porque el volumen de alrededor de 105 transacciones por segundo no justifica su plano de control (ADR-01). No se contrata Kafka administrado (MSK), porque RabbitMQ en cada sitio y SQS FIFO en la nube resuelven el orden y la durabilidad con menos operación (ADR-05). No se contratan servicios de trazas y métricas separados de CloudWatch, porque las Bases piden una sola plataforma de observabilidad para nube y on-premise (ADR-14, RT-03.16). Y no se autoaloja un gestor de secretos, porque Secrets Manager rota las credenciales sin el desellado manual que exigiría uno propio (ADR-15).

4.2.2.4 Modelo de contratación

Los servicios se contratan por uso, con la capacidad base comprometida mediante Savings Plans y el peak de septiembre cubierto con capacidad efímera que se libera al terminar (ADR-12). Los ambientes de Desarrollo, Calidad y Pre-Producción se reducen o apagan fuera del horario de uso. La reversibilidad está asegurada por la elección de servicios: Aurora es compatible con PostgreSQL, los datos analíticos se guardan en formato Parquet, y Keycloak, Django y RabbitMQ son de código abierto, de modo que la solución puede trasladarse a otra plataforma sin reescribir la aplicación. Los montos de estos servicios se declaran en la Oferta Económica y no en este documento (Art. 50.2).

4.2.3 Arquitectura de despliegue

La arquitectura física describe qué componentes existen, dónde viven y cómo se conectan. Esta sección describe cómo esa solución se pone en marcha y se mantiene en operación durante los 56 meses del contrato: por qué ambientes pasa un cambio antes de llegar a las bodegas y a la calle, sobre qué red se despliega, cómo sigue operando cuando algo falla y cómo se recupera cuando se pierde un sitio completo o se daña un dato. Los puntos de falla de cada conexión y de cada equipo, con su resolución inmediata, ya están declarados en la sección de conexiones y contingencia (Tablas 12 y 13); aquí se describen los mecanismos que sostienen esa continuidad y cómo se verifican.

Esos mecanismos son tres y no se sustituyen entre sí. La alta disponibilidad responde a la falla de un componente sin que la operación lo note. La recuperación ante desastres responde a la pérdida de un sitio o de una región completa. El respaldo responde al daño

del dato, sea un borrado accidental, una corrupción o un cifrado malicioso, frente a los cuales las réplicas no protegen, porque replican el daño con la misma fidelidad que una escritura legítima.

4.2.3.1 Ambientes y ciclo de entrega

Un cambio de código recorre cuatro ambientes antes de llegar a la operación. Se construye y se prueba de forma unitaria en Desarrollo, se valida funcionalmente en Calidad y se ensaya en Pre-Producción, donde además ocurren la marcha blanca y las pruebas de aceptación y de carga. Solo entonces se promueve a Producción, sin recompilar, de modo que el artefacto que llega a producción es el mismo que se probó. Un quinto ambiente, en la región us-east-1, sostiene la recuperación ante desastres (RT-04.01). La Tabla 4 muestra cada ambiente con su bloque de direccionamiento, su región y su función.

Ambiente	VPC	Región	Función
Desarrollo	10.104.0.0/16	sa-east-1	Construcción y pruebas unitarias
Calidad	10.103.0.0/16	sa-east-1	Pruebas funcionales, DAST y SAST
Pre-Producción	10.102.0.0/16	sa-east-1	Marcha blanca, aceptación y carga
Producción	10.101.0.0/16	sa-east-1	Operación, en varias zonas
Recuperación ante desastres	10.201.0.0/16	us-east-1	Réplica en caliente

Tabla 4 Ambientes de despliegue

Fuente: elaboración propia sobre RT-04.01 y el numeral 4.1 de las Bases Técnicas Transversales.

Cada ambiente reside en una cuenta AWS propia, bajo una organización de AWS Control Tower cuyas políticas de control de servicio impiden que un error o un acceso indebido en un ambiente alcance a otro; la organización incorpora además sus cuentas de gestión, de archivo de registros y de auditoría. Los bloques de direccionamiento no se solapan entre sí ni con los de los sitios on-premise, y solo el ambiente de recuperación reside fuera de la región primaria. Los cinco ambientes están habilitados como condición del

hito H3.

Las bodegas no tienen ambientes propios de prueba, y no los necesitan. El on-premise es producción: la imagen `wms_only` que corre en los centros de distribución es la misma que recorrió Desarrollo, Calidad y Pre-Producción en la nube, y la infraestructura de cada sitio se declara como código versionado. Lo que se ensayó en la nube es, por lo tanto, lo que se instala en Talca y en Concepción, dentro de la ventana de 24 horas del cutover.

Pre-Producción es equivalente a Producción en topología, versiones, configuración y dimensionamiento (RT-04.02), con dos diferencias: se reduce o apaga fuera del horario de uso, con el ahorro reflejado en la estructura de costos, y trabaja con datos sintéticos generados desde la volumetría del caso, cuya anonimización se verifica con Amazon Macie. Durante las pruebas de carga y estrés de la Tabla 27 opera con el dimensionamiento completo de Producción.

El paso de un ambiente a otro lo controla el pipeline de integración continua. Cada cambio se compila y pasa por pruebas unitarias, análisis estático, análisis de composición, escaneo de secretos y de imágenes de contenedor y medición de cobertura, y el pipeline bloquea el despliegue ante un hallazgo crítico o alto o ante una cobertura de la lógica de negocio inferior al 70 % (RT-04.05, RT-04.11). La configuración se externaliza por ambiente y los secretos se gestionan en AWS Secrets Manager con rotación automática (ADR-15). Las migraciones de base de datos siguen la estrategia de expandir y contraer: cada versión solo agrega estructuras, de modo que la versión anterior y la nueva de la aplicación funcionan sobre el mismo esquema durante el despliegue, y las estructuras obsoletas se eliminan en una versión posterior (RT-04.10). El gobierno del repositorio, con ramas protegidas y revisión obligatoria por pares, y la trazabilidad desde el requerimiento hasta el despliegue se desarrollan en el plan de calidad (Subdocumento 9). A Producción no se llega de otra forma: el acceso administrativo excepcional es temporal, mediante AWS Systems Manager Session Manager, con MFA, aprobación previa y sesión grabada.

Los portales de clientes, transportistas y proveedores siguen el mismo ciclo: su aplicación web se publica por ambiente en S3 y CloudFront, con la imagen de aplicación del mismo ambiente como backend, y entra a producción con el hito de enero de 2029.

4.2.3.1.1 Liberación y reversión

Cada versión se libera con estrategia azul-verde: la versión nueva se despliega junto a la vigente y recibe tráfico de forma gradual, en etapas de canario, después de haberse demostrado el mismo procedimiento en Pre-Producción (RT-04.07). La puesta en pro-

ducción avanza por proceso, por sitio o por zona comercial, nunca como un evento único que afecte a la vez a la bodega, la preventa, el reparto y la facturación (Caso, Cap. 13.3).

Mientras dura el canario, la versión anterior permanece desplegada, por lo que revertir es devolverle el tráfico, sin recompilar ni volver a desplegar. La reversión es automática y se dispara cuando el percentil 95 de una transacción supera su umbral comprometido (Tabla 26) o cuando la versión nueva registra más errores que la estable en la misma ventana de observación. No se pierde ninguna transacción confirmada: las operaciones en curso quedan en los buffers locales, 24 horas por sitio en el broker y la caché de turno en los dispositivos, y se reprocesan de forma idempotente contra la versión restituida. El esquema tampoco se revierte, porque la migración de la versión solo agregó estructuras. Lo que se pierde es la versión, no la operación. El tiempo efectivo de reversión se mide en cada ensayo en Pre-Producción, con un máximo contractual de 4 horas (Art. 78.3).

Si la falla de un despliegue se manifestara durante la ventana de despacho, la bodega y el reparto continuarían con su operación local (Tabla 2) mientras se revierte, sin detener la salida de los camiones (Caso, Cap. 17.6).

4.2.3.1.2 Calendario y cadencia

El calendario de Puelche limita cuándo se puede intervenir la plataforma. El caso prohíbe intervenir los sistemas en septiembre y en diciembre y durante el cierre contable de cada mes, y exige indisponibilidad cero en la ventana de despacho (Caso, Cap. 10, restricción 8). La Tabla 5 cruza cada período con lo que admite.

Período	Despliegue	Indisponibilidad programada
1 al 25 de septiembre	No	No
Todo diciembre	No	No
Tres primeros días hábiles del mes	No	No
05:30–07:00, lunes a sábado	No	No
22:00–06:00, preparación de pedidos	Sí, sin interrupción	No
08:00–18:00, recepción de proveedores	Sí, sin interrupción	No

Tabla 5 — continuación

Período	Despliegue	Indisponibilidad programada
Resto del calendario	Sí, sin interrupción	Excepcional, con aviso de 10 días hábiles

Tabla 5 Ventanas de despliegue

Fuente: Caso, Cap. 10 (restricción 8), Cap. 13.3 y Cap. 15 (valor de RT-10.05); RT-10.06.

El despliegue sin interrupción es, por lo tanto, la regla y no una capacidad opcional: solo fuera de las ventanas protegidas se admite una indisponibilidad programada, y únicamente por excepción. En la ventana nocturna, además, toda intervención en bodega considera el turno de preparación. Descontados los congelamientos, quedan unos diez meses desplegables al año, de los que se excluyen los tres primeros días hábiles de cada mes. Sobre ese margen se fija una cadencia quincenal de despliegue y un tiempo de hasta cinco días hábiles desde que se confirma un cambio de código hasta que llega a producción, compatible con el plazo de siete días para remediar una vulnerabilidad crítica que declara la arquitectura de seguridad. La tasa de cambios fallidos no supera el 5 % de los despliegues del mes y el tiempo de restauración no supera 4 horas, conforme al Artículo 78.3 (RT-04.12). Las correcciones de incidentes críticos usan el mismo pipeline, con prioridad y fuera de la cadencia quincenal, dentro del plazo de resolución de 4 horas.

4.2.3.2 Red de despliegue

La sección de conexiones describe los caminos entre los sitios, el terreno y la nube, y su conmutación (Figura 2 y Tabla 11). El despliegue agrega tres definiciones sobre esa red: dónde llegan los túneles, cómo se reparte el direccionamiento y cómo se dirige el tráfico entre regiones.

Los túneles VPN de Talca y de Concepción terminan en el VPN Gateway adjunto a la VPC de Producción. Es la única VPC con enlace hacia los sitios, coherente con que el on-premise es producción: Desarrollo, Calidad y Pre-Producción no tienen conectividad con las bodegas, de modo que un error en un ambiente de prueba no puede alcanzarlas. El direccionamiento se asigna sin solapamiento, según la Tabla 6.

Dominio	Bloque	Segmentación
Talca	10.1.0.0/16	VLAN de gestión, servidores, operación, estaciones e IoT
Concepción	10.2.0.0/16	Mismas VLAN que Talca
Cross-docking	10.3.0.0/16 a 10.5.0.0/16	Red plana con salida a SSM e IoT
Sitio adicional previsto	10.6.0.0/16	Reservado
VPC Producción, zona pública	10.101.1.0/24 y 10.101.2.0/24	Balanceador, origen de CloudFront, NAT y portales
VPC Producción, zona privada	Resto de 10.101.0.0/16	Aplicación, datos y VPN Gateway

Tabla 6 Direccionamiento y segmentación

Fuente: elaboración propia; RT-02.12 y RT-03.04.

Cada sitio con cómputo dispone de un bloque propio, y el centro de distribución que Puelche evalúa abrir hacia 2030 ya tiene el suyo reservado, de modo que su incorporación es una parametrización de la infraestructura como código y no un rediseño (RT-02.12). En la nube, solo la zona pública expone servicios: la aplicación y los datos residen en subredes privadas y consumen los servicios de AWS por VPC Endpoints, sin tráfico por Internet, por lo que ningún componente de datos es alcanzable desde fuera (RT-03.04).

El tráfico de los usuarios externos entra por CloudFront y por la capa de protección descrita en la arquitectura de seguridad. Entre regiones, Route 53 opera con enrutamiento de conmutación por falla y verificaciones de salud activas: sa-east-1 recibe todo el tráfico en operación normal y la conmutación hacia us-east-1 es automática ante falla, coherente con la modalidad activo-pasiva del ADR-09.

La red también debe devolver a la normalidad a un sitio que operó desconectado. El compromiso es resincronizar la flota en hasta 10 minutos y un centro de distribución en hasta 2 horas después de un corte de 24 horas (Tabla 2). Tomando como cota el volumen transaccional anual de toda la solución, unos 375 GB (Tabla 20), atribuido a un solo centro de distribución y duplicado por el peak de septiembre, un corte de 24 horas acumula unos 2,1 GB. La evidencia de entrega no se suma, porque el terreno la envía por la red celular sin pasar por el centro de distribución. Con los anchos de banda de la

Tabla 19, ese volumen se drena en unos 14 minutos por la fibra de Talca y en 27 por la de Concepción; aun por los enlaces LTE de respaldo tarda 55 minutos en Talca y 1 hora y 31 minutos en Concepción, dentro del compromiso de 2 horas en todos los casos. Al reconectar, la calidad de servicio prioriza el broker y el registro de escritura anticipada sobre la telemetría.

4.2.3.3 Alta disponibilidad

No todos los servicios necesitan el mismo nivel de continuidad. El Artículo 78 fija cuatro niveles de servicio, y la solución asigna cada servicio a uno según el efecto de su indisponibilidad sobre la operación (RT-10.02), como muestra la Tabla 7.

Nivel	Disponibilidad	Resolución	Servicios
Crítico	99,9 %	4 h	Preparación y despacho, entrega, toma de pedido, consulta de stock y crédito, bloqueo por excursión térmica e identidad
Alto	99,5 %	8 h	Planificación de rutas, cobranza y rendición, integración con el ERP, documentos tributarios, registro de temperatura y evidencia de entrega
Medio	99,0 %	24 h	Portales, notificaciones, canal moderno, consultas de geolocalización y registros de auditoría y seguridad
Bajo	98,0 %	48 h	Analítica, tableros y reportería

Tabla 7 Clasificación de servicios por nivel de servicio

Fuente: Art. 78.1 y 78.2 de las Bases Administrativas; transacciones críticas según el Caso, Cap. 15 (RT-09.01).

Son críticos los servicios cuya falla detiene un proceso de negocio sin alternativa: la preparación, la entrega, la toma de pedido y la consulta de stock y crédito son las transacciones operacionales críticas que fija el caso, la ventana de despacho no admite ejecución manual, el bloqueo por excursión térmica responde a una exigencia sanitaria y sin identidad no opera ningún otro servicio. Los servicios altos tienen una alternativa costosa, como planificar la ruta a mano en 3,5 horas o retener en cola hasta 24 horas las transacciones hacia el ERP; los medios tienen una alternativa disponible, y los bajos

no impiden operar. La consecuencia para la arquitectura es directa: el compromiso penalizable del 99,9 % recae sobre seis servicios, y todos se ejecutan en el on-premise o tienen un camino local en el dispositivo.

Esa es la razón por la que el 99,9 % de extremo a extremo no depende de multiplicar las disponibilidades de la infraestructura. El numeral 7.2 de las Transversales fija un mínimo de 99,95 % mensual para la energía, la climatización, la red, el cómputo, la base de datos y los portales, pero esos valores son pisos por subsistema y su producto en serie quedaría por debajo del 99,9 %. El compromiso se sostiene en la redundancia interna de cada subsistema y en la ruta que sigue cada transacción. La confirmación de preparación, la más estricta, se ejecuta contra la base local del centro de distribución y no atraviesa la WAN ni la nube; descansa sobre energía y climatización en N+1, un par de firewall en alta disponibilidad, dos switches en stack, un clúster de tres nodos N+1 y almacenamiento Ceph sobre RAID 10, con un solo elemento en serie, la instancia de escritura VM-02, que se reinicia en otro nodo del clúster (Tabla 12). Las transacciones de terreno, por su parte, tienen dos caminos en paralelo: la nube y la caché de turno del dispositivo.

En la nube, todos los servicios con requisito de alta disponibilidad operan en al menos dos zonas (RT-03.02). Aurora mantiene su escritor en sa-east-1a y dos lectores en sa-east-1b y sa-east-1c, y conmuta en menos de 30 segundos; ElastiCache mantiene primario y réplica en dos zonas y conmuta en menos de 60 segundos; las tareas de ECS Fargate se distribuyen en dos zonas y se reprograman solas ante la pérdida de una; y DynamoDB, el balanceador y los NAT Gateway son multizona por diseño. Ninguna conmutación supera un minuto. Ante el peak de septiembre, el escalamiento automático y la degradación controlada del apartado de dimensionamiento sostienen los umbrales de desempeño sin intervención.

4.2.3.4 Recuperación ante desastres

La recuperación ante desastres es activo-pasiva en caliente (ADR-09): la región us-east-1 mantiene una réplica reducida pero funcional de la plataforma, escalable a carga completa en menos de 30 minutos, que se promueve solo cuando se pierde la región primaria. Los objetivos son un RTO de hasta 4 horas y un RPO de hasta 15 minutos para los servicios críticos (RT-07.04). Cada dominio de datos alcanza ese RPO con su propio mecanismo de replicación, como muestra la Tabla 8.

Dominio	Mecanismo	RPO
Transaccional en nube	Aurora Global Database hacia us-east-1	< 1 s
Telemetría	DynamoDB Global Tables	Continuo
Evidencia, documentos y respaldos	Replicación de S3 entre regiones con control de tiempo	< 15 min
WMS on-premise	AWS DMS sobre el registro de escritura anticipada, por la VPN	≤ 15 min con enlace
Mensajes críticos	Patrón outbox en base y cola	≤ 15 min
Mensajes no críticos	Cola con reposición diferida	≤ 24 h

Tabla 8 Replicación y RPO por dominio de datos

Fuente: elaboración propia a partir del ADR-09.

Todos los dominios críticos se replican de forma continua. El único cuyo RPO depende de una condición externa es el WMS on-premise, porque su réplica viaja por la WAN: si un sitio pierde sus dos caminos, AWS DMS encola los cambios en origen y los entrega sin pérdida al reconectar, pero mientras dure el corte la réplica en nube queda desactualizada, hasta un máximo de 24 horas. Por eso el retraso de replicación se mide de forma continua y genera alarma a los 5 y a los 15 minutos (RT-07.03).

4.2.3.4.1 Conmutación y retorno

La conmutación de región separa lo reversible de lo irreversible. El enrutamiento se conmuta de forma automática, porque si la región primaria se recupera el tráfico vuelve solo. La promoción de la base de datos, en cambio, rompe la replicación y obliga a reconciliar al volver, por lo que exige la autorización del CLIENTE. La Tabla 9 muestra la secuencia completa.

Paso	Acción	Ejecución	Tiempo
1	Detección por verificación de salud de la región primaria	Route 53	< 5 min

Tabla 9 — continuación

Paso	Acción	Ejecución	Tiempo
2	Conmutación del enrutamiento hacia us-east-1	Automática	—
3	Confirmación y autorización de la promoción	CLIENTE, con aviso por SNS	—
4	Promoción de Aurora en us-east-1	Systems Manager Automation	15–20 min
5	Escalado de ECS a carga completa	Systems Manager Automation	< 30 min
6	Actualización de DNS	Systems Manager Automation	45–60 min
7	Reconexión del broker y sincronización del borde	Systems Manager Automation	—
8	Validación funcional de extremo a extremo	Operación	—

Tabla 9 Secuencia de conmutación de región

Fuente: elaboración propia a partir del ADR-09.

Los pasos con tiempo declarado suman, en el peor caso y ejecutados en serie, cerca de 2 horas más el tiempo de la decisión, dentro del RTO de 4 horas. Solo el tercer paso requiere intervención humana, y es ahí donde reside la protección contra una conmutación innecesaria. Como los pasos cuarto a séptimo están automatizados, el equipo de tecnologías de información de Puelche, de cuatro personas, puede ejecutar el procedimiento tras la transferencia de conocimiento (RT-07.05), con el acompañamiento del servicio de operación del adjudicatario.

El retorno a la región primaria sigue seis pasos: resincronización con verificación de alcance, reconciliación de las transacciones de la contingencia contra la bitácora, transferencia de los eventos pendientes, conmutación coordinada del DNS, validación funcional e informe con el tiempo real empleado (RT-07.06).

4.2.3.4.2 Sitios secundarios y amenazas comunes

La solución tiene dos sitios secundarios, uno por dominio: el CD Concepción para el on-premise y la región us-east-1 para la nube. Talca y Concepción, separados por unos 250 a 400 km según el análisis de emplazamiento, comparten dos amenazas: un terremoto o maremoto de zona costera y un corte de la malla eléctrica nacional. La distancia disponible dentro del área de operación de Puelche, que abarca 340 km entre sus extremos (RT-21.16), no neutraliza esa exposición. La mitiga, primero, la independencia operacional de ambos sitios, que operan 24 horas sin depender el uno del otro, Talca con generación propia y Concepción con alimentación protegida en su gabinete de borde; y, segundo, la nube, que está a unos 2.300 km de Talca y no comparte esas amenazas. Ante un evento que afecte a los dos centros, el dato transaccional permanece en la región primaria con su RPO de 15 minutos: la bodega se detiene por la indisponibilidad física de los recintos, no por pérdida de información. La región de recuperación, a unos 7.700 km de la primaria, completa la independencia del dominio en nube (RT-07.02).

Cuando la contingencia afecta solo a la bodega de Talca, el DRP local promueve el WMS de Concepción (VM-C01) en cinco pasos, con un RTO adicional de 1 a 2 horas. La identidad no necesita conmutación en ningún escenario: su autoridad reside en la nube y las cachés locales son de solo lectura, de modo que no existe un maestro local que promover (ADR-06).

4.2.3.4.3 Operación durante una contingencia regional

Mientras la región primaria no está disponible, la bodega y el terreno siguen operando contra sus bases locales y sus dispositivos, y los servicios en nube vuelven con la promoción de la réplica. Dos capacidades quedan fuera hasta el retorno, por diseño: la analítica, porque la región secundaria no se explota analíticamente, y las consultas sobre datos de geolocalización de personas, que no se replican fuera de sa-east-1 conforme a los resguardos de residencia y transferencia internacional declarados en la arquitectura de seguridad. Ninguna de las dos es un servicio crítico, y ambas se restituyen al volver a la región primaria.

La réplica que sostiene todo lo anterior se compone de la base Aurora promovible en us-east-1, alimentada por AWS DMS; de las copias inmutables en ambas regiones; de la bóveda física externa; de la copia local D-05 en Talca; y del procedimiento de conmutación y retorno. Se reparte en dos dominios y cuatro ubicaciones, de modo que la pérdida de una sola no deja al dato sin copia.

4.2.3.5 Respaldos

El respaldo protege contra lo que las réplicas replican: un dato borrado por error, corrompido o cifrado de forma maliciosa. La solución aplica un esquema 3-2-1-1-0 único para la nube y el on-premise. Mantiene tres copias —los datos activos, las instantáneas de Aurora junto con la copia local D-05, y el respaldo exportado a S3— en dos medios, base de datos y almacenamiento de objetos. Una copia está fuera del sitio, replicada a us-east-1, y otra es inmutable, en S3 Object Lock en modo Compliance con AWS Backup Vault Lock. El cero corresponde a los errores de restauración, que se verifican cada mes.

La copia inmutable es el control frente a un ataque con credenciales administrativas comprometidas: en modo Compliance, ni un administrador ni la cuenta raíz pueden borrarla ni modificarla durante su retención, y el bloqueo de la bóveda, con 3 días de enfriamiento y un año de retención mínima, impide eliminar los respaldos una vez activado (RT-07.11). La copia local D-05 cumple otra función: es la copia de recuperación rápida, cifrada con una clave independiente de la de producción, que permite restaurar el WMS en hasta 4 horas sin depender del enlace (RT-07.10), y por eso no se cuenta como la copia inmutable. Un medio físico cifrado se rota además cada semana a una bóveda externa, conforme a la custodia de medios del sitio principal.

La Tabla 10 muestra, para cada dominio de datos, con qué frecuencia se respalda, cuánto tiempo se retiene y en cuánto tiempo se restaura por completo.

Dominio	Frecuencia	Retención	Restauración
Transaccional de bodega	Continua y copia local D-05	35 días	≤ 4 h
Transaccional en nube	Diaria y recuperación continua	35 días	≤ 4 h
Identidad	Diaria y recuperación continua	35 días	≤ 4 h
Trazabilidad sanitaria	Continua	Vida útil + 5 años	< 2 h
Registros de temperatura	Diaria y continua	5 años	≤ 8 h
Evidencia de entrega	Continua con versionado	6 años	≤ 8 h

Tabla 10 — continuación

Dominio	Frecuencia	Retención	Restauración
Respaldo de documentos tributarios	Continua con versionado	6 años	≤ 8 h
Geolocalización de personas	Continua	12 meses	≤ 24 h
Registros de seguridad y auditoría	Continua	7 años	≤ 24 h

Tabla 10 Respaldo y restauración por dominio de datos

Fuente: RT-07.13; Art. 78.2 de las Bases Administrativas; retenciones del Caso, Cap. 15, y retiro sanitario del Caso, Cap. 18.

Cada tiempo de restauración corresponde al plazo de resolución que el Artículo 78.2 asigna a la criticidad del servicio que usa el dato, con una excepción más exigente: la trazabilidad sanitaria se restaura en menos de 2 horas, porque ese es el plazo en que Puelche debe responder un retiro sanitario (Caso, Cap. 18). Las retenciones cumplen o superan las del caso. La restauración, además, puede ser parcial: la recuperación de Aurora a un instante específico, sobre una instancia temporal, permite restituir un registro, una tabla, un módulo o el sistema completo sin intervenir el ambiente productivo (RT-07.14).

AWS Backup materializa esas frecuencias sobre los recursos de la plataforma: respalda Aurora a diario con recuperación continua a un instante específico y DynamoDB a diario, ambos con 35 días de retención; EFS con 30 días y EBS con 14; los documentos legales en S3 de forma continua, con versionado y Object Lock durante 6 años y réplica entre regiones; y los registros de seguridad y auditoría durante 7 años bajo Object Lock.

4.2.3.6 Verificación de la continuidad

Los mecanismos anteriores se verifican con pruebas periódicas; no se dan por supuestos. Antes de cada paso a producción, y al menos una vez por semestre durante la Operación, se inyectan de forma controlada las fallas que enumera RT-10.07 —caída de una instancia, de una zona o de una dependencia externa, latencia elevada y saturación de disco— y se comprueba que cada una produzca la resolución declarada en las Tablas 12 y 13. La recuperación ante desastres se ensaya dos veces al año con conmutación real,

y el RTO y el RPO efectivamente alcanzados deben cumplir el compromiso en el 100 % de los ensayos (RT-07.07, Art. 78.3). Los respaldos se restauran cada mes sobre una muestra representativa, con medición del tiempo real de restauración (RT-07.12). Todas estas pruebas se programan fuera de la ventana de despacho y de los períodos de congelamiento, y cada una produce un informe con las desviaciones encontradas y su plan de corrección.

La disponibilidad efectiva de cada servicio, las métricas del proceso de despliegue y el resultado de estas pruebas se miden sobre la plataforma de observabilidad y se entregan en el informe mensual de nivel de servicio (Art. 79). Es ahí donde el CLIENTE puede comprobar que lo que declara esta sección se cumple.

4.2.4 Conexiones, puntos de falla y contingencia

Esta sección describe cómo se conectan los sitios, el terreno y la nube, identifica cada punto donde esa conexión o su infraestructura puede fallar, y declara cómo se resuelve cada falla o, cuando no se resuelve de forma automática, cuál es la contingencia. Su punto de partida es el caso: la conectividad actual de Puelche se corta con frecuencia y en algunos lugares no existe (Caso, Cap. 6), por lo que la solución no puede suponer un enlace disponible y debe decir, para cada conexión, qué pasa cuando no lo está.

4.2.4.1 Conexiones entre sitios, terreno y nube

Los dos dominios fijos, la nube y el on-premise, se conectan por túneles VPN IPsec que terminan en el firewall de cada centro de distribución (D-01) y en el VPN Gateway de AWS, con enrutamiento dinámico BGP. Cada sitio tiene dos caminos físicamente independientes: fibra y LTE en los centros de distribución, y Starlink y LTE de dos proveedores en los cross-docking, que no tienen fibra (ADR-02). El terreno no pasa por los sitios: los terminales de preventa y de reparto hablan directamente con API Gateway por la red celular del operador. La Figura 2 muestra esas conexiones.

La figura distingue dos tipos de conexión. Las líneas continuas son conexiones hacia la nube, y todas se inician desde el sitio o desde el dispositivo, sin puertos abiertos hacia el on-premise. Las únicas excepciones son la réplica de AWS DMS, que lee el registro de escritura de PostgreSQL en VM-02, y el worker celery-erp-sync, que consulta la capa anticorrupción en VM-04; ambas entran por el túnel IPsec autenticado y quedan auditadas. Las líneas discontinuas son sincronizaciones entre sitios o descargas locales, que no dependen de la nube: Concepción sincroniza con Talca por la VPN, los cross-




Figura 2 Conexiones entre los sitios, el terreno y la nube

Fuente: elaboración propia.

docking envían a Talca el detalle de su WMS entre brokers, y los termógrafos sincronizan por Bluetooth con el terminal del conductor durante la ruta —que alerta la excursión térmica en el momento y la reenvía a la nube cuando recupera cobertura— y descargan el registro completo al gateway del centro de distribución cuando el camión vuelve. Los eventos críticos de los cross-docking van directo a SQS FIFO, de modo que la operación de esas plataformas no depende de Talca.

La Tabla 11 resume cada conexión con su medio, su camino alternativo y el tiempo de conmutación entre ambos.

Conexión	Medio y protocolo	Camino alternativo	Conmutación
CD Talca con la nube	Fibra D-03, túneles IPsec con BGP	LTE D-04	Menos de 30 s
CD Concepción con la nube	Fibra D-03, túneles IPsec con BGP	LTE D-04	Menos de 30 s

Tabla 11 — continuación

Conexión	Medio y protocolo	Camino alternativo	Conmutación
Cross-docking con la nube	Starlink D-06, HTTPS y MQTTS salientes	LTE D-04 de dos proveedores	Menos de 30 s
Concepción con Talca	TCP 8080 y 5432 con TLS sobre la VPN	Operación autónoma	No aplica
Cross-docking con Talca	AMQPS 5671 entre brokers	Envío diferido	No aplica
Terreno con la nube	Red celular del operador, HTTPS	Almacén local del dispositivo	No aplica
Termógrafos con el terminal y con el sitio	BLE con el terminal del conductor en ruta; Bluetooth al regresar al centro de distribución	Registro interno del termógrafo	No aplica
Usuarios externos con los portales	Internet, HTTPS por CloudFront	Ninguno: el autoservicio requiere conexión	No aplica
Región primaria con la secundaria	Replicación nativa de Aurora, DynamoDB y S3	Respaldo inmutable	Promoción autorizada

Tabla 11 Conexiones de la solución y su camino alternativo

Fuente: elaboración propia; conectividad actual según el caso (Caso, Cap. 6) y decisión ADR-02.

Solo tres conexiones tienen un segundo camino de red, y son las que unen un sitio con la nube. Las demás no lo necesitan porque su alternativa no es otro enlace sino la operación sin conexión: Concepción opera sin Talca, el terreno opera sin señal y el termógrafo guarda su propio registro. Por eso la redundancia de enlaces reduce la frecuencia de las desconexiones, pero no es condición para operar. El portal de clientes es la única conexión sin alternativa, y eso es deliberado: el autoservicio no se ofrece sin conexión (RT-03.13).

4.2.4.2 Puntos de falla en los sitios y en los enlaces

Cada conexión se apoya en equipos del sitio que también pueden fallar. La Tabla 12 recorre esos puntos de falla, desde el enlace hasta la energía del recinto, e indica para cada uno el mecanismo que la resuelve y la contingencia si ese mecanismo no basta.

Punto de falla	Resolución	Contingencia
Fibra de un centro de distribución	BGP conmuta los túneles al LTE en menos de 30 s.	Si cae también el LTE, operación local 24 h.
Starlink de un cross-docking	El LTE de dos proveedores toma el tráfico en menos de 30 s.	La ventana de 3 h opera 100 % local y sincroniza al reconectar.
Enlace de Los Ángeles en la madrugada	Starlink queda como camino único, porque la red móvil falla a esa hora.	La ventana de madrugada opera íntegramente local.
Firewall de Talca	La unidad pasiva asume las direcciones y los túneles en menos de 30 s.	Operación local 24 h sin enlace.
Firewall de Concepción	Equipo único; se repone.	Concepción opera 24 h sin enlace mientras se reemplaza.
Nodo del clúster de Talca	Las VM se reinician en los nodos restantes, con sus datos replicados por Ceph.	Ante un segundo nodo, el DRP local promueve el WMS de Concepción en 1 a 2 h.
Instancia de escritura VM-02	Se reinicia en otro nodo del clúster.	D-05 restaura la base en hasta 4 h sin enlace.
Disco de un servidor	El RAID 10 reconstruye sobre el repuesto en caliente.	Ceph conserva una segunda copia en otro nodo.
Miembro del stack de switches de Talca	El otro miembro mantiene el tráfico.	Reposición sin corte.
Servidor de borde de Concepción	RAID 10 y doble fuente cubren las fallas probables.	La pila se restaura desde la réplica en Aurora.
Mini-PC de un cross-docking	Equipo único; se repone.	El nuevo equipo se resincroniza desde Talca y SQS FIFO.
Periféricos de andén	Sin redundancia.	Respaldo manual de la operación del andén.

Tabla 12 — continuación

Punto de falla	Resolución	Contingencia
Energía de la sala de Talca	UPS N+1 de 30 min y generador que toma carga en 8 a 15 s.	Estanque de 24 h y contrato de reabastecimiento.
Climatización de la sala de Talca	Segunda unidad de precisión en N+1.	Alerta del monitoreo de los sensores ambientales.

Tabla 12 Puntos de falla en los sitios y en los enlaces

Fuente: elaboración propia; puntos únicos de falla declarados conforme a RT-02.11.

La tabla muestra que los puntos únicos de falla que quedan están donde la redundancia no compensa su costo: el firewall y el servidor de Concepción, el mini-PC de cada cross-docking y los periféricos de andén. En los tres primeros casos la contingencia es la misma autonomía que ya existe para los cortes de enlace, y ningún punto único de falla está en la ruta de la ventana de despacho de Talca, que tiene redundancia en cada capa. Los mecanismos de alta disponibilidad que sostienen estas resoluciones se desarrollan en la sección de arquitectura de despliegue.

4.2.4.3 Puntos de falla en la nube, el terreno y las integraciones

La Tabla 13 completa el recorrido con los puntos de falla que están fuera de los sitios: la nube, el terreno y los sistemas de terceros.

Punto de falla	Resolución	Contingencia
Zona de disponibilidad de sa-east-1	Aurora conmuta en menos de 30 s, ElastiCache en menos de 60 s y Fargate reprograma las tareas.	La operación continúa en las zonas restantes.
Región sa-east-1 completa	Route 53 redirige el tráfico y, con autorización del CLIENTE, se promueve la réplica en us-east-1.	RTO de 4 h y RPO de 15 min; la bodega y el terreno operan en local.

Tabla 13 — continuación

Punto de falla	Resolución	Contingencia
Túnel VPN durante la replicación	DMS encola los cambios en el origen.	Reanuda sin pérdida al reconectar; la réplica queda desactualizada durante el corte.
IdP maestro o enlace de identidad	Las cachés de solo lectura validan las sesiones localmente.	Token de turno de 8 h en bodega y 14 h en terreno; cuenta de emergencia sellada (ADR-15).
Señal móvil en ruta	La aplicación opera contra el almacén local del dispositivo.	Sincroniza al reconectar dentro de los 10 min de la Tabla 2.
ERP legado	La capa anticorrupción retiene las transacciones en cola hasta 24 h.	El ERP no se modifica; las transacciones se entregan al recuperarse.
Excursión térmica sin enlace	El gateway bloquea el despacho en menos de 5 s en el borde.	Buffer de 14 h y alerta al reconectar.
SII, cadenas o notificaciones	Reintento con espera creciente y cola de mensajes fallidos.	Reproceso desde la cola al recuperarse el tercero.
Carga del peak de septiembre	Escalado automático de Fargate, Celery y Aurora (ADR-12).	Limitación de tasa en API Gateway.

Tabla 13 Puntos de falla en la nube, el terreno y las integraciones

Fuente: elaboración propia a partir de los registros de decisión ADR-02, ADR-06, ADR-09, ADR-12 y ADR-15.

Ninguna de estas fallas detiene la bodega ni el terreno. La peor de ellas, la pérdida de toda la región primaria, deja sin servicio a los portales y a la analítica hasta la promoción de la réplica, pero la preparación, el despacho y la entrega siguen operando contra sus bases locales y sus dispositivos, porque ninguna de esas transacciones depende de la nube para confirmarse.

4.2.5 Dimensionamiento y plan de capacidad

Esta sección deriva la capacidad de la solución desde la volumetría del caso, declara las dieciséis dimensiones que el numeral 14.2 pide estimar, dimensiona el cómputo, el almacenamiento y los enlaces en ambos dominios, y fija el plan para crecer tres veces sin rediseño. El caso advierte que un dimensionamiento basado en el promedio diario estará equivocado, porque la carga no es plana (Caso, Cap. 14.2). Por eso cada valor se calcula sobre la ventana en que ocurre, y cuando se adopta un supuesto se declara junto a su fundamento.

4.2.5.1 Criterios y método

El perfil de un día hábil concentra la carga en cuatro ventanas que no coinciden entre sí (Caso, Cap. B.1):

- **Preparación de pedidos:** de 22:00 a 06:00 en Talca, con 120 terminales de cámara en simultáneo.
- **Despacho:** de 05:30 a 07:00, con la salida de 96 camiones, 42 propios y 54 de transportistas.
- **Preventa:** de 09:00 a 18:00, con 62 preventistas y unas 2.600 visitas diarias.
- **Sincronización de la flota:** de 17:00 a 20:00, al regreso de los dispositivos de terreno.

Sobre ese perfil, el dimensionamiento sigue cinco reglas. La carga de diseño es el peak de septiembre multiplicado por 1,5, es decir $2.600 \times 1,5 = 3.900$ entregas diarias toleradas sin degradación (RNF-19.04). La solución debe soportar tres veces la volumetría inicial sin rediseño (RT-09.03). Toda medición de desempeño se expresa en percentil 95. El cómputo en nube escala de forma automática y se paga por uso (ADR-12), mientras que el on-premise se dimensiona al margen útil, sin sobrecompra. Y los totales de esta sección son los mismos que usan los registros de decisión ADR-01, ADR-04, ADR-10 y ADR-12.

4.2.5.2 Volumetría de referencia

La Tabla 14 reúne los valores que entrega el CLIENTE y que sirven de base a todos los cálculos de esta sección.

Magnitud	Valor base
Clientes activos y puntos de entrega	14.200
Pedidos	31.000 al mes
Líneas de pedido y de preparación	260.000 al mes
Unidades despachadas	2,4 millones al mes
SKU activos	8.400
Posiciones de almacén en Talca	11.400, con 87 % de ocupación
Entregas en día hábil normal	1.400
Entregas en día hábil de peak de septiembre	2.600
Kilómetros recorridos	420.000 al mes
Documentos tributarios	34.000 al mes
Camiones con equipo de frío	28: 18 propios y 10 de transportistas
Puntos de medición de temperatura	28, en 7 módulos de 4 canales
Instalaciones	6, de las cuales 5 alojan cómputo

Tabla 14 Valores base de dimensionamiento

Fuente: Caso, Cap. 2.2, Cap. 2.3 y Tabla 14.1; tipología del cómputo según RT-06.01; los puntos de medición son de elaboración propia.

De estos valores, el que gobierna el dimensionamiento no es el número de clientes sino la relación entre el día normal y el peak: 2.600 entregas frente a 1.400 son 1,86 veces más carga durante las tres primeras semanas de septiembre. El dimensionamiento del on-premise se calcula sobre los cinco recintos que alojan cómputo (RT-06.01): los centros de distribución de Talca y Concepción y las tres plataformas de cross-docking de Curicó, Chillán y Los Ángeles. La sexta instalación que declara la volumetría no se identifica en la operación descrita por el caso; esa divergencia se registra como consulta al mandante (Art. 43.3) y como supuesto, sin alterar los valores de la Tabla 14.

La Tabla 15 muestra la proyección del caso a tres años.

Magnitud	Año 0	Año 3	Variación
Clientes	14.200	15.500	+9 %
Pedidos al mes	31.000	36.000	+16 %
Líneas al mes	260.000	305.000	+17 %
Entregas en día normal	1.400	1.650	+18 %
Entregas en día de peak	2.600	3.100	+19 %
Kilómetros al mes	420.000	480.000	+14 %
Documentos tributarios al mes	34.000	40.000	+18 %
Instalaciones	6	7	+1

Tabla 15 Proyección de la volumetría a tres años

Fuente: Caso, Tabla 14.1.

El crecimiento real que proyecta el caso es de 16 % a 19 % en tres años, muy por debajo del factor 3 que exige RT-09.03. El dimensionamiento que sigue cubre ese factor 3, de modo que la solución tiene margen ante un crecimiento mayor al proyectado.

4.2.5.3 Transacciones por segundo

La preparación nocturna mueve 260.000 líneas al mes; en 25 días hábiles son 10.400 líneas por noche, que en las 8 horas del turno (28.800 s) dan una demanda media de 0,36 líneas por segundo. El diseño no se hace sobre esa media sino sobre la concurrencia máxima: 120 terminales confirmando una línea cada 6 segundos son 20 transacciones por segundo, 55 veces la demanda media, lo que absorbe el inicio del turno, cuando todos los preparadores confirman a la vez, y el conteo cíclico que comparte la ventana. Con el mismo criterio, 62 preventistas registrando una línea cada 8 segundos son 8 transacciones por segundo. La Tabla 16 suma esos flujos.

Flujo	Cálculo	TPS
Confirmación de preparación	120 terminales $\times$ 1 confirmación cada 6 s	20
Registro de preventa	62 preventistas $\times$ 1 línea cada 8 s	8
Movimientos, sincronización y telemetría	Supuesto que cubre el vuelco de los brokers y los 76.600 mensajes diarios de telemetría	7
Régimen normal	20 + 8 + 7	35
Diseño en peak de septiembre	35 $\times$ 3	105

Tabla 16 Transacciones por segundo de diseño

Fuente: elaboración propia a partir del perfil operacional del caso (Caso, Cap. B.1).

El factor 3 del peak no es arbitrario: combina el aumento estacional de 1,86 veces con el margen de 1,5 de la carga de diseño, lo que da 2,8, redondeado a 3. Los 105 transacciones por segundo resultantes son el valor único de diseño de esta sección, el mismo que citan el ADR-01 y el ADR-12, y sostienen el dimensionamiento de la base transaccional y el escalado del cómputo en nube.

La ventana de despacho, en cambio, no es la de mayor carga. En ella ocurren 1.400 confirmaciones de carga, 1.400 timbrados de guía, 96 vinculaciones de conductor con camión y 96 cierres de ruta, en total 2.992 transacciones; aun concentradas en la primera media hora (1.800 s), son 1,7 transacciones por segundo. La ventana es crítica porque no admite indisponibilidad, no por su volumen: el cómputo se dimensiona por la preparación nocturna y el peak de septiembre, y la resiliencia por la ventana de despacho.

4.2.5.4 Usuarios, concurrencia y dispositivos

Las personas usuarias internas son unas 620: 62 preventistas, 42 conductores propios, cerca de 160 conductores de terceros, 310 personas de centro de distribución, unas 40 de administración y gerencia, y 4 de TI. Las externas son unas 14.400 al cierre de la Etapa 2: 14.200 clientes con autoatención, 180 proveedores y 10 empresas transportistas. La Tabla 17 detalla la concurrencia por rol.

Rol	Concurrencia	Dispositivo
Preventistas	62	Zebra EC55, parque de 62 más 20 % de reserva
Conductores	≈ 200	Zebra TC58e, parque único para propios y externos
Preparadores del turno nocturno	120	Zebra MC9400 Cold Storage, 144 en Talca y 30 en Concepción
Personal de centro de distribución	110	Estaciones y terminales fijos
Supervisión y mesa de ayuda	≈ 20	Estaciones de trabajo
Dispositivos de terreno registrados	≈ 270, hasta 300	EC55 y TC58e

Tabla 17 Usuarios y terminales concurrentes

Fuente: elaboración propia a partir del Caso, Cap. 2.4 y Tabla 14.1.

La suma de los perfiles da unas 510 personas concurrentes: $62 + 200 + 120 + 110 + 20$. Es una cota superior, porque la preventa y la preparación nocturna no coinciden en el tiempo. Los dispositivos de terreno en operación simultánea son los 62 de preventa y los cerca de 200 de reparto, unos 270; con la proyección a tres años, 70 preventistas y 230 conductores, llegan a 300.

4.2.5.5 Almacenamiento y datos a migrar

El almacenamiento se calcula por tipo de dato, porque cada uno tiene su propio ritmo y su propia retención.

- **Transaccional:** se estima en 375 GB por año entre el maestro de bodega y el transaccional en nube. A cinco años suma cerca de 1,9 TB, del mismo orden que los 1.890 GB asignados al clúster de Talca.
- **Evidencia de entrega:** 1.400 entregas diarias en 300 días hábiles son 420.000 entregas al año. Con una firma de 30 KB y una o dos fotografías de 200 KB, cada

entrega ocupa unos 230 KB, lo que da $420.000 \times 230 \text{ KB} \approx 97 \text{ GB}$, unos 100 GB al año. Con la retención de 6 años suman unos 600 GB, en almacenamiento por niveles.

- **Series de temperatura y de posicionamiento:** 56 fuentes de temperatura, 28 puntos de cámara y 28 termógrafos, con una muestra cada 5 minutos, generan 5,89 millones de registros al año; 42 camiones con una posición cada 30 segundos durante 12 horas y 300 días generan 18,1 millones. Con unos 145 bytes por registro, los 24 millones suman 3,5 GB en crudo al año, que en formato columnar comprimido quedan en unos 0,9 GB. El crudo vive 30 días; la serie consolidada se conserva 5 años para temperatura y 12 meses para geolocalización de personas.
- **Datos históricos a migrar:** unos 30 GB estructurados. Solo las ventas y pedidos de tres años son 9,4 millones de líneas de 1 KB, 9,4 GB, y los movimientos de inventario de dos años son 3,4 millones de registros de 0,5 KB, 1,7 GB; el resto corresponde a los maestros, a cinco años de trazabilidad sanitaria y a las cuentas por cobrar vivas. El histórico documental permanece en el ERP, que sigue siendo la fuente tributaria.

El dato que más crece no es el transaccional sino la evidencia de entrega, y por eso se guarda en almacenamiento de objetos por niveles y no en la base de datos. Las series de tiempo, que dominan el número de registros, tampoco pasan por la base transaccional: se ingieren en DynamoDB y se consolidan en la capa analítica.

4.2.5.6 Integraciones y volumen de mensajes

La solución tiene 15 integraciones. La Tabla 18 deriva el volumen de las diez que mueven mensajes, sobre 25 días hábiles al mes y con el peak de septiembre al doble.

Integración	Mensajes al día	Peak	Derivación
ERP por la capa anticorrupción	4.700	9.400	1.240 pedidos, 46 recepciones, 1.400 preparaciones, 1.400 entregas y 600 recaudaciones
Documentos tributarios y acuse	2.700	5.400	34.000 documentos al mes y su acuse, en 25 días
Trazabilidad GS1 EPCIS	52.000	104.000	260.000 líneas al mes $\times$ 5 eventos, en 25 días

Tabla 18 — continuación

Integración	Mensajes al día	Peak	Derivación
Telemetría de cadena de frío	16.100	16.100	56 fuentes × 288 muestras diarias
Telemetría de flota	60.500	72.000	42 camiones × 120 posiciones por hora × 12 h
Sincronización de terreno	13.000	26.000	1.240 pedidos, 1.400 entregas y 10.400 confirmaciones
Intercambio con el canal moderno	550	1.100	136 pedidos diarios × 4 mensajes
Notificaciones	2.800	5.600	Hora estimada de llegada y acuse por entrega
Autorización de pago	500	1.000	Fracción del canal tradicional que migra a pago electrónico
Mapas y geocodificación	200	400	Una corrida de ruteo por zona y recálculos por incidencia

Tabla 18 Volumen de mensajes por integración

Fuente: elaboración propia a partir de la Tabla 14.1 del caso.

El total en régimen es de unos 153.000 mensajes al día. Dos series de tiempo, la trazabilidad y la telemetría, aportan unos 129.000 de ellos, y ninguna atraviesa la base transaccional. Las cinco integraciones restantes del catálogo son de configuración y administración, con volumen despreciable frente a estas cifras.

4.2.5.7 Ancho de banda, dispositivos de reparto y sincronización

El enlace de cada centro de distribución transporta la replicación de la base, el vuelco de los brokers, la telemetría y el respaldo hacia la nube. No transporta la sincronización del terreno, que viaja por la red celular directo a la nube. La Tabla 19 declara el ancho de banda por sitio.

Sitio	Régimen	Peak	Respaldo
CD Talca	20 Mbps por fibra	50 Mbps	LTE de 5 a 10 Mbps
CD Concepción	10 Mbps por fibra	20 Mbps	LTE de 3 a 5 Mbps
Cross-docking, cada uno	Starlink, plan de 500 GB	Igual al régimen	LTE de 2 a 5 Mbps, dos proveedores

Tabla 19 Ancho de banda por sitio

Fuente: elaboración propia.

El peak lo fija el respaldo. El respaldo semanal a la nube pesa hoy unos 40 GB y llega a 120 GB con el crecimiento de 3 veces; transmitido en la ventana nocturna de 8 horas exige $120 \text{ GB} \times 8 / 28.800 \text{ s} \approx 33 \text{ Mbps}$, que caben en los 50 Mbps de Talca junto con el tráfico de régimen. La replicación y los brokers, en cambio, son pequeños: aun atribuyendo a un solo sitio el volumen transaccional anual completo, duplicado por el peak, suman unos 2,1 GB al día, 0,2 Mbps en promedio. Por eso el régimen de 20 Mbps deja holgura para las consolas web del personal del sitio, y el LTE de respaldo alcanza para la replicación y los brokers, aunque no para el respaldo semanal, que se difiere hasta que vuelve la fibra.

Un dispositivo de reparto genera entre 8 y 12 MB en un turno sin señal. En el peak, 2.600 entregas repartidas en 96 camiones son unas 27 por ruta, que se redondean a 30; con 230 KB de evidencia cada una suman 6,9 MB, a los que se agregan la ruta del día, el maestro acotado de productos y precios y la cola de escrituras pendientes. Al recuperar cobertura, 10 MB se sincronizan en $10 \times 8 / 0,2 = 400 \text{ s}$, menos de 7 minutos, aun con apenas 0,2 Mbps efectivos de red celular, lo que sostiene el objetivo de 10 minutos por dispositivo de la Tabla 2. La flota completa, unos 200 dispositivos de 10 MB, suma 2 GB en la ventana de 17:00 a 20:00, apenas 1,5 Mbps agregados en la entrada de la nube.

4.2.5.8 Mesa de ayuda y equipo de operación

Con 620 personas usuarias internas y un contacto mensual por persona en operación estabilizada, la mesa recibe unos 620 contactos al mes; durante las oleadas de puesta en producción el factor sube a 2,5, unos 1.550 contactos, y en el peak de septiembre aumenta 40 %. Los clientes del canal tradicional no entran por esta mesa: se atienden por autoatención. Los 620 contactos en 25 días hábiles son unos 25 al día; si el 20 %

se concentra en la hora punta, son unos 5 contactos por hora, que con 8 minutos de atención suman $5 \times 8 / 60 = 0,67$ Erlang. Con el modelo Erlang C, dos agentes cumplen el objetivo de atender el 80 % de los contactos en 20 segundos. A esa base se suman la cobertura de la ventana de despacho y del turno nocturno de bodega, el segundo nivel y la supervisión, lo que da una mesa de 7 personas: 3 agentes diurnos, 1 nocturno, 1 supervisor y 2 especialistas de segundo nivel. Los parámetros se recalibran con los datos de la operación real. El centro de operaciones de red y la confiabilidad se prestan como servicio gestionado.

4.2.5.9 Síntesis de las dieciséis dimensiones

La Tabla 20 reúne el valor declarado para cada dimensión del numeral 14.2 del caso, con la subsección donde se deriva.

Dimensión	Valor declarado	Derivación
TPS en régimen normal	35	Transacciones por segundo
TPS en la ventana de despacho	1,7	Transacciones por segundo
TPS en el peak de septiembre	105	Transacciones por segundo
Personas usuarias registradas	620 internas y 14.400 externas	Usuarios y concurrencia
Personas usuarias concurrentes en peak	510 como cota superior	Usuarios y concurrencia
Dispositivos de terreno simultáneos	270, hasta 300	Usuarios y concurrencia
Almacenamiento transaccional anual	375 GB	Almacenamiento
Evidencia de entrega anual	100 GB	Almacenamiento
Series de temperatura y posición anuales	3,5 GB en crudo y 0,9 GB consolidados	Almacenamiento
Datos históricos a migrar	30 GB	Almacenamiento

Tabla 20 — continuación

Dimensión	Valor declarado	Derivación
Integraciones y mensajes	15 integraciones y 150.000 mensajes al día	Integraciones
Ancho de banda por sitio	Talca 20 a 50 Mbps y Concepción 10 a 20 Mbps	Ancho de banda
Datos de un dispositivo de reparto por turno	8 a 12 MB	Ancho de banda
Sincronización de la flota	10 min por dispositivo	Ancho de banda
Contactos mensuales a la mesa	620 en régimen y 1.550 en marcha blanca	Mesa de ayuda
Dotación de la mesa	7 personas	Mesa de ayuda

Tabla 20 Las dieciséis dimensiones del numeral 14.2 del caso

Fuente: elaboración propia; dimensiones según el Caso, Cap. 14.2.

Ninguna dimensión queda sin valor ni sin derivación. Las que exigieron un supuesto propio, como el ritmo máximo de confirmación, el tamaño de la evidencia o el volumen transaccional anual, lo declaran en su subsección, de modo que el CLIENTE puede recalcular el resultado si el supuesto cambia.

4.2.5.10 Dimensionamiento on-premise

El clúster de Talca tiene tres nodos iguales, de modo que la pérdida de cualquiera deja dos supervivientes capaces de sostener todas las máquinas virtuales (N+1). La Tabla 21 compara lo asignado con lo que queda disponible tras perder un nodo.

Recurso	Asignado	Físico en el clúster	Utilización N+1
vCPU	30	96 hilos, 3 nodos de 32	30 de 64, 47 %
Memoria	68 GB	384 GB, 3 nodos de 128	68 de 256, 27 %
Almacenamiento Ceph	1.890 GB	5,76 TB útiles	33 %

Tabla 21 Utilización del clúster de Talca con un nodo caído

Fuente: elaboración propia.

Con un nodo caído, el clúster todavía usa menos de la mitad de su cómputo y poco más de un cuarto de su memoria. La capacidad de almacenamiento resulta de tres nodos con cuatro discos NVMe de 1,92 TB en RAID 10, 3,84 TB por nodo, y de la réplica 2 de Ceph: $3 \times 3,84 / 2 = 5,76$ TB. La Tabla 22 muestra cómo se reparten los recursos asignados entre las seis máquinas virtuales.

VM	Rol	vCPU	Memoria	Disco
VM-01	Motor WMS	8	16 GB	100 GB
VM-02	Base transaccional del WMS	8	32 GB	1.500 GB
VM-03	Broker de colas	4	8 GB	200 GB
VM-04	Capa anticorrupción del ERP	4	4 GB	20 GB
VM-05	Caché de identidad	4	4 GB	20 GB
VM-06	Colector de observabilidad y agente SSM	2	4 GB	50 GB

Tabla 22 Máquinas virtuales del clúster de Talca

Fuente: elaboración propia.

VM-02 concentra casi la mitad de la memoria y el 80 % del disco, porque es el único punto de escritura del maestro de bodega; es también el primer cuello de botella, como se explica más adelante. El servidor de borde de Concepción ofrece 12 vCPU y 24 GB de memoria sobre discos NVMe en RAID 10 con repuesto en caliente, suficientes

para el WMS de un sitio de la mitad de tamaño que Talca durante 24 horas sin enlace. En cada cross-docking, el mini-PC industrial ejecuta el WMS, su base y su broker en contenedores, y conecta el router de Starlink y el LTE de respaldo.

La Tabla 23 verifica el almacenamiento y el rendimiento de la base transaccional.

Aspecto	Cálculo	Resultado
Ocupación inicial del pool	1.890 GB de 5.760 GB	33 %
Ocupación con crecimiento de 3 veces	$1.890 \text{ GB} \times 3 = 5.670 \text{ GB}$	Requiere el cuarto nodo
Pool con el cuarto nodo	$4 \times 3,84 \text{ TB} / 2 = 7,68 \text{ TB}$	74 %
Respaldo local D-05	NAS en RAID 6 con 4 discos de 4 TB	8 TB útiles
Operaciones de disco de VM-02	$105 \text{ TPS} \times 8 \text{ operaciones por transacción}$	840 IOPS frente a más de 100.000

Tabla 23 Almacenamiento y rendimiento de la base transaccional

Fuente: elaboración propia.

El almacenamiento no es el límite del clúster en régimen, pero sí con el crecimiento de 3 veces: 5.670 GB llenarían el 98 % del pool de tres nodos, por encima del umbral en que Ceph deja de aceptar escrituras con seguridad. El cuarto nodo, que el plan de capacidad incorpora de todos modos por cómputo, eleva el pool a 7,68 TB y deja la ocupación en 74 %. En rendimiento de disco la holgura es de dos órdenes de magnitud.

4.2.5.11 Dimensionamiento en nube

La Tabla 24 declara la capacidad base y la de peak de cada servicio de cómputo y datos en nube, con el criterio que dispara el escalado.

Servicio	Base	Peak	Escala por
ECS Fargate, aplicación Django	2 tareas	6 tareas	CPU sobre 70 %

Tabla 24 — continuación

Servicio	Base	Peak	Escala por
ECS Fargate, workers Celery	2 tareas	4 tareas	Profundidad de cola
Lambda de validación y firma	100 concurrentes	500 reservadas	Eventos de IoT Core y S3
Aurora PostgreSQL	db.r6g.large en 2 zonas	db.r6g.xlarge y 2 lectores	CPU sobre 60 %
ElastiCache	cache.r6g.large	cache.r6g.xlarge	Memoria sobre 75 %
DynamoDB	Bajo demanda	Bajo demanda	Sin gestión de capacidad
IoT Core	270 dispositivos	300 dispositivos	Concurrencia de terreno
Keycloak	1 tarea	2 tareas en 2 zonas	CPU sobre 60 %

Tabla 24 Capacidad de los servicios en nube

Fuente: elaboración propia; decisión ADR-12.

El paso de base a peak triplica la aplicación y duplica los workers y la base, que es la proporción del factor 3 de la Tabla 16. El escalado combina un componente predictivo, que en agosto precalienta las tareas y reserva la concurrencia de Lambda, con uno reactivo que responde en menos de 2 minutos y aprovisiona en menos de 3. DynamoDB y Lambda escalan sin configuración, y la capacidad se paga por uso.

4.2.5.12 Plan de capacidad y crecimiento de 3 veces

El crecimiento se absorbe con el mismo diseño, sin cambiar la topología, las VLAN, la réplica ni la nube. La Tabla 25 muestra la acción para cada recurso on-premise.

Recurso	Diseño	Con 3 veces	Acción
vCPU del clúster	30 de 64, 47 %	90 asignadas	Cuarto servidor idéntico en el gabinete R04: 96 hilos con N+1
Memoria	68 de 256 GB, 27 %	205 GB	Cabe en los 256 GB con N+1, 80 %
Pool Ceph	1.890 de 5.760 GB	5.670 GB	El cuarto nodo lleva el pool a 7,68 TB, 74 %
Enlaces de Talca y Concepción	20 y 10 Mbps	50 y 20 Mbps	Contrato escalonado de los enlaces
TPS de VM-02	105	315	Escala de 8 a 12 vCPU y de 32 a 64 GB, con particionado mensual

Tabla 25 Plan de capacidad para el crecimiento de 3 veces

Fuente: elaboración propia.

El cuarto servidor es la única compra adicional que exige el crecimiento de 3 veces, y resuelve a la vez el cómputo y el almacenamiento. Como el gabinete R04 de la sala técnica está reservado para ese crecimiento, la ampliación no requiere obras. En nube, el mismo factor se absorbe con el escalado automático de la Tabla 24, sin cambios de arquitectura.

4.2.5.13 Umbrales de desempeño

La Tabla 26 fija el umbral de respuesta, en percentil 95, de cada operación que el caso y las Bases declaran crítica.

Operación	Umbral
Confirmación de una línea de preparación de pedidos	1 s
Registro de una entrega en el local del cliente	2 s
Registro de una línea en la toma de pedido de preventa	1,5 s

Tabla 26 — continuación

Operación	Umbral
Consulta de stock y crédito en preventiva	2 s
Transacción operacional crítica de terreno, de extremo a extremo	3 s
Carga inicial de una página del portal	2 s
Navegación entre vistas ya cargadas	1 s
Interfaz de programación de consulta simple	500 ms
Interfaz de programación de escritura transaccional	800 ms
Búsqueda con criterios compuestos	3 s
Informe estándar en línea	30 s

Tabla 26 Umbrales de desempeño en percentil 95

Fuente: Caso, Cap. 15, RT-09.01, para las cuatro primeras filas; Bases Técnicas Transversales, numeral 9.1, para las demás.

Las cuatro primeras operaciones son las que fija el caso, y tres de ellas se resuelven sin atravesar la WAN: la confirmación de preparación contra la base local del sitio y los dos registros de terreno contra el almacén local del dispositivo. La consulta de stock y crédito es la única que depende de la nube, y por eso se atiende desde la caché. Los umbrales se miden con CloudWatch y se verifican en Pre-Producción con las pruebas de carga.

4.2.5.14 Primer cuello de botella

El primer recurso que se satura al crecer la carga es VM-02, la base transaccional del maestro de bodega, porque toda la preparación nocturna y todo el despacho pasan por su único punto de escritura. Se detecta cuando el percentil 95 de escritura supera 800 ms, cuando el tiempo de confirmación se triplica, cuando la espera de disco supera 15 % o cuando la cola de conexiones supera entre 5 y 10. La mitigación es progresiva: primero, escalar VM-02 de 8 a 12 vCPU y de 32 a 64 GB dentro del margen N+1; luego, particionar las tablas por mes y agregar un gestor de conexiones; después, una réplica de solo lectura para las consultas; y por último, el cuarto nodo o la partición de la base

al agotar el margen. En nube, el equivalente es Aurora, que escala con lectores, y SQS FIFO absorbe el pico de sincronización de las 17:00 a las 20:00 (ADR-05).

4.2.5.15 Degradación controlada

Cuando la carga o la red exceden lo previsto, la solución degrada en orden y sin perder transacciones. En el enlace, la calidad de servicio prioriza el broker y el registro de escritura anticipada, las colas no críticas se difieren fuera de la ventana de despacho y la conmutación entre caminos ocurre en menos de 30 segundos. Sin enlace, los brokers y los colectores guardan hasta 24 horas y reconcilian en orden al reconectar. En la nube, API Gateway limita la tasa de solicitudes, Celery aplica tiempos de espera y reintentos con espera creciente, y los mensajes que fallan pasan a una cola de mensajes fallidos para su reproceso. Cuando una solicitud se encola o se limita, la persona usuaria recibe un mensaje explícito con el estado de su operación, nunca un error genérico (RT-09.08).

4.2.5.16 Pruebas de carga y estrés

Los valores de esta sección se verifican con pruebas en Pre-Producción, que opera con el dimensionamiento completo de Producción durante esas pruebas. La Tabla 27 declara las tres pruebas.

Prueba	Carga	Resultado esperado
Carga	1,5 veces la carga de diseño: 5.850 entregas diarias, unas 160 TPS sostenidas	Umbral de la Tabla 26 cumplidos con perfiles horarios reales
Estrés	Incremento hasta el punto de quiebre, al menos 3 veces	Curva de tiempo de respuesta frente a la carga
Informe de carga	Curvas, saturación y uso de CPU, memoria, disco, enlace y colas	Insumo del hito de producción del mes 16

Tabla 27 Pruebas de carga y estrés

Fuente: elaboración propia.

La prueba de carga multiplica por 1,5 una carga de diseño que ya incluía ese margen,

de modo que $105 \times 1,5 \approx 160$ transacciones por segundo verifican la solución por encima de cualquier volumen que el caso proyecta. Las pruebas usan k6 y Gatling con controladores propios contra las API de integración y del broker, se ejecutan al cierre de la Etapa 1 (mes 13) y de la Etapa 2 (mes 19), y se repiten cada trimestre. Su calendario formal está en el Formulario T-13.

4.2.5.17 Actualización del plan de capacidad

Durante la operación, la capacidad se revisa cada trimestre comparando el consumo real con el proyectado en cómputo, memoria, almacenamiento, enlace, colas y transacciones por segundo. Una alerta anticipada se dispara cuando un recurso alcanza el 70 % o cuando la tendencia indica que se agotará en dos semanas, y cada alerta produce una propuesta de ajuste de dimensionamiento y de costo. La ampliación sigue el orden de la Tabla 25: vCPU y discos dentro del equipamiento físico, contrato escalonado de enlaces y, al acercarse al margen, el cuarto nodo. En nube, los umbrales del escalado automático y la concurrencia reservada se revisan al menos 30 días antes de cada peak de septiembre.

4.2.6 Especificaciones Implementos a proveer (Hardware y Software)

Esta sección resume y analiza el equipamiento y el software que la solución requiere en las instalaciones del CLIENTE, en el terreno y en la plataforma de nube. El detalle de cada elemento, con su producto ofertado, su ubicación, su cantidad y su justificación, se entrega en el Anexo 4.A (Formulario T-11), que acompaña a esta parte como anexo. El equipamiento físico lo adquiere el CLIENTE, y el adjudicatario lo especifica, instala, integra y mantiene durante el contrato (Art. 14.2).

4.2.6.1 Síntesis del equipamiento por familia

La Tabla 28 agrupa el equipamiento en ocho familias, con sus cantidades y los sitios donde se instala.

Familia	Equipamiento y cantidad	Sitios
Cómputo	3 servidores del clúster, 1 servidor de borde y 3 mini-PC industriales	Talca, Concepción y cross-docking
Almacenamiento de respaldo	1 NAS WORM cifrado, D-05	Talca
Red y seguridad	3 firewalls, 6 switches de sitio, 1 switch de gestión y 9 puntos de acceso Wi-Fi 6E	Los cinco sitios con cómputo
Enlaces	2 enlaces de fibra, 5 enlaces LTE y 3 kits Starlink	CD y cross-docking
Terreno	62 terminales EC55 más 20 % de reserva, cerca de 200 terminales TC58e, 200 impresoras de cabina y 200 terminales de pago	Calle y camiones
Bodega	174 terminales de cámara, 6 impresoras de andén, 3 balanzas y 6 escáneres GS1	CD y cross-docking
Cadena de frío	7 módulos de sensores con 28 puntos, 2 gateways IoT y 28 termógrafos	CD, cámaras y camiones
Puestos y sala técnica	8 estaciones de trabajo y la infraestructura de sala de Talca: UPS, generador, 2 unidades de clima de precisión, 4 gabinetes y 7 cámaras	Talca y Concepción

Tabla 28 Síntesis del equipamiento a proveer por familia

Fuente: elaboración propia; detalle en el Anexo 4.A (Formulario T-11).

Más de nueve de cada diez unidades están en el terreno y en la bodega, no en la sala técnica: son unos 860 dispositivos de trabajo frente a menos de 50 equipos de cómputo, red y sala. Esa proporción refleja el caso, donde la operación ocurre en la calle, en la cámara y en el andén, y explica por qué la gestión de dispositivos (N-13) es un componente con emplazamiento propio y no un accesorio.

4.2.6.2 Criterios de selección

Cada familia se especifica contra una condición del caso que el equipamiento de oficina no resiste. Los 174 terminales de cámara están certificados para trabajar a -30°C con guantes gruesos y batería de recambio en caliente, porque la preparación de congelados

ocurre a -22°C (Caso, Cap. 4.5); su número cubre los 120 preparadores simultáneos de Talca con 20 % de reserva por la rotación de 38 %, más 30 en Concepción. Los terminales de terreno operan un turno completo sin señal, a una mano y bajo sol directo (RT-13.08). Los mini-PC de los cross-docking son de rango industrial, porque las naves no tienen climatización y el supuesto de diseño es de hasta 50°C bajo la techumbre en verano. Los 28 termógrafos cubren los 18 camiones propios y los 10 refrigerados de los transportistas que declara la Tabla 14 del caso, porque el instrumento viaja con la carga y su registro ampara la cadena de frío aun cuando el vehículo no sea del CLIENTE; están calibrados contra un patrón NIST en dos puntos, porque su registro es la prueba de la cadena de frío ante un cliente o ante la autoridad sanitaria.

En la sala técnica el criterio es la redundancia sin sobrecompra. Los tres servidores del clúster son idénticos, de modo que la pérdida de cualquiera deja capacidad para todas las máquinas virtuales, y la cuarta unidad solo se agrega con el crecimiento de 3 veces, en el gabinete R04 ya reservado. Los firewalls de Talca van en par y el de Concepción es único, porque en ese sitio la contingencia ante la falla es la misma autonomía que cubre los cortes de enlace.

4.2.6.3 Software y licenciamiento

El software de base es de código abierto en todos los componentes que el adjudicatario opera: PostgreSQL, RabbitMQ, Keycloak, Proxmox VE, Ceph y Docker, además de la aplicación, escrita en Django y Python y, en el terreno, en Kotlin. Los únicos elementos con suscripción son los servicios de la plataforma de nube, descritos en la sección 4.2.2, la gestión de dispositivos y los agentes de detección en endpoints. Esta composición mantiene la reversibilidad de la solución y evita que el CLIENTE quede atado a un licenciamiento propietario. El Anexo 4.A (Formulario T-11) detalla, además del equipamiento, cada servicio de nube y cada componente de software con su cantidad y su justificación.

Especificaciones del sitio principal on-premise (CD Talca)

Tipología declarada (numeral 6.1 de las Transversales): sala técnica principal.. El CD Talca aloja el núcleo del componente on-premise, es decir cómputo, almacenamiento y procesamiento sustantivos en instalaciones del CLIENTE. Concentra el motor WMS, la base transaccional del maestro de bodega, el broker de colas, la capa anticorrupción del ERP, la caché de identidad, la telemetría y el respaldo local. Por eso se le aplican íntegramente los requisitos RT-06.01 a RT-06.34, y no el régimen proporcional de una sala de sitio.

Disponibilidad de infraestructura comprometida: 99,95 % mensual, conforme al numeral 6.1 y a la tabla del numeral 7.2 de las Transversales, medida por componente: energía del recinto, climatización, red y comunicaciones, servidores y cómputo, y motor de base de datos. El compromiso se sostiene con redundancia N+1 en energía y climatización, doble acometida con transferencia automática, generación autónoma propia y monitoreo continuo con alertamiento; no se invoca ninguna clasificación de instalación de tercero, porque las Bases no exigen certificación de nivel sino el cumplimiento verificable de cada requisito técnico individual. Este valor es el nivel de la infraestructura del recinto y es distinto del compromiso contractual penalizable del Artículo 78°, que recae sobre la transacción de negocio de extremo a extremo ($\geq 99,9$ % mensual, RT-10.01).

El programa arquitectónico propuesto considera $\approx 173 \text{ m}^2$ y 14 recintos: sala blanca de 32 m^2 , NOC de 14 m^2 , sala de sistemas de alimentación ininterrumpida y baterías, sala de climatización, sala de extinción, distribuidor principal y acometidas, recinto de custodia de medios de 10 m^2 , patio de generador y recintos de apoyo. La distribución por recinto y la disposición de los equipos se describen a continuación, recinto por recinto, en el programa de la sala.

Energía: UPS doble conversión on-line 6 kVA con configuración N+1 y banco VRLA con autonomía ≥ 30 min a plena carga; grupo electrógeno de 12 kVA con estanque para 24 h y contrato de reabastecimiento; transferencia automática red↔generador con prueba mensual con carga real; PDU verticales A/B por gabinete con medidor; factor de potencia $\geq 0,95$.

Climatización: 2 CRAC de precisión ≈ 12.000 BTU/h en N+1, con free cooling, pasillo frío confinado y rango ASHRAE TC 9.9 de 18–27 °C y 40–60 % HR medido a la toma de aire del equipo; PUE objetivo de diseño 1,7 (valor conservador para sala de servidores pequeña con climatización de precisión N+1) con medición continua en 2 puntos y reporte trimestral.

Incendios: detección temprana por aspiración AnaLASER; extinción con agente limpio FM-200 conforme NFPA 75/2001 con botón de aborto; extintores ABC y CO₂ por recinto.

Seguridad física: 4 capas de acceso con biometría facial y resguardo AFIS, esclusa antipassback y bitácora electrónica, una persona a la vez y acompañada; 12 puertas controladas y 7 cámaras IP con retención ≥ 30 días integradas al control de acceso; NOC de 14 m² contiguo a la sala con ventana interior («ver sin entrar»); sensores ambientales DCIM/BMS.

Custodia de medios: recinto de 10 m² en la segunda línea, sin luz UV (≤ 300 lux), 40–60 % HR, ventilación forzada y 18–27 °C; medio cifrado transportable rotado semanalmente a bóveda externa bajo custodia acreditada con cadena de custodia y bitácora; la pierna inmutable S3 es complementaria, no la reemplaza.

Cableado y comunicaciones: cableado estructurado Cat6A F/UTP + fibra OM4 certificado enlace por enlace sobre piso técnico de 40 cm, jerarquía ANSI/TIA-942 ENI→MDA→HDA→ZDA→EDA, con dos ductos de ingreso independientes; 4 racks 42U en gabinete de servidores y comunicaciones separados, con el cuarto (R04) reservado al crecimiento a 3 años.

Los componentes de infraestructura de sala del CD Talca (UPS, generador, transferencia automática, climatización, seguridad física, extinción, cableado y gabinetes) se detallan en la Tabla 32 del Anexo 4.A (Formulario T-11), que acompaña a esta parte como anexo. El equipamiento de cómputo, red y comunicaciones que se aloja en estos gabinetes se resume en la sección 4.2.6.

Especificaciones del sitio secundario

Cómo se satisface el numeral 7.1.. Las Transversales exigen un sitio secundario en dependencias distintas del principal, en modalidad activo-activo o activo-pasivo, con replicación en línea del ambiente de producción y características tecnológicas equivalentes a las del sitio principal en lo que respecta a los servicios críticos. La solución lo satisface con dos sitios secundarios, uno por cada dominio del despliegue híbrido, porque la carga crítica vive en ambos:

- **Para el componente on-premise, el CD Concepción:** es una dependencia física distinta, a 340 km del extremo opuesto de la red y sin amenazas comunes con Talca, y opera el motor de almacenes con su propia base local y autonomía de 24 horas. No es un sitio en espera: opera de forma autónoma todos los días y asume la carga de bodega de Talca mediante promoción controlada.
- **Para la carga principal en nube, la región AWS us-east-1:** aloja la réplica pasiva promovible del núcleo transaccional, a ≈ 7.700 km de la región primaria y ≈ 8.500 km de Talca, sin amenazas comunes.

El mecanismo de recuperación ante desastres (modalidad activo-pasiva, $RTO \leq 4$ h, $RPO \leq 15$ min), el procedimiento de conmutación y retorno, las pruebas semestrales, la tabla de componentes de la réplica y el esquema de respaldos 3-2-1-1-0 se declaran en la sección de arquitectura de despliegue.

El gabinete de borde con que se habilitan el sitio secundario on-premise y las tres plataformas de cross-docking es el equipo C/D del Anexo 4.A (Formulario T-11); su emplazamiento y sus características se detallan en la tabla de emplazamiento de la sección 4.2.1.

Tecnologías de software ofertadas

Las tecnologías se eligen bajo los criterios de neutralidad tecnológica, soporte vigente por los 56 meses contractuales y preferencia por servicios administrados y componentes de código abierto con estándares abiertos, de modo que el CLIENTE conserve la reversibilidad de la solución:

- **B1 — Aplicación.** Django monolito modular (Python) + Celery sobre AWS ECS Fargate (2–6 tareas con escala automática). La misma imagen se reutiliza en modo wms_only dentro del ambiente on-premise.
- **B2 — BD transaccional nube (maestro).** Amazon Aurora PostgreSQL en sa-east-1 (Multi-AZ), con réplica pasiva promueble en us-east-1 para recuperación ante desastres ($RTO \leq 4 \text{ h}$ / $RPO \leq 15 \text{ min}$).
- **B3 — BD transaccional on-premise.** PostgreSQL 16 (VM-02 Talca / VM-C02 Concepción): sistema de verdad de la bodega durante cortes de enlace, con flujo continuo hacia la réplica en nube por AWS DMS CDC sobre el WAL lógico (registro de escritura anticipada que permite replicar cambios en tiempo real) ($RPO \leq 15 \text{ min}$).
- **B4 — Broker de mensajería.** RabbitMQ local (colas offline por sitio) + SQS FIFO en nube (reconciliación): cada sitio absorbe hasta 24 h de operación sin enlace con vuelco en orden estricto e idempotencia (D-AL-03). Las tareas derivadas de cada evento las despacha Celery desde el monolito.
- **B5 — Identidad (IdP maestro).** Keycloak en ECS/Fargate (OIDC/OAuth 2.1, MFA, SSO), autoridad única en sa-east-1 con cachés locales de solo lectura (ADR-06); el modelo completo se describe en la sección de seguridad.
- **B6 — Telemetría IoT.** AWS IoT Core + Greengrass v2 + sensores Ebyte ME31 (B-01/B-02): registro continuo de cadena de frío con decisión de bloqueo por excursión térmica 100 % en el borde.
- **B7 — Observabilidad.** Plataforma única: instrumentación OpenTelemetry con colectores ADOT on-premise (VM-06, VM-C04, cross-dock; buffer en disco 24 h) que emiten a CloudWatch (logs, métricas y trazas) en sa-east-1 (ADR-14); sin herramientas duplicadas por ambiente ni infraestructura de monitoreo que operar.
- **B8 — Virtualización on-premise.** Proxmox VE/KVM + Ceph (12 OSD, réplica 2, 3 monitores): tolera la pérdida de cualquier nodo con quórum real; respaldo único

3-2-1-1-0 con NAS D-05 y pierna inmutable en nube.

- **B9 — Orquestación de contenedores de borde.** Docker/Docker Compose + WMS en los 3 cross-docking (E-01) y en el borde de Concepción: instalación y parcheo sin dependencia de la red, con paridad de versiones.
- **B10 — Gestión y configuración.** Ansible (F-02, parches/CIS) + Terraform/CDK IaC (multi-zona): configuración declarada como código versionado en el repositorio del CLIENTE.
- **B11 — Gestión de dispositivos de terreno (MDM).** N-13 — Android Enterprise / Zebra DNA (servicio gestionado): enrolamiento por IMEI contra el usuario, política (cifrado local, PIN, modo quiosco), actualización Over-The-Air de la aplicación y de la caché de turno, inventario del parque y borrado remoto selectivo; sin infraestructura on-premise (equipo de TI de 4 personas).
- **B12 — Gestión de secretos.** AWS Secrets Manager + SSM Parameter Store (N-12): rotación automática, sin credenciales embebidas; consumo saliente por VPC Endpoint desde los nodos on-premise (ADR-15); credencial de emergencia en sobre sellado en el recinto de custodia.
- **B13 — Seguridad lógica.** WAF v2 + Shield + API Gateway + SIEM/Security Lake + EDR (F-03) + Macie: superficie expuesta mínima y detección concentrada en un solo registro, bajo política Zero Trust.
- **B14 — Analítica / BI.** Redshift Serverless (OLAP, 5 años) + QuickSight: separación OLTP/OLAP con latencia máxima de 4 h para los tableros del CLIENTE.
- **B15 — Licenciamiento.** Servicios AWS por servicio + OSS sin licencia (Keycloak, PostgreSQL, Proxmox VE, RabbitMQ): reversibilidad y ausencia de dependencia propietaria.

4.5.1 Integración con el ERP y documentos tributarios

El ERP de 2017 no se reemplaza ni se modifica (Cap. 10 del caso): permanece como única fuente de verdad tributaria. La solución entrega los datos de operación a través de la capa anticorrupción (ACL, VM-04) y el ERP emite los documentos tributarios (guía de despacho electrónica, factura, boleta y nota de crédito con folios SII), con acuse de recibo con efectos legales —una sola verdad, un solo emisor. El acceso desde la nube a este ERP ocurre únicamente vía la ACL (celery-erp-sync → ACL, nunca escritura directa).

Registro de decisiones de arquitectura

Registro consolidado de las quince decisiones de arquitectura que condicionan esta propuesta. Es entregable contractual conforme a RT-02.04 y se mantiene actualizado durante toda la ejecución. Para cada decisión se indica la alternativa escogida, las alternativas descartadas con el motivo de rechazo, y el criterio de selección. Todas las decisiones fueron aprobadas entre el 05 y el 06 de septiembre de 2026.

4.6.1 ADR-01 · Estilo arquitectónico

Decisión adoptada. Monolito modular Django 5.x LTS / Python 3.12, desplegado en ECS Fargate con apps por dominio y límites de contexto DDD. Módulos críticos (WMS offline, shipper, workers, portal) en procesos separados.

Alternativas descartadas. *Microservicios EKS:* volumen (~105 TPS) dos órdenes bajo el umbral que los justifica; 4 personas no operan 9–13 componentes de plano de control; TCO estimado en +USD 40–70 K / 56 m (estimación interna basada en la operación de EKS con el equipo del CLIENTE). *Monolito clásico WMS 2013:* sin fronteras de módulo, proveedor desaparecido; viola RT-02.02.

Criterio de selección. Pertinencia al volumen real (BTT §2.3); operabilidad por 4 personas; TCO 56 meses; despliegue independiente sin particionar el dominio. Normativa: RT-02.01/02.02/02.03, RT-09.05, BA Art. 16, RNF-19.01–04. Relacionada: D5, D8, D14 (Arq. Lógica).

4.6.2 ADR-02 · Conectividad WAN

Decisión adoptada. Doble camino por sitio: fibra + LTE en los centros de distribución, Starlink + LTE en los cross-docking. Conmutación automática < 30 s.

Alternativas descartadas. *Fibra en cross-docks:* naves industriales sin cobertura de

fibra; costo de obra desproporcionado. *VSAT GEO*: latencia 500–700 ms RTT; penaliza RNF-05.01 y costo superior. *Tri-camino (fibra + Starlink + LTE)*: tercer camino no aporta disponibilidad significativa dado que cada sitio opera autónomamente ante pérdida total de enlace (24 h CD, 14 h terreno).

Criterio de selección. Dos caminos de física distinta satisfacen RT-03.17 sin punto único de fallo; la autonomía local cubre la pérdida total de enlace, por lo que un tercer camino es innecesario; cero mantención de radio para el equipo de 4 personas del CLIENTE. Normativa: RT-03.10/03.17, RT-10.05, RNF-13.01/13.07/13.08. Relacionada: Decisión 16.1 N° 26.

4.6.3 ADR-03 · Modelo de despliegue híbrido

Decisión adoptada. Borde operacional on-premise (WMS maestro Talca, edge Concepción, WMS en cross-docks) + carga principal en AWS. 11 componentes on-prem, 12 híbridos, 13 nube pura.

Alternativas descartadas. *Solo nube*: inadmisible (Art. 16); sin enlace la bodega muere en minutos; picking en cámara –22 °C inviable con RTT 40–80 ms. *Solo on-premise*: inadmisible (Art. 16).

Criterio de selección. Único modelo que satisface Art. 16 en sus 4 numerales; latencia ≤ 1 s en cámara resuelta localmente; autonomía 24 h CD / 14 h terreno; TCO contenido con servicios administrados AWS. Normativa: BA Art. 16.1–16.4, RT-03.01/03.02/03.10/03.19, RNF-02.01/05.01/05.02. Relacionada: D7, Decisión 16.1 N° 17.

4.6.4 ADR-04 · Persistencia políglota

Decisión adoptada. PostgreSQL+PostGIS (transaccional WMS, CP), Aurora (OLTP cloud + DRP), DynamoDB (IoT raw, AP, TTL 30 d), S3+Redshift Serverless (OLAP + series de temperatura), S3 Object Lock/Glacier (retención legal 5 años).

Alternativas descartadas. *Motor único relacional*: no escala ingesta IoT sin degradar picking (RNF-11.02). *InfluxDB*: segundo motor exótico a operar; serie de tiempo cabe en capa OLAP. *DynamoDB para todo*: no ofrece ACID cross-tabla para reconciliación determinista.

Criterio de selección. Posición CAP declarada por dominio (RT-05.02); 3 motores admi-

nistrados operables por el equipo de TI del CLIENTE; retención sanitaria D.S. 977/96 con inmutabilidad; RPO $\leq$ 15 min por réplica Aurora. Normativa: RT-05.01/05.02/05.11-15, RNF-09.01/09.02/11.02. Relacionada: D2, D4, Decisión 16.1 N° 18.

4.6.5 ADR-05 · Mensajería asíncrona

Decisión adoptada. RabbitMQ local por sitio (buffer 24 h) + shipper idempotente → SQS FIFO (VPC Endpoint outbound) + Celery workers (tareas derivadas de eventos) + IoT Core MQTT (ingesta edge).

Alternativas descartadas. *REST síncrono*: no sobrevive corte a mitad de ventana; rompe reconciliación. *Kafka/MSK*: operar clústeres en 5 sitios es desproporcionado para el equipo disponible y 105 TPS.

Criterio de selección. Resiliencia offline (buffer local + reproducción idempotente); reconciliación determinista RT-03.12; Zero Trust (todo outbound); TCO proporcional al volumen. Normativa: RT-02.06/02.07, RT-03.10/03.12, RNF-07.01/13.01, BA Art. 21. Relacionada: D4.

4.6.6 ADR-06 · Identidad híbrida (Modelo B)

Decisión adoptada. Keycloak IdP maestro en AWS (ECS Fargate, 2 tareas Multi-AZ, backend Aurora) + caché local solo lectura (TTL 8 h) en Talca y Concepción. Tokens offline por perfil (8 h bodega, 14 h reparto). OTP para conductores externos.

Alternativas descartadas. *IdP solo nube*: paraliza bodega ante corte. *AD maestro local*: duplica administración, crea maestro a promover en DR. *Keycloak maestro local*: nube no puede autenticar si el enlace cae.

Criterio de selección. Autonomía offline sin maestro local a promover; autoridad única en nube; OTP sin correo para externos (RT-12.12); MFA Art. 22; operado por el equipo reducido del CLIENTE sin directorio propietario. Normativa: RT-12.10/12.11/12.12, RT-03.10, RNF-13.01, BA Art. 22, RF-15.01-05, RF-06.08. Relacionada: D6, Decisión 16.1 N° 34.

4.6.7 ADR-07 · Movilidad de terreno

Decisión adoptada. App nativa Android Kotlin para preventa, reparto y picking. SQLite/Room, SDK Zebra DataWedge (GS1 + QR), impresión BT (ZQ620), POS PAX. Dispositivos Rugged: EC55, TC58e, MC9400 Cold Storage.

Alternativas descartadas. *PWA*: no controla SDK Zebra de forma fiable ni persiste turno completo sin capa nativa. *Híbrida Flutter*: runtime intermedio degrada interacción con periféricos industriales.

Criterio de selección. Control nativo de periféricos (DataWedge intents); offline total 14 h con sincro < 10 min; UI para guantes -22 °C, una mano, lluvia; curva de aprendizaje ≤ 2 h; un artefacto para 3 perfiles. Normativa: RT-13.08, RT-12.11, RT-03.19, RNF-05.02/05.03/06.01, RF-06.11-13. Relacionada: Decisión de proyecto N° 19.

4.6.8 ADR-08 · Destino del WMS legado 2013

Decisión adoptada. Reemplazo total en Etapa 1 por módulo WMS del monolito (ADR-01): Talca maestro, Concepción edge, cross-docks sobre E-01. Migración por dominio, oleadas por sitio, reversión azul-verde.

Alternativas descartadas. *Mantener e integrar*: proveedor desaparecido, sin soporte; no soporta multi-sitio, picking FEFO (primero en expirar, primero en salir), SSCC GS1 ni conteo cíclico ciego. *Extender a otros sitios*: arrastra riesgo de soporte inexistente en ventana crítica.

Criterio de selección. Requisitos RF-02.x que el WMS 2013 no contempla; riesgo operacional inaceptable; TCO amortizado con reducción conteo 2,3 %→~0,3 % y merma 1,7 %→<1 %; reversión azul-verde garantizada. Normativa: RT-05.11-15, RT-03.10, RNF-02.01/05.01, Caso 16.1 N° 14. Relacionada: Decisión 16.1 N° 14 (delegada por el CLIENTE).

4.6.9 ADR-09 · Estrategia DR

Decisión adoptada. Activo-pasivo warm standby multi-región: DMS CDC + Aurora WAL hacia us-east-1; DRP local Talca→Concepción (RTO +1-2 h); pruebas 2×/año; respaldo 3-2-1-1-0 con S3 Object Lock.

Alternativas descartadas. *Activo-activo*: duplica infraestructura y exige reconciliación

de doble escritura sin beneficio medible. *Backup + restore frío*: RTO 24–72 h, incumple RNF-20.06. *Solo intrarregional*: postura mínima si CLIENTE no aprueba Art. 23; aceptando RTO 24–72 h ante caída de región.

Criterio de selección. $RTO \leq 4 \text{ h}$ / $RPO \leq 15 \text{ min}$; proporcionalidad al volumen; DR de identidad resuelto en nube (ADR-06); pruebas semestrales reales. Normativa: RT-07.01/07.07, RNF-20.06/20.07, BA Art. 20. Relacionada: Decisión 16.1 N° 27.

4.6.10 ADR-10 · Almacenamiento on-premise y RAID

Decisión adoptada. RAID 10 NVMe para BD transaccional del WMS (VM-02); RAID 6 con hot-spare para evidencia POD, logs y rollups; hipervisor Ceph N+1.

Alternativas descartadas. *RAID 5*: probabilidad de URE durante rebuild en discos 8–16 TB; solo tolera 1 fallo. *RAID 1 puro para todo*: sobre-costos 50 % aplicado a datos no críticos sin beneficio proporcional.

Criterio de selección. IOPS deterministas en ventana de despacho (>100 K vs. ~840 necesarios); tolerancia a fallo de disco (RNF-13.04) con justificación (RNF-13.05); TCO contenido con RAID 10 solo en lo transaccional. Normativa: RT-03.14, RNF-13.03/13.04/13.05. Relacionada: Decisión 16.1 N° 28.

4.6.11 ADR-11 · Integración B2B/EDI canal moderno

Decisión adoptada. Hub EDI centralizado GS1 (EANCOM/GS1 XML + EPCIS) en nube, con conector configurable por cadena, equivalencias GTIN (RF-12.03), bandeja de excepciones (RF-12.06) y ACL hacia ERP/GDE. Canal moderno operativo $\leq$ enero 2029.

Alternativas descartadas. *Punto-a-punto por cadena*: multiplica adaptadores; mantenimiento desproporcionado ante cambios de cadena. *EDI delegado al ERP*: expone frontera frágil; viola Zero Trust (escritura directa desde cadena).

Criterio de selección. Estandarización GS1 (Cap. 16.2); esfuerzo marginal por cadena nueva; aislamiento ERP por ACL (Zero Trust); plazo enero 2029. Normativa: RT-05.23, RT-16.16/16.17, RNF-12.01, RF-12.03/12.06. Relacionada: RF-12, RF-01.10.

4.6.12 ADR-12 · Absorción del peak de septiembre

Decisión adoptada. Cómputo elástico: Fargate 2→6, Celery 2→4, Lambda 100→500, Aurora large→xlarge +2 readers, DynamoDB on-demand. Escala predictiva + reactiva. Base con Savings Plan, peak con cómputo efímero.

Alternativas descartadas. *Capacidad fija al peak:* paga 12 meses la capacidad de 3 semanas. *Solo escala reactiva:* burst predecible de septiembre; la reactiva sola introduce lag en ventana crítica.

Criterio de selección. Perfil no plano al peak $\times 1,5$ (RNF-19.04); cuello de botella identificado (RT-09.05); FinOps (RT-03.06): base reservada + peak efímero; congelamiento 1-25 sept y diciembre (RT-10.05). Normativa: RT-09.05, RT-03.06/03.08/03.09, RNF-19.01-04, RT-10.05. Relacionada: Decisión 16.1 N° 30.

4.6.13 ADR-13 · Puerta de enlace de servicios

Decisión adoptada. Amazon API Gateway como Capa 3 única: autorizador OIDC (Keycloak), validación de esquema OpenAPI, cuotas y límites de tasa por actor/ruta, versionado /v{major}, propagación de transaction_id a Capa 8.

Alternativas descartadas. *Kong autoadministrado:* agrega componente crítico a parchar en ruta de la venta; riesgo en ventana 05:30-07:00 con el equipo disponible. *Desarrollo propio (middleware Django):* sin cuotas/rate-limit nativos; viola Art. 21.2.

Criterio de selección. Cumplimiento literal Art. 21.2 sin desarrollo propio; servicio administrado para 4 personas; coherencia entre vistas (Art. 16.4); reversibilidad por contratos OpenAPI/AsyncAPI estándar. Normativa: BA Art. 21.2, RT-02.01/02.02, RT-11.11, RT-05.16/05.18, Art. 16.3. Relacionada: D8.

4.6.14 ADR-14 · Plataforma de observabilidad

Decisión adoptada. Plataforma única en nube: instrumentación OTel, colectores ADOT on-premise con buffer 24 h, logs en CloudWatch Logs (12+24 m), métricas en CloudWatch Metrics (13 meses) y trazas en CloudWatch con retención declarada. Tableros nativos de CloudWatch para operación.

Alternativas descartadas. *Prometheus+Grafana+Loki local + cloud:* dos plataformas (viola Art. 16.4 y RT-03.16); VM-06 sin capacidad. *AMP + X-Ray + Grafana:* cua-

tro servicios de observabilidad para un equipo de 4 personas; complejidad operativa desproporcionada sin ganancia funcional sobre CloudWatch nativo.

Criterio de selección. Art. 16.4 y RT-03.16 piden una plataforma; buffer ADOT resuelve «sin puntos ciegos» durante corte; ninguna decisión 05:30–07:00 depende de tablero; CloudWatch es nativo de AWS y no requiere infraestructura adicional; el equipo del CLIENTE no opera servidores de observabilidad. Normativa: BA Art. 16.4, RT-03.16, RT-14.01–09, RT-09.01. Relacionada: D14.

4.6.15 ADR-15 · Gestión de secretos

Decisión adoptada. AWS Secrets Manager (secretos con rotación: ERP, SII, Transbank, certificados AS2/EDI) + SSM Parameter Store (config no sensible). Consumo outbound por VPC Endpoint. Cifrado CMK KMS, separación de funciones. Cuenta de emergencia en sobre sellado offline.

Alternativas descartadas. *HashiCorp Vault autoadministrado:* modo sellado tras reinicio exige intervención humana de madrugada; agrega infraestructura. *Sin gestor centralizado:* prohibido por Art. 21.4.

Criterio de selección. Servicio administrado sin desellado manual; Zero Trust (consumo outbound); separación de funciones Art. 21.2 vía IAM/CloudTrail; contingencia offline independiente de la nube. Normativa: BA Art. 21.4/21.2, Art. 16.2/16.3, RT-04.09, RT-11.09. Relacionada: D13, SEC-01.

Anexo 4.A — Formulario T-11: Especificaciones técnicas ofertadas

Este formulario detalla los componentes de infraestructura, plataforma, licenciamiento y hardware especificados para la solución, con su ubicación, su cantidad y su justificación, conforme al Formulario T-11 de las Bases Administrativas. Su resumen y análisis están en la sección 4.2.6, y los servicios de nube se agrupan por función en la sección 4.2.2. El equipamiento físico lo adquiere el CLIENTE, y el adjudicatario lo especifica, instala, integra y mantiene (Art. 14.2).

Infraestructura de cómputo y almacenamiento

La Tabla 29 detalla los servidores y el almacenamiento de respaldo de los cinco sitios con cómputo.

Componente	Producto ofertado	Ubicación	Cant.	Justificación
C1 — Servidor del clúster	Dell PowerEdge R6615 o HPE DL325 Gen11: EPYC 9124 de 16 núcleos, 128 GB DDR5 ECC, RAID 1 para el sistema y RAID 10 con 4 NVMe de 1,92 TB y repuesto en caliente, 2 puertos de 10 GbE y doble fuente	CD Talca, gabinete R01	3	Tres nodos iguales dejan capacidad para todas las máquinas virtuales si falla uno (RT-08.03), y los discos NVMe en RAID 10 superan con holgura las operaciones de disco del peak de septiembre.

Tabla 29 — continuación

Componente	Producto ofertado	Ubicación	Cant.	Justificación
C2 — NAS de respaldo local	NAS con bloqueo de escritura WORM y cifra- do de disco	CD Talca, gabinete R01	1	Es la copia local de recuperación rápida del esquema 3-2-1-1-0: restaura el WMS en hasta 4 h sin depender del enlace (RNF-20.06), y complementa la copia inmutable en nube sin reemplazarla.
C3 — Servi- dor de borde de Concep- ción	Dell R250 o HPE DL20 Gen11: Xeon E-2300 de 6 núcleos, 32 GB y RAID 10 con 4 NVMe de 960 GB y repuesto en caliente	CD Con- cepción, gabinete de borde	1	Sostiene el WMS con 24 h de operación au- tónoma, con 12 vCPU y 24 GB asignados para el volumen de Concepción y doble fuente.
C4 — Nodo de cross- docking	Mini-PC industrial Ad- vantech ARK-2250 o NUC Pro 12: i5 o i7 de 12.ª generación, 16 GB, NVMe de 512 GB y mó- dem LTE Cat-12 con doble SIM	Curicó, Chi- llán y Los Ángeles	3	Opera en naves sin climatización, con un supuesto de diseño de hasta 50 °C en verano, y sin fibra (RT-03.17); usa Starlink por Ethernet como enlace principal y LTE de dos proveedores como respaldo, con conmutación en menos de 30 s.

Tabla 29 Formulario T-11: infraestructura de cómputo y almacenamiento

Red y seguridad

La Tabla 30 detalla los equipos de red, los enlaces y la VPN.

Componente	Producto ofertado	Ubicación	Cant.	Justificación
C5 — Firewall y Customer Gateway	Clúster activo/pasivo de firewalls UTM de grado empresarial con sincronización de sesiones, D-01	CD Talca, gabinete R02	2	El sitio principal no admite un perímetro de equipo único (RT-08.03): la unidad pasiva asume direcciones y túneles en menos de 30 s, en circuitos eléctricos distintos (RT-08.04). Es el punto de terminación de la VPN Site-to-Site.
C6 — Switch core	Cisco Catalyst 9300-48P o equivalente en stack, D-02	CD Talca, gabinete R02	2	Los dos equipos forman un único plano de distribución, de modo que la falla de uno no interrumpe el tráfico (RT-08.03).
C7 — Switch de gestión	Switch de capa 2 para la VLAN de gestión y consola KVM	CD Talca, gabinete R02	1	Aísla los puertos de administración de los servidores en una VLAN dedicada con MFA, y permite recuperar los equipos aunque la red de producción esté caída.
C8 — Distribución horizontal	Paneles de fibra OM4 y cobre Cat6A certificado	CD Talca, gabinete R03	1	Cableado certificado enlace por enlace (RT-06.04), con dos ductos de ingreso independientes a la sala (RT-06.32).

Tabla 30 — continuación

Componente	Producto ofertado	Ubicación	Cant.	Justificación
C9 — Red inalámbrica industrial	Puntos de acceso Wi-Fi 6E industriales en la VLAN de operaciones, con estudio de cobertura en bodega y cámara	Bodegas de Talca y Concepción	9	Da cobertura a 120 terminales en Talca y 30 en Concepción, con segmentación por tipo de dispositivo y cobertura verificada dentro de las cámaras (RT-03.23).
C10 — Enlace principal	Fibra óptica simétrica: Talca de 20 a 50 Mbps y Concepción de 10 a 20 Mbps, D-03	CD Talca y CD Concepción	2	Dimensionado sobre la replicación de la base, el vuelco de los brokers y la telemetría, de unos 0,2 Mbps en promedio, y sobre el respaldo semanal a la nube, de 40 a 120 GB en la ventana nocturna, unos 33 Mbps (RT-03.20); los valores cubren el crecimiento de 3 veces sin rediseño (RT-09.03).
C11 — Enlace de respaldo	LTE empresarial con SIM dedicada: Talca de 5 a 10 Mbps, Concepción de 3 a 5 Mbps y cross-docking de 2 a 5 Mbps con dos proveedores, D-04	CD Talca, CD Concepción y los tres cross-docking	5	Evita depender de un solo camino o proveedor (RT-03.17), con conmutación en menos de 30 s: en los centros de distribución respaldada a la fibra y en los cross-docking respalda a Starlink.

Tabla 30 — continuación

Componente	Producto ofertado	Ubicación	Cant.	Justificación
C12 — VPN	AWS Site-to-Site VPN IPsec IKEv2 con BGP	Talca y Concepción hacia sa-east-1	2 túneles por CD	Replica la base, sincroniza los brokers y transmite telemetría cifrado y con enrutamiento dinámico (RT-03.21), con una MTU de túnel de 1.436 bytes.
C13 — Firewall de borde	Firewall de borde de grado empresarial, D-01	CD Concepción, gabinete de borde	1	Es el Customer Gateway del túnel hacia AWS y conmuta entre fibra y LTE en menos de 30 s (RT-08.03, RT-03.17).
C14 — Switch de borde	Cisco Catalyst 9300 o equivalente, D-02	CD Concepción, gabinete de borde	1	Sostiene la red de bodega del sitio secundario durante 24 h de autonomía, sin depender del sitio principal (RT-08.03).
C15 — Switch de cross-docking	Netgear GS308E o equivalente, de 8 puertos Gigabit gestionables, D-02	Curicó, Chillán y Los Ángeles	3	Equipo compacto para una nave sin sala técnica: conecta el mini-PC, el router Starlink, los escáneres y los terminales.

Tabla 30 Formulario T-11: red y seguridad

Dispositivos de terreno y de operación

La Tabla 31 detalla los dispositivos que usan las personas en la calle, en la bodega y en la cadena de frío.

Componente	Producto ofertado	Ubicación	Cant.	Justificación
C16 — Terminal de pre-venta	Zebra EC55: Android, IP67, uso con guantes y lector 2D SE4100	Preventistas en cinco regiones	62 más 20 %	Opera sin señal, dura la jornada con una carga, funciona con guantes y su pantalla se lee a pleno sol (RT-08.11).
C17 — Terminal de reparto	Zebra TC58e: 5G, lector SE55, batería de 7.000 mAh, GPS L1/L5, IP65/68 y -30 °C	42 conductores propios y cerca de 160 externos	200 más reserva	Un solo modelo para conductores propios y externos: mismo repuesto, misma capacitación y misma integración.
C18 — Impresora de cabina	Zebra ZQ620 Plus: 3 pulgadas, ZPL, IP54 y Link-OS	Una por conductor	200	Imprime la evidencia de entrega y los comprobantes en la cabina, con batería de reemplazo.
C19 — Terminal de pago	PAX A920 Pro: Android 14, PCI PTS 7.x y EMV L1/L2	Una por conductor	200	Cobra con tarjeta en el local del cliente con certificación PCI PTS y EMV, integrado por Bluetooth con la aplicación de reparto.
C20 — Terminal de cámara	Zebra MC9400 Cold Storage Freezer: -30 °C, lector SE58 de 100 pies, batería de 5.000 mAh y Wi-Fi 6E	Talca 144 y Concepción 30	174	Prepara pedidos en la cámara a -22 °C con guantes gruesos, lee a distancia y recambia la batería en caliente (RT-08.11, RT-08.12, RT-13.08).
C21 — Impresora de andén	Zebra ZT411: 203 dpi, 14 ips, Ethernet y ZPL	Talca 4 y Concepción 2	6	Imprime la etiqueta SSCC GS1-128 al armar la unidad logística (RF-01.07), legible a lo largo de toda la cadena (RT-05.23).

Tabla 31 — continuación

Componente	Producto ofertado	Ubicación	Cant.	Justificación
C22 — Balanza de recepción	Dibal BEV con plataforma ME e indicador DMI-610 inoxidable, RS-232 y Ethernet	Talca 2 y Concepción 1	3	Captura el peso de recepción en línea hacia el WMS (RF-01.01), sin digitación, con calibración certificada.
C23 — Escáner de cross-docking	Zebra DS2208: 1D, 2D y GS1 DataBar, garantía de 60 meses	Curicó, Chillán y Los Ángeles	6	Lee los códigos GS1 en la desconsolidación y el re-despacho; dos por plataforma cubren dos muelles simultáneos.
C24 — Sensor de temperatura	Módulo Ebyte ME31-XDXX0400: 4 canales PT100, Modbus RTU/TCP, de -40 a +85 °C, con sondas de 3 hilos	Cámaras de Talca y Concepción	7 módulos, 28 puntos	Alimenta el registro continuo de la cadena de frío, con una exactitud de $\pm 1,1$ °C a -22 °C que distingue una excursión real de la variación del instrumento.
C25 — Termógrafo de camión	Onset InTemp CX450: Bluetooth, de -30 a +70 °C con $\pm 0,5$ °C y calibración NIST en dos puntos	Camiones con equipo de frío: 18 propios y 10 de transportistas	28	Registra la temperatura del transporte de forma independiente y sin conexión durante toda la ruta; alerta la excursión térmica en el terminal del conductor y descarga el registro por Bluetooth al volver al centro. Los 10 camiones refrigerados de los transportistas se instrumentan con el mismo equipo, porque el termógrafo va con la carga y no depende del dueño del vehículo.

Tabla 31 — continuación

Componente	Producto ofertado	Ubicación	Cant.	Justificación
C26 — Estación de trabajo	PC i5 o i7, 16 GB, SSD NVMe de 512 GB cifrado y 2 monitores de 24 pulgadas	Talca 5 y Concepción 3	8	Puestos de despacho, administración, planificación, calidad y TI (RNF-23.04), con disco cifrado gestionado desde el EDR y doble monitor (RT-08.08).
C27 — Kit satelital	Starlink Enterprise fijo, antena en techumbre y router, plan de 500 GB por 56 meses, D-06	Curicó, Chillán y Los Ángeles	3	Es el enlace principal de los cross-docking, que no tienen fibra, con LTE como respaldo automático (RT-03.17, RT-08.13); reposición de hardware estimada en 15 % durante el contrato.
C28 — Gateway IoT	Advantech ADAM-6000 con AWS IoT Greengrass Core, B-02	CD Talca y CD Concepción	2	Detecta la excursión térmica y bloquea el despacho en el borde, con un buffer local de 14 h si cae el enlace.

Tabla 31 Formulario T-11: dispositivos de terreno y de operación

Infraestructura de la sala técnica de Talca

La Tabla 32 detalla la infraestructura de la sala técnica principal. Las especificaciones del recinto se desarrollan en el capítulo del sitio principal.

Componente	Producto ofertado	Ubicación	Cant.	Justificación
D1 — UPS	Doble conversión en línea de 6 kVA, N+1, con banco VRLA de 30 min o más	Sala de UPS y baterías	1	Sin interrupción entre la caída de la red y la partida del generador, con 30 min o más a plena carga (RT-06.07).
D2 — Generador	Grupo electrógeno de 12 kVA con estanque para 24 h y contrato de reabastecimiento	Patio del generador	1	Toma la carga de TI y clima en 8 a 15 s, y el estanque garantiza 24 h (RT-06.08).
D3 — Transferencia automática	Transferencia red - generador con tablero de protecciones selectivas	Acometida, accesible desde el exterior	1	Se prueba cada mes con carga real y admite termografía periódica (RT-06.10).
D4 — Climatización	2 unidades de precisión de 12.000 BTU/h en N+1, con free cooling, de 18 a 27 °C y de 40 a 60 % HR	Sala de climatización	2	Mantiene el rango ASHRAE en la toma de aire del equipo (RT-06.13, RT-06.14), con pasillo frío confinado.
D5 — Distribución eléctrica	2 PDU verticales A/B por gabinete, con medidor	Cuatro gabinetes de la sala	8	Dos caminos eléctricos por gabinete (RT-08.04); el medidor es el denominador del PUE.
D6 — Detección de incendio	Detección por aspiración AnaLASER o equivalente	Sala blanca	1	Detecta antes de que exista llama visible (RT-06.16).
D7 — Extinción	FM-200 o equivalente según NFPA 75 y 2001, con botón de aborto	Sala blanca	1	Agente limpio sobre equipos energizados (RT-06.17), y extintores ABC y CO ₂ por recinto (RT-06.18).

Tabla 32 — continuación

Componente	Producto ofertado	Ubicación	Cant.	Justificación
D8 — Control de acceso	Biometría facial con resguardo AFIS, esclusa y bitácora electrónica	Acceso a la sala, en cuatro capas	1	Doble factor con re-verificación biométrica y antipassback (RT-06.20, RT-06.21, RT-06.23).
D9 — Video-vigilancia	Cámaras IP con retención de 30 días o más y respaldo auditable	Sala y perímetro	7	Cubre cada puerta controlada e integra el video con el control de acceso (RT-06.24).
D10 — Recinto de custodia	Sala de 10 m ² con iluminación LED sin UV de hasta 300 lux, 40 a 60 % HR, ventilación forzada y 18 a 27 °C	Segunda línea de la sala	1	Conserva los medios de respaldo sin degradarlos (RT-06.27), con acceso sin cruzar la sala blanca (RT-06.26).
D11 — Gabinetes	4 racks de 42U: R01 servidores, R02 red, R03 distribución y respaldo, R04 crecimiento	Sala blanca	4	Separa servidores y comunicaciones (RT-06.05); R04 absorbe el crecimiento a tres años sin obras.
D12 — Cableado estructurado	Cat6A y fibra OM4 certificados por enlace, sobre piso técnico de 40 cm	Sala	1	Cumple la norma por enlace (RT-06.04) con recorridos verificados para 10 GbE.

Tabla 32 Formulario T-11: infraestructura de la sala técnica de Talca

Plataforma de nube y servicios gestionados

La Tabla 33 detalla los servicios contratados en la plataforma de nube y en servicios gestionados de terceros, ordenados por componente del catálogo.

Componente	Servicio ofertado	Ubicación	Cant.	Justificación
N-01 a N-03 — Portales	S3, CloudFront, AWS WAF, API Gateway y la tarea portal en ECS Fargate	sa-east-1, DMZ pública	1 aplicación para 3 portales	Publica los portales de clientes, transportistas y proveedores sin exponer los sitios del CLIENTE (RT-03.04).
N-04 — Plataforma de aplicación	ECS Fargate, Application Load Balancer, Elastic Container Registry y CodeBuild	sa-east-1 en 2 zonas; réplica reducida en us-east-1	2 a 6 tareas y 2 a 4 workers	Ejecuta el monolito Django y los workers Celery con escalado automático para el peak de septiembre (ADR-01, ADR-12).
N-05 — Base de datos en nube	Aurora PostgreSQL con Aurora Global Database y AWS DMS	sa-east-1 y us-east-1	1 clúster	Transaccional de los módulos en nube y réplica del WMS, con conmutación entre zonas en menos de 30 s y RPO de 15 min (ADR-04, ADR-09).
N-06 — Telemetría cruda	DynamoDB bajo demanda con Global Tables	sa-east-1 y us-east-1	1 tabla por serie	Recibe las lecturas de IoT sin gestión de capacidad y las expira a los 30 días (ADR-04).
N-07 — Caché	ElastiCache for Redis con primario y réplica	sa-east-1 en 2 zonas	1 clúster	Responde la consulta de stock y crédito de preventa en menos de 2 s.
N-08 — Ingesta de IoT	IoT Core, Lambda e IoT Greengrass	sa-east-1 y gateways de borde	2 gateways y 28 termógrafos	Recibe, valida y alerta la telemetría de cadena de frío, y gestiona la flota de gateways.
N-09 — Mensajería	SQS FIFO y SNS	sa-east-1	1 cola por sitio	Reconcilia los sitios en orden y sin duplicados, y difunde las alertas de frío (ADR-05).

Tabla 33 — continuación

Componente	Servicio ofertado	Ubicación	Cant.	Justificación
N-10 — Plataforma analítica	S3, Glue, Redshift Serverless y QuickSight	sa-east-1	1 lago de 5 años	Separa la analítica del transaccional y publica los tableros del CLIENTE.
N-11 — Respaldo y réplica	AWS Backup con Vault Lock, S3 Object Lock y replicación de S3 entre regiones	sa-east-1 y us-east-1	1 política	Mantiene la copia inmutable del esquema 3-2-1-1-0 y la réplica de recuperación (ADR-09).
N-12 — Seguridad y gobierno	KMS, Secrets Manager, Parameter Store, IAM Identity Center, Shield Advanced, GuardDuty, Security Hub, Inspector, Macie, Security Lake, CloudTrail, Config, CloudWatch, Systems Manager, Control Tower, Organizations, Cost Explorer y Budgets	sa-east-1; claves y secretos también en us-east-1	5 cuentas	Cumple los controles del Artículo 21 y el gobierno de costos como servicios administrados (ADR-14, ADR-15).
D-01 — Red en nube y terminación de la VPN	VPC, Transit Gateway, Site-to-Site VPN, NAT Gateway, VPC Endpoints y Route 53	sa-east-1 y us-east-1	2 túneles por CD	Conecta los sitios con la nube sin tráfico de datos por Internet (RT-03.03, RT-03.04).
N-13 — Gestión de dispositivos	Android Enterprise y Zebra DNA como servicio gestionado	Servicio en nube y agente en el dispositivo	462 dispositivos	Enrola, configura, actualiza y borra de forma selectiva el parque de terreno y de bodega (RT-03.18).

F-03 — De-tección en endpoints	Consola EDR gestionada y agentes	Servicio en nube y agente en cada nodo y estación	1 por endpoint	Detecta y responde en nube y on-premise desde una sola consola (RT-11.16).
--------------------------------	----------------------------------	---	----------------	--

Tabla 33 Formulario T-11: plataforma de nube y servicios gestionados

Software de base y licenciamiento

La Tabla 34 detalla el software que opera sobre el equipamiento y la plataforma anteriores.

Componente	Producto ofertado	Ubicación	Cant.	Justificación
Aplicación	Monolito modular en Django y Python con workers Celery, en una imagen única con modo wms_only	Nube, VM-01, VM-C01 y E-01	1 imagen	Una sola base de código para nube y sitios, con paridad de versiones (ADR-01).
Aplicación de terreno	Aplicación nativa Android en Kotlin, con SQLite y Zebra DataWedge	EC55, TC58e y MC9400	1 artefacto para 3 perfiles	Controla los periféricos industriales y opera un turno completo sin señal (ADR-07).
Base de datos	PostgreSQL 16 con PostGIS, código abierto	VM-02, VM-C02 y los tres E-01	5 instancias	Registro de la bodega durante los cortes, replicado a Aurora por DMS.
Broker	RabbitMQ, código abierto	VM-03, VM-C04 y los tres E-01	5 instancias	Buffer de 24 h por sitio con vuelco ordenado a SQS FIFO (ADR-05).
Identidad	Keycloak, código abierto	Fargate, VM-05 y VM-C03	1 maestro y 2 cachés	Autoridad única en nube con cachés de solo lectura (ADR-06).
Virtualización	Proxmox VE con Ceph, código abierto	Clúster de Talca	1 clúster de 3 nodos	Tolera la pérdida de un nodo sin detener la bodega.

Tabla 34 — continuación

Componente	Producto ofertado	Ubicación	Cant.	Justificación
Contenedores de borde	Docker y Docker Compose, código abierto	Concepción y los tres cross-docking	4 sitios	Instalación y parcheo sin dependencia de la red.
Observabilidad de sitio	AWS Distro for OpenTelemetry y agente SSM	VM-06, VM-C04 y los tres E-01	5 colectores	Buffer de 24 h y envío a CloudWatch al reconectar (ADR-14).
Configuración	Ansible y Terraform con CDK, código abierto	Repositorio del CLIENTE	1 repositorio	Infraestructura y configuración declaradas como código versionado.

Tabla 34 Formulario T-11: software de base y licenciamiento